

**Technická univerzita v Košiciach**  
**Fakulta elektrotechniky a informatiky**

**Automatická detekcia koronálnych dier a  
aktívnych oblastí na Slnku**

**Diplomová práca**

**2021**

**Bc. Martin Harman**

**Technická univerzita v Košiciach**  
**Fakulta elektrotechniky a informatiky**

**Automatická detekcia koronálnych dier a  
aktívnych oblastí na Slnku**

**Diplomová práca**

Študijný program: Hospodárska informatika  
Študijný odbor: Informatika  
Školiace pracovisko: Katedra kybernetiky a umelej inteligencie (KKUI)  
Školiteľ: doc. Ing. Peter Butka, PhD.  
Konzultant: Ing. Viera Maslej Krešňáková  
RNDR. Šimon Mackovjak, PhD.

**Košice 2021**

**Bc. Martin Harman**

## **Abstrakt v SJ**

Kozmické počasie je fenomén, ktorý má obrovský dopad na naše každodenné životy v modernej spoločnosti. Slnko je strojcom života na Zemi, ale aj pôvodcom kozmického počasia. Vďaka najmodernejším satelitom na obežnej dráhe Zeme dokážeme monitorovať zdroje kozmického počasia - aktivitu Slnka v reálnom čase. Aby bolo možné tieto zdroje monitorovať automaticky, vytvorili sme model hlbokej neurónovej siete na segmentáciu koronálnych dier a aktívnych oblastí. Náš model dosahuje výsledky, ktoré je možné porovnať so súčasnými metódami využívanými na detekciu štruktúr slnečnej koróny. Výstup nášho modelu je možné využiť na ďalšiu analýzu a výskum slnečnej koróny.

## **Kľúčové slová**

Hlboké učenie, segmentácia, konvolučné neuronové siete, koronálne diery, aktívne oblasti

## **Abstrakt v AJ**

Space weather is a phenomenon that has a huge impact on our daily lives in modern society. The sun is a maker of life on earth but also the cause of space weather. Thanks to modern spacecraft on Earth's orbit, we can monitor sources of space weather - the Sun in real-time. In order to monitor these resources, we have developed a model of a deep neural network for the segmentation of coronal holes and active regions. Our model provides results that can be compared which currently used segmentation models. The output of our model can be used for further analysis and research of the solar corona.

## **Kľúčové slová v AJ**

Deep learning, segmentation, convolutional neural networks, coronal holes, active regions

**TECHNICKÁ UNIVERZITA V KOŠICIACH**  
**FAKULTA ELEKTROTECHNIKY A INFORMATIKY**  
Katedra kybernetiky a umelej inteligencie

**ZADANIE  
DIPLOMOVEJ PRÁCE**

Študijný odbor: **Informatika**

Študijný program: **Hospodárska informatika**

Názov práce:

**Automatická detekcia koronálnych dier a aktívnych oblastí na Slnku**

Automated detection of solar coronal holes and active regions

Študent: **Bc. Martin Harman**

Školiteľ: **doc. Ing. Peter Butka, PhD.**

Školiace pracovisko: **Katedra kybernetiky a umelej inteligencie**

Konzultant práce: **Ing. Viera Maslej Krešňáková, RNDr. Šimon Mackovjak,  
PhD.**

Pracovisko konzultanta: **Ústav experimentálnej fyziky SAV**

Pokyny na vypracovanie diplomovej práce:

1. Podať teoretický prehľad problematiky metód hlbokého učenia vhodných pre automatickú detekciu koronálnych dier a aktívnych oblastí na Slnku, s dôrazom na využitie konvolučných neuronových sietí pre segmentáciu.
2. Analyzovať a predspracovať dostupné dátovú množinu, navrhnuť postupy pre detekciu koronálnych dier a aktívnych oblastí pomocou zvolených metód hlbokého učenia.
3. Realizovať a vyhodnotiť navrhnuté postupy detektie na zvolenej množine dát.
4. Vypracovať dokumentáciu podľa pokynov katedry a vedúceho práce.

Jazyk, v ktorom sa práca vypracuje: slovenský

Termín pre odovzdanie práce: 23.04.2021

Dátum zadania diplomovej práce: 30.10.2020



.....  
prof. Ing. Liberios Vokorokos, PhD.  
dekan fakulty

## **Čestné vyhlásenie**

Vyhlasujem, že som diplomovú prácu vypracoval samostatne s použitím uvedenej odbornej literatúry.

Košice 20. 4. 2021

.....

*Vlastnoručný podpis*

## **Poděkování**

Chcel by som poděkovat doc. Ing. Peterovi Butkovi, PhD. za jeho odborné rady a připomienky, ktoré pomohli k vzniku tejto práce. Taktiež by sa rád poděkoval mojej konzultantke Ing. Vierke Maslej Krešňákovej za jej sprevádzanie v oblasti hlbokého učenia a za jej rady a připomienky pri navrhovaní modelu. Za uvedenie do problematiky kozmického počasia dăkujem RNDr. Šimonovi Mackovjakovi, PhD., ktorý mi pomáhal orientovať sa v tejto oblasti.

# **Obsah**

<b>Úvod</b>	<b>1</b>
<b>1 Hlboké učenie</b>	<b>3</b>
1.1 Dopredné neuronové siete . . . . .	4
1.2 Aktivačné funkcie . . . . .	6
1.3 Optimalizácia . . . . .	9
1.4 Chybová funkcia . . . . .	10
1.5 Vyhodnocovacie metriky . . . . .	11
1.6 Regularizácia . . . . .	12
1.7 Konvolučné neuronové siete . . . . .	14
1.8 Segmentácia obrazu . . . . .	17
<b>2 Slnečná koróna</b>	<b>20</b>
2.1 Living with a Star . . . . .	23
2.2 Slnečná koróna a hlboké učenie . . . . .	25
2.3 Slnečná koróna – dostupné dátá . . . . .	28
<b>3 Segmentácia koronálnych dier a aktívnych oblastí</b>	<b>32</b>
3.1 Použité technológie . . . . .	33
3.2 Príprava dát . . . . .	34
3.3 SCSS-Net . . . . .	38
3.4 Post-processing . . . . .	41
3.5 Vyhodnotenie výsledkov . . . . .	42
3.5.1 Koronálne diery . . . . .	43
3.5.2 Aktívne oblasti . . . . .	45
<b>4 Záver</b>	<b>50</b>
<b>Zoznam príloh</b>	<b>59</b>

## Zoznam obrázkov

1–1	Vennov diagram umelej inteligencie	4
1–2	Jednovrstvový perceptrón	5
1–3	Viacvrstvový perceptrón	6
1–4	Priebeh funkcie sigmoid	8
1–5	Priebeh funkcie ReLU	9
1–6	Ukážka pod/preučenia	13
1–7	Neurónová sieť po použití regularizačnej techniky dropout, ktorej následkom je vynechanie neurónu	14
1–8	Konvolúcia	16
1–9	Pridanie okraju – <i>Padding</i>	16
1–10	Max-pooling	16
1–11	Klasifikácia - Detekcia - Segmentácia	17
1–12	Ukážka snímky (vľavo) a segmentačnej masky (vpravo) zo súťaže ISBI-2012	18
1–13	U-Net architektúra	19
2–1	Aktívna oblast (vľavo) a koronálna diera (vpravo) – SDO/AIA 193Å	21
2–2	Koronálna slučka – TRACE 171Å	22
2–3	Prístroj SDO/AIA	24
2–4	Ukážka snímok vyhotovených vo filtroch SDO/AIA	25
2–5	Priestorové zobrazenie výskytu AR (vľavo) a CH (vpravo)	27
2–6	Snímky slnka SDO/AIA 171Å (vľavo) a 193Å (vpravo) – 2. október 2020 23:00	29
2–7	Porovnanie anotácií koronálnych dier	31
3–1	Čiastočné zatmenie Slnka 11. Marca 2013	33
3–2	Predspracovanie a augmentácia dát	35
3–3	Rozdiel v intenzite jasu na snímkach z roku 2010 (vľavo) a z roku 2018 (vpravo) – SDO/AIA	36

3–4	SCSS-Net architektúra . . . . .	38
3–5	Priebeh učenia . . . . .	41
3–6	Post-processing . . . . .	42
3–7	Porovnanie segmentácií koronálnych dier . . . . .	46
3–8	Ukážka segmentácií koronálnych dier . . . . .	47
3–9	Porovnanie segmentácií aktívnych oblastí . . . . .	48
3–10	Ukážka segmentácií aktívnych oblastí . . . . .	49

## Zoznam tabuliek

3 – 1 Prehľad získaných anotácií CH . . . . .	37
3 – 2 Prehľad získaných anotácií AR . . . . .	38
3 – 3 Výsledky modelov za použitia rôznych optimalizačných funkcií . . . . .	40
3 – 4 Výsledky modelov (CH) na validačnej množine . . . . .	44
3 – 5 Výsledky modelov na testovacej množine zloženej zo SPoCA anotácií	44
3 – 6 Výsledky modelov na testovacej množine zloženej z Region Growth anotácií . . . . .	45
3 – 7 Výsledky modelov (AR) na validačnej množine . . . . .	46
3 – 8 Výsledky modelov na testovacej množine . . . . .	48

## Zoznam symbolov a skratiek

**Adam** Adaptive Moment Estimation

**AI** Artificial Intelligence

**AIA** Atmospheric Imaging Assembly

**Angström (Å)** dĺžková miera používaná v spektroskopii

**API** Application Programming Interface

**AR** Active Region

**BCE** Binary Cross-entropy

**CE** Cross-entropy

**CH** Coronal Hole

**CNN** Convolutional Neural Network

**EUV** Extreme Ultraviolet

**FNN** Feedforward Neural Network

**HEK** Heliophysics Event Knowledgebase

**IoU** Intersection over Union

**LReLU** Leaky Rectified Linear Unit

**LWS** Living with a Star

**MLP** Multilayer Perceptron

**MSE** Mean Squared Error

**PReLU** Parametric Rectified Linear Unit

**ReLU** Rectified Linear Unit

**SCCS-Net** Solar Coronal Structures Segmentation Network

**SDO** The Solar Dynamics Observatory

**SGD** Stochastic Gradient Descent

**SOHO** The Solar and Heliospheric Observatory

**SPoCA** Spatial Possibilistic Clustering Algorithm

## Úvod

Slnko sa nachádza v strede našej slnečnej sústavy a je zdrojom všetkého života na Zemi. Prebieha v ňom obrovské množstvo fyzikálnych javov, niektoré z týchto javov majú vplyv nielen na Slnko samotne, ale aj na našu Zem. Všetky takéto javy ovplyvňujúce Zem a jej blízke okolie nazývame kozmické počasie. Kozmické počasie je ovplyvňované najmä slnečným vetrom, ktorý vzniká v koronálnych dierach a aktívnych oblastiach na Slnku. Aby sme dokázali lepšie porozumieť týmto solárnym javom potrebujeme ich prv správne identifikovať.

V spolupráci so RNDr. Šimonom Mackovjakom, PhD., ktorý pracuje na Oddeľení kozmickej fyziky, Ústav experimentálnej fyziky Slovenskej Akadémie Vied sme navrhli proces automatickej detekcie aktívnych oblastí a koronálnych dier pomocou metód hlbokého učenia, nakoľko súčasné metódy segmentácie týchto oblastí zvyčajne využívajú klasické metódy strojového učenia ako zhlukovanie. Jednou z inšpirácií k vytvoreniu segmentačného modelu hlbokej neurónovej siete na segmentáciu aktívnych oblastí a koronálnych dier bola práca autorov [Illarionov and Tlatov \(2018\)](#), ktorá sa venovala segmentácií koronálnych dier. Snažili sme sa tak priniesť nové postupy, presnejší segmentačný model a venovať sa aj segmentácií aktívnych oblastí.

V tejto práci sme sa venovali teórií hlbokého učenia, predovšetkým metódam, ktoré sme využili pri vytváraní nášho modelu hlbokej neurónovej siete. Dôraz sme kládli na konvolučné neuronové siete a architektúru využívanú na segmentáciu snímok.

Nakoľko kozmické počasie nie je oblasť, ktorej sa venuje hospodárska informatika, tejto oblasti sme sa venovali len stručne. Podali sme prehľad o tom čo sú, kedy a ako vznikajú koronálne diery a aktívne oblasti a ako môžu ovplyvňovať život na Zemi a technológie na jej obežnej dráhe.

V analytickej časti sme sa bližšie pozreli na využitie strojového učenia v oblasti kozmického počasia. V tejto časti sme odhalili možné aplikácie hlbokého učenia,

ktoré ponúkajú voľne dostupné dátá zo satelitných meraní. Následne sme sa bližšie venovali prácam, ktoré sa venovali klasifikácií alebo segmentácií koronálnych dier a aktívnych oblastí. V nasledujúcej časti sa venujeme dostupným dátam, ktorými sú snímky Slnka a anotácie anotácie aktívnych oblastí a koronálnych dier. Neskôr sme popísali proces predspracovania týchto dát. Opísali sme architektúru našej konvolučnej neurónovej siete, ktorú sme nazvali SCSS-Net a vyhodnotili natrénované segmentačné modely.

## 1 Hlboké učenie

Hlboké učenie robí obrovské pokroky v riešení problémov, na ktoré tradičné metódy strojového učenia nestačia. Ukázalo sa, že metódy hlbokého učenia sú veľmi dobré pri objavovaní zložitých štruktúr vo viacrozumných dátach, a sú preto využiteľné v mnohých oblastiach vedy, ekonomiky a vládneho sektoru. Hlboké učenie prinieslo prielom v oblasti rozpoznávania snímok pomocou konvolučných neurónových sieti. V oblasti spracovania prirodzeného jazyka nachádza hlboké učenie obrovské uplatnenie na klasifikáciu textu, rozpoznávania sentimentu a prekladu (Lecun et al., 2015).

V súčasnosti sa metódy hlbokého učenia tešia veľkej popularite hlavne v oblasti spracovania prirodzeného jazyka a počítačového videnia. Pojem hlboké učenie bol prvýkrát použitý autorom Rina Dechtera v roku 1986 (Dechter, 1986). Prvý model neurónovej siete však bol predstavený autormi Warren McCulloch a Walter Pitts v roku 1943 (Schmidhuber, 2015).

V počiatkoch umelej inteligencie sa vedci zameriavalí na riešenie problémov, ktoré sú náročné pre ľudí. Pri riešení takýchto problémov dosahovala umelá inteligencia úspech, pretože ich riešenie vedeli opísat formálnymi a matematickými pravidlami. Nakoniec sa ukázalo, že skutočnou výzvou umelej inteligencie sú úlohy, ktoré ľudia riešia intuitívne, automaticky a nepredstavujú tak pre nás náročnú úlohu.

Umelej inteligencii chýbala schopnosť extrahovať znalosti z pôvodných dát a zvyčajne sa rozhodovala pomocou vopred definovaných pravidiel. Túto schopnosť počítačom prinieslo až predstavenie strojového učenia. Algoritmy strojového učenia sa spoliehajú, že na vstupe dostanú sadu informácií, vďaka ktorým sa algoritmus naučí korelácie medzi jednotliviny informáciami. Tieto informácie tiež nazývame príznaky (angl. *features*). Výber vhodných príznakov má veľký dopad na výsledný algoritmus strojového učenia. Pre veľa úloh je až príliš náročne sa rozhodnúť, ktoré vlastnosti extrahovať. Na riešenie takýchto úloh sa preto začalo využívať hlboké učenie, vďaka ktorému sme schopní extrahovať komplexné príznaky na riešenie zložitých úloh (Goodfellow et al., 2016).

Obrázok [1–1] znázorňuje vzťah medzi umelou inteligenciou, strojovým učením a hlbokým učením. Tento vzťah ukazuje, že strojové učenie a hlboké učenie sú podmnožinou umelej inteligencie. Vývojom umelej inteligencie sa snažíme napodobit ľudské správanie a myslenie. Pri strojovom učení zvyčajne využívame štatistické metódy a extrahované znalosti, ktoré slúžia na učenie algoritmu. O tom aké znalosti z dát extrahovať rozhoduje dátový vedec po dôkladnej analýze dát. Algoritmy hlbokého učenia však nepotrebuju vopred extrahované znalosti, pretože sa dokážu samé naučiť potrebné informácie zo vstupných dát.



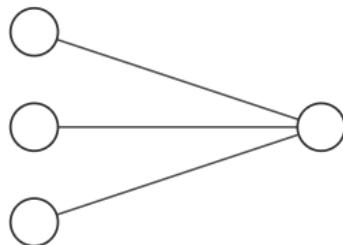
**Obrázok 1 – 1** Vennov diagram umelej inteligencie

## 1.1 Dopredné neuronové siete

Dopredné neuronové siete sú zostavené z neurónov, ktoré sú usporiadané vo vrstvách. Prvú vrstvu siete nazývame vstupná (angl. *input layer*), poslednú vrstvu nazývame výstupná (angl. *output layer*) a vrstvy, ktoré sa nachádzajú medzi vstupom a výstupom nazývame skryté (angl. *hidden layer*) vrstvy (Svozil et al., [1997]).

Neurónová sieť zložená iba z dvoch vrstiev (vstupu a výstupu), je najjednoduchšia forma neurónovej siete (viď. Obrázok [1–2]). Takúto sieť označujeme ako jedno-

vrstvový perceptrón (angl. *singlelayer perceptron*) a je kľúčovým komponentom vo viacvrstvových dopredných sietach ([Šarūnas Raudys, 1998](#)).



Vstupná vrstva  $\in \mathbb{R}^3$       Výstupná vrstva  $\in \mathbb{R}^1$

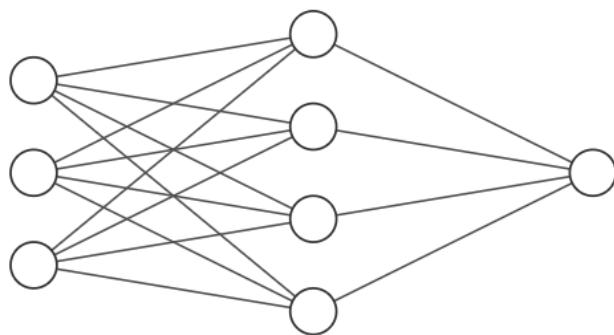
**Obrázok 1 – 2** Jednovrstvový perceptrón

Jednovrstvový perceptrón bol vyvinutý vedcami [Rumelhart et al. \(1985\)](#) inšpirovaný prácou vedcov [McCulloch and Pitts \(1943\)](#). Jednovrstvový perceptrón je algoritmus binárneho klasifikátora nazývaný prahová funkcia (angl. *threshold function*), ktorý z jedného alebo viacerých binárnych vstupov vytvorí jeden binárny výstup ([Nielsen, 2015](#)). Tento perceptrom je vyjadrený vzťahom [1.1](#), kde  $x$  je vstup,  $f(x)$  je binárny výstup a  $\sum_j w_j x_j$  je vážená suma vstupu.

$$f(x) \begin{cases} 0 & \text{ak } \sum_j w_j x_j \leq \text{prah} \\ 1 & \text{ak } \sum_j w_j x_j > \text{prah} \end{cases} \quad (1.1)$$

Zložením viacerých jednovrstvových perceptronov vytvoríme viacvrstvový perceptrón (angl. *multilayer perceptron*, skr. MLP). MLP je nazývaný aj ako dopredná neurónová sieť (angl. *feedforward neural network*, skr. FFN), pretože informácie v nich prúdia cez funkciu  $f$  v jednom smere od vstupu  $x$  cez skryté vrstvy, ktoré definujú funkciu  $f$ , až po výstup  $y$  a nazývame ich sietami, pretože sú zvyčajne zložené z viacerých rôznych funkcií. Model neurónovej siete zvykne byť reprezentovaný usmerneným acyklickým grafom popisujúcim ako sú prepojené funkcie v neurónovej sieti ([Goodfellow et al. 2016](#)). Na Obrázku [1 – 3](#) je znázornený viacvrstvový perceptrón – dopredná neurónová siet, kde vidíme neuróny v jednotlivých vrstvách, ktoré

sú prepojené medzi sebou. Neuróny v jednej vrstve sú prepojené s neurónmi vo vrstve nasledujúcej a tieto prepojenia medzi jednotlivými neurónmi sú charakterizované váhovým koeficientom, ktorý značí dôležitosť tohto prepojenia (Svozil et al., 1997).



Vstupná vrstva  $\in \mathbb{R}^3$       Skrytá vrstva  $\in \mathbb{R}^4$       Výstupná vrstva  $\in \mathbb{R}^1$

**Obrázok 1 – 3** Viacvrstvový perceptrón

## 1.2 Aktivačné funkcie

Dopredné neuronové siete predstavili koncept skrytych vrstiev vyžadujúce výber aktivačnej funkcie, ktorá sa použije na výpočet hodnôt skrytej vrstvy (Goodfellow et al., 2016). Aktivačné funkcie, niekedy nazývané aj prenosové funkcie, definujú výstup neurónu v rozsahu hodnôt. Medzi najzákladnejšie aktivačné funkcie patria kroková alebo prahová aktivačná fukncia, *piecewise* aktivačná funkcia, logistická a hyperbolická aktivačná funkcia (Rios et al., 2020). V neurónových sietach aktivačná funkcia definuje ako sa vstup transformuje na výstup. Vo viacvrstvových hlbokých neurónových sietach zvyčajne využívame jednu aktivačnú funkciu v skrytych vrstvách, a inú na vrstve výstupnej. V skrytych vrstvách sa najčastejšie využíva ReLU, logistická aktivačná funkcia alebo hyperbolický tangens. Vo výstupnej vrstve vyberáme aktivačnú funkciu podľa toho, aký je náš očakávaný výstup z neurónovej siete:

- regresia – lineárna aktivačná funkcia,
- binárna klasifikácia – sigmoidálna aktivačná funkcia,
- klasifikácia do viacerých tried – softmax aktivačná funkcia.

V tejto kapitole sa budeme bližšie venovať sigmoidálnej funkcie a ReLU, pretože práve tieto funkcie využívame v našom modeli, ktorému sa budeme venovať v Kapitole [3]. Vo všetkých skrytých vrstvách využívame aktivačnú funkciu ReLU a na výstupnej vrstve využívame sigmoid, pretože sa rozhodujeme, či daný pixel patrí alebo nepatrí do danej triedy.

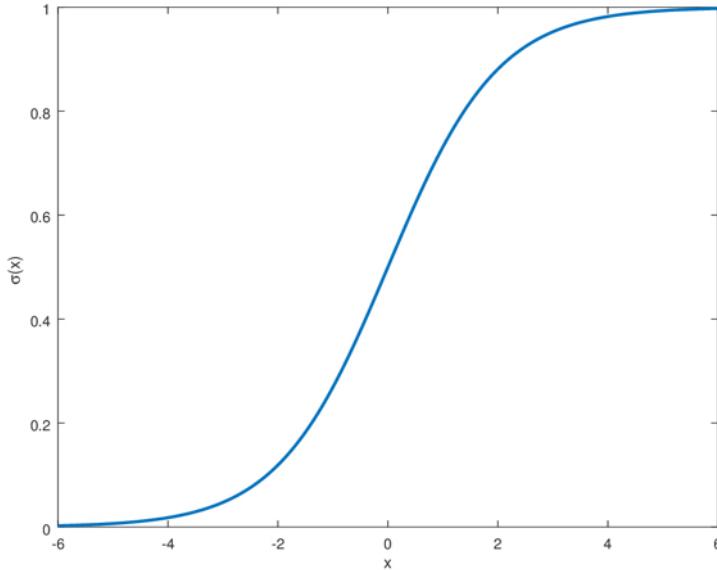
### Sigmoidálna funkcia

Sigmoidálna funkcia je vďaka jej nelinearite jedna z najpoužívanejších funkcií v dopredných neurónových sietach. Je to diferencovateľná funkcia, ktorá je definovaná pre všetky reálne vstupné hodnoty a má všade pozitívnu deriváciu. Vykazuje dostačný stupeň hladkosti a je tiež vhodným rozšírením limitujúcich nelinearít, ktoré boli v minulosti využívané v neurónových sietach (Han and Moraga, [1995]). Nazývame ju aj ako logistická funkcia a je známa svojím tvarom písmena S zobrazeným na Obrázku [1–4]. Logistická funkcia je vyjadrená vzťahom [1.2] a jej hodnoty jej výstupu sa pohybujú medzi 0 a 1. Vďaka tomu sa najčastejšie využíva ako aktivačná funkcia na výstupnej vrstve pre binárnu klasifikáciu.

$$f(x) = \frac{1}{1 + e^{-x}} \quad (1.2)$$

### Rektifikovaná lineárna jednotka

Rektifikovaná lineárna jednotka (skr. ReLU), vyjadrená vzťahom [1.3] patrí medzi najobľúbenejšie funkcie využívané na skrytej vrstve, a to vďaka jej jednoduchosti a výpočtovej nenáročnosti. Ako môžeme vidieť na Obrázku [1–5], tak ReLU nadobúda nulovú hodnotu pre vstup  $x < 0$ , ale pre vstup  $x \geq 0$  nadobúda nezmenené hodnoty vstupu. ReLU umožňuje sieti ľahko získať reprezentácie pri nízkej náročnosti na



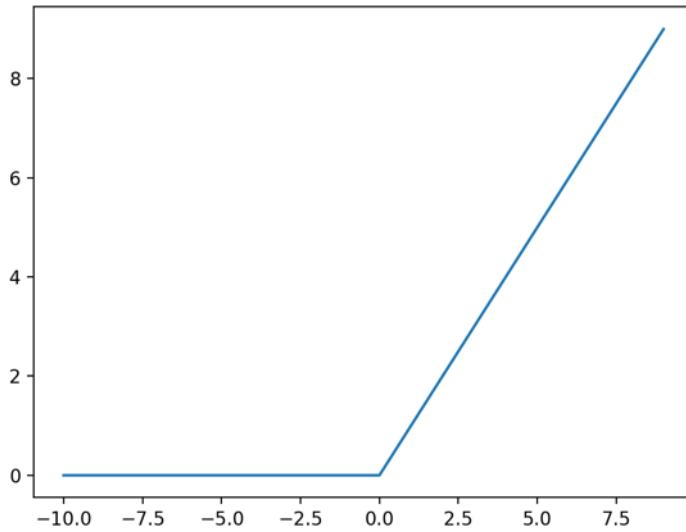
**Obrázok 1 – 4** Priebeh funkcie sigmoid

výpočtový výkon vďaka tomu, že nevyužíva exponenciálne funkcie. Napriek experimentálnym výsledkom, ktoré ukazujú, že nulové hodnoty môžu pomôcť pri učení s učiteľom (angl. *supervised learning*), môže ReLU spôsobovať problém miznúcich gradientov (Glorot et al., 2011).

$$f(x) = \max(0, x) \quad (1.3)$$

Problém miznúcich gradientov môžeme vyriešiť využitím optimalizačnej funkcie Leaky ReLU (skr. LReLU), ktorá je vyjadrená vzťahom 1.4 a na rozdiel od klasickej ReLU funkcie, LReLU nadobúda malé nenulové hodnoty (Maas et al., 2013). Obdobou LReLU funkcie je Parametrická ReLU funkcia (skr. PReLU) vyjadrená vzťahom  $f(x) = \max(ax, x)$ , kde  $a \leq 1$  je učiteľný parameter. V prípade ak  $a = 0$  získame tým ReLU funkciu a ak  $a = 0.01$  dostaneme LReLU (He et al., 2015).

$$f(x) \begin{cases} x & \text{ak } x \geq 0 \\ 0.01x & \text{ak } x < 0 \end{cases} \quad (1.4)$$



Obrázok 1 – 5 Priebeh funkcie ReLU

### 1.3 Optimalizácia

Väčšina algoritmov hlbokého učenia vyžaduje nejakú formu optimalizácie. Pod optimalizáciou chápeme úlohu minimalizovať alebo maximalizovať funkciu  $f(x)$ , úpravou  $x$ . Maximalizácia môže byť dosiahnutá pomocou minimalizačného algoritmu minimalizáciou  $-f(x)$  (Goodfellow et al., 2016). V hlbokom učení sa optimalizáciou neurónovej siete snažíme minimalizovať chybu pri učení úpravou atribútov neurónovej siete, ako napríklad rýchlosť učenia. Na optimalizáciu neurónovej siete sa najčastejšie využívajú metódy gradientového zostupu, ako napríklad Stochastický gradient zostupu (skr. SGD) alebo SGD s momentom (Robbins, 2007; Kiefer et al., 1952). Pre prípad, kedy je gradient v jednom smere oveľa väčší než v inom sa využívajú metódy s adaptívnou rýchlosťou učenia, ako napríklad Adagrad (Duchi et al., 2011), RMSProp (Tieleman and Hinton, 2012) alebo Adam (Kingma and Ba, 2017).

Počas trénovania našej hlbokej neurónovej siete sme najlepšie výsledky dostali ak sme využili optimalizačný algoritmus Adam, preto si v nasledujúcej časti bližšie popíšeme práve tento optimalizačný algoritmus.

**Adam** (*Adaptive Moment Estimation*) kombinuje výhody metód AdaGrad a RMSProp. Je to algoritmus pre optimalizáciu funkcií na základe gradientu prvého rádu a je založený na adaptívnych odhadoch momentov nižšieho rádu. Táto metóda je výpočtovo efektívna, má malé nároky na pamäť a je vhodná na riešenie problémov, ktoré vyžadujú veľké množstvo dát alebo parametrov. Aktualizácia parametrov optimizéra Adam je daná vzťahmi [1.5] až [1.9], kde máme parametre  $w^{(t)}$  a chybovú funkciu  $L^{(t)}$ , pričom  $t$  je index iterácie. (Kingma and Ba, 2017).

$$m_w^{(t+1)} \leftarrow \beta_1 m_w^{(t)} + (1 - \beta_1) \nabla_w L^{(t)} \quad (1.5)$$

$$v_w^{(t+1)} \leftarrow \beta_2 v_w^{(t)} + (1 - \beta_2) (\nabla_w L^{(t)})^2 \quad (1.6)$$

$$\hat{m}_w = \frac{m_w^{(t+1)}}{1 - \beta_1^{t+1}} \quad (1.7)$$

$$\hat{v}_w = \frac{v_w^{(t+1)}}{1 - \beta_2^{t+1}} \quad (1.8)$$

$$w^{(t+1)} \leftarrow w^{(t)} - \eta \frac{\hat{m}_w}{\sqrt{\hat{v}_w} + \epsilon}, \quad (1.9)$$

kde  $\beta_1 = 0.9$  je momentová konštanta,  $\beta_2 = 0.999$  je tlmiaci faktor a aby sa zabránilo deleniu nulou slúži malé číslo  $\eta$ .

## 1.4 Chybová funkcia

Chybová funkcia je funkcia, ktorú sa snažíme minimalizovať. Takúto funkciu nazývame ako cieľová funkcia alebo kritérium. V rámci minimalizácie funkcie sa takáto funkcia nazýva taktiež nákladová, stratová alebo chybová funkcia (Goodfellow et al., 2016). Na to aby sme vypočítali akú chybu dosahuje model počas optimalizačného procesu je potrebné zvoliť vhodnú chybovú funkciu. Samotný výber funkcie môže byť problém sám o sebe, pretože nie vždy je ľahké vytvoriť funkciu, ktorá meria presne to, čo chceme. Často je potrebné urobiť kompromis medzi tým, čo chceme, čo môžeme merať a čo môžeme efektívne optimalizovať. Najčastejšie sa používa niekoľko základných funkcií (Reed and Marks, 1998):

- priemerná štvorcová chyba (angl. *mean squared error*, skr. MSE) pri problémoch s aproximáciou (regresiou),
- krížová entropia (angl. *cross-entropy*, skr. CE) pri klasifikačných úlohách.

Kedže našou úlohou je segmentácia snímok, čo je vlastne len klasifikácia pixelov, tak sme ako chybovú funkciu využívali krížovú entropiu. Bližšie sa jej budeme venovať v nasledujúcej časti.

**Krížová entropia** bola motivovaná adaptívnym algoritmom na odhad pravdepodobnosti zriedkavých udalostí v zložitých sietach, ktorý zahŕňa minimalizáciu odchýlok (De Boer et al., 2005). Krížová entropia je mierou rozdielu medzi dvoma rozdeleniami pravdepodobnosti pre danú náhodnú premennú alebo množinu udalostí a je vyjadrená vzťahom 1.10. Pre prípad binárnej klasifikácie sa využíva binárna krížová entropia (angl. *binary cross-entropy*, skr. BCE) vyjadrená vzťahom 1.11, kde  $y$  reprezentuje pravú hodnotu a  $\hat{y}$  reprezentuje predikovanú hodnotu (Murphy, 2012).

$$\text{CE} = - \sum_i^M y_i \log(\hat{y}_i) \quad (1.10)$$

$$\text{BCE} = - (y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})), \quad (1.11)$$

## 1.5 Vyhodnocovacie metriky

Na vyhodnotenie modelov sa zvyknú používať metriky, ktoré nám pomáhajú jednoducho porovnať výsledky viacerých modelov medzi sebou. Medzi najčastejšie používanú metriky na vyhodnotenie klasifikačných algoritmov patrí celková úspešnosť (angl. *accuracy*), ktorá vyjadruje pomer správne klasifikovaných tried oproti všetkým klasifikovaným triedam. Pre úlohu segmentácie však táto metrika nie je práve najvhodnejšia, pretože nám nehovorí nič o nesprávne klasifikovaných pixeloch.

Segmentačné modely sa najčastejšie vyhodnocujú pomocou Jaccardovho indexu (angl. *Jaccard index*) (Legendre and Legendre, 2012) a Dice koeficientu (Sorensen,

[1948]). Jaccardov index je označovaný ako „priesečník cez zjednotenie“ (angl. *Intersection Over Union*, skr. IoU), pretože IoU vyjadruje prekrytie predikovanej oblasti so skutočnou oblasťou vydelený zjednotením oboch oblastí. Dice koeficient, ktorý je známy v dátovej analytike ako F1 skóre vyjadruje podobnosť medzi dvoma súbormi údajov. IoU a DICE sú vyjadrené vzťahmi:

$$\text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \quad (1.12)$$

$$\text{Dice} = \frac{2\text{TP}}{2\text{TP} + \text{FP} + \text{FN}} \quad (1.13)$$

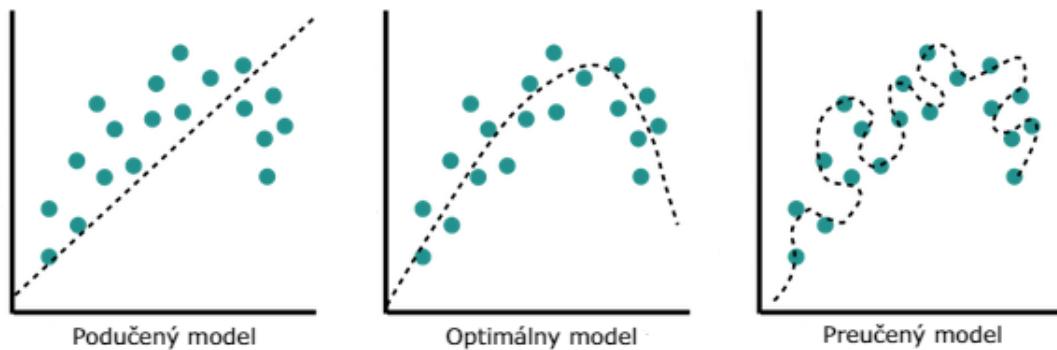
kde:

- TP – true positive – všetky pixely, ktoré boli klasifikované do spravnej triedy,
- FP – false positive - všetky pixely, ktoré boli nesprávne označené, že patria do danej triedy,
- FN – false negative – všetky pixely. ktoré boli nesprávne označené, že do danej triedy nepatria.

## 1.6 Regularizácia

Skôr ako si popíšeme regularizačné techniky, tak si zavedieme pojmy trénovacia, validačná, testovacia množina a vysvetlíme ako boli využité v tejto práci. Pod pojmom trénovacia množina chápeme súbor dát, ktoré slúžia na trénovanie modelu. Ako validačnú množinu berieme malú časť dát z trénovacej množiny, ktorú sme nepoužili na trénovanie modelu, ale na vyhodnocovanie procesu učenia. Testovacia množina slúži ako nezávislá časť dát, na ktorej vyhodnocujeme natrénovaný model. Schopnosť dosahovať dobré výsledky na neznámych dátach sa nazýva generalizácia. V strojovom učení je jednou z najväčších výziev vytvorenie algoritmu, ktorý dosahuje dobré výsledky nielen na trénovacích dátach, ale aj na dátach nových. Veľa stratégií v strojovom učení je navrhnutých na redukciu validačnej chyby, niekedy aj za cenu zvýšenia trénovacej chyby. Tieto stratégie sú označované ako regularizácia.

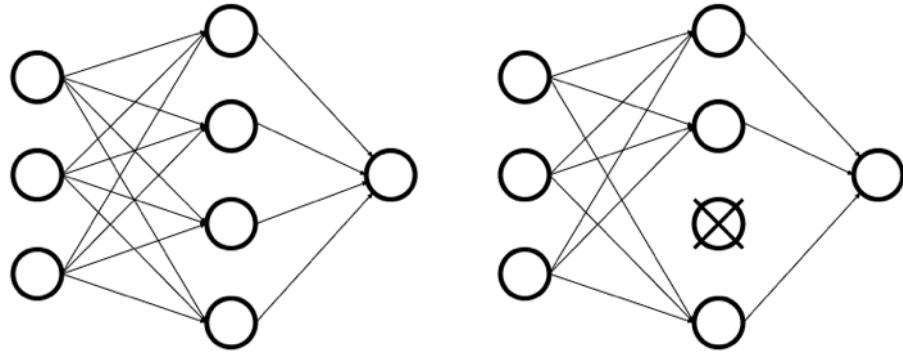
V strojovom učení sa snažíme aby bola zovšeobecnená chyba (angl. *generalization error*) čo najmenšia. Počas učenia neurónovej siete môže dôjsť k podučeniu (angl. *underfitting*), ku ktorému dochádza ak model nedosahuje dostatočné nízku chybu na trénovacích dátach. V prípade klasifikácie to má za následok nespravené zaradenie príkladov do tried. K preučeniu (angl. *overfitting*) dochádza ak je príliš veľký rozdiel medzi trénovacou a testovacou chybou, teda ak je testovacia chyba výrazne väčšia než trénovacia chyba. V takomto prípade model dokáže veľmi presne klasifikovať príklady, ktoré už pozná alebo sú im príliš podobné, ale nedokáže správne zaradiť nové príklady (Goodfellow et al., 2016). Na Obrázku 1–6 je znázornený príklad podučenia na ľavej časti grafu kde chyba ešte nie je dostatočne nízka a preučenia na pravej časti grafu, kde chyba je dostatočne nízka, ale rozdiel medzi trénovacou a testovacou chybou je príliš veľký. K najčastejším formám regularizácie neurónových sieti patrí L1 a L2 norma, dropout, augmentácia dát a včasné zastavenie.



Obrázok 1–6 Ukážka pod/preučenia

**Dropout** je silná regularizačná stratégia, ktorú možno považovať za jednu z najlepších metód, ak chceme zabrániť preučeniu modela. Je efektívnejší než iné regularizačné stratégie a môže byť kombinovaný s inými metódami regularizácie. Medzi výhody dropout metódy patrí to, že je výpočtovo nenáročný a nie je limitovaný typom neurónovej siete (Goodfellow et al., 2016). Funkcia dropout zabezpečuje vynechanie alebo vypadnutie neurónov v neurónovej sieti. Na Obrázku 1–7 je zobrazené, že vynechaním neurónu docielime jeho dočasné vymazanie a prerušenie spojení s inými

neurónmi. Vynechanie neurónu zvyčajne prebieha náhodne na základe stanovenej pravdepodobnosti (Srivastava et al., 2014).



**Obrázok 1 – 7** Neurónová sieť po použití regularizačnej techniky dropout, ktorej následkom je vynechanie neurónu

## 1.7 Konvolučné neuronové siete

Medzi najpopulárnejšie hlboké neurónové siete patria konvolučné neuronové siete (angl. *Convolutional Neural Network*, skr CNN), ktoré dosahujú vynikajúce výsledky vo oblasti počítačového videnia. Aj napriek tomu, že konvolučné neuronové siete boli dlho známe a dosahovali dobré výsledky, tak sa tieto modely sa najviac preslávili vďaka sieti AlexNet Krizhevsky et al. (2012), ktorá zaznamenala obrovský úspech v klasifikácii snímok pochádzajúcich z ImageNet databázy, ktorá obsahuje viac než milión snímok rozdelených do 1000 tried (Lecun et al. 2015). Základnou myšlienkou konvolučných neurónových sietí je navrhnuté také riešenie, ktoré nám umožní prehľbiť sieť za použitia menšieho počtu parametrov. Tento cieľ sa zvyčajne dosahuje zmenšením veľkosti snímky na vstupe siete, ale hlavne v skrytých vrstvách siete pomocou konvolučných a vzorkovacích vrstiev (Aghdam and Heravi, 2017).

Konvolučné neuronové siete sú špeciálnym druhom neurónových sieti, ktoré sú zamerané na spracovanie dát, ktoré majú formu mriežky. Tieto dátá môžu byť jednorozmerné napr. časové rady a text, dvojrozmerné napr. obrázky alebo viacrozmerné. Označenie „konvolučná“ vychádza zo špeciálnej lineárnej matematickej ope-

rácie dvoch funkcií nazývanej konvolúcia, ktorá sa zvykne vyjadrovať vztahom:

$$s(t) = (x * w)(t), \quad (1.14)$$

kde znak  $*$  predstavuje konvolúciu funkcií  $x$  a  $w$ . Prvá funkcia  $x$  je označovaná ako vstup a druhá funkcia  $w$  je označovaná ako kernel resp. konvolučný filter. Výstup konvolúcie funkcií  $x$  a  $w$  sa nazýva mapa príznakov (angl. *feature map*). Typická konvolučná neurónová siet je zložená z troch fáz. V prvej fáze konvolúcie vytvárajú lineárne aktivačné funkcie, ktoré následne v druhej fáze, nazývanej fáza detekcie putujú do nelineárnej aktivačnej funkcie napr. ReLU a v tretej fáze sa používa plne prepojená vrstva, ktorá slúži na klasifikáciu (Goodfellow et al., 2016).

- **Konvolučná vrstva** (angl. *convolutional layer*) je základná súčasť CNN, ktorej základom je matematická operácia – konvolúcia. Na Obrázku 1–8 máme vstupnú oblasť (vľavo), ktorá reprezentuje binárny obrázok, konvolučný filter (v strede) a výstup konvolúcie (vpravo). Pri aplikovaní konvolučného filtra určujeme aj vertikálny a horizontálny posun (angl. *stride*), tie určujú o koľko bodov resp. pixelov sa bude konvolučný filter posúvať. Veľkosť vstupu, veľkosť a posun filtra ovplyvňujú veľkosť výstupu. V našom prípade sme na vstup o veľkosti  $5 \times 5$  aplikovali  $3 \times 3$  konvolučný filter s posunom 1 vo vertikálnom aj horizontálnom smere, to malo za dôsledok, že výstup konvolúcie mal veľkosť  $3 \times 3$ . Ak chceme aby si výstup po konvolúcií zachoval rovnakú veľkosť ako vstup, môžeme vstupnému obrázku pridať okraj v podobe núl. Pri použití *padding* sa môže stred konvolučného filtra ocitnúť v rohu snímky, čo môže pomôcť modelu lepšie zachytiť príznaky na okraji snímky. Výsledok aplikácie nulového okraja (angl. *zero-padding*) je zobrazený na Obrázku 1–9.
- **Združovacia vrstva (vzorkovacia)** (angl. *pooling layer*) sa využíva na redukovanie veľkosti výstupu a nahradza ho súhrnnou štatistikou, napr. priemerom alebo maximálnymi hodnotami (Goodfellow et al., 2016). Na Obrázku 1–10 máme vstup o veľkosti  $4 \times 4$ , ktorý zredukujeme pomocou  $2 \times 2$  max-poolingu

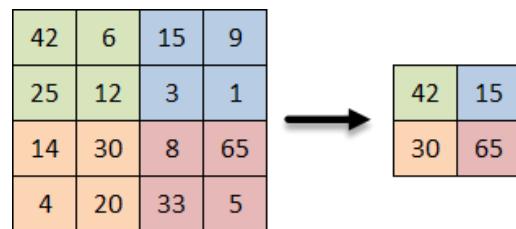
$$\begin{array}{|c|c|c|c|c|} \hline 1 & 1 & 1 & 0 & 0 \\ \hline 0 & 1 & 1 & 1 & 0 \\ \hline 0 & 0 & 1 & 1 & 1 \\ \hline 0 & 0 & 1 & 1 & 0 \\ \hline 0 & 1 & 1 & 0 & 0 \\ \hline \end{array} * \begin{array}{|c|c|c|} \hline 1 & 0 & 1 \\ \hline 0 & 1 & 0 \\ \hline 1 & 0 & 1 \\ \hline \end{array} = \begin{array}{|c|c|c|} \hline 4 & 3 & 4 \\ \hline 2 & 4 & 3 \\ \hline 2 & 3 & 4 \\ \hline \end{array}$$

Obrázok 1 – 8 Konvolúcia

0	0	0	0	0	0	0
0	1	1	1	0	0	0
0	0	1	1	1	0	0
0	0	0	1	1	1	0
0	0	0	1	1	0	0
0	0	1	1	0	0	0
0	0	0	0	0	0	0

Obrázok 1 – 9 Pridanie okraju – *Padding*

na veľkosť  $2 \times 2$ , týmto zmenšíme náročnosť siete, pričom zachované dôležité informácie. Hlavným cieľom združovacej vrstvy je znížiť rozmer mapy príznakov, preto sa nazýva aj ako vzorkovanie. Združovanie sa uplatňuje na každej mape príznakov osobitne. To znamená, že ak výstup konvolučnej vrstvy má 50 máp príznakov, tak sa operácia združovania použije na každú z týchto máp osobitne a vytvorí sa tak 50 nových máp príznakov, ktoré budú mať zredukované rozmery (Aghdam and Heravi, 2017).



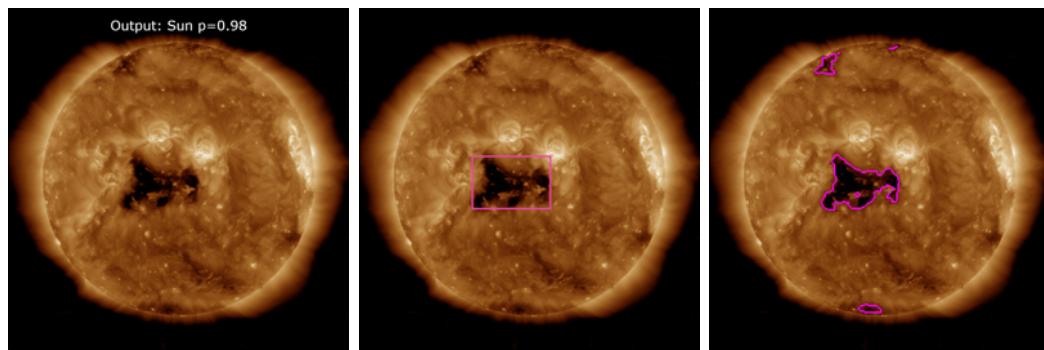
Obrázok 1 – 10 Max-pooling

- **Plne prepojená vrstva** (angl. *fully connected layer*) slúži ako dopredná neurónová sieť, ktorá sa využíva ako výstupná vrstva konvolučných neurónových sieti. Vstupom do tejto vrstvy je matica transformovaná na jednorozmerný vektor. Ten je vstupom pre aktivačnú funkciu, zvyčajne *sigmoid* alebo *softmax* podľa toho, či ide o binárnu klasifikáciu alebo klasifikáciu viacerých tried (Goodfellow et al., 2016).

## 1.8 Segmentácia obrazu

Počítačové videnie bolo tradične jednou z najaktívnejších oblastí výskumu aplikácií hlbokého učenia, pretože videnie je úloha, ktorá je pre ľudí jednoduchá, ale pre počítače náročná (Ballard et al., 1983). Oblast počítačového videnia a rozoznávania snímok je veľmi obrovská a zahŕňa širokú škálu spôsobov spracovania snímok a úžasné rozmanitosť aplikácií (Goodfellow et al., 2016). Poznáme tri základné metódy rozpoznávania snímok, znázorene na Obrázku 1–11:

- **Klasifikácia** – označí do akej triedy patrí daná snímka.
- **Detekcia** – detegovaný objekt ohraničí obdĺžnikom.
- **Segmentácia** – určí, ktoré pixely patria danému objektu.



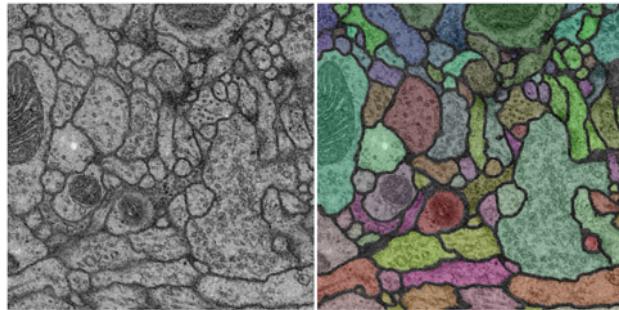
**Obrázok 1–11** Klasifikácia - Detekcia - Segmentácia

V minulosti sa na segmentáciu snímok využívalo prahovanie (Sahoo et al., 1988), zhluikovanie (Hartigan and Wong, 1979) alebo detekcia hrán (Canny, 1986). V sú-

časnosti medzí najúspešnejšie techniky segmentácie snímok patria metódy hlbokého učenia, konkrétnie konvolučné neuronové siete (Lecun et al., 2015), ktoré boli opísané v podkapitole 1.7.

### Architektúra U-Net

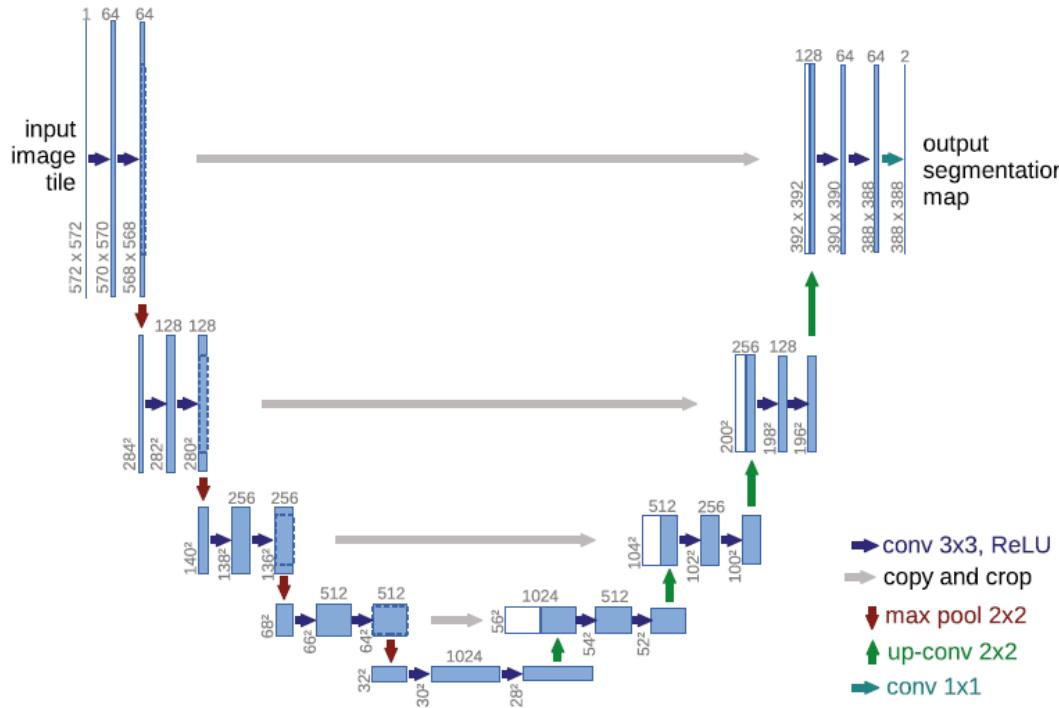
U-Net bola predstavená autormi (Ronneberger et al., 2015) a zaznamenala veľmi dobré výsledky pri segmentácii biomedicinských snímok. V roku 2012 vyhrala *ISBI Challenge* – súťaž zameranú na automatickú segmentáciu neuronálnych štruktúr (viď. Obrázok 1–12).



**Obrázok 1 – 12** Ukážka snímky (vľavo) a segmentačnej masky (vpravo) zo súťaže ISBI-2012

Táto architektúra je úpravou a rozšírením plne prepojenej konvolučnej neurónovej siete predstavenej autormi (Long et al., 2014). U-Net bola modifikovaná, aby vytvárala presnejšie segmentácie za použitia menšieho počtu trénováciach snímok. Táto neuronová sieť nemá žiadne plne prepojené vrstvy a segmentačné mapy obsahujú iba tie pixely, pre ktoré je na vstupnom obrázku k dispozícii celý kontext. Na predikciu pixelov v okrajovej oblasti snímky sa chýbajúci kontext extrapoluje zrkadlením vstupnej snímky.

Architektúra U-Net je zobrazená na Obrázku 1–13 a je zložená z enkódera (ľava časť) a dekódera (prava časť). Enkodér je typickou časťou konvolučných neurónových sieti a pozostáva zo vstupu a niekoľkých aplikácií dvoch konvolučných vrstiev s veľkosťou filtra  $3 \times 3$  pixelov. Následne zredukovala veľkosť snímky pomocou funkcie *max-pooling* s veľkosťou okna  $2 \times 2$  pixelov. Dekodér tento proces opakuje v opač-



Obrázok 1 – 13 U-Net architektúra

nom smere, kde namiesto zmenšovania veľkosti snímky pomocou *max-pooling*, siet snímku postupne zväčšuje na pôvodnú veľkosť pomocou funkcie *up-sampling* s veľkosťou okna  $2 \times 2$  pixelov. Na prepojenie správnych veľkostí snímok a extrahovaných príznakov v jednotlivých úrovniach siete je použitá funkcia *concatenate*, ktorá slúži ako prepojenie medzi enkodérom a dekodérom. Na výstupe je použitá konvolučná vrstva s veľkosťou filtra  $1 \times 1$ , ktorá slúži na klasifikáciu (Ronneberger et al., 2015). Práve táto siet sa stala odrazovým mostíkom pre nás výskum segmentácie slnečných štruktúr.

## 2 Slnečná koróna

Kozmické počasie predstavuje zmeny vo vesmírnom prostredí medzi Slnkom a Zemou. Štúdie kozmického počasia sa zaoberajú javmi, ktoré ovplyvňujú život na Zemi a systémy na obežnej dráhe Zeme. Dokonca aj počasie na Zemi, od povrchu planéty smerom do vesmíru, je ovplyvňované Slnkom. A tak kozmické a aj pozemské počasie je určované malými zmenami, ktoré Slnko podstúpi počas svojho slnečného cyklu ([Space Weather Prediction Center](#), 2021).

Medzi oblasti, na ktoré má kozmické počasie najväčší vplyv patria:

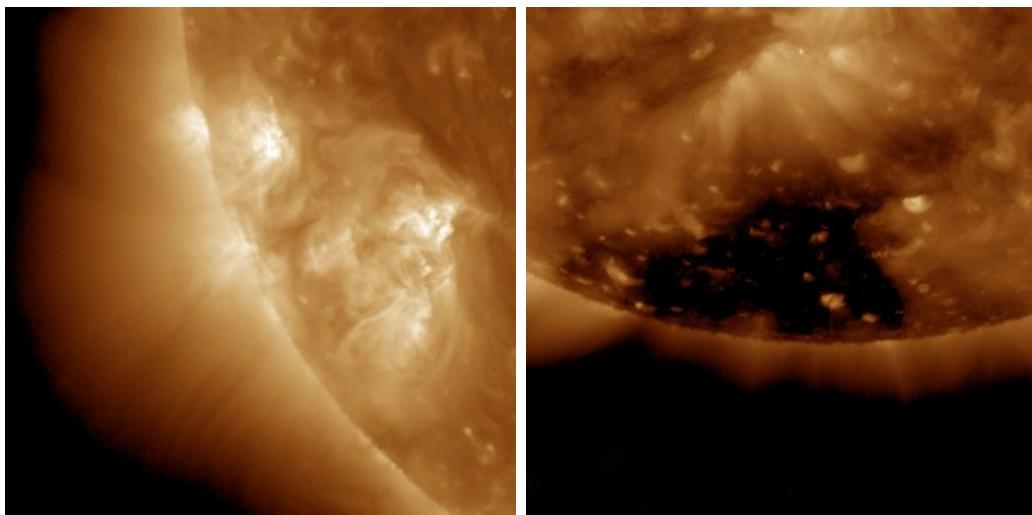
- klíma Zeme,
- elektrická sieť,
- GPS systémy,
- satelitná komunikácia.

**Slnečná fyzika** je rozvíjajúca sa vedecká disciplína integrujúca štúdie o premenlivosti Slnka, okolitej heliosfére a klimatickom prostredí. Slnečná fyzika, nazývaná aj heliofyzika je oblasť fyziky, ktorá sa zaobrá Slnkom a slnečnou aktivitou. Za posledných pár storočí naše chápanie toho, ako Slnko riadi vesmírne počasie a podnebie na Zemi a iných planétach, napredovalo čoraz rýchlejšie ([Schrijver and Siscoe 2010](#)). Vo vonkajších atmosférách na Slnku, môžu vznikať rôzne prírodné javy, ktoré nazývame solárne javy, medzi ktoré patrí:

- slnečný vietor,
- slnečné erupcie,
- výrony koronálnej hmoty,
- slnečné škvrny,
- koronálne diery.

Tieto solárne javy môžu spôsobovať problémy naším moderným technológiám, ktoré sú citlivé na rôzne výkyvy kozmického počasia. Zmeny v ionosfére počas geomagnetických búrok narúšajú vysokofrekvenčnú rádiovú komunikáciu a navigáciu v systéme GPS a energetické častice vo forme slnečného vetra poškodzujú kritickú elektroniku satelitov na obežnej dráhe Zeme. Napríklad v roku 1983 zapríčinili geomagnetické indukované prúdy kolaps Hydro-Québeckej elektrickej siete, čo spôsobilo poruchu transformátora a 9 hodinový výpadok elektriny. Túto udalosť zapríčinila geomagnetická búrka, ktorá vznikla v dôsledku výronu koronálnej hmoty.

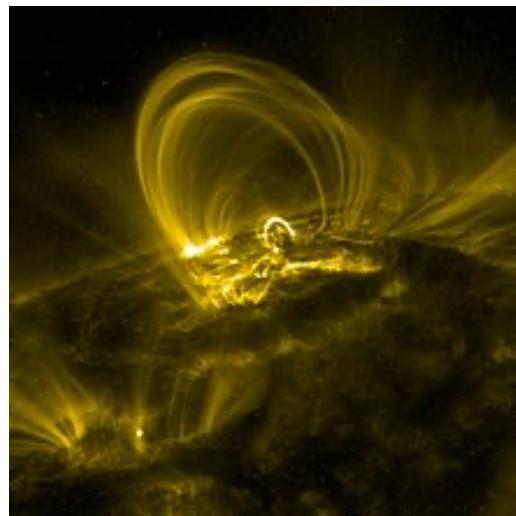
Slnko prechádza pravidelnými zmenami alebo cyklami vysokej a nízkej aktivity, ktoré sa opakujú približne každých 11 rokov. Počas týchto cyklov dochádza k tzv. solárному minimu a solárному maximu. Počas solárneho minima sa na slnku objavuje najmenej slnečných škvŕň a počas solárneho maxima je zas počet slnečných škvŕň najväčší ([Garner, 2015](#)).



**Obrázok 2 – 1** Aktívna oblast (vlavo) a koronálna diera (vpravo) – SDO/AIA 193Å

**Koronálne diery**, zobrazené na Obrázku 2 – 1 sa na extrémne ultrafialových snímkach javia ako tmavé oblasti v slnečnej koróne. Javia sa ako tmavé škvrny, pretože sú to chladnejšie a menej husté v porovnaní s ich okolím. Sú to oblasti s otvoreným unipolárnym magnetickým poľom, ktoré umožňuje slnečnému vetru ľahšie uniknúť do otvoreného vesmíru. Dlhotrvajúce koronálne diery sú zdrojom vysokorýchlosných prúdov slnečného vetra. Označenie „koronálna“ odkazuje na vonkajšiu vrstvu slnečnej atmosféry, ktorú nazývame koróna.

Koronálne diery môžu mať trvanie až 27 dní a sú najčastejšie a najstabilnejšie na severom a južnom póle Slnka, ale môžu sa rozšíriť aj do nižších slnečných šírok. Priemerná životnosť polárnych koronálnych dier je približne 6 až 10 rotácií Slnka. Niekedy sa časť koronálnej diery oddelí od koronálnej diery, ktorá vznikla na póle a stane sa samostatnou. Najčastejšie sa vyskytujú v rokoch po solárnom maxime resp. počas rokov solárneho minima (Rušin and Rybanský, 1990; *Coronal Holes*, 2021).



**Obrázok 2 – 2** Koronálna slučka – TRACE 171 Å

**Aktívne oblasti**, zobrazené na Obrázku 2 – 1 sú oblasti so silným magnetickým poľom, ktoré môže byť až 1000 krát silnejšie ako priemerné magnetické pole Slnka. Najčastejšie ich môžeme spozorovať počas vrcholu slnečného cyklu, kedy je magnetické pole Slnka narušené. Aktívne oblasti sa na röntgenových a ultrafialo-

vých snímkach Slnka sa javia ako oblasti s vysokou intenzitou. Silné magnetické pole okolo aktívnej oblasti uvoľňuje intenzívne výbuchy energie, ktoré majú formu vysokoenergetických fotónov a častíc. Okolo aktívnych oblastí sa často objavujú koronálne slučky zobrazené na Obrázku 2–2 (van Driel-Gesztelyi and Green, 2015; *Active Regions on the Sun*, 2021).

## 2.1 Living with a Star

Living with a Star (skr. LWS) je program NASA, ktorý ma za cieľ poskytnúť vedecké poznatky v oblasti slnečnej fyziky a jej aspektov, ktoré môžu mať vplyv na život a spoločnosť. Konečným cieľom je vyvinúť schopnosť predikovať neustále sa meniacu aktivitu Slnka. Aktuálne NASA misie vrámci programu LWS:

- The Solar Dynamics Observatory (skr. SDO)
- Van Allen Probes (skr. VAP)
- Parker Solar Probe (skr. PSP)
- Solar Orbiter (skr. SolO) – v spolupráci s ESA

**The Solar Dynamics Observatory** je prvá misia, ktorá bola spustená vrámci programu LWS vo februári 2010. Cieľom SDO je porozumieť slnečnej aktivite a následne predikovať tie slnečné udalosti, ktoré ovplyvňujú život na zemi a technológie (Pesnell et al., 2011). Tento cieľ sa snaží dosiahnuť pomocou zodpovedania otázok:

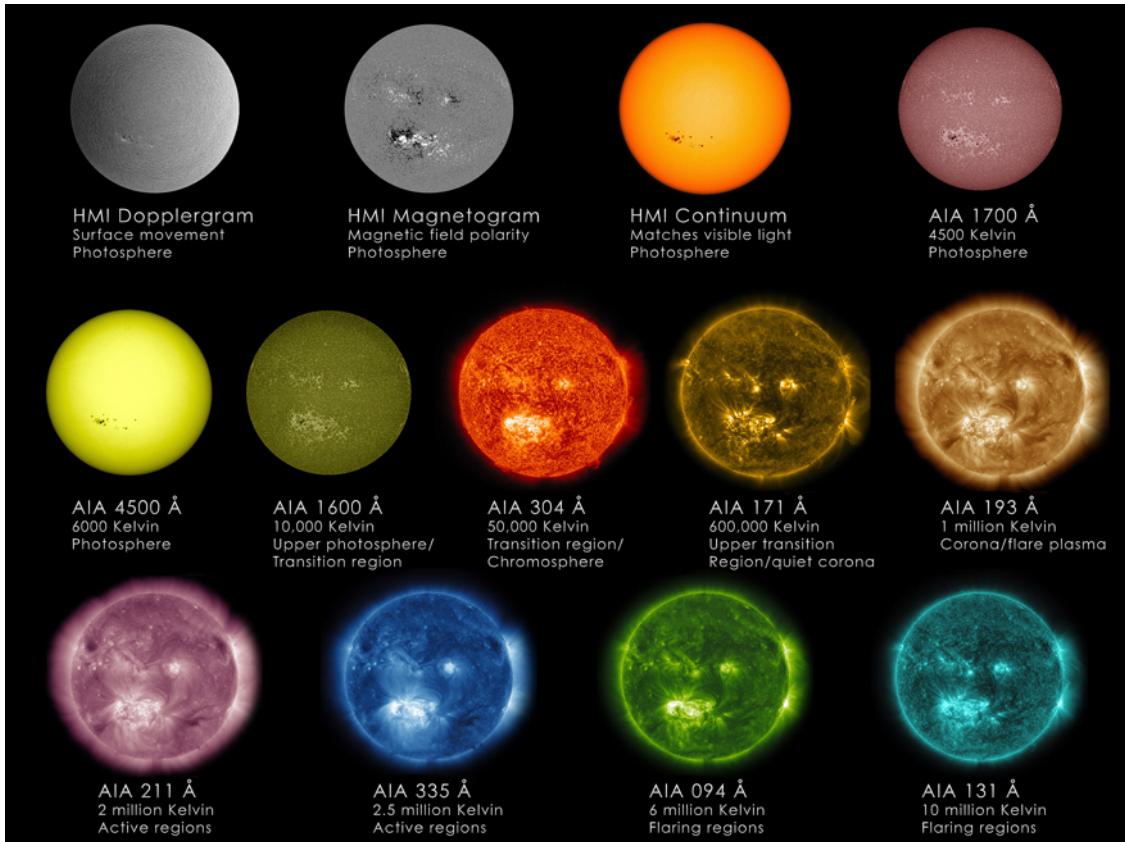
- Ako je generované a štrukturované magnetické pole Slnka?
- Ako uchovaná magnetická energia je konvertovaná a vypustená do heliosféry a priestoru zeme vo forme slnečného vetru, energických častíc a slnečného žiarenia?

Na palube SDO sa nachádza niekolko výskumných zariadení:

- **Atmospheric Imaging Assembly** (skr. AIA) – vyhotovuje snímky slnka každých 12 sekúnd v 10 vlnových dĺžkach (94Å, 131Å, 171Å, 193Å, 211Å, 304Å, 335Å, 1600Å, 1700Å, 4500Å). Prístroj AIA je zobrazený na Obrázku 2 – 3 a snímky Slnka v jednotlivých vlnových dĺžkach sú zobrazené na Obrázku 2 – 4
- **EUV Variability Experiment** (skr. EVE) – meria spektrum extrémne ultrafialového žiarenia Slnka s vysokou presnosťou.
- **Helioseismic and Magnetic Imager** (skr. HMI) – meria slnečné magnetické pole. Rozširuje možnosti SOHO/MDI prístroja, pokrytím celého disku pri vyššom priestorovom rozlíšení a novými schopnosťami vektorového magnetogramu.



Obrázok 2 – 3 Prístroj SDO/AIA



Obrázok 2 – 4 Ukážka snímok vyhotovených vo filtroch SDO/AIA

## 2.2 Slnečná koróna a hlboké učenie

Podľa [Camporeale] (2019) pre oblasť kozmického počasia, nie je strojové učenie a hlavné neuronové siete neznáma oblasť. Prvé pokusy o vytvorenie predikčných modelov neurónových sieti siahajú až do obdobia 90-tých rokov. Avšak aj napriek tomu, že neuronové siete boli využívané aj v tejto oblasti, tak konvolučné neurónové siete boli v oblasti kozmického počasia využité minimálne. Oblasť kozmického počasia má veľký potenciál na aplikovanie metód strojového a hlbokého učenia, pretože má všetky potrebné prvky, ktoré sú potrebné pre úspešnú aplikáciu strojového učenia. K dispozícii máme obrovské množstvo dát, ktoré boli zhromaždené počas niekoľkých desaťročí vesmírnych misií. V mnohých odvetviach sú dáta strážene a nedostupné, ale v oblasti kozmického počasia je väčšina dát dostupná pre širokú verejnosť. Na-

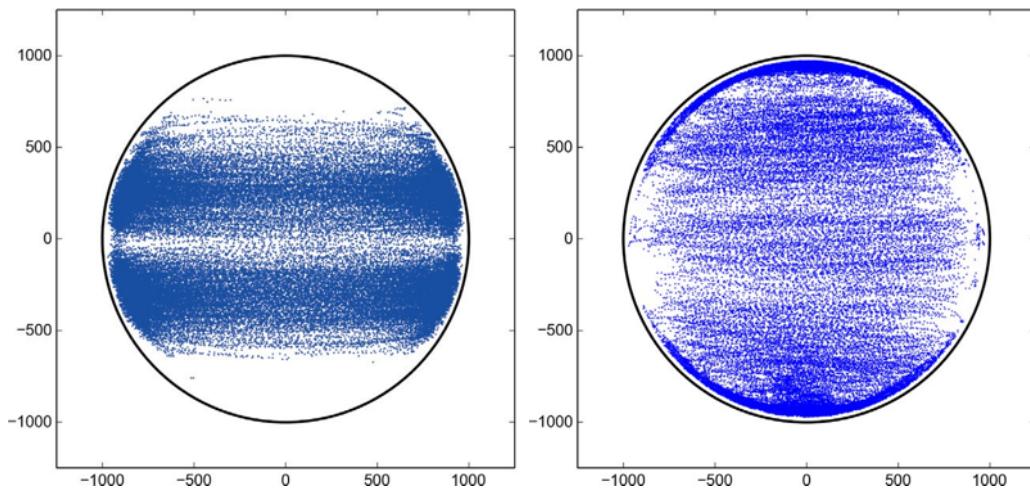
príklad satelity Advanced Composition Explorer (skr. ACE) a Wind and the Deep Space Climate Observatory (skr. DSCOVR) poskytujú údaje o plazme v blízkosti prvého Lagrangeovho bodu (skr. L1) s niekoľkými časovými rozlíšeniami, z ktorých sa niektoré datujú až 20 rokov dozadu. Satelity The Solar and Heliospheric Observatory (skr. SOHO) a SDO, opísaný v podkapitole [2.1] poskytujú magnetogramy, koronogramy a snímky slnka v rôznych vlnových dĺžkach. Kedže sa jedná o oblasť kozmického počasia tak asi nebude žiadnym prekvapením, že najobľúbenejšou úlohou pre aplikáciu strojového učenia je predikcia a to hlavne:

- predpoveď geomagnetických indexov,
- predikcia relativistických elektrónov na geosynchrónej obežnej dráhe Zeme,
- predpoveď slnečných erupcií,
- predpovedanie vývoja výronov koronálnej hmoty.

Práca [Schuh et al., 2016] predstavila komplexný prehľad solárnych javov a snímok zachytených satelitom SDO, ktoré sú verejne dostupné prostredníctvom Heliophysics Event Knowledgebase (skr. HEK) modulu. Autori vytvorili početné štatistiky a exploratívne analýzy, ktoré poskytujú cenné kontextové informácie pre lepšie pochopenie dát uložených v HEK – úložisku informácií o solárnych javoch, ku ktorím je možné pristúpiť pomocou aplikačného rozhrania (angl. *application programming interface*, skr. API) [Hurlburt et al., 2012]. Solárne javy zozbierané z HEK databázy sa odohrali v časovom období od začiatku roka 2010 až po koniec roka 2014. Medzi zozbieranými solárnymi javmi boli:

- aktívne oblasti,
- koronálne diery,
- slnečné škvrny,
- slnečné erupcie a ďalšie.

Na Obrázku 2–5 je vykreslená priestorová poloha aktívnych oblastí a koronálnych dier na základe stredov anotácií pochádzajúcich z algoritmu SPoCA, ktorý je stručne popísaný v kapitole 2.3. Tento obrázok nám vizuálne dokazuje, že sa koronálne diery najčastejšie vyskytujú póloch Slnka.



**Obrázok 2–5** Priestorové zobrazenie výskytu AR (vľavo) a CH (vpravo)

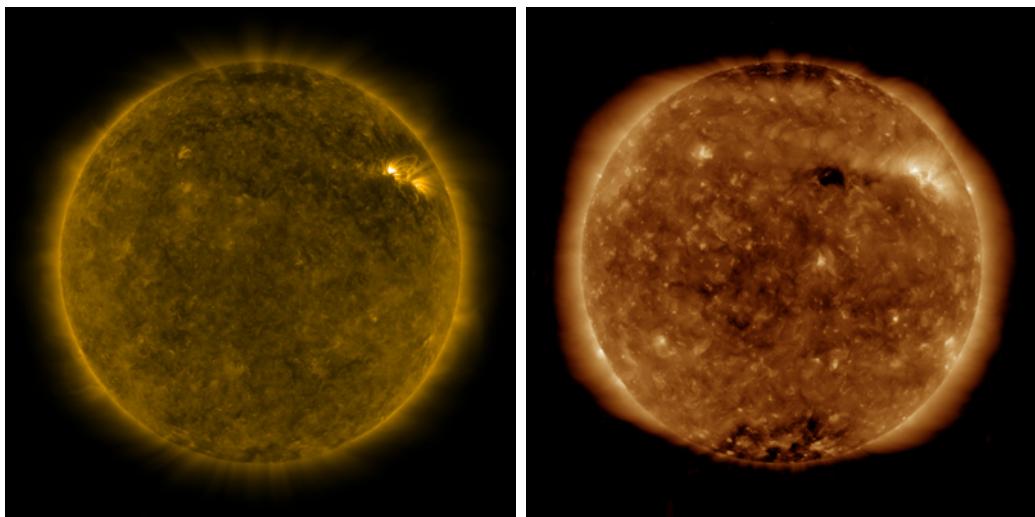
Segmentácií aktívnych oblastí, koronálnych dier alebo iných solárnych javov sa venovalo hned niekoľko prác, avšak iba málo z nich využili na segmentáciu hlboké neuronové siete. Najčastejšie sú využívané prahovacie alebo zhlukovacie metódy. Nižšie si popíšme niekoľko prác venujúcich sa detekcií solárnych udalostí, z ktorých sa najväčšej pozornosti dostava hlavne detekcií koronálnych dier. Práca autorov Henney and Harvey (2005) sa venovala automatickej detekcií koronálnych dier za pomoci spektroheliogramov a fotosférických magnetogramov. Vytvorili algoritmus automatickej detekcie, ktorý využíva morfológickú analýzu obrazu, prahovanie a vyhľadzovanie na odhad polohy, hraníc a polarity koronálnych dier. Autori Krista and Gallagher (2009) využili extrémne ultrafialové a röntgenové snímky vyhotovené prístrojmi STEREO, SOHO a Hinode na identifikáciu koronálnych dier pomocou prahovania intenzity založenej na histograme. Najväčšou limitáciou tejto metódy, bola detekcia koronálnych dier v blízkosti okraja, kedy dochádzalo k nesprávnemu určeniu hraníc oblasti. Upravená verzia algoritmu SPoCA a snímky z nástroja SDO

boli využitá autormi [Delouille et al. (2018)] na segmentáciu koronálnych dier. Cieľom ich práce bolo vylepšiť algoritmus SPoCA a vytvoriť klasfikačný model, ktorý by rozpoznával, či sa na snímke nachádza koronálna diera alebo filament. Na klasifikáciu využili niekoľko algoritmov strojového učenia ako napríklad rozhodovacie stromy, k-nn a SVM. Oblast kozmického počasia sa venuje častejšie koronálnym dieram než aktívnym oblastiam, pričom sú najčastejšie využívane klasické metódy strojového učenia. Vďaka tomu sa nám vyskytuje príležitosť využiť konvolučné neuronové siete na automatickú detekciu týchto oblastí. Segmentácií koronálnych dier pomocou konvolučných neurónových sieti sa však venovali aj autori [Illarionov and Tlatov (2018)]. Autori v práci sami uvádzajú a dúfajú, že ich práca bude motiváciou pre pokračovanie výskumu využitia neurónových sieti na analýzu Slnečných snímok. Preto ich práca pre nás slúžila ako motivácia priniesť lepší model neurónovej siete na detekciu nielen koronálnych dier, ale aj aktívnych oblastí. Ná trénovanie modelu využili snímky Slnka vo vlnovej dĺžke 193Å vyhotovené satelitom SDO. Ako zdroj anotácií im slúžil algoritmus, ktorý nazvali region growth. Ich neurónová sieť bola založená na architektúre U-Net predstavenej v podkapitole 1.7 a dávajú dôraz na to, že výsledky dosiahnuté ich neurónovou sietou je možné zlepšiť dôraznejšou úpravou siete. Na vyhodnotenie modelu využili testovaciu množinu, ktorá pozostávala zo snímok Slnka z roku 2017. Model vyhodnocovali pomocou DICE koeficientu, ktorého priemerná hodnota na testovacej množine bola na úrovni 81%. S iným prístupom prišli autori [Jatla et al. (2020)], ktorých cieľom je predikcia geomagnetických búrok. K tomuto cieľu sa chcú priblížiť pomocou viac-modelovej segmentácie koronálnych dier extrémne ultrafialové snímky (angl. *extreme ultraviolet*, skr. EUV) a magnetické mapy.

### 2.3 Slnečná koróna – dostupné dátá

Pre natrénovanie modelu neurónovej siete slúžiaceho na segmentáciu obrazových dát potrebujeme 2 typy dát. Prvým typom sú snímky, na ktorých sa nachádza

objekt určený na segmentáciu a druhým typom je informácia, kde sa daný objekt na konkrétnnej snímke nachádza. Touto informáciou môže byť sústava súradníc, ktorá určuje hranice daného objektu alebo snímka vo forme čierno-bielej binárnej masky, ktorá určuje či daný pixel je (1, resp. biela farba) alebo nie je súčasťou (0, resp. čierna farba) objektu.



Obrázok 2 – 6 Snímky slnka SDO/AIA 171Å (vľavo) a 193Å (vpravo) – 2. október 2020 23:00

V nasledujúcej časti stručne popíšeme ako sme získali tieto dátá:

1. **Snímky** pochádzajú z programu SDO/AIA opísaného v podkapitole 2.1. Pre našu úlohu sme vybrali snímky slnka v dvoch rozličných vlnových dĺžkach, ktorými sú 171Å a 193Å. Ako môžeme vidieť na obrázku 2–6 na snímkach vo vlnovej dĺžke 171Å je najväčší kontrast medzi aktívnymi oblastami a povrchom slnka čo, ale neplatí pre koronálne diery, ktoré sú však veľmi dobré viditeľné na snímkach vo vlnovej dĺžke 193Å a preto sme rozhodli že:

- 171Å - budú slúžiť na segmentáciu aktívnych oblastí (angl. *active region*, skr. AR),
- 193Å - budú slúžiť na segmentáciu koronálnych dier (angl *coronal holes*, skr. CH).

V našej práci sme využívali snímky v rozlíšení 4096x4096 vo formáte JPEG 2000 (Taubman and Marcellin, 2002) a PNG snímky získané z HEK API (Hurlburt et al., 2012). Snímky Slnka je však možné získať aj z iných zdrojov<sup>1</sup>.

2. **Anotácie** aktívnych oblastí a koronálnych dier sú dostupné zvyčajne vo forme súradníc, ktoré ohraničujú danú oblasť, tieto súradnice sme následne spracovali a vytvorili z nich binárne masky. Pre AR máme k dispozícii iba 2 zdroje anotácií, zatiaľ čo anotácií CH máme viacero zdrojov.

Zdroje anotácií:

- SPoCA-suite<sup>2</sup> (AR a CH) – Zo SPoCA-suite sme získali anotácie pre AR aj CH. Tento nástroj využíva tri typy fuzzy zhľukovacích algoritmov: Fuzzy C-means (FCM) a jej regularizovanú verziu nazývanú Possibilistic C-means (PCM) a Spatial Possibilistic Clustering Algorithm (SPOCA) (Delouille et al., 2012).
- Vlastné (AR a CH) – Tieto anotácie vznikli vrámci anotačného projektu Zooniverse (Simpson et al., 2014), ktorý bol súčasťou bakalárskej práce (Urbán, 2020). Anotovanie pozostávalo z ručného označovania AR a CH.
- CHIMERA<sup>3</sup>(CH) – Algoritmus Chimera bol vytvorený na detekciu koronálnych dier a prvý krát predstavený v publikácii Garton, Tadhg M. et al. (2018). Tento algoritmus funguje na princípe segmentácie intenzity medzi tróma vlnovými rozsahmi 171Å, 193Å a 211Å, ide o tzv. „multi-thermal intensity segmentation”.
- Region Growth<sup>4</sup> (CH) – Tento algoritmus bol taktiež vytvorený len na detekciu koronálnych dier a bol predstavený v publikácii Tlatov et al.

<sup>1</sup> Ďalšie zdroje snímok: <https://sdo.gsfc.nasa.gov/data/> [https://sdowww.lmsal.com/suntoday\\_v2/](https://sdowww.lmsal.com/suntoday_v2/) <http://jsoc.stanford.edu/>

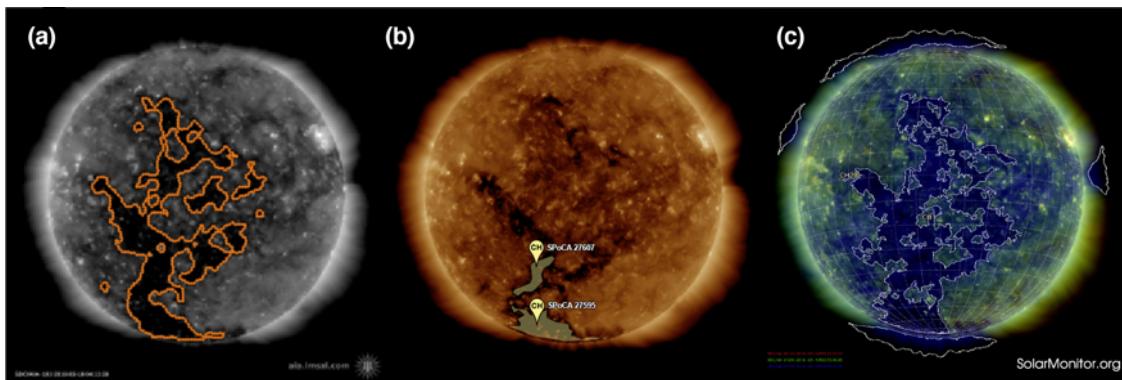
<sup>2</sup> Dostupné online na <https://helioviewer.org/> a pomocou Sunpy knižnice a HEK API v jazyku Python

<sup>3</sup> Dostupné online na <https://solarmonitor.org/>

<sup>4</sup> Dostupné online na <https://observethesun.com/>

(2014). Region Growth funguje na princípe poloautomatikého spracovania SDO/AIA 193Å snímok.

Na snímke 2–7 (A–region growth, B–SPoCA, C–CHIMERA) autorov Illarionov and Tlatov (2018) alebo na snímke 3–7 (B–SPoCA, C–region growth, D–CHIMERA) môžeme vidieť porovnanie anotácií rôznych zdrojov, z ktorých SPoCA má často nepresné anotácie, ktoré nezahrnujú celú koronálnu dieru alebo zahrnujú oblasť, ktorá už nieje koronálna diera. Anotácie CHIMERA zahrnujú cele koronálne diery, ale zároveň aj menej tmavé oblasti nazývané filamenty. Region growth anotácie sú výsledkom poloautomatickej segmentácie a môžeme ich vyhodnotiť ako najlepšie.

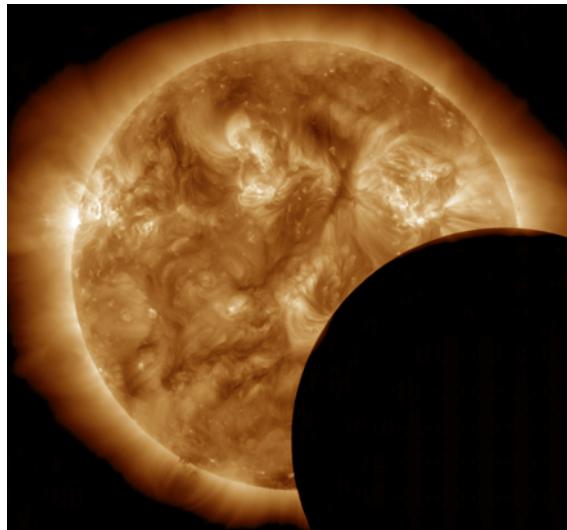


Obrázok 2 – 7 Porovnanie anotácií koronálnych dier

### 3 Segmentácia koronálnych dier a aktívnych oblastí

Pre vytvorenie úspešného klasifikačného, segmentačného alebo napríklad predikčného modelu je dôležité stanoviť si cieľ, ktorý chceme pomocou daného modelu dosiahnuť. V našom prípade ide o vytvorenie segmentačného modelu pomocou metód hlbokého učenia, ktorý prinesie lepšie segmentácie než doteraz využívaný SPoCA algoritmus. Cieľom nie je vytvoriť len model na segmentáciu konkrétnych udalostí (koronárnych dier či aktívnych oblastí), ale zároveň priniesť akýsi návod počnúc od vytvorenia segmentácií v Zooniverse, ktorým sa venovala bakalárska práca Urbán (2020) až po automatickú segmentáciu rôznych aj menej špecifických štruktúr. Komplexným cieľom našej výskumnej skupiny je teda priniesť podrobný návod ako segmentovať rozličné štruktúry slnečnej koróny. Náš prístup budeme testovať na dvoch rozdielnych udalostiach, aktívne oblasti špecifické jasným žiareniom a na druhej strane koronálne diery špecifické pravé tmavými oblastami. Architektúra modelu by tak mala byť univerzálnej aj pre iné špecifické segmentačné úlohy.

Jediná limitácia, ktorú v tejto aj v budúcej prací vidíme sú dátá. Preto veľmi dôležitým krokom je zoznamenie sa z dátami, ktoré sme predstavili v kapitole 2.3 a následné ich príprava do podoby, ktorú vyžaduje trénovaný model na vstupe. Proces prípravy dát zvyčajne vyžaduje ich očistenie od nepotrebných prvkov, v našom prípade sme odstránili poškodené snímky alebo snímky kde došlo k zakrytiu Mesiacom, ako môžeme vidieť na Obrázku 3–1. Súčasťou prípravy dát bolo aj ich predspracovanie a augmentácia, tieto procesy popíšeme v podkapitole 3.2. Nasledujúcim krokom je modelovanie, v ktorom vytvoríme a natrénujeme model a vyhodnotíme ho na základe určených kritérií. Po vyhodnotení modelu môžeme pokračovať nasadením modelu alebo sa vrátiť späť k predspracovaniu dát alebo modelovaniu. Takýto postup je označovaný ako CRISP-DM (Paralic, 2003) a je rozdelený do 6 fáz: pochopenie cieľa, pochopenie dát, príprava dát, modelovanie, vyhodnotenie, nasadenie.



Obrázok 3 – 1 Čiastočné zatmenie Slnka 11. Marca 2013

### 3.1 Použité technológie

Na vypracovanie praktickej časti tejto práce sme využili open-source programovací jazyk **Python**, ktorý má veľkú podporu pre hlboké učenie, analýzu dát, ale aj pre vedu. Iba pre oblasť slnečnej fyziky existuje viac než 28 modulov resp. knižníc (Burrell et al., 2018). Využité knižnice:

- **Tensorflow**<sup>5</sup> je open-source platforma vyvinutá spoločnosťou Google. Je to knižnica určená primárne na numerické výpočty a na vývoj hlbokých neurónových sieti. Tensorflow podporuje trénovanie neurónových sieti na viacerých CPU aj GPU.
- **Keras**<sup>6</sup> sa stal pevnou súčasťou Tensorflow s príchodom verzie Tensorflow 2.0. Keras je intuitívna knižnica určená pre vývoj neurónových sieti, ktorá bola vyvinutá aby umožnila rýchly a jednoduchý vývoj a prototypovanie.
- **Astropy**<sup>7</sup> je výsledkom snahy vytvoriť jednotnú knižnicu pre astrofyziku a astronómii. Je to open-source knižnica vyvinutá pre jazyk Python, ktorá obsa-

---

<sup>5</sup><https://www.tensorflow.org/>

<sup>6</sup><https://keras.io/>

<sup>7</sup><https://www.astropy.org/>

huje rôzne nástroje a funkcie používané v bežných astronomických nástrojoch (Price-Whelan et al., 2018; Robitaille et al., 2013).

- **Sunpy**<sup>8</sup> je komunitou vyvíjaná open-source knižnica určená pre solárnu fyziku. Pretože Sunpy sa zaobrá astrofyzikálnymi koncepciami, je vývoj tejto knižnice úzko spojený s vývojom knižnice Astropy (The SunPy Community and Barnes, 2020).
- **OpenCV**<sup>9</sup> je multiplatformová open-source knižnica určená pre oblasť počítačového videnia a strojového učenia. Obsahuje viac než 2500 optimalizovaných algoritmov. Je využívaná hlavne na manipuláciu s videom a snímkami.
- **Pillow**<sup>10</sup> je knižnica pre jazyk Python určená na manipuláciu so snímkami jej hlavná výhoda oproti OpenCV spočíva v používateľskej prístupnosti.

### 3.2 Príprava dát

Prípravu dát, sme rozdelili do 2 krokov a to fixné zmeny, ktoré popíšeme v časti predspracovanie dát a augmentáciu dát, teda rozširovanie dátovej množiny augmentačnými technikami, ktorím sa budeme venovať v oddiele augmentácia dát.

#### Predspracovanie dát

Proces predspracovania dát pre snímky 193Å (CH) obsahoval jeden krok navyše než pre snímky 171Å (AR). Tento krok spočíval v odstránení čierneho pozadia, ktoré spôsobovalo problémy pri segmentácii prevažne v oblasti pólov, pretože koronálne diery, ktoré sú charakterizované čiernymi pixelmi a splývali tak s čiernym pozadím. Na tento problém už poukázali (Illarionov and Tlatov, 2018) a po otestovaní sa nám prvotne potvrdil rovnaký výsledok. Tento problém sa nám neskôr podarilo eliminovať ďalšou úpravou siete, ale rozhodli sme sa zachovať tento proces predspracovania

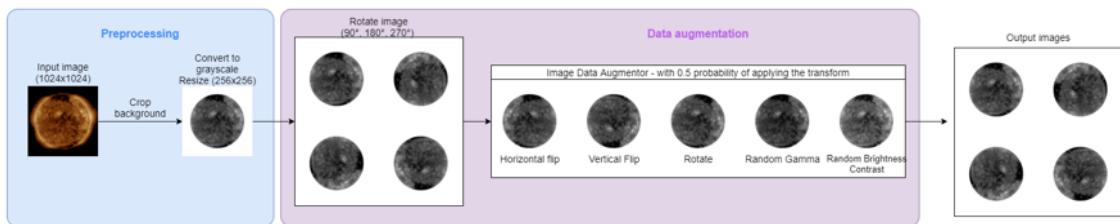
---

<sup>8</sup><https://sunpy.org/>

<sup>9</sup><https://opencv.org/>

<sup>10</sup><https://pillow.readthedocs.io/en/stable/>

dát. Ďalším krokom predspracovania dát bolo konvertovanie farebnej škály snímok na odtiene sivej a zníženie rozlíšenia vstupnej snímky na  $256 \times 256$ . Na Obrázku 3–2 je v modrom rámčeku znázornený proces predspracovania dát pre koronálne diery.



Obrázok 3 – 2 Predspracovanie a augmentácia dát

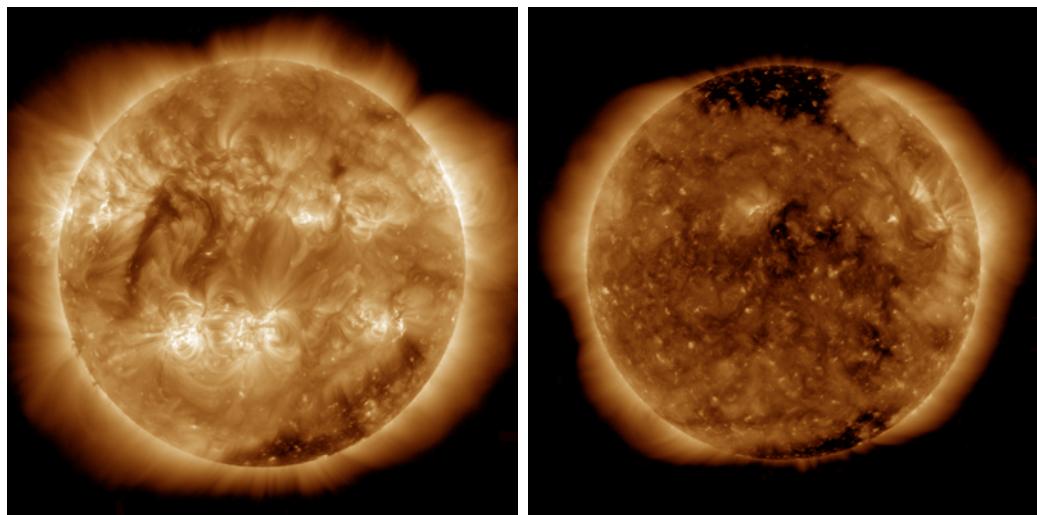
## Augmentácia dát

Neuronové siete sú známe tým, že pre dosiahnutie dobrých výsledkov vyžadujú veľké množstvo dát. Z veľkej dátovej množiny dokáže neurónová siet extrahovať lepšie príznaky aj pri horšej kvalite dát (Perez and Wang, 2017). Avšak, získanie veľkého množstva označených dát vyžaduje veľmi veľa času a ľudských zdrojov, pretože tento proces zvyčajne spočíva v manuálnom označovaní dát. Augmentácia dát je najlepším spôsobom ako vyriešiť tento problém. Aplikáciou malých zmien ako napríklad rotácia alebo prevrátenie snímky, vytvoríme nové príklady, ktoré môžu značne zlepšiť výsledky neurónovej siete (Shorten and Khoshgoftaar, 2019 | Mikołajczyk and Grochowski, 2018). Pri augmentácii dat je nutné dbať na to aby použité techniky augmentácie boli relevantné danej oblasti, napríklad pre naše dáta by bolo nevhodné snímky roztahnúť alebo zväčšiť, pretože v našej dátovej množine sa táka snímka nevyskytuje a ani sa tam objaviť nemôže.

Pre zväčšenie dátovej množiny sme rotovali snímky o 90, 180 a 270 stupňov. Týmto spôsobom sme získali štvornásobne väčšiu dátovú množinu. Okrem aplikovania rotácií sme tak tiež využili ImageDataAugmentor, ktorý aplikoval nasledujúce transformácie s 50% pravdepodobnosťou:

- Horizontálne prevrátenie – prevrátenie snímky v ose y.
- Vertikálne prevrátenie – prevrátenie snímky v ose x.
- Rotácia – rotácia snímky v rozmedzí  $(-45, 45)$  stupňov. Na extrapoláciu bola využitá metóda `cv2.BORDER_REPLICATE`, ktorá zachovala biele resp. čierne pozadie.
- Náhodná gama – náhodný posun gama v rozmedzí  $(100, 150)$ .
- Náhodný jas a kontrast – náhodná zmena jasu v rozmedzí  $(0, 0.2)$  a kontrastu v rozmedzí  $(0, 0.4)$ .

Transformácie vo forme zmene jasu, kontrastu a gamy boli použité na vykompenzovanie snímok slnka, ktoré sa javia byť jasnejšie resp. tmavšie, pozri Obrázok 3–3. Takéto jasnejšie snímky sa nachádzajú v rozmedzí rokov 2012-2016 počas maxima slnečnej aktivity, čiže ich máme v značne väčšom počte a niektoré modely, ktoré boli učené na takýchto svetlejších snímkach dosahovali horšie segmentácie na snímkach tmavých.



**Obrázok 3–3** Rozdiel v intenzite jasu na snímkach z roku 2010 (vľavo) a z roku 2018 (vpravo) – SDO/AIA

Na augmentáciu dát bola použitá Python knižnica `Albumentations` (Buslaev et al. 2020) spolu s generátorom `ImageDataAugmentor` (Tukiainen, 2019). Ukážky týchto augmentácií možno vidieť vo fialovom rámčeku na Obrázku 3–2.

## Rozdelenie dátových množín

Ako už bolo spomenuté v podkapitole 2.3, k dispozícii máme snímky Slnka z dvoch rôznych filtrov (171Å a 193Å) a niekolko rôznych zdrojov anotácií, z ktorých sa budú odvíjať naše vstupné dátové množiny, pozri Tabuľky 3–1 a 3–2. Každú z týchto dátových množín použijeme na trénovanie samostatného modelu, ktorý bude následne testovať na validačnej množine pozostávajúcej z posledných 10% snímok dátovej množiny a na nezávislej testovacej množine. Žiadna snímka z testovacej a validačnej množiny nebola použitá na trénovanie modelu.

Testovacie množiny:

- 193Å – 353 snímok z roku 2017 + anotácie Region Growth
- 171Å – 360 snímok z roku 2016 + anotácie SPoCA

**Tabuľka 3 – 1** Prehľad získaných anotácií CH

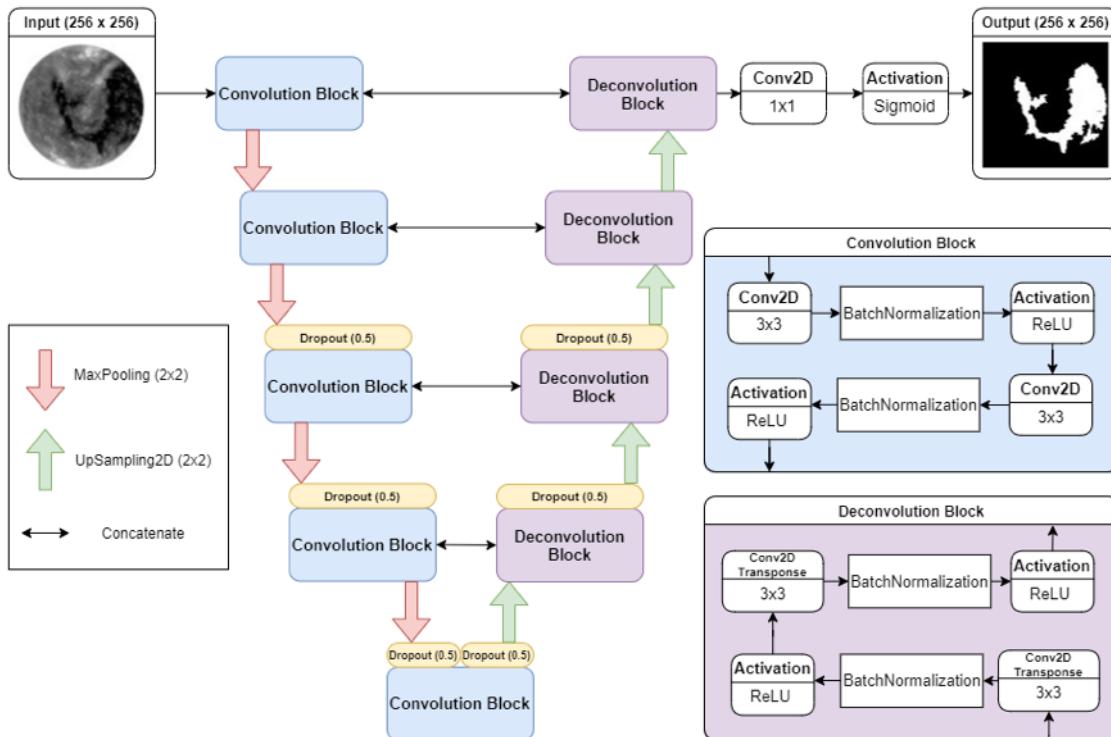
Zdroj	Počiatočné	Rotované	Trénovacia množina	Validačná množina
Vlastné	537	2148	1933	215
SPoCA	537	2148	1933	215
Chimera	653	2612	2351	261
Region growth	1968	7872	7085	787

### 3.3 SCSS-Net

Architektúra nášho modelu (znázornená na obrázku 3–4), ktorú sime nazvali SCSS-Net (Solar Coronal Structures Segmentation Network) je inšpirovaná architektúrou neurónovej siete U-Net (Ronneberger et al. [2015]), predstavenej v podkapitole 1.8.

**Tabuľka 3 – 2** Prehľad získaných anotácií AR

Zdroj	Počiatočné	Rotované	Trénovacia množina	Validačná množina
Vlastné	533	2132	1919	213
SPoCA	1091	4364	3928	436
SPoCA + vlastné	1607	6428	5785	643



**Obrázok 3 – 4** SCSS-Net architektúra

Vstupom našej siete je snímka Slnka vo velkosti  $256 \times 256$  pixelov. Takúto velkosť sme zvolili pretože pri tomto vstupe boli predikcie dostatočne presné a zároveň

časová a hardvérová náročnosť výpočtov bola relatívne nízka. Rovnako ako bežné konvolučné neuronové siete je SCSS-Net zložený z enkodéra a dekodéra:

- **Enkodér** (ľavá časť) – je zložený z piatich konvolučných blokov. Tieto konvolučné bloky obsahujú dve  $3 \times 3$  konvolúcie nasledované batch normalizáciou a aktivačnou fuknciou ReLU. Pre prvé štyri konvolučné vrstvy platí, že na konci každej z nich nasleduje **max-pooling**  $2 \times 2$  a zdvojnásobujeme počet konvolučných filtrov (32, 64, 128, 256, 512). Pri poslednej vrstve, resp. konvolučnom bloku sa tento proces otočí, počet filtrov sa znova zmenší o polovicu, nasleduje  $2 \times 2$  **upsampling** a začína dekodér.
- **Dekodér** (pravá časť) – pozostáva zo štyroch dekonvolučných blokov, ktoré sa líšia od konvolučných blokov tým, že namiesto konvolúcií využívajú transponované konvolúcie. Pred každým dekonvolučným blokom dochádza k nadvzorkovaniu - **upsampling**, a zníženiu filtrov o polovicu.

Na prepojenie snímok a príznakov medzi jednotlivými úrovňami siete využívame funkciu **concatenate** – tá nám umožňuje spojiť pôvodnú vstupnú snímku s naučenými príznakmi. Siet je regularizovaná pomocou funkcie dropout s 50% pravdepodobnosťou počnúc tretím konvolučným blokom a končiac druhým dekonvolučným blokom. Výstup tvorí konvolučná vrstva o veľkosti  $1 \times 1$  s aktivačnou funkciou sigmoid. Na výstupe tak získavame segmentačné masky, ktoré pre každý pixel určujú s akou pravdepodobnosťou daný pixel patrí do danej triedy.

### Optimalizácia parametrov SCSS-Net

Aby náš model dosiahol čo najlepšie výsledky, upravovali sme rôzne parametre a hyperparametre modelu. Najprv sme sa zamerali na parametre, ktoré mali dopad na hardvérové nároky modelu – vstupná veľkosť snímky, **batch-size** a počet konvolučných filtrov modelu. Prioritne sme chceli vytvoriť model, ktorý je ľahko reprodukovateľný na bežnom hardvérovom vybavení počítača. Model sme trénovali na

grafickej karte NVIDIA GeForce GTX 1060 Max-Q. Na to aby nám stačila jej 6GB pamäť sme zvolili vstupnú veľkosť snímky  $256 \times 256$  a **batch-size** o veľkosti 20 snímok. Pri 64 konvolučných filtroch sme dosiahli zlepšenia výsledkov o 1-3%, ale aj pri **batch-size=1** nám model hlásil chybovú hlášku **OutOfMemory**, preto sme nakońec zvolili 32 konvolučných filtrov. Následne sme využili aj väčšiu výpočtovu silu GPU Tesla K40 s 12GB pamäťou, kde sme robili experimenty na väčších vstupných obrázkoch, väčším počtom konvolučných filtrov a podobne. Došli sme však k záveru, že takéto modely sa často preučili. Preto sme ostali pri štandardnom hardvérovom vybavení a vyššie predstavených nastaveniach modelu.

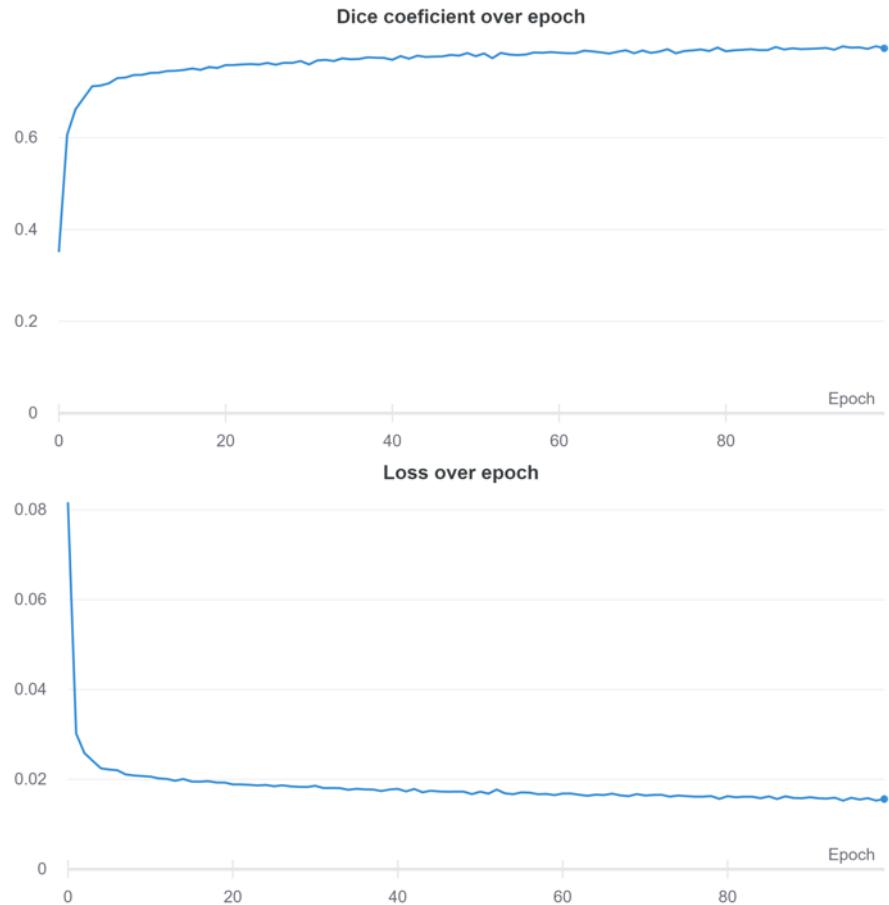
Taktiež sme vyskúšali rôzne optimalizačné funkcie, z ktorých najlepšie výsledky model dosahoval pri použití optimizera Adam a RMSprop. Výsledky modelu trénovaného na rovnakých dátach za použitia rôznych optimalizačných funkcií môžeme vidieť v Tabuľke 3–3. V ďalších experimentoch sme využívali populárny optimizer Adam.

**Tabuľka 3–3** Výsledky modelov za použitia rôznych optimalizačných funkcií

Optimalizačná funkcia	Dice	Dice threshold
Adam	0.82	0.87
Adagrad	0.70	0.83
SGD	0.74	0.83
RMSprop	0.82	0.87

Na Obrázku 3–5 sa nachádza priebeh učenia modelu trénovaného na region growth anotáciach. Natrénoval tento model na 7872 snímkach trvalo 7 hodín a 10 minút, pričom jedna epocha trvala približne 4 minúty. Ďalšie grafy priebehu tohto trénovania, zobrazenia systémového a procesného využitia CPU, GPU počas trénovania modelu, grafickú ukážku modelu či samotný konzolový výpis priebehu učenia,

sú dostupné online<sup>11</sup> a boli vytvorené pomocou API Weights & Biases<sup>12</sup>. V budúcej práci sa budeme venovať komplexnej vizualizácií všetkých modelov a vizuálnemu porovnaniu priebehov a závislostí jednotlivých metrík pomocou tohto API.



**Obrázok 3 – 5** Priebeh učenia

### 3.4 Post-processing

Ako už bolo spomenuté, výstupom modelu je v našom prípade pravdepodobnosťou z akou daný pixel snímky je koronálna diera, resp. aktívna oblasť. Nami požadovaný výstup je však:

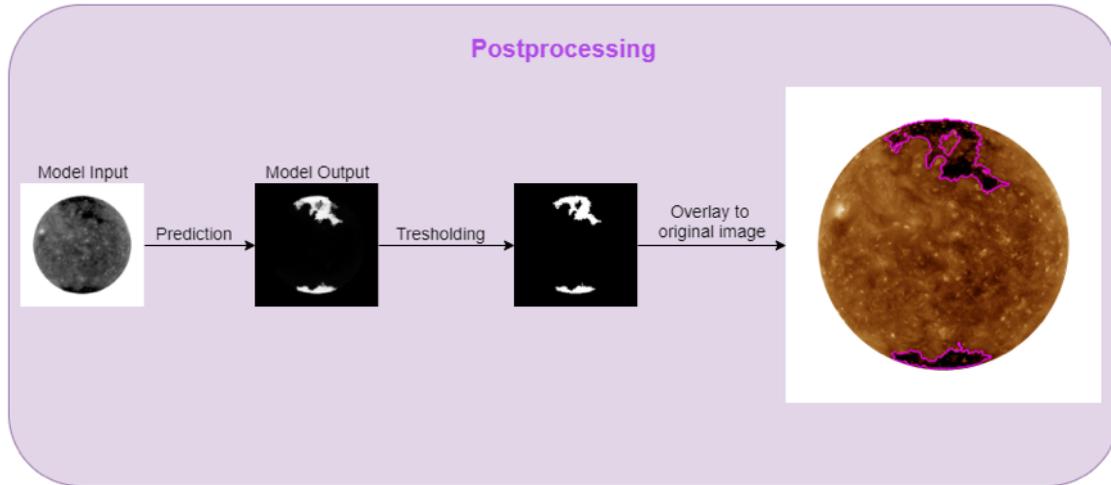
1. binárna maska, ktorá môže slúžiť na štatistickú analýzu slnečných štruktúr,

<sup>11</sup> <https://wandb.ai/matinus/sun-segmentation/runs/2p0ciuvk/>

<sup>12</sup> <https://wandb.ai/site>

2. snímka slnka, na ktorej bude vykreslená oblasť, kde sa daná slnečná štruktúra nachádza. Takáto snímka môže slúžiť na prezentáciu a vizuálnu analýzu.

V niekoľkých krokoch, ktoré sú zobrazené na Obrázku 3–2, sme výstup dostačne spracovali aby získal nami požadovanú podobu. Pre získanie binárnej segmentačnej masky sme všetky hodnoty menšie než 0.5 zmenili na 0 a väčšie na 1. Aplikovaním prahovania sme tak získali čiernobielu snímku, kde biele pixely boli tie, ktoré model označil za koronálnu dieru, resp. aktívnu oblasť. Pre získanie kontúr sme využili metódy počítačového videnia na nájde hrán, tzv. edge detection. Nájdene kontúry boli vo veľkosti vstupu ( $256 \times 256$ ), ktoré sme následne prepočítali na pôvodnú veľkosť snímky ( $1024 \times 1024$ ).



Obrázok 3 – 6 Post-processing

### 3.5 Vyhodnotenie výsledkov

Model, ktorý sme predstavili v podkapitole 3.3 sme trénovali samostatne pre úlohu segmentácie koronálnych dier na štyroch dátových množinách popísaných v Tabuľke 3–1 a model slúžiaci na segmentáciu aktívnych oblastí bol trénovaný na troch dátových množinách predstavených v Tabuľke 3–2. Natrénovali sme tak 4 modely slúžiace na segmentáciu CH a 3 modely slúžiace na segmentáciu AR. Každý z týchto

modelov bol trénovaný na vlastnej dátovej množine a bol testovaný oproti 10% dát z rovnakého zdroja anotácií a zároveň sme tieto modely testovali na nezávislej dátovej množine. Pre testovanie segmentácií koronálnych dier sme zvolili snímky z roku 2017 a vytvorili sme dve testovacie množiny. Jedná z testovacích množín bola zložená z Region Growth anotácií pretože tieto anotácie sme pokladali za najlepšie a zároveň sme ich mali v najväčšom počte. Druhá testovacia množina bola zložená z anotácií SPoCA. Na testovanie segmentácií aktívnych oblastí sme vyбрали snímky roku 2016 a anotácie z algoritmu SPoCA pretože naše vlastné anotácie sa pohybovali v rozmedzí rokov 2012-2015 a nemáme ich k dispozícii vo veľkom počte.

Každý z modelov sme trénovali počas 100 epoch, pričom sme využili funkciu `CallbackCheckpoint`, ktorá ukladá model iba v tej epoche, v ktorej bola chyba najmenšia. Pomocou tejto funkcie môžeme trénovať model počas toľkých epoch a nemusíme sa báť toho, že posledný uložený model nebude ten najlepší.

### 3.5.1 Koronálne diery

Na Tabuľke 3–4 môžeme vidieť, že model dosahoval dostatočné dobre výsledky na validačných množinách aj v prípade modelu, ktorý bol učený na našich vlastných anotáciách, ktoré sme nemali k dispozícii vo veľkom počte. Naopak na výsledkoch modelu trénovaného na dátovej množine zloženej zo SPoCA anotácií, ktoré boli v rovnakom počte ako naše vlastné anotácie, sa nám potvrdzuje, že tieto anotácie niesu dokonalé a obsahujú veľa chýb. V prípade modelov, trénovaných na dátovej množine CHIMERA a Region Growth vidíme, že na validačnej množine dosiahli podobné výsledky a z toho môžeme usúdiť, že výrazne rozdielna veľkosť dátovej množiny (2351 - CHIMERA a 7085 - Region Growth) nemusela mať veľký vplyv.

Výsledky z validačnej množiny sa však nehodia na celkové vyhodnotenie modelov a ich porovnanie medzi sebou. Na rozhodnutie, ktorý z natrénovaných modelov je najlepší sme tieto modely otestovali na dvoch nezávislých testovacích množinách. V Tabuľke 3–5 môžeme vidieť výsledky na testovacej množine zloženej z anotácií SPoCA. Najlepšie výsledky dosiahol model trénovaný na region growth anotáciách.

**Tabuľka 3 – 4** Výsledky modelov (CH) na validačnej množine

Trénovacia množina	Validačná množina	Dice	IoU
Vlastné	215	0.85	0.74
SPoCA	215	0.74	0.59
Chimera	261	0.86	0.76
Region growth	787	0.88	0.78

Modely trénované na SPoCA a CHIMERA anotáciách dosiahli porovnatelné výsledky, avšak aj napriek tomu, že žiadne snímky z testovacej množiny neboli použité na trénovanie, tak v prípade SPoCA modelu to mohlo ovplyvniť výsledky. Na tejto testovacej množine si mal najhoršie výsledky model trénovaný na našich vlastných anotáciach.

**Tabuľka 3 – 5** Výsledky modelov na testovacej množine zloženej zo SPoCA anotácií

Trénovacia množina	Testovacia množina	Dice	IoU
Vlastné	353	0.56	0.39
SPoCA	353	0.59	0.42
Chimera	353	0.59	0.42
Region growth	353	0.63	0.46

Avšak ak sa pozrieme na Tabuľku 3–6, ktorá obsahuje výsledky jednotlivých modelov testovaných na region growth anotáciách, tak môžeme vidieť, že model SPoCA mal oveľa horšie výsledky. Naopak zvyšné modely majú oveľa lepšie výsledky, z ktorých najlepší je model Region growth za ním CHIMERA a model trénovaný na vlastných anotáciach.

Na Obrázku 3–7, kde veľkými písmenami sú označené snímky s pôvodnými anotáciami (A - vlastné, B - SPoCA, C - Region growth, D - CHIMERA) a malými písmenami snímky segmentované modelom (a - vlastné, b - SPoCA, c - Region gro-

**Tabuľka 3 – 6** Výsledky modelov na testovacej množine zloženej z Region Growth anotácií

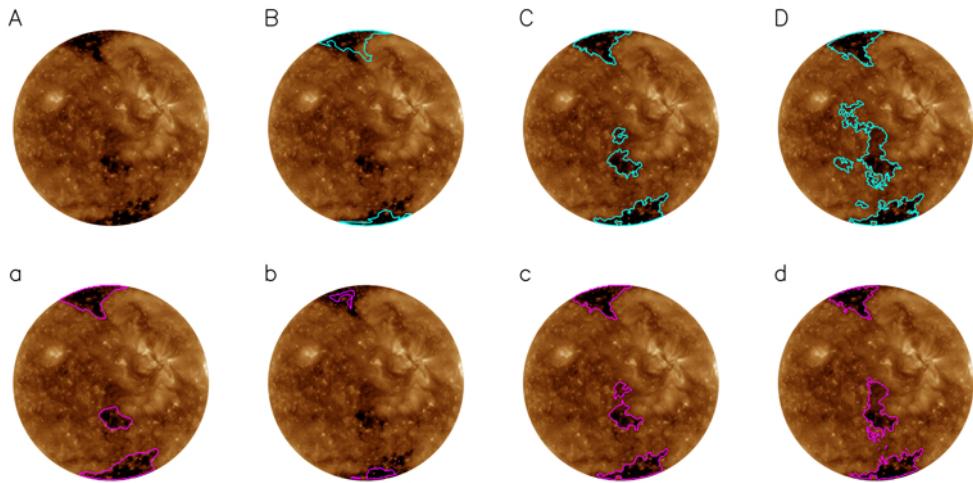
Trénovacia množina	Testovacia množina	Dice	IoU
Vlastné	353	0.83	0.71
SPoCA	353	0.35	0.21
Chimera	353	0.85	0.73
Region growth	353	0.88	0.78

wth, d - CHIMERA) môžeme spozorovať, že výsledná DICE metrika SPoCA modelu na SPoCA testovacej množine bola naozaj ovplyvnená rovnakým zdrojom anotácií. Napriek tomu, že SPoCA anotácie niesu práve najkvalitnejšie, tak sa SPoCA model odnaučil segmentovať tie časti snímky, ktoré už niesu koronálna diera. Podobný jav môžeme spozorovať aj pri modely CHIMERA, kde pôvodne anotácie (D) preceňujú veľkosť koronálnych dier, ale model už tieto oblasti, ktoré sa za koronálne diery už nepovažujú neoznačuje ako CH. Model trénovaný na našich vlastných anotáciách (A<sup>13</sup>) sa dokázal naučiť veľmi presne segmentovať koronálne diery aj napriek tomu, že sme mali k dispozícii iba limitovaný počet anotácií. Vďaka veľkému počtu kvalitných anotácií sú segmentácie modelu Region growth takmer rovnaké ako pôvodné anotácie. Ukážku segmentácií vytvorených modelom, ktorý bol trénovaný na region growth anotáciach, môžeme vidieť na Obrázku 3–8.

### 3.5.2 Aktívne oblasti

Segmentácia aktívnych oblastí bola zložitejšia, pretože sme nemali k dispozícii do statočné množstvo kvalitných anotácií. SPoCA anotácie obsahovali veľké množstvo nesprávne označených oblastí a nakoľko ručná anotácia snímok je veľmi časovo náročná, tak vlastných anotácií máme v príliš malom množstve a preto sme sa rozhodli vytvoriť testovaciu dátovú množinu iba zo SPoCA anotácií. Na základe týchto faktov sme sa pri segmentácii aktívnych oblastí spoliehali hlavné na vizuálne porovnanie

<sup>13</sup>Vlastnú anotáciu sme nemali k dispozícii pre túto snímku.



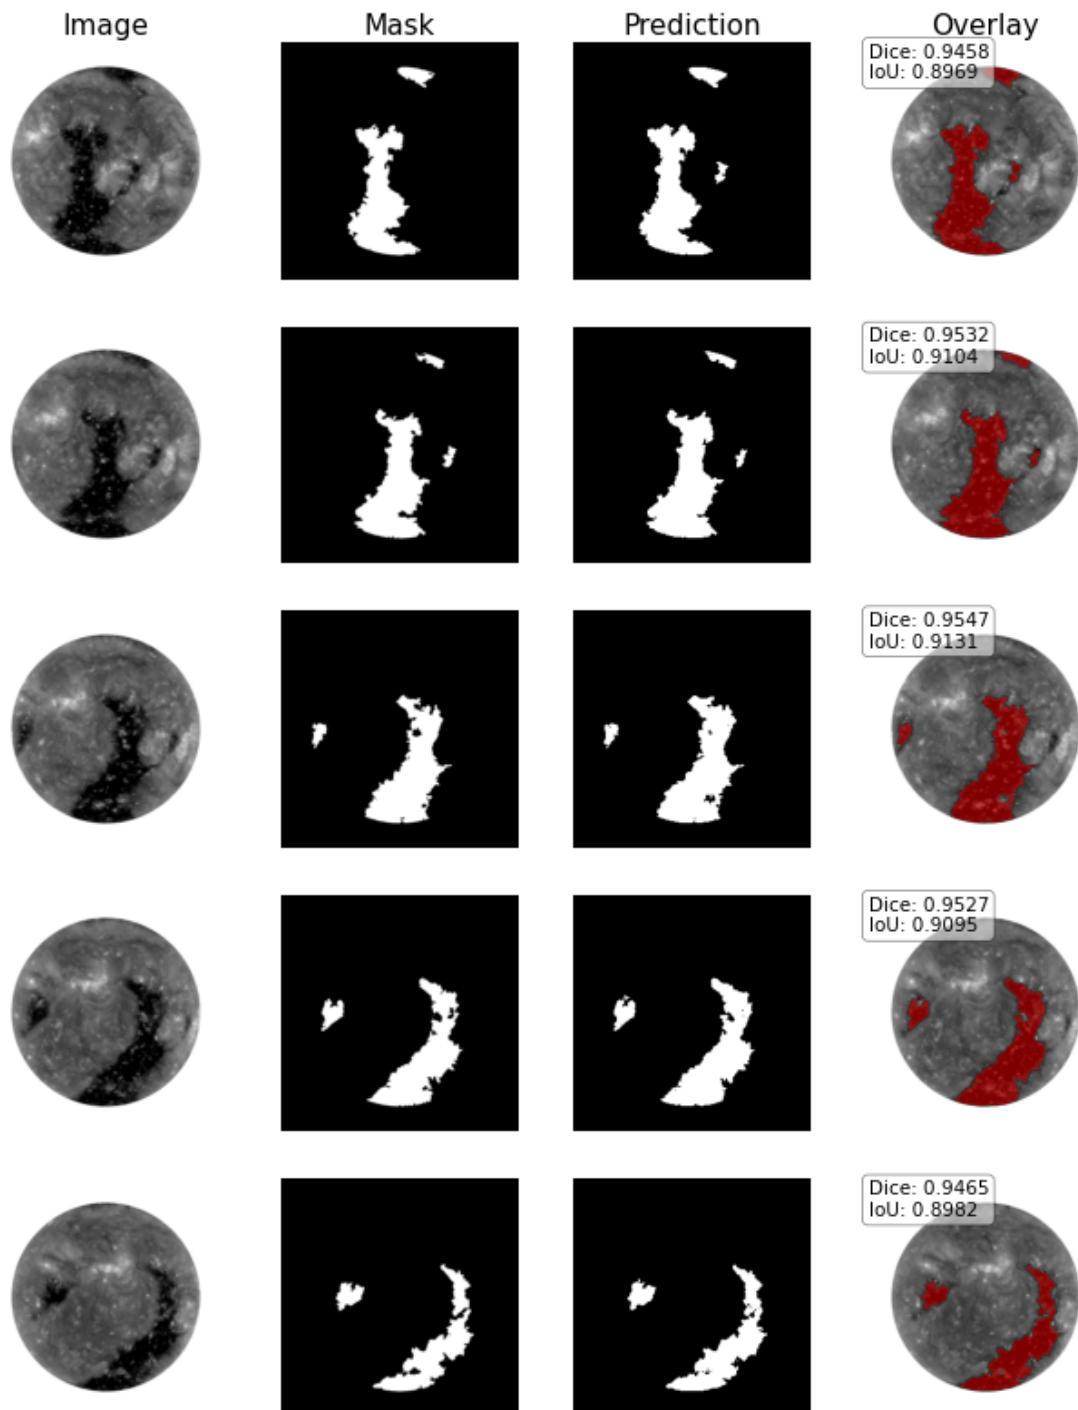
Obrázok 3 – 7 Porovnanie segmentácií koronálnych dier

Tabuľka 3 – 7 Výsledky modelov (AR) na validačnej množine

Trénovacia množina	Validačná množina	Dice	IoU
Vlastné	213	0.81	0.68
SPoCA	436	0.71	0.55
SPoCA + vlastné	643	0.51	0.34

segmentácií. Na Tabuľke 3 – 7 model SPoCA na segmentáciu AR dosiahol porovnatelne výsledky na validačnej množine ako model SPoCA na segmentáciu CH. Na validačnej množine dosiahol najlepšie výsledky model učený na našich vlastných anotáciách a najhoršie ten, ktorý bol učený na oboch dátových množinách. Ukážku segmentácií vytvorených modelom, ktorý bol trénovaný na spojenej dátovej množine, môžeme vidieť na Obrázku 3 – 10.

Ak sa pozrieme na výsledky z testovacej množiny v Tabuľke 3 – 8 tak to pre model trénovaný na našich vlastných anotáciách vyzerá horšie a výsledok modelu trénovaného na spojenej množine je približný priemer zvyšných modelov. Preto aby sme mohli lepšie model vyhodnotiť, tak sa musíme pozrieť na výsledne anotácia a rozhodnúť sa na základe nich.



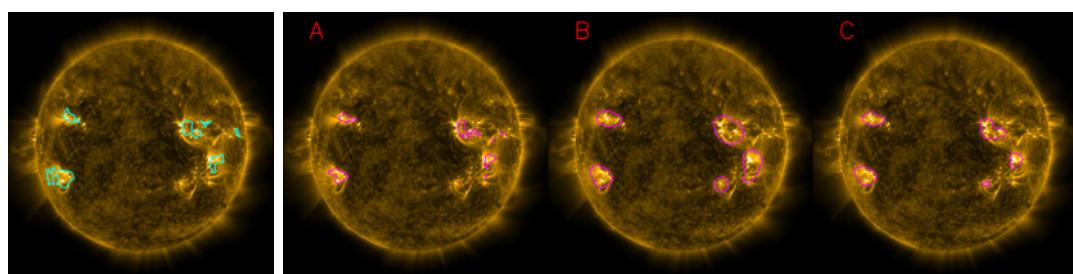
Obrázok 3 – 8 Ukážka segmentácií koronálnych dier

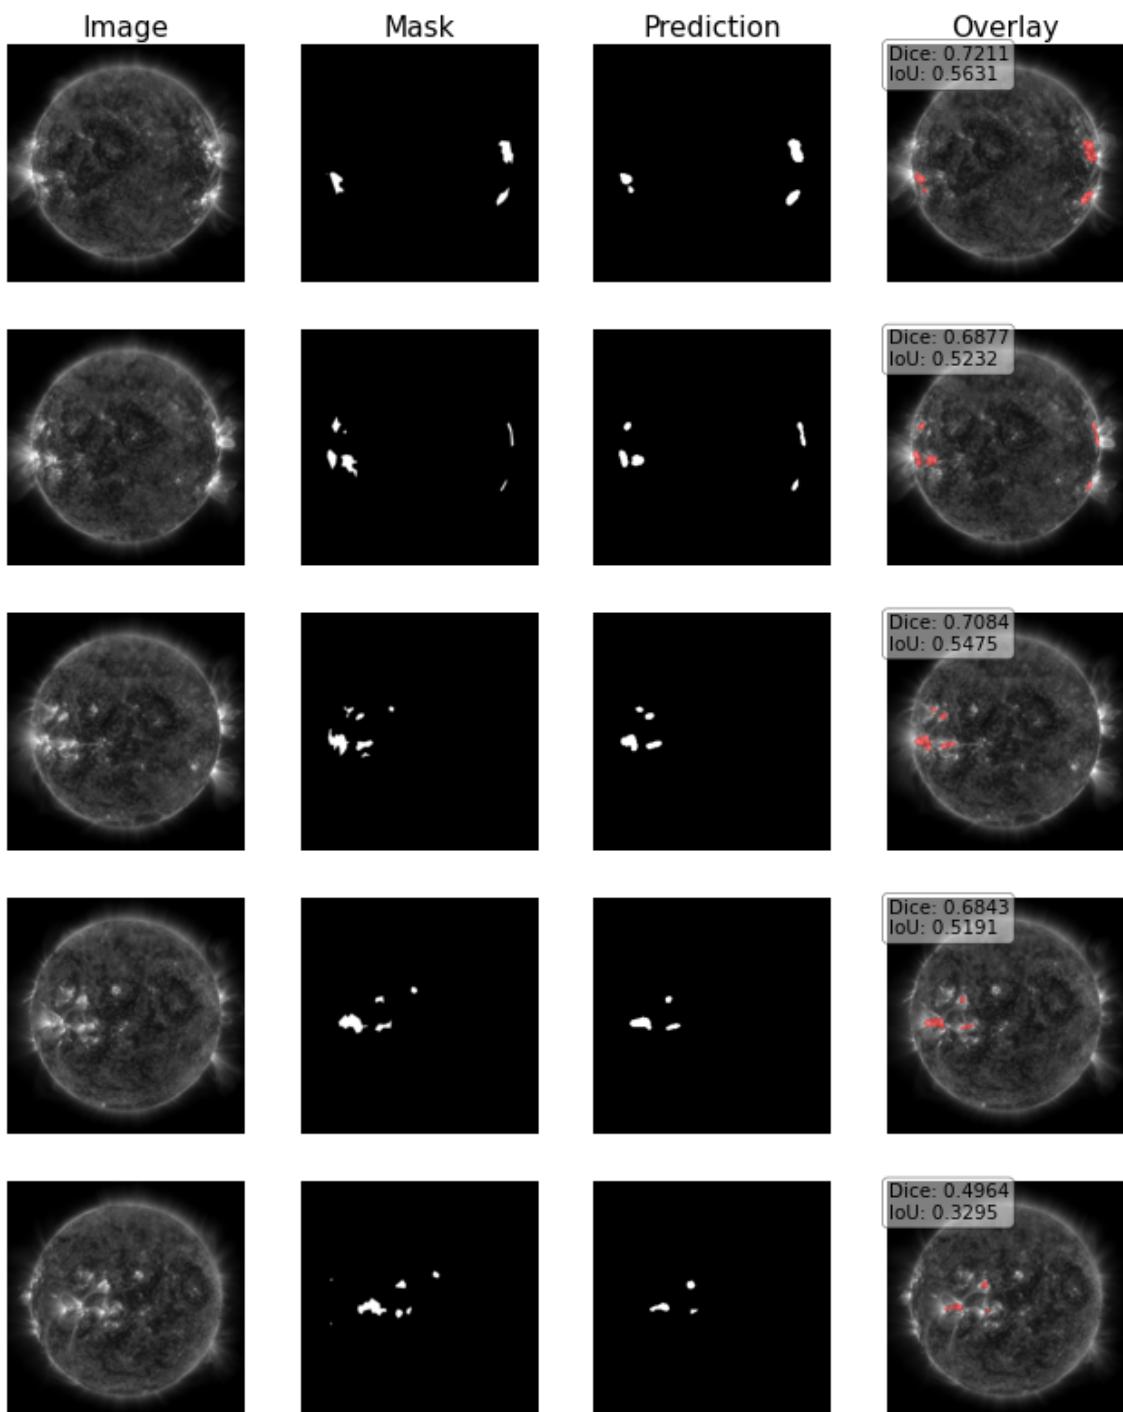
Na Obrázku 3 – 9 sa nachádza pôvodná SPoCA anotácia (vľavo) a písmenami označené sú označené segmentácie jednotlivých modelov (A - SPoCA, B - vlastné, C -

**Tabuľka 3 – 8** Výsledky modelov na testovacej množine

<b>Trénovacia množina</b>	<b>Testovacia množina</b>	<b>Dice</b>	<b>IoU</b>
Vlastné	360	0.44	0.28
SPoCA	360	0.68	0.51
SPoCA + vlastné	360	0.56	0.39

SPoCA + vlastné). SPoCA model segmentoval menšie oblasti, ale zato presnejšie než sú pôvodné anotácie zatial čo, model naučený na našich anotáciách (B) segmentoval AR dôkladnejšie resp. segmentoval väčšie oblasti. Ak sa pozrieme na Obrázok 3–9 tak môžeme vidieť, že model sa naučil aj „štýl“ anotácie a je vidieť, ktorý model bol trénovaný na anotáciach z algoritmu, a ktorý na anotáciach vytvorených človekom. Po bližšom posúdení výsledných snímkov sme sa rozhodli, že model naučený na spojenej dátovej množine (C) segmentuje aktívne oblasti najpresnejšie. Tento model segmentuje AR dostatočne presne a zároveň nevytvára až také oblúkovite oblasti, ktoré segmentujú aj časti slnka, ktoré už AR niesu.

**Obrázok 3 – 9** Porovnanie segmentácií aktívnych oblastí



Obrázok 3 – 10 Ukážka segmentácií aktívnych oblastí

## 4 Záver

Cieľom tejto práce bolo vytvoriť model hlbokej neurónovej siete určenej na segmentáciu koronálnych dier a aktívnych oblastí. V prvej časti práce sme sa venovali teoretickému prehľadu o využitých metódach a o samotnom hlbokom učení. Bližšie sme sa zamerali na konvolučné neuronové siete a ich architektúry využívané na segmentačné úlohy.

Ďalej sme sa pozreli na kozmické počasie, na jeho pôvod a možné dopady na život na Zemi. Zamerali sme sa na pôvodcu vesmírneho počasia, ktorým je Slnko, a na javy odohrávajúce sa v jeho atmosfére. Bližšie sme opísali dve solárne štruktúry, ktorými boli koronálne diery a aktívne oblasti, pričom tie mal za úlohu segmentovať náš model neurónovej siete. Pozreli sme sa bližšie na súčasne metódy detekcie slnečných štruktúr a na práce venujúce sa tejto problematike. Z týchto prác bola pre nás motiváciou práve práca Illarionov and Tlatov (2018), pričom sme sa snažili o prekonanie ich výsledkov, čo sa nám aj podarilo.

Počas vypracovávania tejto práce sa nám podarilo nájsť a zozbierať dátá koronálnych dier z niekoľkých zdrojov, vďaka čomu sme mohli preskúmať dátá o rôznej kvalite a počte a ich dopadu na výsledný segmentačný model. Zistili sme, že ak máme dátá dobrej kvality, napríklad anotácie vytvorené manuálne nie je ich potrebné až také veľké množstvo. Naopak ak máme dátá v horšej kvalite, ktorými boli v našom prípade anotácie SPoCA, tak ich potrebujeme veľmi veľa. Najlepší prípad však je ak máme dostatok dát vo veľmi dobrej kvalite, ako v prípade region growth anotácií. Vďaka týmto anotáciám, ktoré boli využité aj v práci Illarionov and Tlatov (2018) sa nám podarilo prekonáť ich výsledky o približne o 6%.

V prípade modelu trénovaného za účelom segmentácie aktívnych oblastí sme dosiahli najpresnejšie výsledky po zväčšení dátovej množiny spojením kvalitnejších manuálnych anotácií s horšími, ale zato početnejšími SPoCA anotáciami. Kedže sme nemali žiadne kvalitné anotácie aktívnych oblastí, ktoré by sme mohli využiť ako referenčné anotácie, pri vyhodnocovaní tohto modelu zamerali hlavne na vizuálne

vyhodnotenie modelu.

Segmentačné modely môžeme vyhodnotiť ako úspešne, avšak vždy sa nájde priesitor na zlepšenie alebo rozšírenie. Jedným z takýchto rozšírení môže byť vytvorenie jednotného modelu, ktorý by segmentoval aktívne oblasti, ale aj koronálne diery za použitia dvoch vstupných snímok v podobe 171Å a 193Å. Táto práca vznikla v spolupráci s RNDr. Šimonomom Mackovjakomom, PhD., ktorý pracuje na Oddeľení kozmickej fyziky ÚEF, SAV a spolu s ním, vedúcim tejto práce doc. Ing. Peterom Butkom, PhD. a konzultantkou Ing. Vierkou Maslej Krešňákovou sme pripravili odborný článok s cieľom jeho publikácie v karentovanom časopise Monthly Notices of the Royal Astronomical Society (skr. MNRAS).

## Literatúra

*Active Regions on the Sun* (2021). <https://scied.ucar.edu/sun-active-region>.

Aghdam, H. H. and Heravi, E. J. (2017). Guide to convolutional neural networks, *New York, NY: Springer* **10**: 978–973.

Ballard, D. H., Hinton, G. E. and Sejnowski, T. J. (1983). Parallel visual computation, *Nature* **306**(5938): 21–26.

Burrell, A. G., Halford, A., Klenzing, J., Stoneback, R. A., Morley, S. K., Annex, A. M., Laundal, K. M., Kellerman, A. C., Stansby, D. and Ma, J. (2018). Snakes on a spaceship—an overview of python in heliophysics, *Journal of Geophysical Research: Space Physics* **123**(12): 10,384–10,402.

Buslaev, A., Iglovikov, V. I., Khvedchenya, E., Parinov, A., Druzhinin, M. and Kalinin, A. A. (2020). Albumentations: Fast and flexible image augmentations, *Information* **11**(2).

Camporeale, E. (2019). The challenge of machine learning in space weather: Nowcasting and forecasting, *Space Weather* **17**(8): 1166–1207.

Canny, J. (1986). A computational approach to edge detection, *IEEE Transactions on pattern analysis and machine intelligence* (6): 679–698.

*Coronal Holes* (2021). <https://www.swpc.noaa.gov/phenomena/coronal-holes>.

De Boer, P.-T., Kroese, D. P., Mannor, S. and Rubinstein, R. Y. (2005). A tutorial on the cross-entropy method, *Annals of operations research* **134**(1): 19–67.

Dechter, R. (1986). Learning while searching in constraint-satisfaction-problems, *Proceedings of the Fifth AAAI National Conference on Artificial Intelligence*, AAAI'86, AAAI Press, p. 178–183.

Delouille, V., Hofmeister, S. J., Reiss, M. A., Mampaey, B., Temmer, M. and Veronig, A. (2018). Chapter 15 - coronal holes detection using supervised classification, *in* E. Camporeale, S. Wing and J. R. Johnson (eds), *Machine Learning Techniques for Space Weather*, Elsevier, pp. 365–395.

Delouille, V., Mampaey, B., Verbeeck, C. and de Visscher, R. (2012). The spocasuite: a software for extraction and tracking of active regions and coronal holes on euv images.

Duchi, J., Hazan, E. and Singer, Y. (2011). Adaptive subgradient methods for online learning and stochastic optimization., *Journal of machine learning research* **12**(7).

Garner, R. (2015). Solar storm and space weather - frequently asked questions.  
[https://www.nasa.gov/mission\\_pages/sunearth/spaceweather/index.htm](https://www.nasa.gov/mission_pages/sunearth/spaceweather/index.htm).

Garton, Tadhg M., Gallagher, Peter T. and Murray, Sophie A. (2018). Automated coronal hole identification via multi-thermal intensity segmentation, *J. Space Weather Space Clim.* **8**: A02.

Glorot, X., Bordes, A. and Bengio, Y. (2011). Deep sparse rectifier neural networks, *in* G. Gordon, D. Dunson and M. Dudík (eds), *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, Vol. 15 of *Proceedings of Machine Learning Research*, JMLR Workshop and Conference Proceedings, Fort Lauderdale, FL, USA, pp. 315–323.

Goodfellow, I., Bengio, Y. and Courville, A. (2016). *Deep Learning*, MIT Press.  
<http://www.deeplearningbook.org>

Han, J. and Moraga, C. (1995). The influence of the sigmoid function parameters on the speed of backpropagation learning, *in* J. Mira and F. Sandoval (eds), *From Natural to Artificial Neural Computation*, Springer Berlin Heidelberg, Berlin, Heidelberg, pp. 195–201.

- Hartigan, J. A. and Wong, M. A. (1979). Algorithm as 136: A k-means clustering algorithm, *Journal of the royal statistical society. series c (applied statistics)* **28**(1): 100–108.
- He, K., Zhang, X., Ren, S. and Sun, J. (2015). Delving deep into rectifiers: Surpassing human-level performance on imagenet classification, *CoRR abs/1502.01852*.
- Henney, C. and Harvey, J. (2005). Automated coronal hole detection using he i 1083 nm spectroheliograms and photospheric magnetograms, *arXiv: Astrophysics* .
- Hurlburt, N., Cheung, M., Schrijver, C., Chang, L., Freeland, S., Green, S., Heck, C., Jaffey, A., Kobashi, A., Schiff, D., Serafin, J., Seguin, R., Slater, G., Somani, A. and Timmons, R. (2012). Heliophysics Event Knowledgebase for the Solar Dynamics Observatory (SDO) and Beyond, **275**(1-2): 67–78.
- Illarionov, E. A. and Tlatov, A. G. (2018). Segmentation of coronal holes in solar disc images with a convolutional neural network, **481**(4): 5014–5021.
- Jatla, V., Pattichis, M. S. and Arge, C. N. (2020). Image processing methods for coronal hole segmentation, matching, and map classification, *IEEE Transactions on Image Processing* **29**: 1641–1653.
- Kiefer, J., Wolfowitz, J. et al. (1952). Stochastic estimation of the maximum of a regression function, *The Annals of Mathematical Statistics* **23**(3): 462–466.
- Kingma, D. P. and Ba, J. (2017). Adam: A method for stochastic optimization.
- Krista, L. D. and Gallagher, P. T. (2009). Automated coronal hole detection using local intensity thresholding techniques, *Solar Physics* **256**(1-2): 87–100.
- Krizhevsky, A., Sutskever, I. and Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks, *in* F. Pereira, C. J. C. Burges, L. Bottou and K. Q. Weinberger (eds), *Advances in Neural Information Processing Systems*, Vol. 25, Curran Associates, Inc.

- Lecun, Y., Bengio, Y. and Hinton, G. (2015). Deep learning, **521**(7553): 436–444.
- Legendre, P. and Legendre, L. (2012). *Numerical ecology*, Elsevier.
- Long, J., Shelhamer, E. and Darrell, T. (2014). Fully convolutional networks for semantic segmentation, *CoRR abs/1411.4038*.
- Maas, A. L., Hannun, A. Y. and Ng, A. Y. (2013). Rectifier nonlinearities improve neural network acoustic models, *Proc. icml*, Vol. 30, Citeseer, p. 3.
- McCulloch, W. S. and Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity, *The bulletin of mathematical biophysics* **5**(4): 115–133.
- Mikołajczyk, A. and Grochowski, M. (2018). Data augmentation for improving deep learning in image classification problem, *2018 international interdisciplinary PhD workshop (IIPhDW)*, IEEE, pp. 117–122.
- Murphy, K. P. (2012). *Machine learning: a probabilistic perspective*, MIT press.
- Nielsen, M. A. (2015). *Neural networks and deep learning*, Vol. 25, Determination press San Francisco, CA.
- Paralic, J. (2003). Objavovanie znalostí v databázach.
- Perez, L. and Wang, J. (2017). The effectiveness of data augmentation in image classification using deep learning, *arXiv preprint arXiv:1712.04621* .
- Pesnell, W. D., Thompson, B. J. and Chamberlin, P. (2011). The solar dynamics observatory (sdo), *The Solar Dynamics Observatory*, Springer, pp. 3–15.
- Price-Whelan, A. M., Sipőcz, B. M., Günther, H. M., Lim, P. L., Crawford, S. M., Conseil, S., Shupe, D. L., Craig, M. W., Dencheva, N. and et al. (2018). The astropy project: Building an open-science project and status of the v2.0 core package, *The Astronomical Journal* **156**(3): 123.

- Reed, R. D. and Marks, R. J. (1998). *Neural Smithing: Supervised Learning in Feedforward Artificial Neural Networks*, MIT Press, Cambridge, MA, USA.
- Rios, J., Alanis, A., Arana-Daniel, N., Lopez-Franco, C. and Sanchez, E. (2020). *Neural Networks Modeling and Control: Applications for Unknown Nonlinear Delayed Systems in Discrete Time*, Elsevier Science.
- Robbins, H. (2007). A stochastic approximation method, *Annals of Mathematical Statistics* **22**: 400–407.
- Robitaille, T. P., Tollerud, E. J., Greenfield, P., Droettboom, M., Bray, E., Aldcroft, T., Davis, M., Ginsburg, A., Price-Whelan, A. M. and et al. (2013). Astropy: A community python package for astronomy, *Astronomy & Astrophysics* **558**: A33.
- Ronneberger, O., Fischer, P. and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation, *International Conference on Medical image computing and computer-assisted intervention*, Springer, pp. 234–241.
- Rumelhart, D. E., Hinton, G. E. and Williams, R. J. (1985). Learning internal representations by error propagation, *Technical report*, California Univ San Diego La Jolla Inst for Cognitive Science.
- Rušin, V. and Rybanský, M. (1990). *Slnečná koróna*, Veda.
- Sahoo, P. K., Soltani, S. and Wong, A. K. (1988). A survey of thresholding techniques, *Computer vision, graphics, and image processing* **41**(2): 233–260.
- Schmidhuber, J. (2015). Deep Learning, *Scholarpedia* **10**(11): 32832.
- Schrijver, C. and Siscoe, G. (2010). *Heliophysics: Evolving Solar Activity and the Climates of Space and Earth*, Cambridge University Press.
- Schuh, M., Angryk, R. and Martens, P. (2016). A large-scale dataset of solar event reports from automated feature recognition modules, *Journal of Space Weather and Space Climate* **6**: A22.

Shorten, C. and Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning, *Journal of Big Data* **6**(1): 60.

Simpson, R., Page, K. R. and De Roure, D. (2014). Zooniverse: Observing the world's largest citizen science platform, *Proceedings of the 23rd International Conference on World Wide Web*, WWW '14 Companion, Association for Computing Machinery, New York, NY, USA, p. 1049–1054.

Sorensen, T. A. (1948). A method of establishing groups of equal amplitude in plant sociology based on similarity of species content and its application to analyses of the vegetation on danish commons, *Biol. Skr.* **5**: 1–34.

*Space Weather Prediction Center* (2021). <https://www.swpc.noaa.gov/>

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. and Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting, *Journal of Machine Learning Research* **15**(56): 1929–1958.

Svozil, D., Kvasnicka, V. and Pospichal, J. (1997). Introduction to multi-layer feed-forward neural networks, *Chemometrics and Intelligent Laboratory Systems* **39**(1): 43–62.

Taubman, D. S. and Marcellin, M. W. (2002). Jpeg2000: standard for interactive imaging, *Proceedings of the IEEE* **90**(8): 1336–1357.

The SunPy Community and Barnes, e. a. (2020). The sunpy project: Open source development and status of the version 1.0 core package, *The Astrophysical Journal* **890**: 68–.

Tieleman, T. and Hinton, G. (2012). Lecture 6.5—RmsProp: Divide the gradient by a running average of its recent magnitude, COURSERA: Neural Networks for Machine Learning.

Tlatov, A., Tavastsherna, K. and Vasil'eva, V. (2014). Coronal holes in solar cycles 21 to 23, *Solar Physics* **289**.

Tukiainen, M. (2019). Imagedataaugmentor, <https://github.com/mjkvaak/ImageDataAugmentor>

Urbán, F. (2020). Získanie anotácií v rámci zvolenej úlohy analýzy astronomických dát.

van Driel-Gesztelyi, L. and Green, L. M. (2015). Evolution of active regions, *Living Reviews in Solar Physics* **12**(1): 1–98.

Šarūnas Raudys (1998). Evolution and generalization of a single neurone: I. single-layer perceptron as seven statistical classifiers, *Neural Networks* **11**(2): 283–296.

## **Zoznam príloh**

**Príloha A** CD médium – záverečná práca v elektronickej podobe, príručky v elektronickej podobe a zdrojový kód.

**Príloha B** Používateľská príručka

**Príloha C** Systémová príručka