

**Technická univerzita v Košiciach**  
**Fakulta elektrotechniky a informatiky**

**Použitie hlbokého učenia pri spracovaní  
dát z kozmickej fyziky**

**Diplomová práca**

**2022**

**Bc. Matej Varga**

**Technická univerzita v Košiciach**  
**Fakulta elektrotechniky a informatiky**

**Použitie hlbokého učenia pri spracovaní  
dát z kozmickej fyziky**

**Diplomová práca**

Študijný program: Inteligentné systémy  
Študijný odbor: Informatika  
Školiace pracovisko: Katedra kybernetiky a umelej inteligencie (KKUI)  
Školiteľ: doc. Ing. Peter Butka, PhD.  
Konzultant: RNDr. Šimon Mackovjak, PhD.  
Ing. Viera Maslej Krešňáková, PhD.

**Košice 2022**

**Bc. Matej Varga**

## **Abstrakt v SJ**

V ionosfére môžu v dôsledku slnečnej aktivity vznikať nepravidelnosti v hustote elektrónov, ktoré sa nazývajú ionosférické scintilácie. Tieto spôsobujú amplitúdové a fázové fluktuácie rádiového signálu, čo ovplyvňuje najmä služby globálnych navigačných satelitných systémov. Scintilačné efekty sú najčastejšie v okolí rovníka a v polárnej oblasti. Práve pre vysoké zemepisné šírky existujú len veľmi málo spolahlivé predikčné modely. To je spôsobené najmä vysokou premenlivosťou ionosféry v čase a priestore. Cieľom práce je aplikovať metódy hlbokého učenia na predikciu ionosférických scintilácií v polárnej oblasti. Tento dátovo-riadený prístup využíva údaje z Kanadskej arktickej ionosférickej siete a ďalšie parametre týkajúce sa slnečného vetra, geomagnetickej aktivity a hustoty iónov v atmosfére.

## **Klúčové slová**

hlboké učenie, ionosférické scintilácie, predikcia, vesmírny výskum

## **Abstrakt v AJ**

In the ionosphere, solar activity can cause irregularities in electron densities, called ionospheric scintillations. These cause amplitude and phase fluctuations in the radio signal, which mainly affects the services of global navigation satellite systems. Scintillation effects are most common around the equator and in the polar region. There are no reliable prediction models for high latitudes. This is mainly due to the high variability of the ionosphere in both time and space. The aim of this work is to apply deep learning methods to predict ionospheric scintillations in the polar region. This data-driven approach uses data from the Canadian High Arctic Ionosphere Network and other parameters related to the solar wind, geomagnetic activity and ion density in the atmosphere.

## **Klúčové slová v AJ**

deep learning, ionospheric scintillations, prediction, space research

**TECHNICKÁ UNIVERZITA V KOŠICIACH**  
**FAKULTA ELEKTROTECHNIKY A INFORMATIKY**  
Katedra kybernetiky a umelej inteligencie

**ZADANIE  
DIPLOMOVEJ PRÁCE**

Študijný odbor: **Informatika**  
Študijný program: **Inteligentné systémy**

Názov práce:

**Použitie hlbokého učenia pri spracovaní dát z kozmickej fyziky**  
Deep learning in space physics

Študent: **Bc. Matej Varga**  
Školiteľ: **doc. Ing. Peter Butka, PhD.**  
Školiace pracovisko: **Katedra kybernetiky a umelej inteligencie**  
Konzultant práce: **RNDr. Šimon Mackovjak, PhD., Ing. Viera Maslej  
Krešňáková, PhD.**  
Pracovisko konzultanta: **Ústav experimentálnej fyziky SAV**

Pokyny na vypracovanie diplomovej práce:

1. Podať teoretický prehľad problematiky metód hlbokého učenia vhodných pre predikciu ionosférických scintilácií.
2. Predspracovať dostupné dáta pre analýzu ionosférických scintilácií, navrhnuť postupy pre ich predikciu pomocou zvolených metód hlbokého učenia.
3. Realizovať a vyhodnotiť navrhnuté postupy predikcie na zvolenej množine dát.
4. Vypracovať dokumentáciu podľa pokynov katedry a vedúceho práce.

Jazyk, v ktorom sa práca vypracuje: slovenský  
Termín pre odovzdanie práce: 22.04.2022  
Dátum zadania diplomovej práce: 29.10.2021



.....  
prof. Ing. Liberios Vokorokos, PhD.  
dekan fakulty

## **Čestné vyhlásenie**

Vyhlasujem, že som diplomovú prácu vypracoval samostatne s použitím uvedenej odbornej literatúry.

Košice 22. 4. 2022

.....

*Vlastnoručný podpis*

## **Poděkovanie**

Moje úprimné poděkování patří doc. Ing. Petrovi Butkovi, PhD., RNDr. Šimonevi Mackovjakovi, PhD. a Ing. Viere Maslej Krešňákové, PhD. za cenné odborné rady, připomienky, ochotu a trpezlivost pri vypracovaní diplomovej práce.

# **Obsah**

<b>Úvod</b>	<b>1</b>
<b>1 Úvod do problematiky</b>	<b>2</b>
1.1 Atmosféra Zeme . . . . .	2
1.2 Globálny navigačný satelitný systém . . . . .	6
1.3 Scintilácie . . . . .	10
<b>2 Hlboké neurónové siete</b>	<b>16</b>
2.1 Dopredné neurónové siete . . . . .	18
2.2 Aktivačné funkcie . . . . .	21
2.2.1 ReLU . . . . .	22
2.2.2 Aktivačné funkcie na výstupných vrstvách . . . . .	24
2.3 Chybové funkcie . . . . .	25
2.4 Optimalizácia . . . . .	26
2.4.1 Delta pravidlo . . . . .	27
2.4.2 Spätné šírenie chyby – Backpropagation . . . . .	28
2.4.3 Zostup gradientu . . . . .	30
2.4.4 Stochastický zostup gradientu . . . . .	31
2.4.5 Adam . . . . .	32
2.5 Regularizácia . . . . .	33
2.5.1 Dropout . . . . .	34
2.5.2 Predčasné zastavenie . . . . .	35
2.6 Konvolučné neurónové siete . . . . .	35
2.7 Rekurentné neurónové siete . . . . .	38
2.7.1 Long short-term memory . . . . .	38
<b>3 Predikcia ionosférických scintilácií</b>	<b>40</b>
3.1 Získavanie dát . . . . .	41
3.2 Pochopenie dát . . . . .	46

3.2.1	Korelačná analýza . . . . .	59
3.2.2	Významnosť príznakov . . . . .	62
3.3	Experimenty . . . . .	63
3.3.1	Dopredné neurónové siete . . . . .	65
3.3.2	Autoregresné modely . . . . .	70
3.3.3	Konvolučné a rekurentné modely . . . . .	73
3.4	Vyhodnotenie . . . . .	77
<b>4</b>	<b>Záver</b>	<b>79</b>
	<b>Zoznam príloh</b>	<b>88</b>

## Zoznam obrázkov

1 – 1	Vrstvy ionosféry počas noci a dňa. Zdroj: McElroy (2012) . . . . .	4
1 – 2	Porovnanie štandardných odchýlok šumu signálu v L1 a L2 ká- náloch GNSS prijímačov od rôznych výrobcov. Zdroj: Demyanov et al. (2020) . . . . .	10
1 – 3	Vizualizácia $S_4$ a $\sigma_\phi$ scintilácie. Zdroj: J.M.Sleewaegen, Belgium, Septentrio (n.d.) . . . . .	12
1 – 4	Mapa slabnutia scintilácií vo frekvenčnom pásme L ako funkcia magnetickej zemepisnej šírky a miestneho času na popoludňajšej pologuli. Zdroj: Basu et al. (1988) . . . . .	13
1 – 5	Globálna distribúcia silných $S_4$ scintilácií. Zdroj: Septentrio (n.d.) .	14
2 – 1	Rozdiel medzi tradičným strojovým učením a metódami hlbokého učenia. Zdroj: Odi and Nguyen (2018) . . . . .	17
2 – 2	Výkonnosť hlbokého učenia vzhľadom na množstvo trénovacích dát. Zdroj: Alom et al. (2019) . . . . .	18
2 – 3	Základný model perceptrónu. . . . .	19
2 – 4	Základný model doprednej neurónovej siete. . . . .	20
2 – 5	Porovnanie priebehu aktivačných funkcií ReLU (vľavo) a Leaky ReLU (vpravo). . . . .	24
2 – 6	Porovnanie MAE, MSE a RMSE na umelých dátach so šumom a bez šumu. Zdroj: Trevisan (2022) . . . . .	26
2 – 7	Porovnanie konvergencie do globálneho minima algoritmom zo- stupu gradientu a algoritmom stochastického zostupu gradientu. .	32
2 – 8	Porovnanie výstupov podučenej, korektne naučenej a preučenej ne- urónovej siete. . . . .	34
2 – 9	Vizualizácia deaktivácie neurónov pri pravdepodobnosti dropoutu 0,5. . . . .	34

2 – 10	Zobrazenie ideálneho momentu predčasného zastavenia trénovania neurónovej siete. . . . .	35
2 – 11	Princíp fungovania konvolučnej neurónovej siete: a. schéma konvolúcie na 1D dátach, b. znázornenie celej 1D konvolučnej neurónovej siete. Zdroj: Enciso and Zingaretti (2019) . . . . .	37
2 – 12	Blok LSTM a jeho časti. Zdroj: Smagulova and James (2020) . . .	39
3 – 1	Pozície GNSS prijímačov v rámci siete CHAIN. Zdroj: CHAIN (2022)	43
3 – 2	Ukážka nevyhovujúcich dát z troch GNSS staníc siete CHAIN. . .	47
3 – 3	Ukážka korektných dát z troch GNSS staníc siete CHAIN. . . . .	47
3 – 4	Grafické znázornenie GNSS prijímača komunikujúceho s viacerými satelitmi (červené čiary) a spôsob vytvorenia „superpozorovania“ (zelená šípka). Zdroj: McGranaghan et al. (2018) . . . . .	54
3 – 5	Grafické znázornenie maximálnej horizontálnej dohľadnosti GNSS prijímača. Zdroj: McGranaghan et al. (2018) . . . . .	54
3 – 6	Vizualizácia stĺpca $\sigma_\phi$ pre GNSS prijímač zo stanice Churchill. . .	55
3 – 7	Vizualizácia individuálnej $\sigma_\phi$ scintilácie. . . . .	58
3 – 8	Vizualizácia individuálnej $\sigma_\phi$ scintilácie. . . . .	59
3 – 9	Analýza významnosti príznakov pre predikciu jednotlivých stĺpcov $\sigma_\phi$ o 1, 5, 15 a 60 minút dopredu. . . . .	63
3 – 10	Vizualizácia rozdelenia datasetu na trénovaciu množinu (modrá), validačnú množinu (oranžová) a testovaciu množinu (zelená). . . .	64
3 – 11	Ukážka konfúznej matice a jej rozdelenia. . . . .	65
3 – 12	Predikcia hodnoty $\sigma_\phi$ 1 minútu dopredu pomocou klasickej doprednej neurónovej siete. . . . .	68
3 – 13	Predikcia hodnoty $\sigma_\phi$ 15 minút dopredu pomocou klasickej doprednej neurónovej siete. . . . .	70
3 – 14	Predikcia hodnoty $\sigma_\phi$ 60 minút dopredu pomocou klasickej doprednej neurónovej siete. . . . .	71

3 – 15	Predikcia hodnoty $\sigma_\phi$ 1 minútu dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou. . . . .	74
3 – 16	Predikcia hodnoty $\sigma_\phi$ 5 minút dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou. . . . .	75
3 – 17	Predikcia hodnoty $\sigma_\phi$ 15 minút dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou. . . . .	76
3 – 18	Predikcia hodnoty $\sigma_\phi$ 60 minút dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou. . . . .	77

## Zoznam tabuliek

3–1 Korelačná analýza stĺpca $\sigma_\phi$ a od neho odvodenými stĺpcami $\sigma_\phi$ posunutými o 1, 5, 15 a 60 minút dopredu. . . . .	62
3–2 Konfúzna matica predikcie hodnoty $\sigma_\phi$ o 1 minútu dopredu pomocou klasickej doprednej neurónovej siete. . . . .	68
3–3 Konfúzna matica predikcie hodnoty $\sigma_\phi$ o 5 minútu dopredu pomocou klasickej doprednej neurónovej siete. . . . .	69
3–4 Konfúzna matica predikcie hodnoty $\sigma_\phi$ o 1 minútu dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou. . . . .	74
3–5 Konfúzna matica predikcie hodnoty $\sigma_\phi$ o hodinu dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou. . . . .	77

## **Zoznam symbolov a skratiek**

**Adam** Algoritmus adaptívnej optimalizácie momenta

**CHAIN** Canadian High Arctic Ionospheric Network

**COSPAR** Committee on Space Research

**GNSS** Global Navigation Satellite System

**GPS** Global Positioning System

**IRI** International Reference Ionosphere

**LSTM** Long short-term memory

**MAE** Mean Absolute Error

**MSE** Mean Square Error

**NASA** National Aeronautics and Space Administration

**PLL** Phase-Lock Loop

**ReLU** Rectified Linear Unit

**RMS Prop** Root Mean Square Propagation

**TEC** Total Electron Content

## Úvod

Navigačné satelitné systémy slúžia na určovanie polohy na Zemi a v istých prípadoch, ako napríklad v letectve, námorníctve alebo záchrane osôb, môže byť ich dostupnosť životne dôležitá. Nepravidelnosti v ionosfére však môžu spôsobiť prerušenie týchto služieb pre určité lokality a spôsobiť tak vážne problémy. Ak by existoval systém, ktorý by dokázal tieto atmosférické javy v čase predpovedať, bolo by sa možné na výpadok navigácie pripraviť a urobiť patričné kroky, aby bol ich negatívny dopad čo najmenší.

Rozvoj strojového učenia, a v poslednej dobe najmä hlbokého učenia, umožňuje nachádzať riešenia na problémy, ktoré boli doteraz príliš náročné, či už z pohľadu komplexnosti alebo masívneho množstva údajov. Ukázalo sa, že tieto algoritmy môžu fungovať napríklad v klasifikácii obrázkov, spracovaní prirodzeného jazyka, medicíne alebo napomáhať vedeckému výskumu.

V súčasnosti predstavuje strojové učenie pri výskume kozmického počasia výzvu aj príležitosť zároveň. Výzvou je, že súčasná revolúcia v dátovej vede nebola v tejto oblasti úplne prijatá, možno preto, že vesmírni fyzici zostávajú skeptickí voči výsledkom a možnostiam týchto metód. Príležitosť spočíva najmä vo vytváraní predkčných modelov počasia vo vesmíre, ktoré môžu v reálnom čase reagovať na zmeny a poskytnúť tak včasné varovanie pre sately na obežnej dráhe a pre aplikácie na nich závislé, že môže dôjsť k ich výpadku.

V našej práci preskúmame možnosti využitia dostupných dát a algoritmov hlbokého učenia na tvorbu modelov schopných predikcie nepravidelností v ionosfére. V prvej kapitole popíšeme dynamické prostredie zemskej atmosféry a proces vzniku týchto nepravidelností, druhá kapitola obsahuje teóriu hlbokého učenia a v tretej kapitole sa zameriame na analýzu dát, tvorbu samotných predkčných modelov a ich vyhodnotenie.

# 1 Úvod do problematiky

## 1.1 Atmosféra Zeme

Atmosféra Zeme je dynamické prostredie. V minulosti ľudstvo nevenovalo veľkú pozornosť procesom, ktoré prebiehajú v jej vrchných vrstvách, nakoľko priamo neovplyňovali náš každodenný život. S rozvojom techniky sa to ale zmenilo. Boli objavené nové závislosti, vplyvy, ale aj možnosti, ako vlastnosti atmosféry využiť vo svoj prospech. Najmä z komunikačného hľadiska je pre nás najdôležitejšia ionizovaná vrstva atmosféry, ktorá je odrazovou plochou pre určité frekvencie rádiových vĺn, vďaka čomu je možné signál šíriť aj na vzdialenosť niekoľko 100 kilometrov. Tá istá vrstva hrá úlohu aj pri prenose signálu z navigačných satelitov, lenže tentoraz negatívnu. Ak je príliš turbulentná, tak ovplyvňuje komunikačné spojenie a v extrémnych prípadoch môže dôjsť až k úplnému výpadku. Takéto ionosférické poruchy nazývame scintilácie. Budeme sa im venovať neskôr v tejto kapitole a v rámci našej práce sa ich budeme snažiť predikovať.

Atmosféra sa delí na 5 hlavných a niekoľko vedľajších vrstiev. Medzi tie hlavné patrí od najnižšej po najvyššiu: troposféra, stratosféra, mezosféra, termosféra a exosféra. Medzi ich charakteristiky patrí (Buis, 2019):

- **Troposféra:** Siahá od zemského povrchu približne do výšky 12 km (nižšie v oblasti pólov a vyššie v okolí rovníka). V tejto tenkej vrstve sa nachádzajú všetky živé organizmy a obsahuje takmer 99% všetkej vodnej pary a aerosólov (drobné pevné alebo kvapalné častice rozptýlené vo vzduchu) v rámci atmosféry. Je to najhustejšia vrstva, nakoľko je stlačená váhou zvyšných vrstiev nad ňou. Odohráva sa tu väčšina počasia a teploty s výškou klesajú.
- **Stratosféra:** Nachádza sa vo výške medzi 12 km a 50 km nad povrhom. Väčšiu časť (približne 15-40 km) tvorí ozónová vrstva. Práve kvôli pohlcovaniu UV žiarenia zo Slnka v tejto vrstve teplota s výškou stúpa.

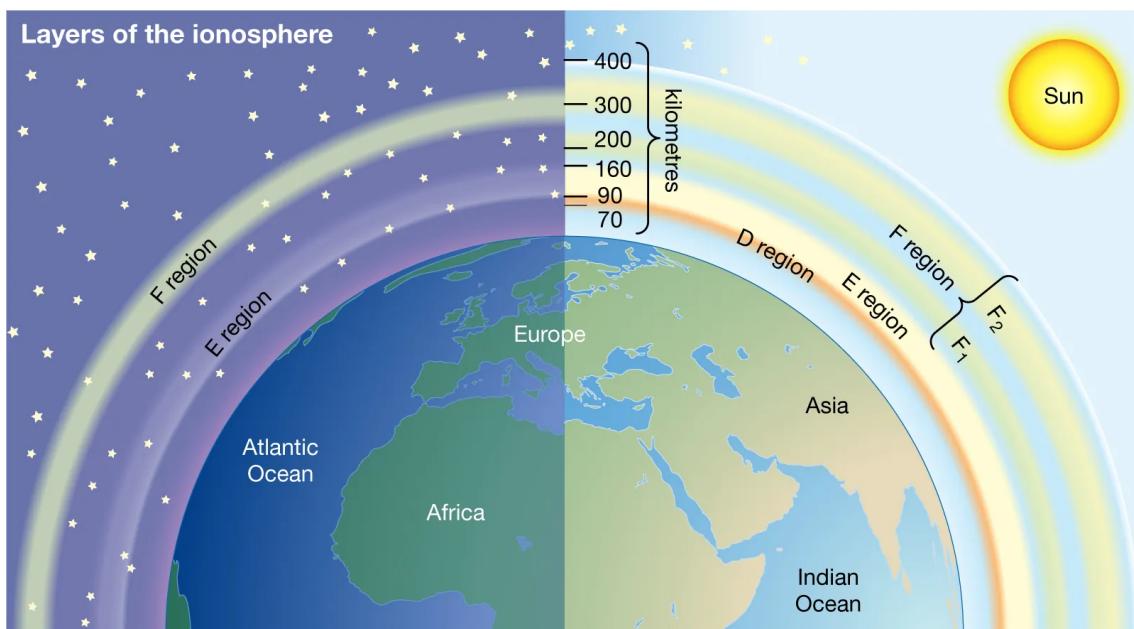
- **Mezosféra:** Pokrýva výšku od 50 km do 80 km. V tejto časti atmosféry teplota znova s výškou klesá a v horných častiach dosahuje hodnoty okolo -85°C. Zaujímavá je taktiež tým, že v nej zhorí väčšina meteorov, ktoré majú kolízny kurz so Zemou.
- **Termosféra:** Patrí jej výška 80 km až 700 km nad povrchom. Vďaka veľmi malej hustote molekúl teplota opäť priamo úmerne stúpa s výškou. Nad polárnymi oblastami môže v tejto vrstve vzniknúť polárna žiara (*aurora borealis/aurora australis*), ak dostatočné množstvo nabitých častíc slnečného vetra vstúpi do atmosféry.
- **Exosféra:** Najvyššia časť zemskej atmosféry. Molekulárna hustota je tu taká nízka, že sa táto vrstva už nespráva ako plyn a častice často uniknú do voľného vesmíru. Dá sa povedať, že jej horná časť splýva s otvoreným kozmickým priestorom. Kvôli tomu je vo veľkej miere ovplyvnená aj kozmickým počasím.

Takéto „tradičné“ rozdelenie na vrstvy podľa správania sa teploty je len jedným z možných rozdelení. Ďalším, pre nás vhodnejším rozdelením, je podľa množstva voľných elektrónov. Hlavným zdrojom vzniku týchto nabitých častíc je Röntgenové a UV žiarenie zo Slnka, ktoré počas dňa neustále dopadá na zemskú atmosféru, kde je absorbované. Tento proces absorpcie energie sa nazýva fotodisociácia. Molekuly kyslíka  $O_2$  disociujú na atomárny kyslík, ktorého tvorba je klúčová, keďže je hlavnou zložkou fotoionizačného mechanizmu, ktorý tvorí ionosféru. Regióny s vyššou koncentráciou takýchto iónov vznikajú v rôznych výškach nad povrhom a súhranne sa nazývajú ionosféra. Z hľadiska predchádzajúceho rozdelenia to zahŕňa termosféru a časti mezosféry a exosféry.

Ionosféra sa delí na 3 základné vrstvy a to D, E a F vrstvu. Tieto nemajú ostré hranice a výšky v ktorých sa nachádzajú sa menia počas dňa a aj v závislosti od ročného obdobia (McElroy, 2012):

- **D vrstva:** je to najnižšia časť ionosféry, začína približne vo výške 60 km až 70 km nad povrhom a siaha do 90 km,
- **E vrstva:** jej začiatok sa pohybuje v rozsahu od 90 km do 100 km a rozprestiera sa až do výšky medzi 120 km a 150 km,
- **F vrstva:** nachádza sa v termosfére od 150 km a siaha niekedy až do výšky 500 km nad zemský povrch.

Výška, percentuálne zastúpenie iónov a vôbec existencia týchto vrstiev sa s časom mení (vid. Obrázok 1 – 1). V noci je ionosféra úplne iná ako cez deň. Počas dňa Slnko neustále dodáva energiu potrebnú na ionizáciu atómov a molekúl a preto počet iónov cez deň rastie, aj keď neustále prebieha aj ich rekombinácia. V noci naopak absentuje zdroj energie, kvôli čomu rekombináčny proces prevažuje nad ionizačným a počet iónov klesá. Po väčšinu nocí D vrstva zaniká úplne a E vrstva sa oslabí na takmer zanedbateľnú úroveň. Najvyššia F vrstva, na rozdiel od nižších, pretrváva aj počas noci, ale je homogénnejšia, keďže počas dňa sa často rozdelí na F<sub>1</sub> a F<sub>2</sub> vrstvy.



Obrázok 1 – 1 Vrstvy ionosféry počas noci a dňa. Zdroj: McElroy (2012)

Pred objavením satelitnej komunikácie bolo bežné, že operátori rádiových komunikačných systémov využívali ionosféru na rozšírenie dosahu signálu. Rádiové vlny sa všeobecne šíria lineárne, takže pre prijímanie signálu bolo potrebné mať vysielač v zornom poli, a teda šírenie signálu bolo limitované kopcovitosťou krajiny a zakrivením Zeme. Niektoré frekvencie rádiového signálu sa však odrážajú od určitých vrstiev nabitých častic v ionosfére. To bolo využívané na zväčšenie územia pokrytého signálom, aj keď sa stávalo, že vznikali hluché miesta, ktoré boli ďaleko pre priamy signál, ale príliš blízko pre odrazený. Rádioví operátori preto museli bráť do úvahy neustále zmeny v ionosfére, najmä posun a zánik niektorých vrstiev počas noci (Bora, 2017).

Ionosféra môže okrem odrazu rádiového signálu niektoré frekvencie aj absorbovať alebo oslabiť. Keďže globálne navigačné satelitné systémy tiež využívajú rádiové signály na komunikáciu s pozemnými zariadeniami, tak ich presnosť určenia polohy môže byť značne znížená, ak dôjde k narušeniu signálu v dôsledku prechodu cez ionosféru. Rovnako satelitná aj pozemná rádiová komunikácia môže byť oslabená alebo úplne prerušená, ak dôjde k absorpcii frekvencií, ktoré daný vysielač využíva (UCAR, 2014).

Tieto, pre komunikáciu nežiadúce javy, ale môžu byť využité aj na výskum ionosféry, ktorá by bola inak neviditeľná. Na tento účel sa využívajú rôzne rádiové antény a radarové systémy umiestnené na zemi, ale aj vo vesmíre. Niektoré antény sú určené na prijímanie rádiových vĺn priamo generovaných v ionosfére, iné využívajú aktívny spôsob vyslania signálu cez ionosféru a prijímač následne meria nakoľko boli tieto signály oslabené, prípadne presmerované.

Okrem denných zmien v ionosfére sú známe aj dlho trvajúce závislosti v tomto komplexnom a dynamickom systéme. Rôzne zemepisné šírky sa otepľujú a ochladzujú v závislosti od ročného obdobia, keďže intenzita slnečného žiarenia sa tiež mení z miesta na miesto kvôli nakloneniu zemskej osi. Podobné zmeny sa dejú aj

v ionosfére, nakoľko miesto najvyššieho dopadu Röntgenových a UV lúčov sa posúva po zemeguli vzhľadom na ročné obdobie. Zmeny v chemickom zložení atmosféry taktiež hrajú rolu a ovplyvňujú rýchlosť rekombinácie, a teda úbytok voľných iónov z atmosféry (UCAR, 2014).

Silný vplyv na variácie ionosféry má aj 11-ročný slnečný cyklus. Rozdiel v jasnosti Slnka medzi minimom a maximom slnečného cyklu sa vo viditeľnom spektre mení o menej ako desatinu percenta, preto pre nás nie je badateľný. Množstvo UV a Röntgenového žiarenia sa však mení aj o faktor 10 a niekedy aj viac (UCAR, 2014). Keďže tieto spektrá priamo ovplyvňujú tvorbu iónov, tak dochádza aj k veľkým zmenám v hustote nabitých častíc. Nehovoriac o tom, že silné geomagnetické búrky a výrony koronálnej hmoty zo Slnka tiež spôsobujú značné jednorazové narušenia ionosféry.

## 1.2 Globálny navigačný satelitný systém

Satelitná navigácia využíva systém satelitov na poskytovanie presnej polohy v priestore. Umožňuje aj malým elektronickým zariadeniam určiť ich zemepisnú šírku, dĺžku a nadmorskú výšku s presnosťou na metre až centimetre s využitím rádiového signálu. Celý systém pracuje na princípe trilaterácie.

Satelit vyšle signál, ktorý obsahuje orbitálne dáta (na výpočet polohy satelitu na orbite) a presný čas, kedy bol signál vyslaný. Na tento účel sa využívajú atómové hodiny, aby sa zabezpečila synchronizácia všetkých satelitov v konštelácii. Tento úkon komplikuje aj fakt, vyplývajúci zo všeobecnej teórie relativity, ktorá okrem iného hovorí, že čas v blízkosti hmotných telies plynne pomalšie. Z tohto dôvodu je potrebné zavádzat časové korekcie, aby sa zachovala maximálna možná presnosť. Atómové hodiny v satelitoch sa oproti tým na Zemi posunú dopredu o 38 mikrosekúnd denne (Clifford, 2022).

Prijímač na zemi porovná časy zakódované v signáli z minimálne štyroch rôznych satelitov a pomocou nich vypočíta vzdialenosť ku každému z nich. Inými slovami, pre každý satelit sa vypočíta gula, na ktorej povrchu sa v nejakom bode nachádza prijímač. Prienikom týchto gúľ sa určí poloha na Zemi. Ak by mal prijímač atómové hodiny, štvrtý satelit by nebol potrebný, nakoľko prienikom troch sfér by vznikli len dva priesečníky v priestore, pričom jeden z nich by bol vo vesmíre a ten nemusíme uvažovať. V praxi je však potrebný aj štvrtý satelit na korekciu časového biasu (Dasgupta, 2016).

Globálne navigačné systémy vysielajú v L-pásme v piatich určených frekvenciách pomenovaných L1 až L5. Frekvencie L1 (1575.42 MHz) a L2 (1227.60 MHz) sú používané všetkými navigačnými satelitmi. L3 (1381.05 MHz) je vyčlenená na komunikáciu s pozemnými stanicami a slúži na detekciu jadrových výbuchov. L5 (1176.45 MHz) v prípade potreby slúži pre aplikácie na záchrannu životov v letectve a poskytuje zvýšenú presnosť a dostupnosť. Nakoniec frekvencia L4 je využívaná na ionosférické korekcie, a teda môže byť využitá aj na výskum ionosféry (Al-Bayari and Sadoun, 2007).

Prvý a najstarší navigačný systém je GPS (Parkinson, 1974) vyvinutý v Spojených štátach amerických. Spustený bol v roku 1978 a pozostáva z 32 satelitov, ktoré obiehajú na strednej orbite vo výške 20 180 km. Obežné dráhy boli volené tak, aby bolo pre každé miesto na Zemi neustále viditeľných 6 satelitov. Spočiatku bol využívaný len na vojenské účely, ale v polovici 80-tych rokov bol s obmedzenou dostupnosťou a presnosťou len 100 metrov sprístupnený aj verejnosti (Dasgupta, 2016).

Ďalším podobným a nemenej významným systémom je európsky Galileo (Benedicto et al., 2000). Tento projekt bol založený Európskou vesmírnou agentúrou a je to prvý program, ktorý sa od začiatku snaží o rozvoj najmä v civilnom smere na rozdiel od zvyšných, ktoré sú stále pod vojenskou kontrolou. Existuje však ustanovenie

o výhradnom vojenskom využití v prípade vojny. Poskytuje aj najlepšiu presnosť, ktorá sa pohybuje na úrovni 1 metra pre bežných užívateľov a do 1 centimetra pre platiacich užívateľov. Galileo je taktiež jedinečný v poskytovaní funkcie globálneho pátrania a záchrany, pretože okrem prenosu tiesňového signálu z núdzových majákov do koordinačného centra, poskytuje aj spätné spojenie na potvrdenie prijatia signálu a spustenia záchrannej akcie (Dasgupta, 2016).

V prípade rýchlo pohybujúcich sa prijímačov, akými sú napríklad lietadlá, dochádza k určitej odchýlke aj vplyvom rýchlej relatívnej zmeny polohy. Naviac, rádiový signál sa prechodom cez ionosféru trochu spomalí v závislosti od uhlu, ktorý zvierajú satelit voči prijímaču, pretože čím je satelit bližšie k horizontu, tým väčšia je vzdialenosť, ktorú musí signál prejsť cez ionosféru. Satelitné prijímače sa tieto odchýlky snažia redukovať kombináciou signálov z väčšieho počtu satelitov a využívaním techník ako Kalmanov filter (Kalman, 1960) na výpočet presnej polohy aj z takýchto zašumiených a neustále sa meniacich dát.

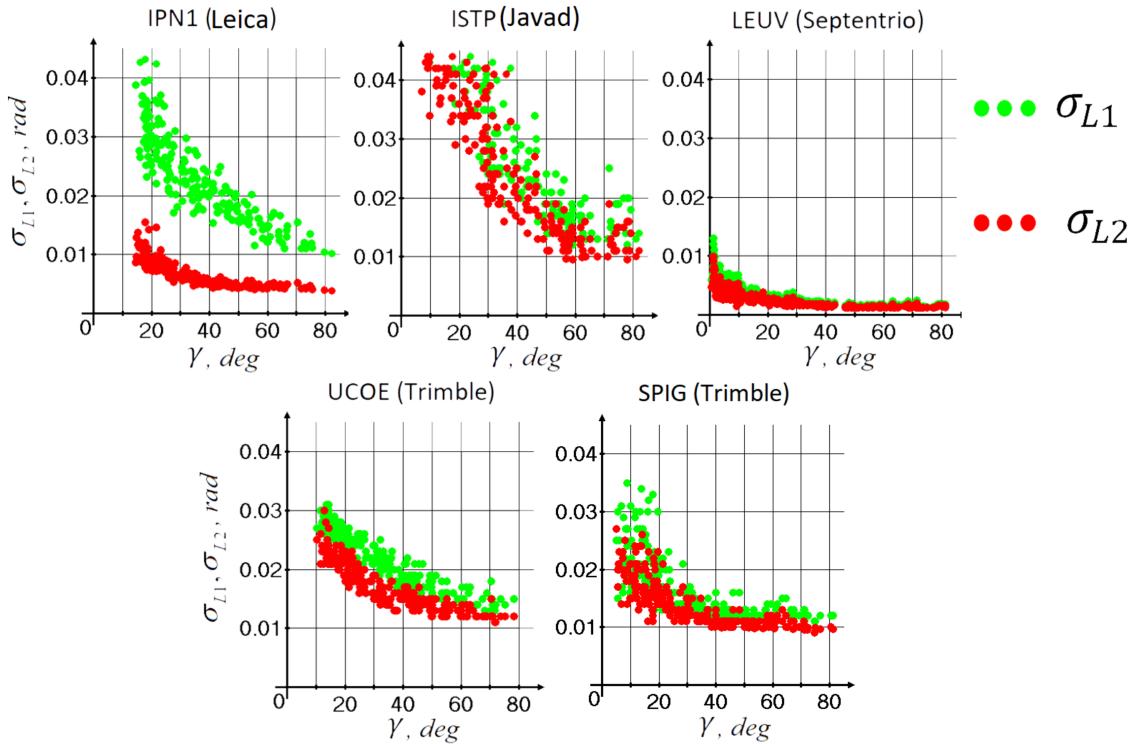
Na výskum ionosféry ale nestačí klasický prijímač, aký má väčšina ľudí zabudovaný vo svojich smartfónoch. Je potrebný špeciálny hardvér a softvér. V súčasnosti je možné dosiahnuť časové rozlíšenie výstupných údajov z prijímača až 100 Hz. Takéto vysoké rozlíšenie umožňuje detegovať aj malé ionosférické turbulencie a môže tak pomôcť vedcom zodpovedať na otázku, aká vzorkovacia frekvencia tvorí hranicu medzi meraním slabej ionosférickej turbulencie a neinformatívnym šumom. Zároveň interné spracovanie signálu vo vnútri prijímača zohráva rovnako klúčovú úlohu ako časové rozlíšenie dát. Bohužiaľ interná funkcionality takéhoto prijímača je pre výskumníkov do istej miery „čiernou skrinkou“, nakolko existuje viacero konkurenčných výrobcov, ktorí svoje know-how nezverejňujú. Viaceré štúdie ukázali, že indexy TEC (*Total electron content*) sa môžu do značnej miery lísiť, ak sú odvodene z rôznych typov/modelov zariadení. Takéto štúdie sú napríklad Yang and Liu (2016), McCaffrey et al. (2017) alebo Bolla and Borre (2018).

Niektoré typy prijímačov používajú L1 podpornú techniku, na sledovanie fázy signálu na L2 frekvencii. Z technického hľadiska a z hľadiska presnosti má tento spôsob značnú výhodu v tom, že ak dôjde k strate signálu na L2 alebo L5 kanáloch, je možné rýchlo spojenie obnoviť pomocou L1 kanála. Naopak, nie je vhodné používať túto techniku pri štúdiách ionosféry, nakoľko umelé prepojenia medzi fázovými a frekvenčnými meraniami na kanáloch L1, L2 alebo L5 majú za následok, že ionosférické vplyvy na prenášaný signál nie sú korektne namerané. Atmosféra vplyvá na rádiový signál zo satelitov rôzne, v závislosti od frekvencie prenášaného signálu. Napríklad spojenie v L2 kanáli môže byť vplyvom ionosféry prerušené, ale pre signál s frekvenciou L1 môže byť ionosféra nadalej prieplastná.

Zvyčajne výskumníci nevedia, či je takáto podporná technika implementovaná v prijímači, z ktorého majú dátu, prípadne v niektorých prípadoch zdieľaných datasetov nevedia ani akým prijímačom boli dátu namerané. V takomto prípade je podľa štúdie od Demyanov et al. (2020) možné využiť korelačný koeficient medzi zložkami fázového šumu v kanáloch L1 a L2 na odhalenie tohto spôsobu merania dát. Vysoká miera korelácie naznačuje použitie tejto podpornej techniky, zatiaľ čo nízka korelácia znamená, že signály sú merané oddelené, čo je pre výskum ionosféry lepšie.

Obrázok 1–2 zobrazuje štandardnú odchýlku šumov v L1 a L2 frekvenciách v závislosti od uhla satelitu nad obzorom. Je vidieť, že hodnoty sa líšia pre rôzne typy prijímačov, ale zvýšený šum pre sately blízko horizontu je badateľný vo všetkých prípadoch. Je to spôsobené viaccestnými dopadmi, vplyvom atmosféry a tiež slabnutím signálu pri nízkych uhloch. Najlepšie z tohto porovnania vyšiel model Septentrio, ktorý mal najnižší šum v oboch frekvenciách.

Poznatky o technike spracovania signálu jednotlivými prijímačmi sú potrebné pre správnu interpretáciu jemných fluktuácií a pre analýzu ionosférických scintilácií (viď. kapitola 1.3). Podľa výsledkov štúdie od Demyanov et al. (2020) sa podporná



**Obrázok 1 – 2** Porovnanie štandardných odchýlok šumu signálu v L1 a L2 kanáloch GNSS prijímačov od rôznych výrobcov. Zdroj: Demyanov et al. (2020)

technika pomocou L1 signálu používa v prijímačoch Septentrio, Javad a Trimble. Ale aj napriek tomu sa vzhľadom na celkové porovnanie na výskum ionosféry za najvhodnejší považuje prijímač Septentrio, keďže práve pre tento typ boli zaznamenané najmenšie hodnoty šumu v oboch skúmaných frekvenciach. Tieto skutočnosti je potrebné zohľadniť pri voľbe a príprave datasetu.

### 1.3 Scintilácie

Scintilácie sú rýchle fluktuácie fázy alebo amplitúdy prijímaného elektromagnetickeho signálu. Vznikajú v dôsledku prechodu signálu ionosférrou. Zmeny v hustote plazmy v ionosfére spôsobujú lom signálu a na prijímači sa tak tvoria konštrukčné a deštrukčné interferencie. Prvé scintilácie boli pozorované už na prirodzenom rádiiovom signále z vesmíru pri pozorovaní hviezd (Little and Maxwell, 1952).

Závažnosť scintilácie sa popisuje dvoma indexami,  $S_4$  a  $\sigma_\phi$ , ktoré kvantifikujú kolísanie amplitúdy a fázy prijímaného signálu.

$$S_4 = \sqrt{\frac{\langle SI^2 \rangle - \langle SI \rangle^2}{\langle SI \rangle^2}} \quad (1.1)$$

je normalizovaná štandardná odchýlka intenzity signálu (*SI – signal intensity*) za určitý časový interval, zvyčajne 60 sekúnd.

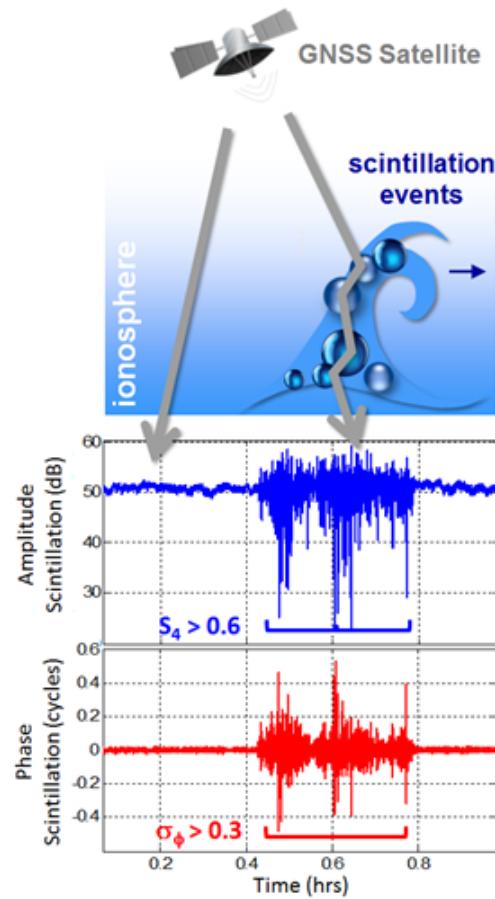
$$\sigma_\phi = \sqrt{\langle \phi^2 \rangle - \langle \phi \rangle^2} \quad (1.2)$$

je štandardná odchýlka fázy filtrovaného signálu, zbaveného trendu. Filtrovanie a zbavenie signálu trendu si vyžaduje spracovanie vzoriek o rovnakej frekvencii a s posunom fázy o  $\frac{\pi}{2}$ . Tieto postupy sú implementované v GNSS prijímačoch.

Presná odozva navigačných prijímačov na scintiláciu do určitej miery závisí aj od interného spracovania signálu prijímačom. Scintilácia môže inhibovať proces záchytenia signálu prijímačom. Aby bol signál prijatý, je potrebné, aby jeho sila bola nad určitou stanovenou hranicou šumu. Scintilácia primárne ovplyvňuje sledovaciu fázu funkcionality prijímača (Datta-Barua et al., 2021).

Frekvencie v L-pásme, v ktorom vysielajú GNSS satelity, sú dostatočne silné na to, aby prešli cez ionosféru, ale nie dosť silné, aby ňou neboli ovplyvnené. Prijímače pri výpočte polohy rátajú s prirodzeným vplyvom kľudnej ionosféry, keď sú ionizované častice homogénne rozložené v priestore, ale problém nastáva pri nepravidelnostiach a lokálnych zhusteniach (viď. Obrázok 1 – 3). Tieto viac-menej náhodné scintilácie nie je bez dostatočne presnej predikcie možné brať do úvahy.

Už aj malé oblasti nepravidelnosti počtu voľných elektrónov v ionosfére, s priesitorovou rozlohou od niekoľkých metrov do niekoľko kilometrov, môžu spôsobiť refrakčné a difrakčné efekty v prijímanom navigačnom signáli. Refrakcia mení smer a rýchlosť šírenia elektromagnetickej vlny a difrakcia spôsobuje priesitorové výkyvy amplitúdy a fázy prijímaného signálu. Pohyb ionosférických nepravidelností vzhľa-



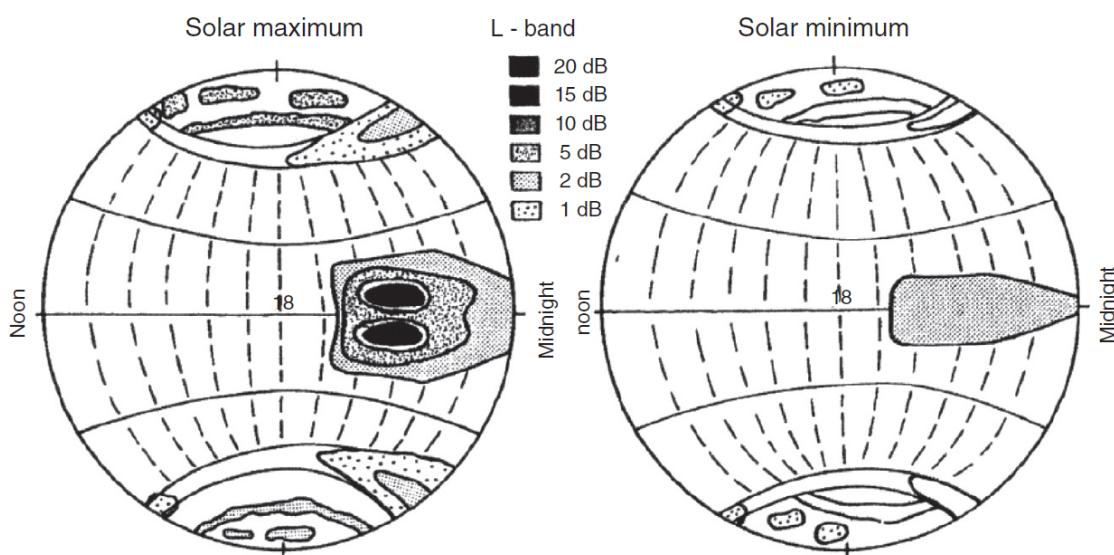
**Obrázok 1 – 3** Vizualizácia  $S_4$  a  $\sigma_\phi$  scintilácie. Zdroj: J.M.Sleewaegen, Belgium, Septentrio (n.d.)

dom na dráhu signálu premieňa tieto priestorové výkyvy na časové výkyvy, ktoré sú v dôsledku difrakčných efektov pozorované ako scintilácie v prijímanom signáli (Rao et al., 2006).

Silná amplitúdová scintilácia môže spôsobiť, že sila prijímaného signálu klesne pod prahový limit a dôjde k strate spojenia. Silná fázová scintilácia môže spôsobiť Dopplerov posun vo frekvencii prijímaného signálu a prekročiť tak šírku vlnového pásma fázového závesu (*PLL- phase-lock loop*), čo vedie k strate fázového spojenia na prijímači (Rao et al., 2006).

Ionosférické scintilácie nevznikajú na Zemi rovnomerne, ako môžeme vidieť na Obrázku 1 – 4. Zvyčajne sa formujú v oblasti pólov alebo v oblasti rovníka. Stredné ze-

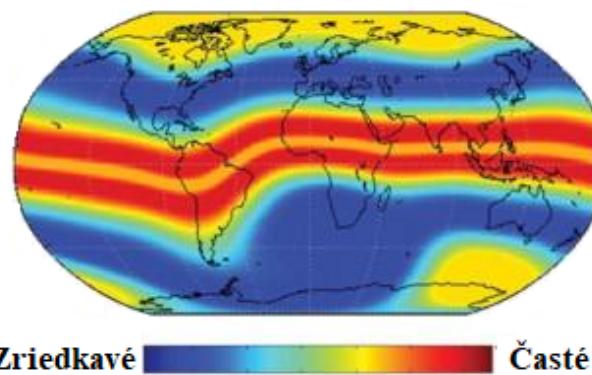
mepisné šírky sú scintiláciami ovplyvnené len minimálne (viď. Obrázok 1–5). Inak povedané, ak aj vzniknú, tak sú zanedbateľné. Scintilácie sú najsilnejšie v nízkych zemepisných šírkach, v blízkosti rovníkovej anomálie ( $\pm 10^\circ$  geomagnetickej zemepisnej šírky), najmä počas súmraku a po západe slnka. Vo vysokých zemepisných šírkach sú o čosi slabšie a vyskytujú sa najmä v zóne výskytu polárnej žiary ( $65^\circ$ - $75^\circ$  geomagnetickej zemepisnej šírky) a v oblasti polárnej čiapky ( $>75^\circ$  geomagnetickej zemepisnej šírky), v podobe menších oblastí zhustenej plazmy, ktoré vznikajú v dôsledku pôsobenia častíc slnečného vetra odklonených zemským magnetickým polom (Pi et al., 2002).



**Obrázok 1–4** Mapa slabnutia scintilácií vo frekvenčnom pásme L ako funkcia magnetickej zemepisnej šírky a miestneho času na popoludňajšej pologuli. Zdroj: Basu et al. (1988)

To že sú scintilácie silnejšie v nižších zemepisných šírkach je spôsobené tým, že morfológia rovníkovej ionosféry je tu značne odlišná od tej v ostatných zemepisných šírkach. Magnetické pole je tu takmer paralelné so zemským povrchom (Rao et al., 2006). V okolí rovníka je spôsob vzniku scintilácií nasledovný. Počas dňa v nadmorských výškach ionosférickej F vrstvy sú vertikálne polarizované elektrické polia skratované cez vodivú E vrstvu, osvetlenú slnkom, na sever a juh od

magnetického rovníka. Avšak po západe slnka sa východné elektrické pole zosilní po znížení vodivosti vo vrstve E. Toto zosilnenie zdvihne F vrstvu do vysokých nadmorských výšok, kde sú rýchlosťi rekombinácie iónov nízke a vytvoria sa priaznivé podmienky na vznik nepravidelností v spodných častiach F vrstvy. Vytvárajú sa ostré gradienty hustoty iónov smerom nahor, v dôsledku rýchlej rekombinácie iónov v nižších vrstvách, keďže na nich prestáva pôsobiť hlavný zdroj ionizácie, slnečné žiarenie. Nelineárny vývoj týchto nepravidelností vedie k tvorbe bublín chudobných na plazmu. Strmé gradienty najmä na okrajoch takýchto bublín vytvárajú scintilácie. Typické sú amplitúdové scintilácie s vysokou intenzitou, ktoré ale aj rýchlo slabnú. Najčastejšie sú pred polnocou, kedy sa môže vyskytnúť séria bublín v rámci jednej oblasti. Výskyt takýchto bublín je silno závislý od ročného obdobia a úrovne slnečnej aktivity.



**Obrázok 1 – 5** Globálna distribúcia silných  $S_4$  scintilácií. Zdroj: Septentrio (n.d.)

V polárnych oblastiach je spôsob tvorby scintilácií odlišný. Počas polárnej žiary sú typické silné fázové a slabé amplitúdové scintilácie. Tzv. aurorálne scintilácie sú najčastejšie pozorované v lokálnych nočných hodinách. Sú výsledkom zrýchlenia nabitych častíc pozdĺž siločiar zemského magnetického poľa a ich vstupom do ionosféry. Tieto časticie sa zrážajú približne vo výške 110 km, čo vedie k zvýšenej ionizácii, optickým a UV emisiám (*aurora borealis/australis*). Tieto nepravidelnosti v hustote voľných elektrónov vedú k scintilačným efektom (Aarons, 1982). Polárny ovál sa po-

čas takýchto udalostí môže rozšíriť o niekoľko stupňov smerom k rovníku a pokryť tak časti severnej Európy a severné časti USA.

Beach (2006) poznamenal, že pre GNSS signál, ktorého vysielač je v pohybe, môže byť použitie  $\sigma_\phi$  ako metriky pre scintilácie problematické. Taktiež Forte and Radicella (2002) si všimli tento nedostatok najmä pre ionosférické nepravidelnosti vo vysokých zemepisných šírkach, v ktorých môže rýchlosť pohybu tejto nepravidelnosti dosiahnuť až 1000 m/s. V týchto prípadoch môže rýchlosť relatívny pohyb satelitov vzhľadom na prijímač a ionosférickej nepravidelnosti vzhľadom na prijímač posunúť zdanlivé scintilácie do vyššieho rozsahu frekvencií, ktoré môžu byť odfiltrované, ak sa pri filtrovaní používa pevná medzná frekvencia (často 0,1 Hz).

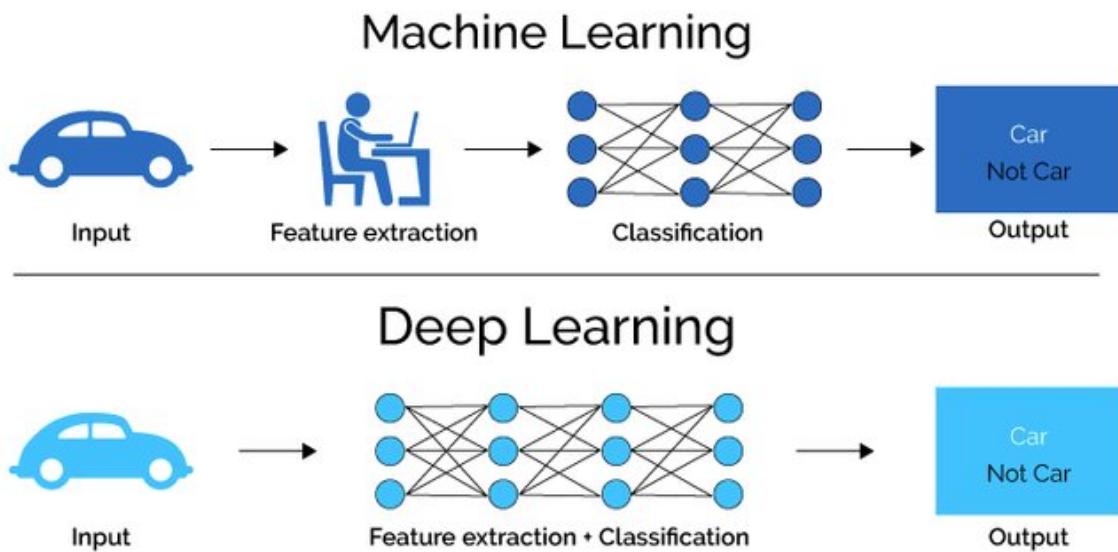
Bolo dokázané, že scintilácie závisia od lokálneho času, ročného obdobia, úrovne geomagnetickej aktivity a 11-ročného slnečného cyklu. Naviac, scintilácie sú aj frekvenčne závislé, čiže ich vplyv nemôže byť eliminovaný napríklad kombinovaním pozorovateľných signálov s inými frekvenciami (Koulouri et al., 2020).

## 2 Hlboké neurónové siete

Metódy strojového učenia umožnili rozvoj mnohých oblastí moderného života. V súčasnosti sa s nimi stretávame vo webových prehľadávačoch, sociálnych sieťach, pri nákupe v e-shopoch, ale aj pri rozpoznávaní reči a tváre v smartfónoch, či dokonca vo vede (Mackovjak et al., 2021; Camporeale, 2019). Čoraz viac z týchto aplikácií využíva triedu techník nazývaných hlboké učenie. V niektorých prípadoch je ich použitie dokonca klúčové, ako napríklad v autonómnych vozidlách, v ktorých bežné metódy strojového učenia nepostačujú (Tian et al., 2018).

Je to aj preto, že konvenčné techniky strojového učenia majú obmedzenú schopnosť spracovať dátu v ich surovej podobe. Tvorba systému na rozpoznávanie vzorov v rámci počítačového videnia si vyžadovala starostlivý návrh a prípravu extraktora príznakov, ktorý by nespracované údaje, ako napríklad hodnoty pixelov obrázka, dokázal transformovať na vhodnejšiu reprezentáciu. Až tieto predpripravené príznaky boli následne použité na učenie subsystému, najčastejšie klasifikátora, ktorý už dokázal rozpoznať vzory a vedel obrázky priradiť k ich zodpovedajúcim triedam (LeCun et al., 2015). Takýto postup bol časovo náročný a naviac človek často nevedel navrhnúť optimálny extraktor. V rámci hlbokého učenia tento krok odpadá a výber, respektíve tvorbu, vhodných príznakov má na starosti samotný algoritmus v procese učenia (vid. Obrázok 2–1).

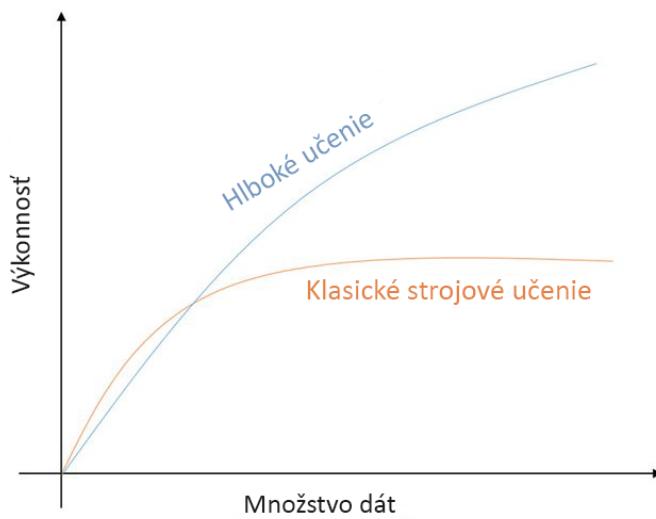
Tento postup so sebou prináša mnohé zlepšenia, ale aj určité prekážky. Hlavnou výhodou je, že príznaky sú automaticky vyvodené a optimálne nastavené na želaný výstup. Algoritmy umelej inteligencie dokážu počas prehľadávania mnohorozmerného priestoru objaviť súvislosti, ktoré si človek v úlohe extraktora nemusí všimnúť alebo ich nemusí považovať za dôležité (Moshayedi et al., 2022). Ďalšou výhodou je možnosť použitia rovnakej hlbokej neurónovej siete na rôzne problémy a aplikácie (*transfer learning*). Najmä v úlohách počítačového videnia stačí v mnohých prípadoch váhy len dotrénovať a nie je potrebné učiť celú sieť od nuly. Takáto fle-



**Obrázok 2 – 1** Rozdiel medzi tradičným strojovým učením a metódami hlbokého učenia. Zdroj: Odi and Nguyen (2018)

xibilnosť je výhodná aj do budúcnosti, pretože je pravdepodobné, že jednoduchým dotrénovaním bude možné riešiť aj nové problémy, ktoré sa ešte len objavia.

Na druhú stranu existujú aj prekážky pri použití týchto techník. Jednou z nevýhod je, že potrebujú veľké množstvo rôznorodých dát, aby ich úspešnosť bola lepšia ako pri klasických metódach strojového učenia. Keď je však dát dostatok, dokážu tradičné metódy v úspešnosti prekonať (vid. Obrázok 2 – 2). S malým datasetom je pre siet ľahšie odlišiť podstatné príznaky od tých nepodstatných a zbaviť sa šumu. Druhou nevýhodou je komplexnosť modelov, kvôli ktorej je ich učenie časovo aj výpočtovo náročné (Moshayedi et al., 2022). S tým súvisí aj absencia postupu, ako zvoliť najvhodnejšiu topológiu, trénovaciu metódu a iné parametre, aby sa dosiahlo čo najlepší možný výsledok. Pri hlbokom učení existuje nespočetné množstvo úprav, ktoré sa dajú na sieti urobiť a bez úplného natrénovalenia a vyhodnotenia úspešnosti siete nie je možné povedať, či budú zmeny prospešné alebo nie.



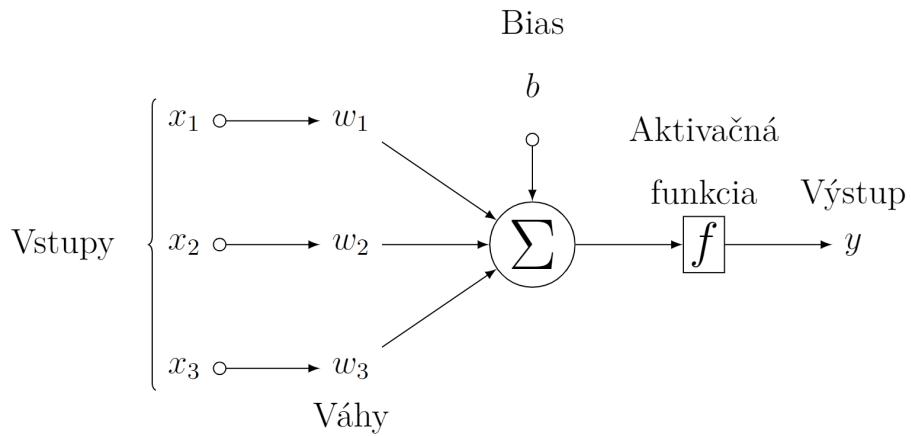
**Obrázok 2 – 2** Výkonnosť hlbokého učenia vzhľadom na množstvo trénovacích dát. Zdroj: Alom et al. (2019)

## 2.1 Dopredné neurónové siete

Pre popísanie hlbokých neurónových sietí je najprv potrebné spomenúť princípy fungovania klasických neurónových sietí a zadefinovať základnú jednotku, z ktorých sú zložené, teda umelý neurón.

Umelý neurón je matematická funkcia, ktorá je inšpirovaná biologickými neurónmi. Ako prví s týmto konceptom prišli McCulloch and Pitts (1943), keď vytvorili prahovú logickú jednotku (*Threshold logic unit*). S priekopníckym vylepšením tejto jednotky neskôr prišiel Rosenblatt (1957), ktorý vyvinul perceptrón. Ten je určený na dichotomickú klasifikáciu a je špeciálnym prípadom formálneho neurónu. Časti perceptrónu sú zobrazené na Obrázku 2 – 3.

Vstup do neurónu je funkciou vstupných signálov a k nim prislúchajúcich synaptických váh. Vo väčšine prípadov je to skalárny súčin vektora vstupov a vektora váh. Z pohľadu informácie sú synaptické váhy najdôležitejšie, keďže v neurónových sietach sú znalosti uchovávané práve v nich. Na tento skalárny súčin je následne aplikovaná aktivačná funkcia a bias. Úlohou aktivačnej funkcie je určiť, či má byť neurón



**Obrázok 2 – 3** Základný model perceptrónu.

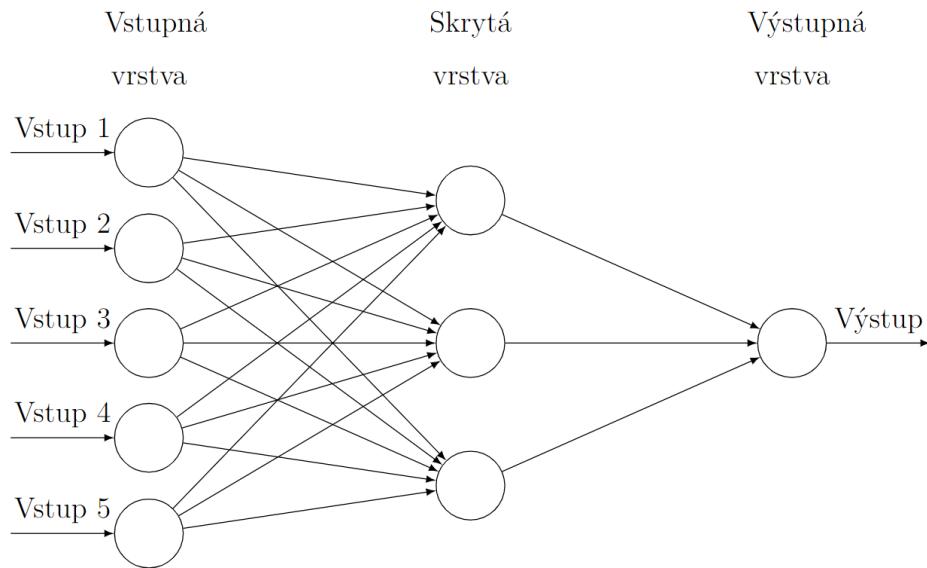
aktivovaný alebo nie a aká hodnota bude z daného neurónu poslaná na nasledujúce vrstvy. Existuje viacero rôznych typov aktivačných funkcií, ktorým sa budeme venovať neskôr. Poslednou časťou je bias, ktorý slúži na posunutie aktivačnej funkcie. Je to vlastne konštanta, ktorej úloha je analogická s úlohou konštanty v lineárnej funkcií. Matematická rovnica popisujúca umelý neurón je:

$$y = f(\bar{w} \cdot \bar{x}) = f\left(\sum_{i=1}^{n+1} w_i x_i\right) + b, \quad (2.1)$$

kde  $y$  je výstup,  $f$  je aktivačná funkcia,  $\bar{w}$  je vektor váh,  $\bar{x}$  je vektor vstupov a  $b$  je bias.

Takýto jeden neurón ale dokáže riešiť iba problémy, ktoré sú lineárne separovateľné. A keďže druhá väčšina problémov z reálneho sveta je nelineárnych, tak je potrebné prepájať tieto umelé neuróny do vrstiev a vrstvy do sietí. Vďaka tomuto vrstveniu sú neurónové siete univerzálnymi aproximátormi funkcií. Existujú tri typy vrstiev z hľadiska ich umiestnenia v topológii siete: vstupná vrstva, výstupná vrstva a skryté vrstvy ako vidíme na Obrázku 2–4. Cez vstupnú vrstvu sa do siete privádzajú hodnoty jednotlivých príznakov, preto je tu počet neurónov rovný počtu príznakov v dátach. Výstupná vrstva poskytuje výsledok modelu pre konkrétné príklady. Počet neurónov na tejto vrstve závisí od charakteru riešeného

problému. Pre regresiu alebo binárnu klasifikáciu postačuje jeden výstupný neurón, pre viac triednu klasifikáciu potrebujeme len jednu vrstvu výstupných neurónov, kolko máme tried. Skrytými vrstvami nazývame všetky vrstvy, ktoré sú medzi vstupnou a výstupnou vrstvou. Ich počet sa označuje pojmom hĺbka modelu. Podľa univerzálnej aproximačnej teórie stačí už jedna skrytá vrstva na aproximáciu ľubovoľnej funkcie. Nehovorí však, kolko neurónov by takáto vrstva mala mať (Goodfellow et al., 2016). O dopredných neurónových sieťach je lepšie uvažovať ako o strojoch na approximáciu funkcií, ktoré sú navrhnuté tak, aby dosiahli štatistické zovšeobecnenie, než ako o modeloch priamej funkcionality mozgu, aj keď čerpajú nejaké poznatky z toho, čo o fungovaní mozgu vieme (Goodfellow et al., 2016).



**Obrázok 2–4** Základný model doprednej neurónovej siete.

Vzhľadom na univerzálnu aproximačnú teóriu je na mieste otázka, či vôbec potrebujeme neurónové siete s veľkým počtom skrytých vrstiev. Odpoveď je, že zatiaľ áno. Hlavným problémom plytkých a širokých sietí (siete s malým počtom skrytých vrstiev, ale s veľkým počtom skrytých neurónov) je to, že sú súce veľmi dobré v pamätaní si znalostí, ale nie sú také dobré v zovšeobecňovaní. To znamená, že sa dokážu naučiť správny výstup aj pre veľké datasety, ale pri nových príkladoch,

na ktorých učenie neprebiehalo, ich výkonnosť klesá, a to nie je výhodné pre zložité problémy z reálneho sveta. V tomto sú hlboké siete oveľa lepšie, pretože veľký počet skrytých vrstiev im umožňuje naučiť sa z príznakov rôzne úrovne abstrakcie (Janiesch et al., 2021). Napríklad pri klasifikácii obrázkov sa na prvých vrstvách rozpoznajú rôzne hrany, rohy a oblúky. V nasledujúcich sa z týchto jednoduchých elementov vytvoria tvary ako štvorce, obdĺžníky alebo trojuholníky a v posledných vrstvách sa sieť naučí rozpoznávať konkrétné objekty. Hlboké siete sa dokážu naučiť rozpoznávať prechodné príznaky medzi surovými dátami a komplexnými príznakmi, čo ich robí oveľa lepšími v zovšeobecňovaní (Janiesch et al., 2021).

Avšak tvrdenie, že nám stačí jediná skrytá vrstva aj na riešenie zložitých problémov je tiež pravdivé. Ba and Caruana (2014) poskytli empirický dôkaz, že plytké neurónové siete sú schopné naučiť sa approximovať rovnaké funkcie ako hlboké siete. Problém je v tom, že plytké siete sa to nedokážu naučiť priamo zo surových dát, ale sú schopné naučiť sa napodobniť hlboký model. V praxi je preto potrebné najprv naučiť hlbokú neurónovú sieť na riešenie komplexného problému a následne je možné naučiť plytkú sieť, aby napodobňovala hlbokú s rovnakou presnosťou. Z toho vyplýva, že teoreticky je možné používať len plytké siete, ale zatiaľ nemáme učiace algoritmy, ktoré by boli schopné takéto siete natrénovali zo surových dát.

## 2.2 Aktivačné funkcie

Ako sme spomínali vyššie, v neurónových sieťach sú aktivačné funkcie zodpovedné za transformáciu sumy váženého vstupu do neurónu na výstup neurónu. Na to aby boli neurónové siete schopné riešiť netriviálne (nelineárne) problémy, je potrebné, aby mali aktivačné funkcie na skrytých vrstvách nelineárne vlastnosti (Jain, 2019). Tieto nelinearity umožňujú neurónovej sieti vytvoriť nelineárnu rozhodovaciú hranicu prostredníctvom kombinácií váh a vstupov. Existuje množstvo aktivačných funkcií s rôznymi vlastnosťami a keďže ich použitie je závislé od riešeného problému

---

a topológie siete, tak sa budeme venovať teoretickému opisu len tých, ktoré v našej práci používame.

### 2.2.1 ReLU

Aktivačná funkcia ReLU (*rectified linear activation function*) je po častiach lineárna, ale ako celok nelineárna funkcia, ktorá kladný vstup posiela priamo na výstup a pri záporných vstupoch vracia nulu (Nair and Hinton, 2010). Používa sa v mnohých typoch neurónových sietí, keďže model sa s ňou ľahšie trénuje a často dosahuje aj lepšie výsledky (Goodfellow et al., 2016). Uplatnenie našla najmä v hlbokých sietach, v ktorých použitie klasických aktivačných funkcií, akými sú sigmoidálna funkcia alebo hyperbolický tangens nie je možné, kvôli tzv. problému miznúceho gradientu. Ten nastáva v prípade, keď sa v procese úpravy váh späťne šíri veľa hodnôt blízkych nule, čo spôsobí, že vrstvy na začiatku siete sa učia pomaly alebo sa dokonca neučia vôbec. Preto je v sietach s veľkým počtom skrytých vrstiev potrebné, aby aktivačná funkcia mala vlastnosti lineárnej funkcie, ale zároveň bola nelineárna, aby siet dokázala zachytiť komplexné vzťahy v dátach. Obe tieto vlastnosti splňa práve ReLU funkcia, ktorá je vyjadrená ako:

$$f(x) = \max(0, x) \quad (2.2)$$

Dá sa povedať, že osvojenie si tejto funkcie v rámci komunity strojového učenia umožnilo naštartovať vývoj veľmi hlbokých sietí (Goodfellow et al., 2016). Tradične sa v oblasti neurónových sietí využívalo aktivačným funkciám, ktoré nie sú plne differencovateľné v celom svojom definičnom obore, čo možno oneskorilo prijatie takýchto typov funkcií. Technicky nemôžeme vypočítať deriváciu pri nulovom vstupe, takže sa môže zdáť, že nie je možné použiť učiace algoritmy založené na gradientovom zo-stupe, ale v praxi tieto algoritmy stále fungujú dostatočne dobre (Goodfellow et al., 2016).

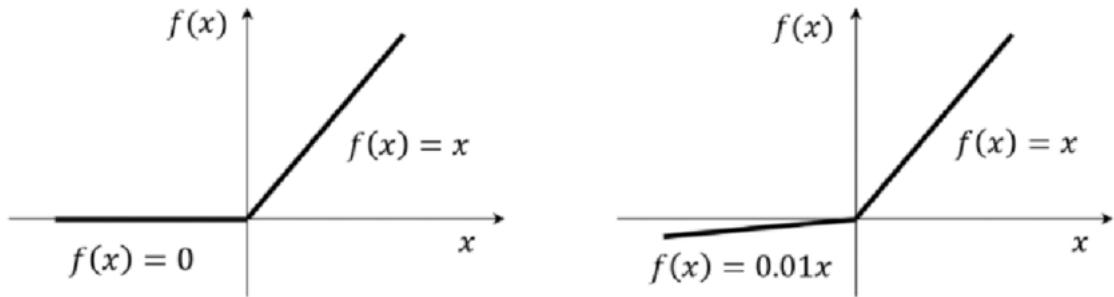
Hlavné výhody tejto aktivačnej funkcie vyzdvihol už Glorot et al. (2011):

- Jednoduchosť výpočtu – je triviálna na implementáciu a nie je výpočtovo náročná, nakoľko netreba počítať exponencionálne funkcie ako napríklad pri sigmoide.
- Riedka reprezentácia – to znamená, že nulové a záporné vstupy môžu viesť k nulovej hodnote na skrytom neuróne. A keďže to nie je hodnota v blízkom okolí nuly, ale presne nula, tak sa zrýchli výpočet a zjednoduší model, keďže takéto neuróny neprispievajú k výstupu siete. Taktiež sa zníži šum, ktorý je bežne do siete vnášaný nevýraznými neurónmi s hodnotami blízkymi nule.
- Lineárne vlastnosti – vo všeobecnosti je ľahšie optimalizovať neurónovú sieť, ak je jej správanie lineárne alebo takmer lineárne. Vďaka tomu sa siete trénované s ReLU aktivačnou funkciou takmer úplne vyhýbajú miznúcemu gradientu, pretože gradienty zostávajú úmerné aktiváciám neurónov.

ReLU má však aj isté obmedzenia. Najväčšou nevýhodou je, že môže nastat prípad, kedy veľké zmeny vo váhach spôsobia, že vážený súčet vstupov do aktivačnej funkcie bude vždy záporný. Vtedy bude výstup z takéhoto neurónu vždy generovať nulu a tým pádom sa nebudú adaptovať ani k nemu smerujúce váhy. Tento problém sa zvykne označovať ako „*dying ReLU*“. Ak sa to stane veľkému počtu neurónov, tak výkonnosť siete klesá. Existujú ale viaceré modifikácie, ktoré sa s tým vedia do určitej miery vysporiadáť. Jednou z nich je Leaky ReLU (viď. Obrázok 2–5), ktorá ako výstup produkuje malé záporné hodnoty, keď je vstup do funkcie menší ako nula a je daná vzťahom:

$$f(x) = \max(\alpha x, x), \quad (2.3)$$

kde  $\alpha$  je nastavená na 0,01. Ak nastavíme  $\alpha$  ako hyperparameter alebo zvolíme inú hodnotu ako 0,01, tak hovoríme o Parametric ReLU.



Obrázok 2 – 5 Porovnanie priebehu aktivačných funkcií ReLU (vľavo) a Leaky ReLU (vpravo).

### 2.2.2 Aktivačné funkcie na výstupných vrstvách

Zatial čo výber aktivačnej funkcie na skrytých vrstvách určuje ako dobre sa model dokáže učiť, aktivačná funkcia na výstupnej vrstve udáva aký typ predikcií (alebo klasifikácií) môže model robiť a preto jej výber závisí od riešenej úlohy (Goodfellow et al., 2016). V našej práci používame na výstupnej vrstve nasledujúce dve aktivačné funkcie:

- Lineárna aktivačná funkcia – taktiež nazývaná výstup bez aktivácie, nakoľko sa suma vážených vstupov nijako nemení a je priamo posielaná na výstup. Táto aktivačná funkcia sa využíva pri regresnom probléme. Jej zápis je nasledovný:

$$f(x) = x \quad (2.4)$$

- Sigmoidálna aktivačná funkcia – nazývaná tiež logistická funkcia. Funkcia ako vstup berie hocjaké reálne číslo a výstup je v rozsahu 0 - 1. Predpis sigmoidálnej funkcie je:

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.5)$$

Na výstupnej vrstve sa používa najmä pre binárnu klasifikáciu, pri ktorej hodnoty väčšie ako 0,5 patria do jednej triedy a menšie hodnoty do druhej triedy.

Vďaka svojmu rozsahu je ju možné považovať aj za predikciu pravdepodobnosti, s akou prípad prisľúcha do jednej z tried.

### 2.3 Chybové funkcie

Klúčovým aspektom pri učení neurónovej siete a vyhodnotení jej úspešnosti je určenie chyby, ktorej sa siet dopúšta pri predikcií jednotlivých prípadov. To zabezpečuje chybová funkcia, ktorá kvantifikuje, nakoľko je model presný pri vykonávaní svojej činnosti. V rámci neurónových sietí je cieľom nájsť také váhy, aby bola chybová funkcia čo najmenšia. Keďže parametre siete sa upravujú podľa chyby na výstupe, tak je dôležité zvoliť správnu chybovú funkciu vzhľadom na konkrétny riešený problém. Pri regresii sa často spolieha na metriky ako MAE (*mean absolute error*), MSE (*mean squared error*) a RMSE (*root mean squared error*).

MAE vyjadruje priemernú absolútну chybu, teda vyhodnocuje vzdialenosť reálnych pozorovaní v dátach od predikcií modelu a následne vypočíta priemer týchto vzdialenosťí. Táto funkcia je daná predpisom:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (2.6)$$

kde  $n$  je počet meraní,  $y_i$  je reálna hodnota a  $\hat{y}_i$  je predikcia modelu. Absolútна hodnota zabezpečuje, aby sa správne započítali aj záporné chyby. Výhodou je, že zachováva mierku, vďaka čomu je ľahko interpretovateľná.

Druhou často využívanou metrikou je priemerná kvadratická chyba – MSE:

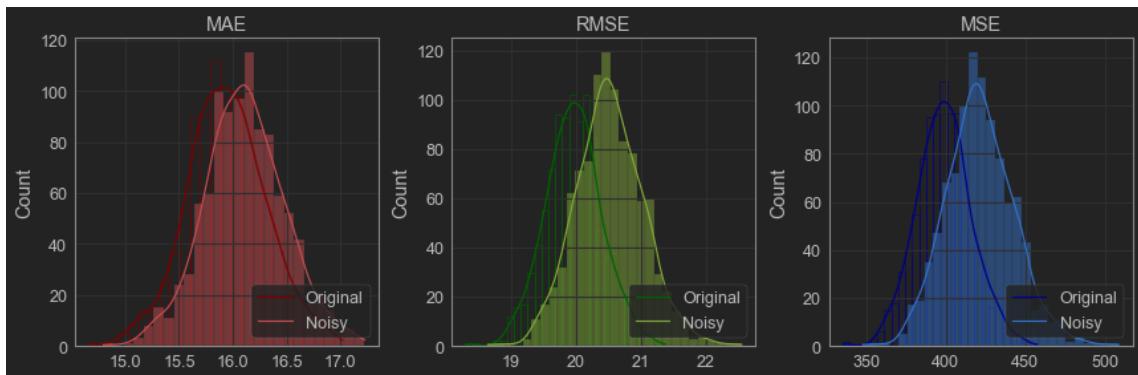
$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad (2.7)$$

Rozdielom oproti MAE je, že používa druhú mocninu namiesto absolútnej hodnoty na vysporiadanie sa so zápornými hodnotami. V dôsledku toho už nie je zachovaná rovnaká mierka s pôvodnými dátami. Povaha mocninovej funkcie spôsobuje, že

čím je chyba väčšia, tým je na ňu MSE citlivejšia. Problémom je, že okrem samotnej chyby je umocnený na druhú aj prípadný šum, ktorý je obsiahnutý v reálnych dátach a aj v predikcií samotného modelu. Na riešenie tohto nedostatku sa používa RMSE, čo je odmocnina sumy kvadratických chýb:

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (2.8)$$

RMSE vracia chybu aspoň čiastočne na pôvodnú mierku a zároveň zachováva vlastnosť penalizácie vyšších chýb. To je vidieť na Obrázku 2–6, v ktorom sa priemer RMSE pohybuje okolo 20,5; zatiaľ čo priemer MAE je 16. Taktiež je možné si všimnúť, že distribúcia MSE a RMSE sa v prípade zašumených dát posunula viac ako pri MAE, na čo treba bráť ohľad najmä pri dátach z reálneho sveta, ktoré takmer nikdy nie sú bez šumu.



**Obrázok 2–6** Porovnanie MAE, MSE a RMSE na umelých dátach so šumom a bez šumu. Zdroj: Trevisan (2022)

## 2.4 Optimalizácia

Hlavný úspech neurónových sietí je založený na schopnosti učiť sa, teda na schopnosti vedieť porovnať výstup s očakávanou hodnotou a upraviť rozhodovací proces tak, aby bola v budúcnosti chyba menšia. Kedže rozhodovanie je vo svojej podstate spôsob transformácie vstupu pomocou váh a vstup z pohľadu siete nie je možné

ovplyvniť, tak je potrebné správnym spôsobom upraviť váhy. Naviac je žiadúce, aby bol celý proces výpočtovo efektívny. Na tento účel existuje viacero algoritmov, súhranne nazývané optimalizačné algoritmy alebo metódy, ktorých úlohou je zmeniť parametre neurónovej siete tak, aby sa minimalizovala nákladová funkcia (*cost function*) a dosiahli sa čo najpresnejšie výsledky.

#### 2.4.1 Delta pravidlo

Delta pravidlo je učiace pravidlo založené na gradiente, určené na výpočet zmeny synaptických váh v jednovrstvovej neurónovej sieti. Ide o špeciálny prípad všeobecnejšieho algoritmu spätného šírenia chyby, ktorý opíšeme neskôr. Delta pravidlo upravuje váhy pomocou výpočtu parciálnej derivácie nákladovej funkcie podľa váhy (Sinčák, 2021):

$$\Delta w_{ij} = -\gamma \frac{\partial C}{\partial w_{ij}}, \quad (2.9)$$

kde  $w_{ij}$  je váha medzi  $i$ -tým a  $j$ -tým neurónom,  $\gamma$  je učiaci koeficient a  $C$  je nákladová funkcia. Z takéhoto zápisu, ale nevieme žiadanú zmenu vypočítať priamo, preto pravú stranu tejto rovnice následne zapíšeme ako:

$$\frac{\partial C}{\partial w_{ij}} = \frac{\partial C}{\partial \hat{y}_j} \frac{\partial \hat{y}_j}{\partial w_{ij}}, \quad (2.10)$$

kde  $\hat{y}_j$  je  $j$ -ty výstup z neurónovej siete. Parciálna derivácia nákladovej funkcie podľa výstupu je vlastne chyba na výstupe a parciálna derivácia  $\hat{y}_j$  podľa váhy  $w_{ij}$  je  $i$ -ty výstup z predchádzajúcej vrstvy. Tieto vzťahy zapíšeme ako:

$$\frac{\partial C}{\partial \hat{y}_j} = -(y_j - \hat{y}_j) \quad \text{a} \quad \frac{\partial \hat{y}_j}{\partial w_{ij}} = o_i. \quad (2.11)$$

Vzťah  $-(y_j - \hat{y}_j)$  substituujeme za  $\delta_j$  a nazývame ho chybový signál. Výsledný vzorec úpravy váhy podľa delta pravidla má tvar:

$$\Delta w_{ij} = \gamma \delta_j o_i. \quad (2.12)$$

Zovšeobecnením delta pravidla vznikol algoritmus spätného šírenia chyby (*backpropagation*).

#### 2.4.2 Spätné šírenie chyby – Backpropagation

Prvé idey, z ktorých táto metóda neskôr vznikla, sa objavili už v 60-tych rokoch 20. storočia (Kelley, 1960; Bryson, 1961). Aj keď sa o tom vedú dohady, tak existuje domnienka, že prvý krok k vývoju tohto algoritmu urobil Linnainmaa (1976), ale od vtedajšej komunity strojového učenia sa mu nedostalo príliš veľa pozornosti. V priebehu nasledujúceho desaťročia bolo spätné šírenie chyby viackrát znova objavené, ale uznanie a všeobecné prijatie získalo až po vydaní článku Rumelhart et al. (1986), v ktorom ho autori použili pri učení viacerých neurónových sietí a fungovalo oveľa rýchlejšie ako dovtedy používané metódy. To otvorilo dvere k využitiu neurónových sietí na zvládnutie mnohých dovtedy neriešiteľných problémov.

Jeden z hlavných problémov pri trénovaní viacvrstvových neurónových sietí spočíva v tom, akým spôsobom učiť interné parametre, teda aké hodnoty by mali mať váhy a biasy skrytých neurónov. Narozdiel od jednovrstvovej neurónovej siete, ktorá má delta pravidlo na aproximáciu jasne daného cieľového výstupu, uzly v skrytej vrstve nemajú cieľový výstup, nakoľko sú len medzikrokom v rámci výpočtov siete. Preto nie je možné jednoducho definovať chybovú funkciu, ktorá by bola špecifická pre daný skrytý neurón. Platí, že každá chyba konkrétneho neurónu závisí od hodnôt parametrov (a teda aj chýb) predchádzajúcich vrstiev a že táto chyba ovplyvní výpočty v nasledujúcich vrstvách. A keďže skutočnú chybu zistíme až na výstupnej vrstve, tak pre úpravu váh musíme postupovať opačným smerom, teda šíriť chybový signál od poslednej vrstvy k prvej. Toto prepojenie parametrov komplikuje matematiku na pozadí, ktorá keď nie je implementovaná efektívne, tak spôsobuje pomalé učenie neurónovej siete. Algoritmus spätného šírenia chyby rieši tieto problémy zjednodušením matematiky zostupu gradientu a zároveň uľahčuje jeho efektívny výpočet.

Backpropagation je vlastne praktickou aplikáciou reťazového pravidla pre derivácie. Klúčovým poznatkom je, že gradient nákladovej funkcie vzhľadom na vstup, môže byť vypočítaný z gradientu nákladovej funkcie vzhľadom na výstup. Rovnicu spätného šírenia je následne možno opakovane použiť na výpočet gradientov vo všetkých vrstvách od výstupnej až po vstupnú (McGonagle et al., n.d.). Rovnica parciálnej derivácie vzhľadom na váhy skrytých vrstiev vyzerá nasledovne:

$$\frac{\partial C}{\partial w_{ij}^k} = \delta_j^k o_i^{k-1} = g'(a_j^k) o_i^{k-1} \sum_{l=1}^{r^{k+1}} w_{jl}^{k+1} \delta_l^{k+1}, \quad (2.13)$$

kde  $C$  je nákladová funkcia,  $w_{ij}^k$  je váha medzi  $j$ -tym neurónom na  $k$ -tej vrstve a  $i$ -tym neurónom na  $k - 1$ -ej vrstve,  $\delta$  je chybový signál,  $o$  je výstup z neurónu,  $g'$  je derivácia aktivačnej funkcie,  $a$  je vstup do aktivačnej funkcie neurónu (skalárny súčin váh a vstupov) a  $r^{k+1}$  je počet neurónov na  $k + 1$ -ej vrstve. Všeobecný algoritmus spätnoväzobného šírenia (McGonagle et al., n.d.) pozostáva z týchto krokov:

1. **Výpočet doprednej fázy:** Vstupný signál sa dopredne šíri po sieti a pre každú vstupno-výstupnú kombináciu dát  $(\vec{x}, y)$  sa uloží výstup modelu  $\hat{y}$ , aktivácia neurónu  $a_j^k$  a výstup neurónu  $o_j^k$  pre každý neurón  $j$  vo vrstve  $k$ , od výstupnej vrstvy, až po výstupnú vrstvu  $m$ . Dopredné šírenie prebieha pre každý neurón v sieti podľa vzorca 2.1.
2. **Výpočet spätnoväzobnej fázy:** Chybový signál sa šíri späťne a pre každú vstupno-výstupnú kombináciu dát  $(\vec{x}, y)$  a pre každú váhu  $w_{ij}^k$  sa uloží  $\frac{\partial C}{\partial w_{ij}^k}$ . Pričom táto fáza sa čiastkovo skladá z:
  - (a) výpočtu chybového signálu na výstupnej vrstve  $\delta_j^m$ ,
  - (b) spätného šírenia chybového signálu  $\delta_j^k$  do skrytých vrstiev od výstupnej vrstvy  $m$ , až po prvú vrstvu,
  - (c) výpočtu parciálnych derivácií  $\frac{\partial C}{\partial w_{ij}^k}$  pre každú váhu  $w_{ij}^k$  spájajúcu  $i$ -ty neurón v  $k - 1$  vrstve s  $j$ -tym neurónom v  $k$ -tej vrstve.

Po získaní všetkých čiastkových gradientov nasleduje úprava váh, ktorá ale závisí od zvolenej optimalizačnej metódy. Pojem backpropagation sa striktne vzťahuje len na výpočet gradientu a nie na to, ako túto informáciu použiť v procese učenia (Goodfellow et al., 2016). Avšak v praxi sa stretнем s voľnejším používaním tohto pomenovania, kedy sa ním označuje celý proces učenia vrátane toho, ako gradient použiť. Jedným z príkladov použitia je napríklad algoritmus zostupu gradientu (*gradient descent*).

#### 2.4.3 Zostup gradientu

Algoritmus zostupu gradientu závisí od derivácií prvého rádu (gradientu) nákladovej funkcie a na základe nich vypočíta, akým smerom by sa mali zmeniť váhy, aby sa dosiahlo minimum nákladovej funkcie. To vykonáva opakoványmi krokmi v opačnom smere, aký udáva gradient (Kwiatkowski, 2021). Ide teda o iteratívny algoritmus. Jeho výhodami sú jednoduchý výpočet, jednoduchá implementácia a je ľahký na pochopenie. Má však aj nevýhody, medzi ktoré patrí vysoké nároky na pamäť, nakoľko váhy mení až po vypočítaní gradientu pre každý prvok datasetu, a teda je potrebné hodnoty gradientov pre každú váhu ukladať. S tým súvisí aj časová náročnosť, ak je dataset príliš veľký, tak môže trvať veľmi dlho, kým skonverguje do minima. Hlavnou nevýhodou ale je, že môže uviaznuť v lokálnom minime namiesto globálneho a tiež má problém prekročiť prípadnú rovinu v chybovom priestore, kedže v takých prípadoch je gradient nulový a nie je jasné ktorým smerom sa vydať. Tento problém spôsobený nekonvexnosťou chybových funkcií sa dlho považoval za hlavnú nevýhodu tejto metódy, ale LeCun et al. (2015) tvrdia, že v praktických problémoch to tak nie je a často k tomu nedochádza. V skratke algoritmus pozostáva z nasledujúcich krokov:

1. Inicializácia - výber počiatočného bodu. V rámci neurónových sietí tento krok prebehne náhodným nastavením počiatočných hodnôt váh. Avšak aby sa urýchlilo učenie a predišlo prípadnému problému miznúceho alebo explodujúceho

gradientu, nie je vhodné nastaviť váhy úplne náhodne, ale podľa určitých pravidiel. Jedným zo spôsobov je He inicializácia (He et al., 2015), ktorá navrhuje nasledovnú inicializáciu váh a biasov:

$$w^l \sim \mathcal{N}(\mu = 0, \sigma^2 = \sqrt{\frac{2}{n^{l-1}}}) \quad \text{a} \quad b^l = 0, \quad (2.14)$$

teda váhy vrstvy  $l$  by mali byť vybraté náhodne z normálnej distribúcie so strednou hodnotou 0 a rozptyлом  $\sqrt{\frac{2}{n^{l-1}}}$ , kde  $n^{l-1}$  je počet neurónov predchádzajúcej vrstvy.

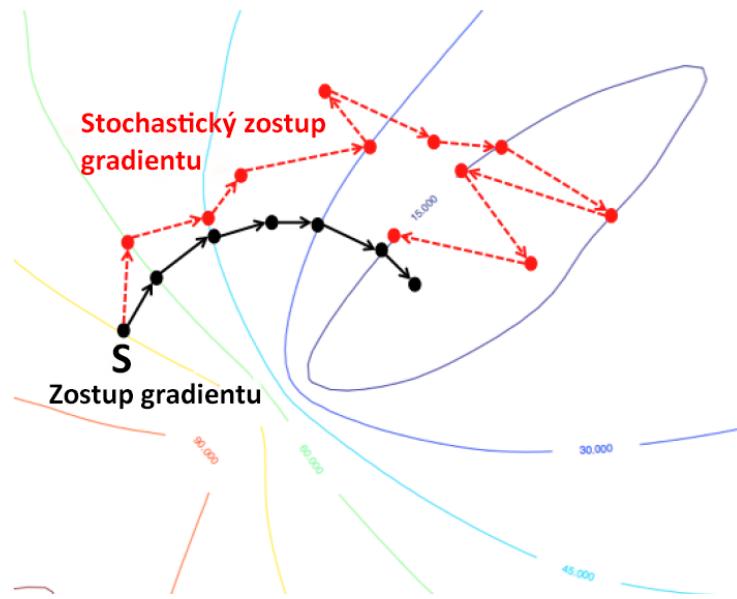
2. Výpočet gradientu v tomto bode.
3. Vykonáť krok v opačnom smere gradientu s určitým učiacim koeficientom.
4. Opakovať kroky 2. a 3., kým sa veľkosť kroku nezmenší na zanedbateľnú úroveň alebo kým sa nedosiahne maximálny počet iterácií.

Existuje viacero modifikácií tohto algoritmu, ktoré sa snažia do istej miery eliminovať niektorú z jeho nevýhod.

#### 2.4.4 Stochastický zostup gradientu

Stochastický zostup gradientu je oproti základnému algoritmu zmenený v tom, že nepočíta s gradientom celého datasetu, ale len s určitou náhodne vybranou podmnožinou (Zhang, 2004). Vďaka tomu konverguje rýchlejšie, dokáže vyjsť aj z lokálnych miním a jeho pamäťové nároky sú takisto menšie. Veľkosť tejto náhodnej vzorky sa nazýva mini-batch a volí sa na začiatku ako hyperparameter.

Nevýhodou sú fluktuácie v nákladovej funkcií, nakoľko smer nie je vždy zvolený optimálne, ako môžeme vidieť na Obrázku 2 – 7. Taktiež je potrebné začať s vyšším učiacim koeficientom a pomaly ho znižovať, aby bolo učenie dostatočne rýchle, ale zároveň aby nedochádzalo k osciláciám okolo globálneho minima.



**Obrázok 2–7** Porovnanie konvergencie do globálneho minima algoritmom zostupu gradientu a algoritmom stochastického zostupu gradientu.

#### 2.4.5 Adam

Optimalizačný algoritmus Adam je rozšírením stochastického gradientového zostupu. Pri predstavovaní algoritmu Kingma and Ba (2014) uviedli viaceré výhody, ktoré použitie tohto algoritmu prináša:

- jednoduchý na implementáciu,
- výpočtovo efektívny,
- nízke pamäťové nároky,
- hodí sa na riešenie problémov s veľkým počtom dát a/alebo parametrov,
- vhodný aj pre nestacionárne ciele,
- vhodný pre problémy so zašumeným gradientom,
- hyperparametre majú intuitívnu interpretáciu a nepotrebuju velké ladenie.

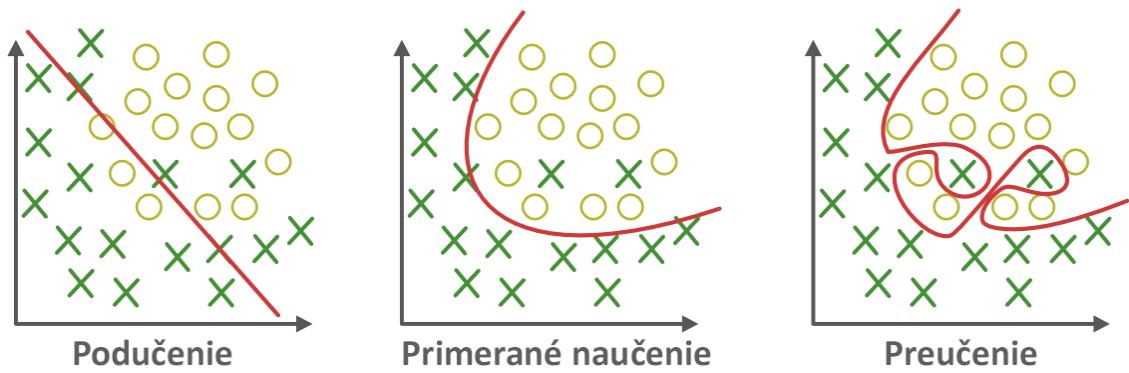
Zatiaľ čo stochastický zostup gradientu používa jeden učiaci parameter pre všetky váhy, Adam má samostatný učiaci parameter pre každú váhu a v procese učenia ich adaptuje. Autori Kingma and Ba (2014) opisujú Adam-a ako kombináciu výhod ďalších dvoch optimalizačných algoritmov:

- AdaGrad – prispôsobuje učiaci koeficient pre každý parameter ich mierkou a vykonáva menšie zmeny pre parametre spojené s často sa vyskytujúcimi príznakmi a väčšie zmeny pre parametre naviazané na zriedkavé príznaky. Zlepšuje výkon pri problémoch s riedkymi dátami.
- RMSProp – rovnako má samostatné učiace koeficienty pre všetky parametre. Snaží sa tlmiť oscilácie pomocou kĺzavého priemeru predchádzajúcich gradien-tov a tým zlepšiť rýchlosť učenia. Dobre funguje pri problémoch s nestacionár-nym cieľom alebo zašumeným gradientom.

Adam namiesto prispôsobenia učiacich koeficientov na základe priemeru prvého momentu (ako v RMSProp), využíva aj priemer druhých momentov gradientov. Algoritmus konkrétnie počíta exponencionálny kĺzavý priemer gradientu a druhú mocninu gradientu.

## 2.5 Regularizácia

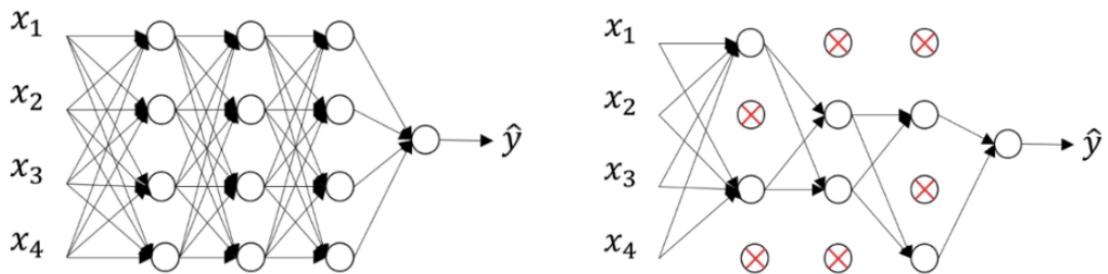
Neurónové siete ako univerzálné approximátory funkcií sú schopné naučiť sa aj komplexné nelineárne funkcie. V niektorých prípadoch, ak sa učenie nezastaví vo vhodný moment, sa sieť može začať učiť approximovať aj šum, ktorý je v dátach obsiahnutý. To sice zlepší jej presnosť na trénovacích dátach, ale častokrát za cenu straty schopnosti zovšeobecňovania, nakoľko šum je jedinečný pre každú trénovaciu množinu. Výsledkom je to, že keď neurónová siet uvidí nové dátá z rovnakej domény, ale ktoré neobsahujú tento šum, tak jej úspešnosť predikcie alebo klasifikácie takýchto prípadov rapídne klesá. Tento jav, zobrazený na Obrázku 2–8, sa nazýva preučenie a cieľom regularizačných techník je mu zabrániť.



**Obrázok 2–8** Porovnanie výstupov podučenej, korektne naučenej a preučenej neurónovej siete.

### 2.5.1 Dropout

Dropout (Srivastava et al., 2014) znižuje varianciu učenia modelu. Je jednou z najčastejšie používaných regularizačných techník v hlbokom učení. Spočíva v tom, že v každej iterácii sa určitý počet náhodne vybraných neurónov „vypne“ a všetky synaptické váhy, ktoré sú spojené s takýmito uzlami sa nezúčastnia ani na doprednom ani na učiacom procese neurónovej siete (viď. Obrázok 2–9). V dôsledku toho vzniká množina jednoduchších podsietí, ktoré fungujú všeobecnejšie. Žiadny neurón sa nemôže spoliehať na jedného konkrétneho predchodcu, respektívne na jeden konkrétny príznak, čo ho nútí rozvíjať viacero váh. Pravdepodobnosť, s ktorou môže dôjsť k deaktivácii neurónu sa udáva ako hyperparameter.

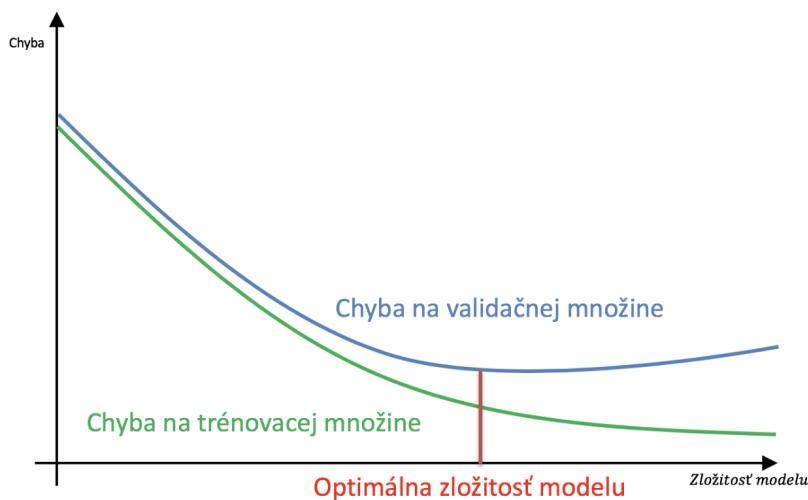


**Obrázok 2–9** Vizualizácia deaktivácie neurónov pri pravdepodobnosti dropoutu 0,5.

### 2.5.2 Predčasné zastavenie

Bežnou konvenciou je dátu rozdeliť na 3 množiny:

- **Trénovaciu:** na ktorej sa siet učí riešiť daný problém a používa ich na úpravu svojich váh.
- **Testovaciu:** túto množinu model uvidí až po svojom úplnom natrénovaní a slúži na objektívne vyhodnotenie jeho úspešnosti.
- **Validačnú:** ktorá slúži na testovanie modelu už počas učenia. V prípade, že výkonnosť siete na tejto množine sa zastaví na určitej hodnote a na trénovacej množine chyba modelu neustále klesá, tak to znamená, že siet sa začína preúčať a je vhodné učenie zastaviť. Optimálny čas zastavenia učenia je zobrazený na Obrázku 2 – 10.



**Obrázok 2 – 10** Zobrazenie ideálneho momentu predčasného zastavenia trénovalia neurónovej siete.

## 2.6 Konvolučné neurónové siete

Hlboké neurónové siete sa snažia napodobniť človeka vo vnímaní okolitého sveta. To zahŕňa schopnosť extrahovať podstatné informácie zo surových dát a následne

ich použiť pri rozhodovaní. Klúčovú úlohu v tomto procese zohrávajú konvolučné neurónové siete (LeCun et al., 1989). Významné pokroky priniesli najmä v oblasti počítačového videnia, v ktorom sú schopné zo vstupného obrazu vybrať rôzne jednoduché črty, ktorých kombináciou dokážu detegovať alebo segmentovať zložité tvary a objekty (Yamashita et al., 2018). Predspracovanie dát požadované v tomto type siete je oveľa nižšie ako pri tradičnejších algoritnoch. Túto výhodu je naviac možné využiť aj v iných doménach, akými je napríklad spracovanie prirodzeného jazyka alebo analýza, či predikcia časových radov.

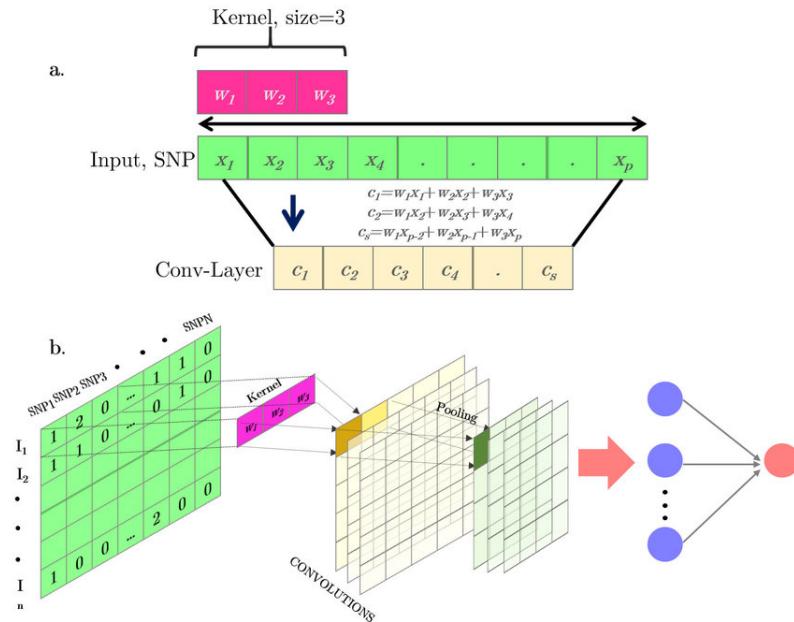
Konvolučná neurónová siet je navrhnutá tak, aby sa automaticky a adaptívne vedela učiť priestorové hierarchie príznakov pomocou spätného šírenia chyby. Je zložená z viacerých stavebných blokov, medzi ktoré patria konvolučné vrstvy, vzorkovacie vrstvy a plne prepojené vrstvy:

- **Konvolučná vrstva:** je tvorená filtrami, ktoré systematicky prechádzajú vstupné dátu a každú hodnotu určitým spôsobom transformujú, pričom zoberú do úvahy aj okolité hodnoty. Tento proces sa nazýva konvolúcia a jeho matematické vyjadrenie je nasledovné:

$$S(i, j) = (K * I)(i, j) = \sum_m \sum_n I(m, n) K(i - m, j - n), \quad (2.15)$$

kde  $I$  sú vstupné dátu, najčastejšie obrazové, kedy sa jedná o maticu pixelov, ale významovo sa môže jednať o hocjaké dátu a filter  $K$ , tiež nazývaný kernel, čo je matica, ktorej hodnoty definujú význam filtra a v procese učenia sa adaptujú. Výstupom je príznaková platňa, ktorá má najvyššie hodnoty na tých miestach, kde rozloženie vysokých a nízkych hodnôt vo vstupných dátach najviac súhlasilo s rozložením hodnôt v kerneli. Jednoducho povedané, kernel sa posúva po matici  $I$  ako je zobrazené na Obrázku 2–11 časť a., prekrývajúce hodnoty sa vynásobia a následne sčítajú, čím vznikne jedno číslo vo výstupnej matici. Aby bolo jednoznačné, na ktoré miesto patrí toto číslo, zvykne byť

dĺžka hrany kernela nepárna, ale nie je to pravidlo. Konvolúcia je najviac využívaná na 2D dátach, ale jej použitie je možné aj na 1D alebo 3D dátach, kedy sa mení len rozmer filtra a spôsob jeho posúvania po vstupe.



**Obrázok 2–11** Princíp fungovania konvolučnej neurónovej siete: a. schéma konvolúcie na 1D dátach, b. znázornenie celej 1D konvolučnej neurónovej siete. Zdroj: Enciso and Zingaretti (2019)

- **Vzorkovacia vrstva:** Jej úlohou je nelineárne zmenšiť príznakovú platňu, vďaka čomu sa znížia výpočtové nároky, zvýši výkon siete a v neposlednom rade sa vyzdvihnu podstatné príznaky zo vstupu (Zhou and Chellappa, 1988). Týmto procesom sa informácia obsiahnutá vo vstupe koncentruje a dôjde k zmenšeniu šírky a výšky vstupných dát, ale počet výstupných matíc zostáva bez zmeny, čiže máme jednu pre každý filter. Vidieť to na Obrázku 2–11 časť b. v strede. Najbežnejšie typy vzorkovacích funkcií sú:

- average pooling: vypočíta sa priemer prekrytých hodnôt,
- max pooling: vyberie sa najvyššia z prekrytých hodnôt,
- min pooling: vyberie sa najnižšia z prekrytých hodnôt.

- **Plne prepojená vrstva:** Zatiaľ čo úlohou predchádzajúcich dvoch typov vrstiev je extrahovať príznaky, plne prepojené vrstvy sú zodpovedné za samotné rozhodovanie siete. Usporiadaním týchto vrstiev za seba vznikne štruktúra, ktorá funguje ako klasická dopredná neurónová sieť.

## 2.7 Rekurentné neurónové siete

Pokiaľ ide o predikciu sekvenčných údajov alebo časových radov, tak bežné dopredné neurónové siete nie sú až také úspešné, pretože nedokážu uchovávať temporálne vzťahy. Síce sa učia na dátach z minulosti, ale pri predikcii berú do úvahy iba jeden momentálny vstup. Takže aj keď dostanú testovacie príklady v rôznom poradí, pre každý jednotlivý prípad vypočítajú rovnaký výstup. S cieľom vyriešiť tento nedostatok vznikli rekurentné siete.

Rekurentné neurónové siete (Jain and Medsker, 1999) sú typom sietí, ktoré majú vo svojej štruktúre spätné slučky na predchádzajúce vrstvy, vďaka ktorým dokážu lepšie pracovať so sekvenciami z minulosti a využiť to do určitej miery na predikciu. Majú v sebe koncept „pamäte“, ktorá im pomáha ukladať informácie o predchádzajúcich vstupoch na vygenerovanie lepšieho výsledku pre ďalší výstup sekvencie. Cieľom je, aby sa dokázali naučiť dlhodobé vzťahy obsiahnuté v dátach, ale empirické dôkazy ukazujú, že majú skôr krátkodobú pamäť. To súvisí s problémom explodujúcich a miznúcich gradientov.

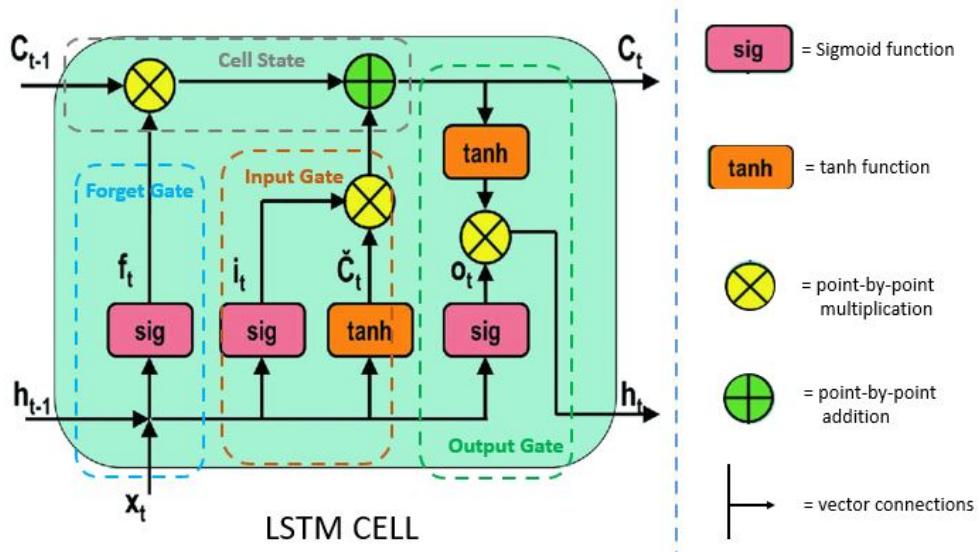
### 2.7.1 Long short-term memory

Alebo tiež LSTM je špeciálny typ architektúry rekurentnej neurónovej siete, ktorú predstavili Hochreiter and Schmidhuber (1997) ako riešenie miznúcich gradientov v tomto type sietí. Ako sa ukázalo v praxi, bežné rekurentné neurónové siete relatívne rýchlo zabudnú kontext a teda je pre nich ťažké spájať informácie, ktoré sú od seba v čase daleko. Narozenie od nich LSTM sú navrhnuté tak, aby riešili problém dlhodobej závislosti. Zapamätávanie si informácií na dlhé časové obdobia

je prakticky ich predvolené správanie a nie niečo, čo by sa potrebovali učiť.

Ich štruktúra je od bežných sietí odlišná v tom, že sa neprepájajú jednotlivé neuróny, ale pamäťové bloky usporiadane do vrstiev. Jeden LSTM blok obsahuje brány, ktoré určujú aká informácia je podstatná a mala by byť uložená, a ktoré údaje už môžu byť zabudnuté. Jeden blok je zložený zo štyroch častí, ako môžeme vidieť na Obrázku 2 – 12:

- **Vstupná brána:** je sigmoidálna vrstva, ktorá rozhoduje, ktoré nové informácie budú vložené do pamäte.
- **Pamäťová bunka:** jej úlohou je ukladať informácie.
- **Zabúdacia brána:** rozhoduje o tom, ktoré informácie budú z pamäte vymazané. Taktiež sa jedná o sigmoidálnu vrstvu.
- **Výstupná brána:** určuje, čo pôjde na výstup podľa obsahu pamäťovej bunky a vstupu.



Obrázok 2 – 12 Blok LSTM a jeho časti. Zdroj: Smagulova and James (2020)

### 3 Predikcia ionosférických scintilácií

Ionosférické scintilácie sa stávajú čoraz dôležitejším a väčnejším problémom, ale nie kvôli tomu, že by naberali na sile alebo intenzite, ale kvôli tomu, že naša spoločnosť sa stáva čím dalej, tým viac závislá od signálu z globálnych navigačných satelitov (Kintner et al., 2007) a kvôli tomu, že expanzia našich technológií do vesmíru sa urýchľuje. Komunikácia so všetkým čo sa momentálne nachádza alebo sa bude nachádzať na orbite Zeme, je postavená na transionosférických signáloch. Napriek časťom degradačným účinkom ionosféry na rádiový signál satelitov, stále chýba účinný spôsob zmierňovania týchto vplyvov a celkový výskum v tomto smere je nedocenený. To súvisí aj s chýbajúcim celkovým povedomím laickej verejnosti o existencii ionosférických scintilácií. Tieto skutočnosti, umocnené zvyšujúcim sa dopytom po GNSS (*Global Navigation Satellite System*) aplikáciách vytvárajú motiváciu na tvorbu predikčných modelov.

Aj keď sa v posledných rokoch podarilo získať nové poznatky vďaka vylepšeným fyzikálnym modelom ionosféry a modelom šírenia signálu cez nepravidelné štruktúry, tak tieto výskumy majú jeden z nasledujúcich problémov: bud sa týkali vysoko špecifických udalostí, teda prípadov konkrétnych scintilácií, z ktorých nie je možné odvodiť širšie súvislosti alebo skúmali príliš zovšeobecnené okolnosti vzniku a priebeh scintilácií. Napríklad Chartier et al. (2016) vytvorili rozsiahlu analýzu scintilácie medzi 20:03 a 20:07 zo 17. októbra 2013, ktorá prispela k lepšiemu pochopeniu fázových scintilácií. Nie je však známe, nakoľko je možné tieto výsledky zovšeobecniť. Oba tieto prístupy majú obmedzenú predikčnú schopnosť. Prvý pokrýva príliš špecifické okolnosti a druhý príliš všeobecné, bez napojenia na časovo-priestorové charakteristiky jednotlivých prípadov. Z toho vyplýva, že stále chýba efektívny predikčný model scintilácií, najmä pre vysoké zemepisné šírky. Využitie by mal napríklad v letectve, v ktorom trasy medzi Európou a Severnou Amerikou vedú práve cez vysoké zemepisné šírky.

V nízkych zemepisných šírkach je tento problém vo viacerých ohľadoch riešiteľnejší a venovalo sa mu aj viac pozornosti, nakoľko vznik scintilácií je spojený s fyzikou opakujúcej sa rovníkovej anomálie, ktorú sme opísali v kapitole 2.3.1. K zložitosti predpovede polárnych scintilácií prispieva aj to, že sú často spojené s kozmickým počasím, na ktorého predikciu zatiaľ tiež neexistujú spoľahlivé modely.

Cieľom našej práce je teda zistiť, či je možné pomocou hlbokých neurónových sietí vytvoriť čisto dátovo-riadený model, ktorý by bol schopný predikcie fázových scintilácií vo vysokých zemepisných šírkach. Dátovo-riadeným modelom myslíme model bez implementácie fyzikálnych zákonitostí a bez toho, aby sme sa snažili pochopiť zložité fyzikálne mechanizmy, ktoré sú zodpovedné za vznik scintilácií. V prospech využitia hlbokého učenia na túto úlohu hovorí aj fakt, že existuje veľké množstvo málo využívaných dát pochádzajúcich z GNSS prijímačov po celom svete. Odhaduje sa, že existujú rádovo terabajty vhodných dát, ale problémom je, že sú veľmi heterogénne a nekonzistentné (pochádzajú z rôznych satelitných systémov, z prijímačov od rôznych výrobcov a sú ukladané v rôznych databázach a formátoch) (McGranaghan et al., 2018).

### 3.1 Získavanie dát

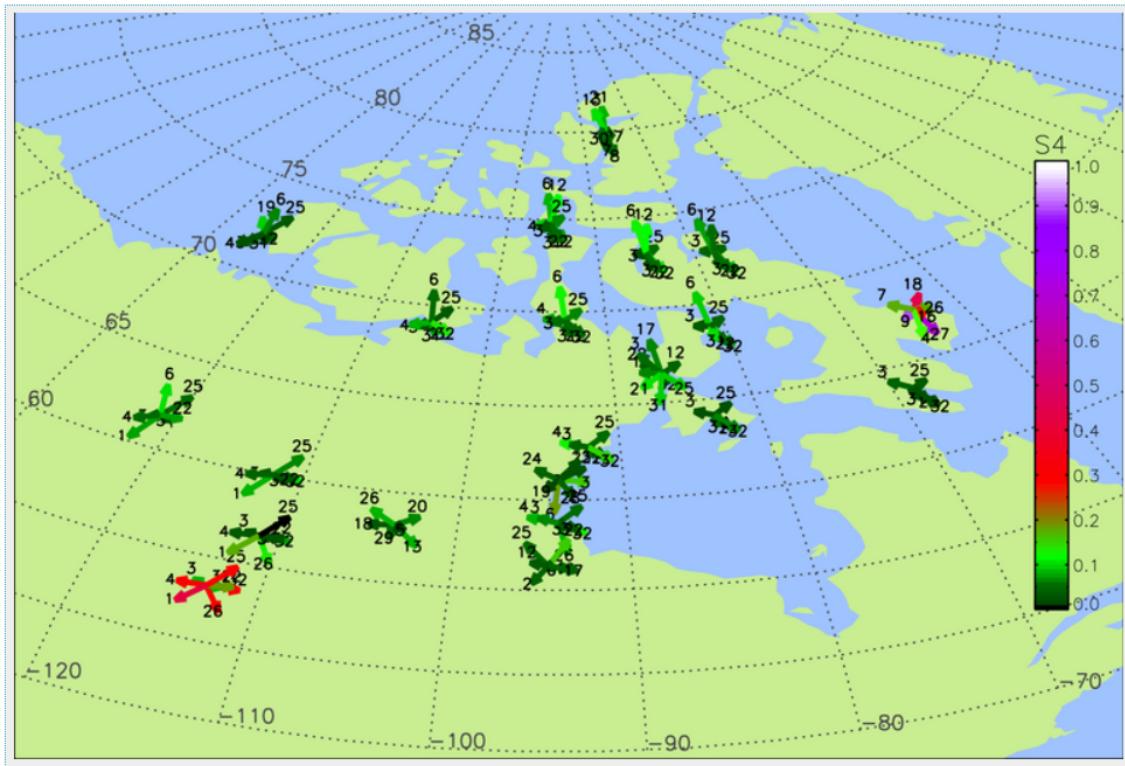
Naše scintilačné dáta pochádzajú zo štúdie od McGranaghan et al. (2018) a boli namerané Kanadskou vysoko-arktickou ionosférickou sieťou (*Canadian High Arctic Ionospheric Network, skr. CHAIN*). Táto siet bola vytvorená s cieľom lepšie pochopiť planetárne prostredie, ktoré je ovplyvnené krátkodobými a dlhodobými zmenami aktivity našej najbližšej hviezdy. Systém Slnko-Zem je komplexne prepojený súbor veľkého množstva fyzikálnych procesov, ktorých spúšťačom je buď priame alebo nepriame pôsobenie slnečnej aktivity. Úplné pochopenie celého systému si vyžaduje znalosti o jednotlivých čiastkových fyzikálnych javoch a ich vzájomných interakciách. Konštrukciou a prevádzkou tejto siete sa vedci snažia získať znalosti potrebné na plné porozumenie vplyvov Slnka na našu planétu.

Sieť CHAIN je distribuované pole 25 vysokorýchlosných GNSS prijímačov a 6 digitálnych ionosférických sond poskytujúcich dátá takmer v reálnom čase. Väčšina týchto prístrojov sa nachádza vo vnútri kanadského polárneho kruhu, zvyšné sú na jeho hranici. Toto územie bolo zvolené z toho dôvodu, že sa jedná o oblasť otvorených magnetických siločiar. Tie sú väčšinou priamo ovplyvňované slnečným vetrom a medziplanetárnym magnetickým poľom. Hmota a energia z tejto interakcie vniká do atmosféry, v dôsledku čoho ionosféra polárnej čiapky často obsahuje viaceré ionizované elektromagnetické štruktúry rôznych veľkostí. Pochopenie týchto štruktúr je nutné k pochopeniu interakcií medzi slnečným vetrom, medziplanetárnym magnetickým poľom, zemskou magnetosférrou a ionosférou. Z hľadiska veľkosti ich vieme rozdeliť do troch skupín:

- makroškála: tzv. ionizačné jazyky ( $>1000\text{ km}$ ),
- mezoškála: polárne škvurny (100-1000 km),
- mikroškála: štruktúry produkujúce scintilácie (1-100 km).

Základné merania pozostávajú z meraní GNSS prijímačov so vzorkovaním 50 Hz, ktoré je už priamo softvérom prijímača prepočítavané na 1-minútové rozlíšenie. Je to z toho dôvodu, že vyššie časové rozlíšenie by bolo príliš nákladné na pamäť a výpočtové spracovanie, bez dostatočnej pridanej vedeckej hodnoty. Táto sieť obsahuje prijímače od výrobcov Septentrio (17 staníc) a NovAtel (8 staníc). Kvôli väčšiemu počtu staníc, konzistentnosti dát a vzhľadom na štúdie opísané v kapitole 2.2 budeme používať iba dátá z prijímačov Septentrio. Priestorové rozloženie týchto staníc vidíme na Obrázku 3–1, kde je možné vidieť aj silu scintilácií medzi jednotlivými stanicami a satelitmi. Jednotlivé čísla pri šípkach označujú konkrétné sately. Ide o stav ionosféry z 25.04.2022 o 10:00 UTC, kedy môžeme vidieť relatívne silné narušenie ionosféry v ľavom dolnom rohu obrázku.

Pre vytvorenie modelu na predikciu scintilácií je dôležité získať čo najviac relevantných dát, použiteľných ako príznaky pri trénovaní. Kedže vznik a závažnosť



**Obrázok 3 – 1** Pozície GNSS prijímačov v rámci siete CHAIN. Zdroj: CHAIN (2022)

scintilácií súvisí so slnečnou aktivitou, slnečným vetrom, zemskou magnetosférou, termosférou a so samotnou ionosférou, tak je klúčové získať dátu ku každej z týchto oblastí s dostatočným časovým rozlíšením, keďže trvanie scintilácií je rádovo od jednotiek minút až po hodiny.

Prvým zdrojom je databáza OMNIWeb, ktorú spravuje NASA Goddard Space Flight Center (Garner, 2015). Táto databáza poskytuje dva typy údajov. Prvým je súbor dát, s nízkym rozlíšením, poskytujúci hodinové priemery parametrov magnetického poľa slnečného vetra v blízkosti Zeme, toku vysoko energetických protónov (s energiami od  $>1$  po  $>60$  MeV) a parametre plazmy, ktoré sú získavané z viacerých satelitov s geocentrickými alebo L1 (*Lagrange point 1*) orbitálnymi dráhami. Geocentrická dráha je taká, pri ktorej je Zem centrálnym telesom a satelit obieha okolo nej. Obežná dráha satelitu nachádzajúceho sa v prvom Lagrangovom bode je heliocentrická, teda satelit obieha okolo Slnka, ale takým spôsobom, že sa vždy

nachádza medzi Zemou a Slnkom. Vďaka tomu dokáže takýto satelit podať informácie o slnečnom vetre ešte predtým, ako zasiahne Zem. Pre dátu z týchto satelitov sa vykonávajú časové posuny pred vypočítaním hodinových priemerov, aby hodnoty súhlasili s časmi, kedy reálne slnečný vietor narazil na magnetosféru Zeme. Vďaka existencií viacerých satelitov sú dátu z nich krížovo porovnávané a niektoré aj krížovo normalizované, aby bola zabezpečená vysoká presnosť meraní. Výhodou týchto dát je taktiež ich rozsiahlosť, kedže niektoré parametre sú nepretržite merané od roku 1963 až do súčasnosti. Druhým typom údajov sú dátu s vysokým rozlíšením, ktoré obsahujú 1 a 5-minútové údaje o medziplanetárnom magnetickom poli posunuté s ohľadom na miesto stretu so zemským magnetickým polom.

Ďalším zdrojom dát je empirický globálny referenčný matematický model zemskej atmosféry NRLMSISE-00 (Picone et al., 2002). NRL je skratka pre Námorné výskumné laboratórium Spojených štátov amerických (*US Naval Research Laboratory*), MSIS znamená hmotnostný spektrometer a nekoherentný rozptylový radar, čo sú dva primárne zdroje údajov použitých pri tvorbe starších verzií tohto modelu a E vyjadruje, že model pokrýva oblasť od povrchu Zeme až po exosféru (model je platný od 0 po 1000 km nad morom). Je to model neutrálnej teploty a hustoty atmosféry v závislosti od výšky nad zemským povrhom. Výhodou tohto modelu je možnosť výpočtu parametrov pre rôzne výšky nad povrhom. Pre nás sú potrebné výšky, v ktorých sa vyskytujú scintilácie. Z modelu sme teda získali dátu od 100 po 300 km vrátane, s krokom 50 km. Nie všetky parametre, ktoré model poskytuje, sú reálne namerané hodnoty. Pre tie oblasti, kde merania chýbajú, sú hodnoty dopočítané pomocou matematického modelu. Pri tomto výpočte sú uvažované štyri vstupné parametre: denná hodnota indexu F10.7, 3-mesačný priemer indexu F10.7, denný ap index a globálne súradnice polohy na Zemi, pre ktorú dátu potrebujeme. Index F10.7 je miera žiarenia generovaného Slnkom o vlnovej dĺžke 10,7 centimetra. Globálna denná hodnota tohto indexu sa meria na miestne poludnie v Rádioastrofyzikálnom observatóriu v Pentictone v Kanade. Ap index je mierou všeobecnej

úrovne geomagnetickej aktivity na Zemi za daný deň. Je odvodený z meraní zmien geomagnetického pola, v dôsledku prúdov v ionosfére a v menšej miere v zemskej magnetosfére, nameraných na mnohých staniciach po celom svete. Oficiálne približné hodnoty vypočítava Nemecké výskumné centrum pre geovedy takmer v reálnom čase a na definitívne hodnoty ich aktualizuje dvakrát mesačne.

Tretím zdrojom dát je semi-empirický globálny referenčný matematický model ionosféry IRI (*International Reference Ionosphere*). Vznikol ako medzinárodný projekt sponzorovaný Výborom pre výskum vesmíru (*COSPAR*) a Medzinárodnou úniou rádiovej vedy (*URSI*). Koncom 60-tych rokov bola založená pracovná skupina s cieľom vytvoriť štandardný model ionosféry pomocou všetkých dostupných zdrojov údajov. Odvtedy bol tento model viackrát aktualizovaný a najnovšia verzia pochádza z roku 2016. Tento model pre zadanú polohu na Zemi, dátum a čas poskytuje hodnoty hustoty elektrónov, teploty elektrónov, teploty iónov a percentuálne zastúpenie jednotlivých iónov vzhľadom na výšku nad povrchom Zeme. V tomto prípade sme zvolili rovnaké rozloženie dát ako pri predchádzajúcom modeli, a to výšky od 100 km po 300 km vrátane s krokom 50 km. Hlavnými zdrojmi údajov sú celosvetová sieť ionosférických sond a výkonné nekoherentné rozptylové radary. Ako pri NRLMSISE, aj tento model prijíma na svoj vstup určité parametre, ktoré konkrétnie sú: denná hodnota, 81-dňový a 12-mesačný kĺzavý priemer F10.7, ďalej 12-mesačný kĺzavý priemer počtu slnečných škvŕní, denný a 3-hodinový ap index a ako posledný parameter 12-mesačný kĺzavý priemer IG indexu. IG index je index slnečnej aktivity odvodený z priemerných poludňajších foF2 údajov dostupných z 13-tich ionosférických pozorovaní po celej Zemi a foF2 je kritická frekvencia F2 ionosférickej vrstvy.

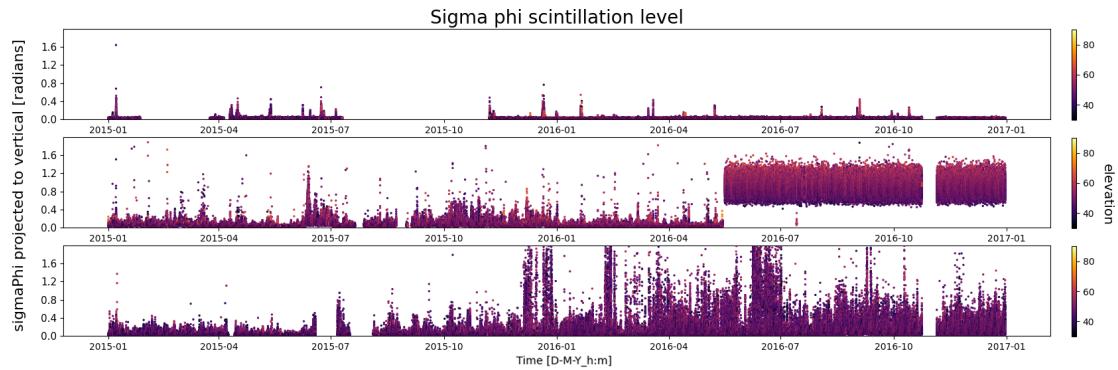
Posledným zdrojom dát je Python knižnica `ephem`. Je to balík na vykonávanie veľmi presných astronomických výpočtov. Jej základ je naprogramovaný v programovacom jazyku C, vďaka čomu umožňuje rýchle výpočty. Vznikla už v roku 1998 a slúži na výpočet polohy planét, komét, asteroidov a satelitov Zeme. Okrem toho

dokáže vypočítať uhlovú vzdialenosť medzi dvoma objektmi na oblohe, určiť konšteláciu v ktorej objekt leží a poskytnúť časy, kedy hľadaný objekt vychádza a kedy zapadá za horizont. My túto knižnicu využijeme na výpočet výšky Slnka nad obzorom. Nakolko sa viacero staníc nachádza za polárnym kruhom, tak nie je vhodné použitie bežného času na odlišenie dňa a noci, keďže počas obdobia polárneho dňa Slnko nezypadá a konštantne ionizuje atmosféru v tejto oblasti.

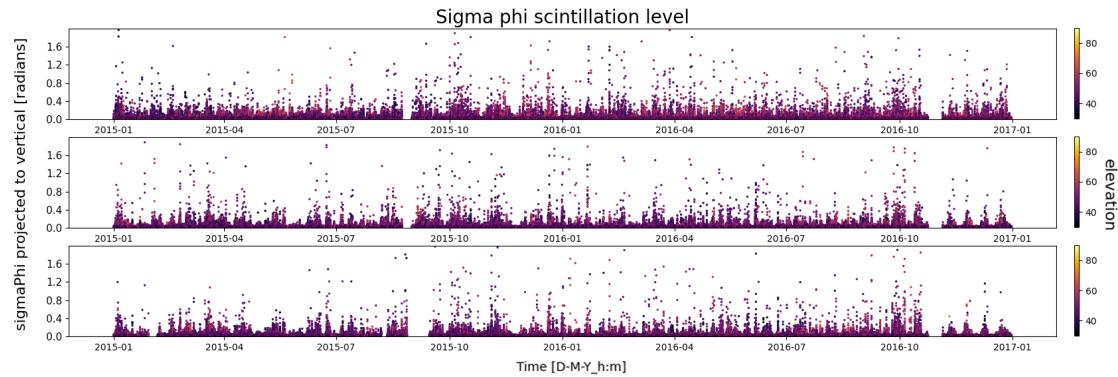
### 3.2 Pochopenie dát

Náš dataset pokrýva minútové merania od 1.1.2015 do 31.12.2016 vrátane a obsahuje údaje z 15-tich staníc. Celkovo to činí 731 dní x 24 hodín x 60 minút x 15 staníc = 15,789 milióna riadkov. Vzhľadom na rozsiahlosť tohto datasetu a nekonzistentnosť meraní medzi niektorými stanicami, sme sa rozhodli, že budeme používať dátá iba z jednej stanice. Po konzultácii s expertom sme zistili, že nesúlad je pravdepodobne spôsobený nesprávnou kalibráciou prijímačov (vid. Obrázok 3 – 2). Pre porovnanie uvádzame aj dátá z korektne nastavených staníc (vid. Obrázok 3 – 3). Týmto krokom sa ušetrí nemalé množstvo výpočtových nárokov a v prípade potreby je v budúcnosti stále možnosť využiť kódy a zvyšné dátá na dotrénovanie modelu. Taktiež bude potrebné nanovo stiahnuť dátá pre ďalšie prijímače, nakoľko modely NRLMSISE a IRI sú závislé od geografickej polohy. Celkovým cieľom je dôkaz uskutočniteľnosti, či je dátovo-riadený prístup na tento problém vhodný a dátá z jednej stanice na to postačujú.

Pre potreby našej práce sme vybrali stanicu umiestnenú v kanadskom meste Churchill, v severnej časti štátu Manitoba, na pobreží Hudsonovho zálivu. Presná poloha GNSS prijímača, použitá aj pri získavaní dát je  $58,759^{\circ}$  severnej zemepisnej šírky a  $-94,086^{\circ}$  východnej zemepisnej dĺžky. Nachádza sa približne 20 metrov nad úrovňou mora. Jedná sa o model PolaRxS od výrobcu Septentrio. V nasledujúcej časti uvádzame zoznam stĺpcov v rámci datasetu, spolu s ich krátkym vysvetlením.



**Obrázok 3 – 2** Ukážka nevyhovujúcich dát z troch GNSS staníc siete CHAIN.



**Obrázok 3 – 3** Ukážka korektných dát z troch GNSS staníc siete CHAIN.

### OMNIWeb:

- *Field magnitude average [nT]* - priemerná sila medziplanetárneho magnetického pola.
- *Bx, By, Bz [nT]* - zložky medziplanetárneho magnetického pola, ktoré je unášané spolu so slnečným vetrom. Komponenty Bx a By sú orientované rovnobežne s ekliptikou Zeme, ale pre aktivitu polárnej žiary je najdôležitejší komponent Bz, ktorý je kolmý na ekliptiku.
- *Lat. angle of B [deg], Long. angle of B [deg]* - zemepisná šírka a dĺžka medziplanetárneho magnetického pola.
- *SW speed [km/s]* - celková rýchlosť slnečného vetra.

- $V_x, V_y, V_z$  Velocity [ $km/s$ ] - x-ová, y-ová a z-ová zložka rýchlosť slnečného vetra.
- Proton density [ $n/cc$ ], Proton temperature [ $K$ ], Flow pressure [ $nPa$ ], Electric field [ $mV/m$ ] - hustota, teplota, tlak a elektrické pole (plazmy) slnečného vetra.
- SW plasma flow lat. angle [deg], SW plasma flow long. angle [deg] - zemepisná šírka a dĺžka prúdenia plazmy slnečného vetra.
- Alpha/Proton ratio - pomer alfa častíc a protónov v slnečnom vetre.
- Quasy Invariant - je pomer hustoty magnetickej energie a hustoty energie prúdu slnečného vetra.
- $K_p$  index - popisuje narušenie geomagnetického poľa, čím silnejší slnečný vietor, tým väčšia turbulencia. Index má hodnoty od 0 pre nízku aktivitu po 9, čo znamená, že prebieha intenzívna geomagnetická búrka.
- $R$  sunspot number - kvantifikuje počet slnečných škvŕn.
- $Dst$  index (disturbance storm time) - popisuje mieru oslabenia magnetického poľa Zeme, respektíve kvantifikuje závažnosť geomagnetických búrok. Čím má nižšiu hodnotu, tým je intenzita búrky vyššia.
- $ap$  index - index geomagnetickej aktivity, dni s vyššou úrovňou aktivity majú vyššiu hodnotu ap.
- $F10.7$  index - je miera žiarenia generovaného Slnkom o vlnovej dĺžke 10,7 centimetra.
- Lyman alpha index - Lyman alfa je spektrálna čiara vodíka. Toto žiarenie je emitované, keď atomárny elektrón prejde z orbitálu  $n=2$  do základného stavu, teda na orbitál  $n=1$ . Tento index udáva množstvo tohto žiarenia prichádzajúceho zo Slnka.

- *Plasma beta* - pomer tlaku slnečného vetra voči tlaku magnetického poľa.
- *Alfvén mach number* - machovo číslo udáva pomer rýchlosťi pohybu telesa určitým prostredím k rýchlosťi zvuku v tomto prostredí. Alfvénovo machovo číslo je špecifické pre rýchlosť Alfvénových vĺn v plazme. Ióny tahané preč zo zarovnania pozdĺž siločiar, sú opäť zachytené magnetickou silou a šíria sa ako vlna pozdĺž siločiar, ktorú nazývame Alfvénova vlna.
- *Magnetosonic mach number* - Magnetosonická vlna je pozdĺžna vlna iónov v zmagnetizovanej plazme šíriaca sa kolmo na stacionárne magnetické pole.
- *BSN (bow shock nose) location Xgse, Ygse, Zgse* - x-ová, y-ová a z-ová súradnica vrchola nárazovej vlny, ktorú vytvára konštantná interakcia slnečného vetra s magnetosférou Zeme.
- *AE, AU, AL index* - AE index (*Auroral electrojet*) je odvodený z horizontálnej zložky variácií geomagnetického poľa na vybraných 10-13 observatóriách pozdĺž aurorálnej zóny na severnej pologuli. Aby sa údaje znormalizovali, vypočítala sa pre každú stanicu základná hodnota spriemerovaním piatich najkľudnejších dní za mesiac. Táto hodnota sa následne odčíta od každého merania stanice. Najväčšie a najmenšie hodnoty z týchto observatórií, pre každú minútu, tvoria AU (*upper*) a AL (*lower*) index. Následne  $AE = AU - AL$ .
- *SYM/D, SYM/H, ASY/D, ASY/H* - popisujú geomagnetické poruchy v stredných zemepisných šírkach pozdĺž asymetrických (ASY) a symetrických (SYM) porúch pre zložky rovnobežné (H) a kolmé (D) na os magnetického dipólu Zeme.
- *PCN index* - monitoruje geomagnetickú aktivitu nad severnou polárnou čiapkou spôsobenú zmenami v medziplanetárnom magnetickom poli, bez ohľadu na čas, ročné obdobie a slnečný cyklus.

**IRI-2016** (každý z týchto parametrov je v datasete pre výšky 100, 150, 200, 250 a 300 km nad zemským povrhom):

- $ne [m^{-3}]$ ,  $Te [K]$ ,  $Ti [K]$  - hustota/počet elektrónov, teplota elektrónov, teplota iónov.
- $nO^+ [\%]$ ,  $nH^+ [\%]$ ,  $nHe^+ [\%]$ ,  $nN^+ [\%]$ ,  $nO_2^+ [\%]$ ,  $nNO^+ [\%]$ ,  $nCL [\%]$  - percentuálne zastúpenie iónov atomárneho kyslíka, atomárneho vodíka, atomárneho hélia, atomárneho dusíka, molekulárneho kyslíka, oxidu dusnatého a iónových zhľukov (*cluster ions*). Iónový zhľuk je ión vytvorený spojením dvoch alebo viacerých atómov alebo molekúl jedného alebo viacerých chemických druhov s iónom prostredníctvom nekovalentných síl.
- $NmF2 [m^{-3}]$ ,  $hmF2 [km]$  - hustota a výška maxima F2 vrstvy.
- $NmE [m^{-3}]$  - hustota maxima E vrstvy.
- $TEC$  (*total electron content*)  $[10^{16} m^{-2}]$  - je to celkový počet elektrónov integrovaných medzi dvoma bodmi (napr. GNSS prijímačom a satelitom) pozdĺž trubice s prierezom jeden štvorcový meter. Udáva teda množstvo voľných elektrónov v atmosfére.
- $foF2 [MHz]$  - kritická frekvencia ionosférickej F2 vrstvy.

**NRLMSISE-2000** (každý z týchto parametrov je v datasete pre výšky 100, 150, 200, 250 a 300 km nad zemským povrhom):

- $He [cm^{-3}]$ ,  $O [cm^{-3}]$ ,  $H [cm^{-3}]$ ,  $N [cm^{-3}]$ ,  $N_2 [cm^{-3}]$ ,  $O_2 [cm^{-3}]$ ,  $Ar [cm^{-3}]$  - počet častic hélia, atomárneho kyslíka, atomárneho vodíka, atomárneho dusíka, molekulárneho dusíka, molekulárneho kyslíka a argónu.
- $Total mass [g * cm^{-3}]$  - celková hmota atmosféry.

- *Anomalous oxygen [cm<sup>-3</sup>]* - Anomálny kyslík je horúci atomárny a jednotlivý ionizovaný kyslík, o ktorom sa predpokladá, že je prítomný v exosfére v blízkosti pólov počas ich príslušných letných období. Táto dodatočná zložka, rozširujúca hlavne vodíkovú a héliovú exosféru, je schopná vysvetliť neočakávané vysoké odporové sily na satelitoch prechádzajúcich blízko pólov počas ich leta.
- *Exospheric temperature [K], temperature at altitude [K]* - teplota exosféry, teplota v určitej výške atmosféry (100, 150, 200, 250, 300 km)

### **PyEphem:**

- *Sun altitude [deg]* - výška Slnka voči obzoru. Horné vrstvy sú osvetlované, až kým Slnko neklesne pod obzor o viac ako 18°.
- *Sun-Earth distance [AU]* - vzdialenosť Zeme od Slnka v astronomických jednotkách.

**Zdrojový dataset** (dáta získané zo štúdie McGranaghan et al. (2018)):

- *Newell CF (coupling function)* - takmer univerzálna funkcia spojenia slnečného vetra a magnetosféry odvodená z 10 premenných stavu magnetosféry (Newell et al., 2007).
- *OVATION diffuse eflux, OVATION mono eflux, OVATION wave eflux, OVATION diffuse nflux, OVATION mono nflux* - atribúty získané z modelu OVATION Prime (Newell et al., 2010). V poradí sú to difúzny tok, monoenergetický tok a vlnový tok energie elektrónov a počet elektrónov difúzneho toku. Tento model bol vytvorený z 11 rokov meraní (zhruba 50 satelitných rokov) a poskytuje štatistické rozloženie zrážok častíc v ionosfére. Ako vstup berie funkciu Newell CF. Vo svojej podstate slúži ako predikčný nástroj a umožňuje získať informácie o zrážkach pre akúkoľvek lokalitu, čo v súčasnosti priamym pozorovaním nie je možné. Tento model neuvádzame v kapitole 3.1 z toho dôvodu, že

sme s ním priamo nepracovali a tieto príznaky boli získané iba zo zdrojového datasetu.

- *dTEC 0min-15s to 0min-0s [TECU]* - rýchlosť zmeny parametra TEC počas 15-tich sekúnd pred pozorovaním.
- *SI [dimensionless]* - je to spektrálny index GNSS signálu. Spektrálny index je mierou závislosti hustoty toku žiarenia od frekvencie.
- *spectral slope [dimensionless]* - spektrálny sklon alebo tiež spektrálny gradient je mierou závislosti odrazivosti od vlnovej dĺžky.
- *S4 projected to vertical [dimensionless]* - intenzita amplitúdových scintilácií.
- *sigmaPhi projected to vertical [radians]* - intenzita fázových scintilácií.

Pri pochopení dát je potrebné venovať zvýšenú pozornosť parametru, ktorý chceme predikovať. V našom prípade je to index fázovej scintilácie –  $\sigma_\phi$ . Nakoľko sa nejedná o úplne surové dátá, ale o dátá pochádzajúce z podobnej štúdie, musíme sa oboznámiť aj s už vykonanou prípravou dát a zhodnotiť, či boli dané kroky dostačujúce alebo je potrebná dodatočná úprava.

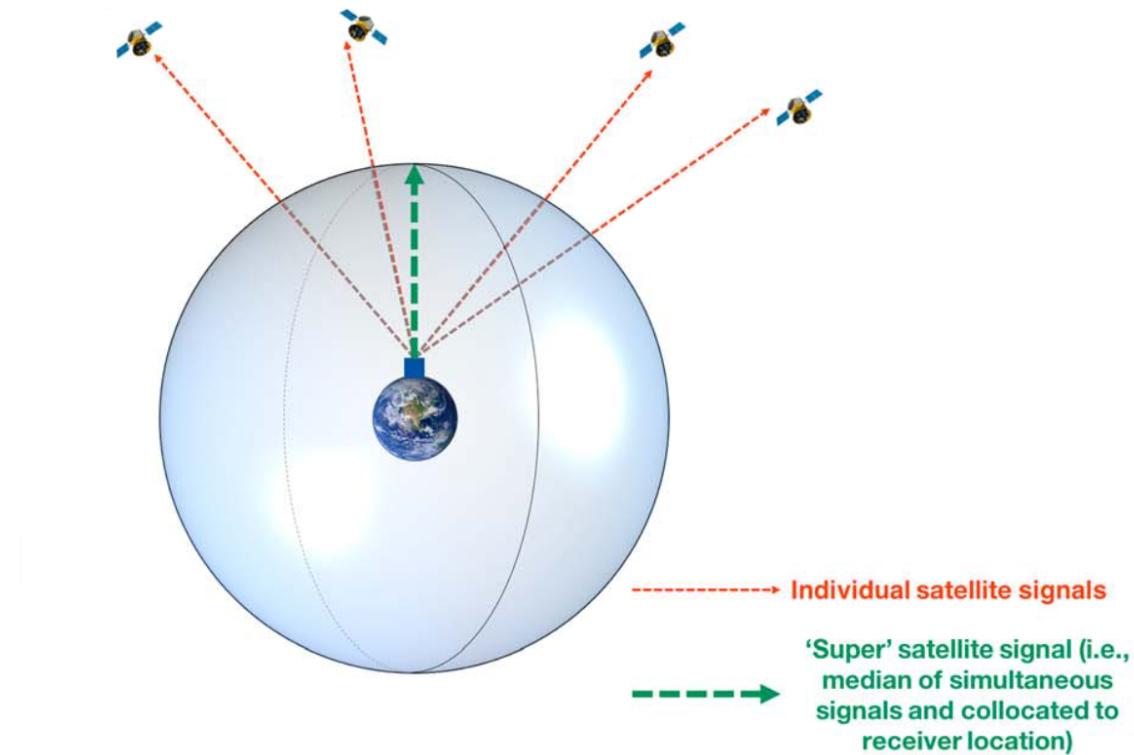
Každé meranie pôvodného datasetu obsahovalo jeden riadok pre jednu minútu komunikácie s konkrétnym satelitom. Kedže GNSS sateliity sú vzhľadom na pozorovateľa na Zemi v neustálom pohybe, tak vychádzajú a zachádzajú za horizont. Práve v týchto krajiných prípadoch je schopnosť prijímača zachytiť signál obmedzená, pretože ten musí prechádzať stále cez hrubšiu časť ionosféry. To zvyšuje šancu na modifikáciu signálu a tiež na vznik tzv. viaccestnej detekcie. To je prípad, kedy sa vyslaný signál satelitu v ionosfére okrem priamej cesty aj viackrát odrazí a prijímač následne zachytí minimálne dva rovnaké údaje, ale v iných okamihoch alebo rôzne údaje v rovnakých okamihoch. Takéto viaccestné signály sa od toho priameho väčšinou líšia vo výkone, oneskorení kódu, nosnej fáze a frekvencii, čo všetko skresluje korelačnú krivku medzi prijatým signálom a replikou vygenerovanou prijímačom,

čo vedie k chybám aj v desiatkach metrov. Pri analýze ionosféry to môže vytvárať falošné scintilácie medzi prijímačom a sledovaným satelitom. Z tohto dôvodu sa aplikuje dosť konzervatívna  $30^\circ$  maska, teda neberú sa do úvahy dátá zo satelitov, ktoré sa v okamihu merania nachádzali nižšie ako  $30^\circ$  nad obzorom.

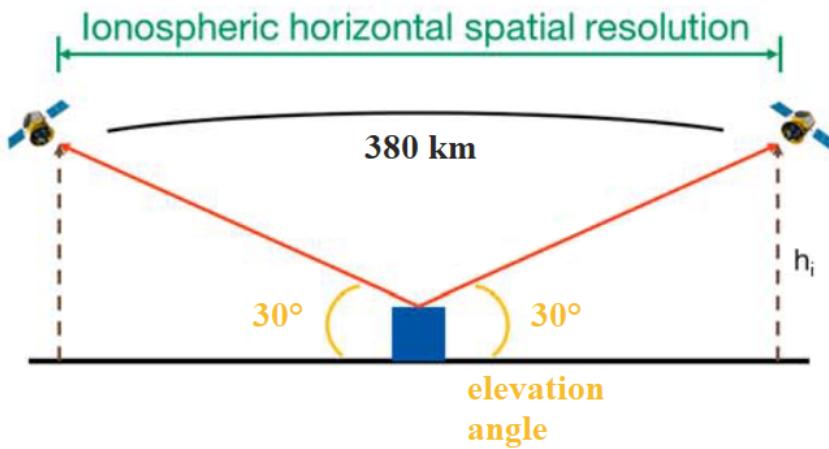
Ďalej boli z datasetu odstránené všetky údaje ovplyvnené stratou uzamknutia (*loss-of-lock*). Strata uzamknutia znamená, že prijímač už nesleduje signál presne. Navigačné správy sa nedajú ďalej dekódovať, čo vedie k menšiemu počtu použiteľných satelitov a teda sa zníži presnosť polohy. Takéto dátá sa dajú odstrániť pomocou parametra času uzamknutia, ktorý obsahujú surové dátá prijímača Septentrio. Odstránené boli všetky údaje, ktoré mali nepretržitý čas uzamknutia nižší ako 200 sekúnd.

Tretím krokom bola redukcia dát premietnutím šikmých signálov do zvislej polohy, vzhladom na geografickú polohu prijímača. Obrázok 3–4 poskytuje ilustráciu tohto kroku. Táto projekcia sa vypočítala pre tri parametre: TEC,  $S_4$  a  $\sigma_\phi$ . V každom okamihu je na oblohe viditeľných viacero satelitov (stále minimálne 6), ktoré sú rôzne ovplyvnené ionosférou. Takéto „superpozorovanie“ je mediánom všetkých pozorovaní pre danú oblasť a dokáže efektívne rozmazať informácie o priestore a vytvoriť tak hrubšie rozlíšenie. Z časovo-priestorového problému teda vznikne iba problém časového charakteru. V tom najhoršom prípade, kedy sú sately na opačných stranách oblohy, teda v azimute vzdialené o  $180^\circ$  a pri minimálnych akceptovaných stupňoch nad horizontom, je horizontálne priestorové rozlíšenie približne 380 km (viď. Obrázok 3–5). V realite sú sateliity po oblohe rozmiestnené pravidelnejšie, takže informácia je „hustejsia“ a teda presnejšia. Takáto transformácia zároveň vytvára čiastočnú rovnováhu medzi potrebami používateľov navigačného signálu, u ktorých je presná predikcia scintilácií veľmi žiadana a momentálnymi predikčnými schopnosťami. Pri predpovedaní scintilácií pre jednotlivé sateliity náročnosť úlohy značne narastá.

Tento prístup má aj svoje nevýhody a jednou z nich je, že sa strácajú informácie



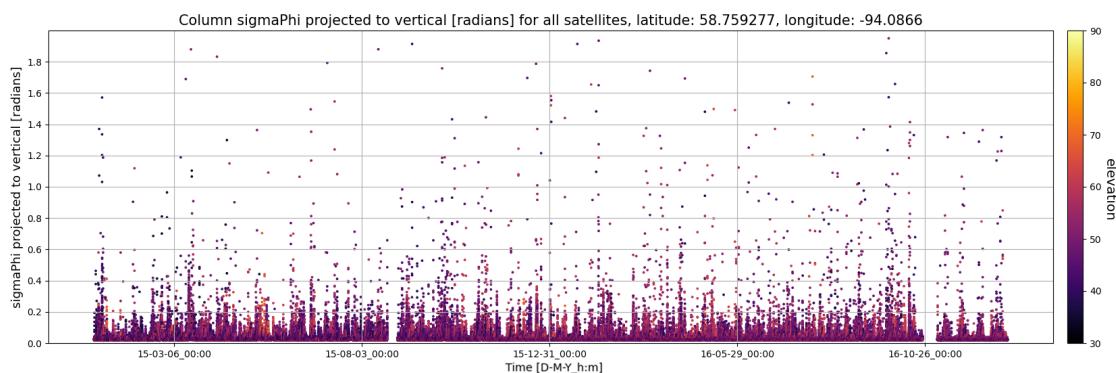
**Obrázok 3 – 4** Grafické znázornenie GNSS prijímača komunikujúceho s viacerými satelitmi (červené čiary) a spôsob vytvorenia „superpozorovania“ (zelená šípka). Zdroj: McGanaghan et al. (2018)



**Obrázok 3 – 5** Grafické znázornenie maximálnej horizontálnej dohľadnosti GNSS prijímača. Zdroj: McGanaghan et al. (2018)

o menších scintiláciách, rádovo v kilometroch až desiatkach kilometrov. Takýto krok podľa nás nemusí byť vždy vhodný a žiadúci. Napríklad pri redších sietach prijímačov by bolo bez tohto kroku možné zachytiť aj prípadné scintilácie vo väčšej vzdialosti, čím by sa vylepšila priestorová predikcia. Taktiež takýto prístup zamedzuje štúdiu jednej scintilácie z rôznych pohľadov, pretože každý prijímač sa virtuálne pozera iba nad seba. V budúcich štúdiách by preto bolo vhodné preskúmať riešiteľnosť tohto problému aj z priestorovo-časového hľadiska, i keď za cenu vyšších výpočtových nárokov a komplikovanejšieho spracovania dát.

Tak ako vo väčšine datasetov z reálneho sveta, aj tento obsahuje chýbajúce hodnoty. Posledným krokom je teda odstránenie riadkov s chýbajúcimi hodnotami v predikovanom stĺpci. V datasete zostalo 790 341 hodnôt, čo predstavuje približne 18 mesiacov meraní z dvoch rokov. Vizualizáciu hodnôt  $\sigma_\phi$  pre roky 2015 a 2016 zo stanice Churchill je možné vidieť na Obrázku 3 – 6. Na x-ovej osi je čas, y-ová udáva hodnotu parametra  $\sigma_\phi$  a farba jednotlivých bodov udáva výšku satelitu nad obzorom.



**Obrázok 3 – 6** Vizualizácia stĺpca  $\sigma_\phi$  pre GNSS prijímač zo stanice Churchill.

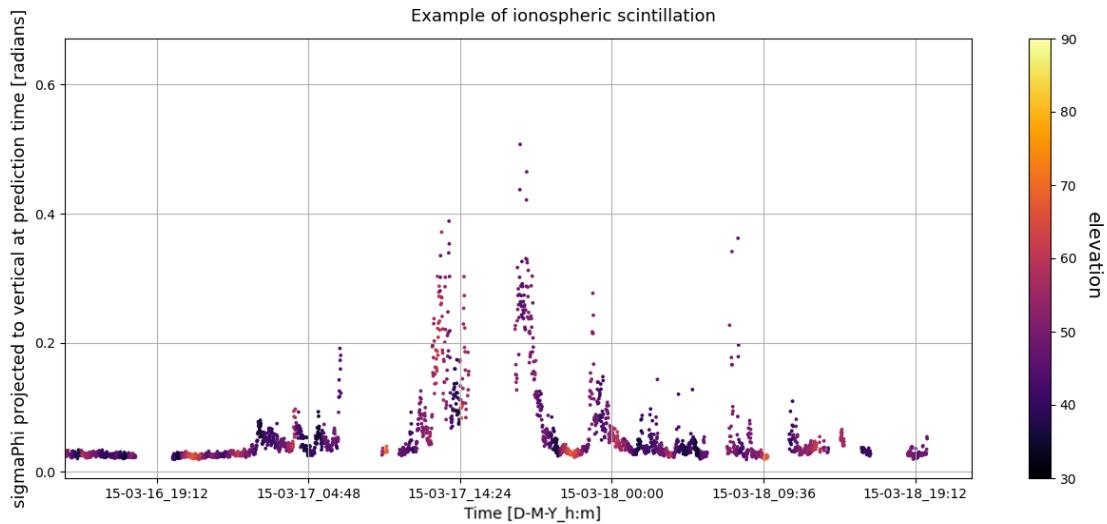
V podkapitole 1.3 sme si predstavili, čo sú scintilácie z fyzikálneho hľadiska. Pre úspešné vytvorenie predikčného modelu je tiež potrebné oboznámiť sa s tým, čo sú scintilácie z dátového pohľadu. V našej práci sa snažíme určiť, či nastane alebo nenaстane scintilácia na základe určeného prahu hodnôt  $\sigma_\phi$ . Aj keď sa líšia názory vedcov

na to, od akých prahových hodnôt už môžeme hovoriť o scintilácií, najčastejšie sa používa hodnota 0,2 alebo 0,1. My sa k tejto úlohe postavíme ako k regresnému problému a nie klasifikačnému. K tomuto rozhodnutiu sme dospeli po úvahе, že tvrdé rozdelenie na dve triedy by spôsobilo stratu informácie. Umocňuje to aj fakt, že pevná hranica vo vedeckej komunite nie je stanovená a je to výhodnejšie aj v praxi. Ak by mal užívateľ aplikácie závislej na navigačnom signále znalosť o tom, aká silná scintilácia nastane, tak by sa vedel sám rozhodnúť, či riziko vykonania nejakej akcie podstúpi alebo nie. Názorným príkladom by bola hodnota  $\sigma_\phi = 0,15$ . V takomto prípade by binárny klasifikátor povedal, že scintilácia nastane, avšak v realite sa jedná len o mierne narušenie atmosféry a navigačný signál bude s veľkou pravdepodobnosťou dostupný, s občasnými výpadkami. Druhým príkladom by bola hodnota  $\sigma_\phi = 1,5$ , pri ktorej by signál nemusel byť dostupný aj desiatky minút. V kritických aplikáciách, akými je letectvo, by to mohlo spôsobiť vážne problémy. Klasifikátor by ale oznámil len to, že scintilácia nastane. Z týchto dôvodov budeme prahovú hodnotu využívať iba pri vyhodnotení predikcie, ale trénovať budeme regresné modely. Podľa zdrojového článku našich dát (McGranaghan et al., 2018), sme si zvolili hraničnú hodnotu 0,1. V ňom autori uvádzajú dva dôvody takéhoto rozhodnutia. Prvým je, že je to štatisticky a geofyzikálne zmysluplná úroveň prispôsobená potrebám používateľov. Pre  $\sigma_\phi < 0,1$  je málo pravdepodobné a pre  $\sigma_\phi > 0,1$  je pravdepodobné, že dôjde k zníženiu výkonnosti GNSS signálu. Druhým dôvodom je aspoň čiastočné zníženie nerovnováhy pozitívnych a negatívnych udalostí, napokolko hodnoty nad 0,1 sú veľmi zriedkavé. V našom datasete s viac ako 700-tisíc meraniami je len 10 308 nad hodnotou 0,1; čo znamená, že pozitivita je len 1,3%. Pri vyššie zvolenom prahu, konkrétnie nastavenom na 0,2; by bola pozitivita len 0,3%. Ak by sa problém riešil pomocou klasifikácie, tak aj pre algoritmy strojového učenia je výhodnejšia nižšie nastavená hraničná hodnota, pretože by sa ľahšie hľadali súvislosti vo fyzikálnych parametroch, ktoré tam stále sú, len pri slabších scintiláciách nie sú také výrazné. Naviac, pre model by pri trénovaní mohlo byť mätúce, že určité hodnoty príznakov by viedli k negatívnemu prípadu a len jemne zvýšené tie isté príznaky k pozitív-

nemu. Faktom je, že pri scintiláciách hodnota  $\sigma_\phi$  často balansuje práve medzi 0,1 a 0,2.

V nasledujúcej časti sa pozrieme na konkrétnie prípady scintilácií v dátach. Na Obrázku 3–7 vidno silnú scintiláciu, ktorej vrchol trvá od 12:00 17.03.2015 do 19:00 toho istého dňa. Počas tejto doby hodnota parametra  $\sigma_\phi$  neklesla pod 0,2. Zaujímavé sú chýbajúce hodnoty uprostred obrázku, ktoré napovedajú, že scintilácia bola taká silná, že signál zo satelitov nebolo vôbec možné zachytiť. Z pohľadu predikcie sú práve takéto udalosti najdôležitejšie, keďže chýbajúca navigácia po dobu niekoľkých desiatok minút môže spôsobiť vážne problémy či už v lodnej alebo leteckej doprave. Problémom ale je, že pre toto obdobie nemáme referenčné hodnoty, a teda ich nevieme pri kontrolovanom type učenia použiť. Jedným z teoretických riešení by bolo doplniť tieto miesta dostatočne vysokými hodnotami signalizujúcimi úplnú stratu signálu, napríklad 1, ale v praxi to nie je také jednoduché ako sa zdá. Ako je možné vidieť v ľavom dolnom rohu Obrázku 3–7, tak aj tu sa objavujú chýbajúce hodnoty, ale nepredchádzajú im žiadne fluktuácie v ionosfére, ani žiadne tento výpadok nenasledujú. Najpravdepodobnejšie je, že príčinou chýbajúcich dát je iný problém ako scintilácia. Môže to byť softvérová chyba vo vnútri prijímača, výpadok elektrickej energie, dočasné externé zatienenie antény alebo iný hardvérový problém. Bohužiaľ z dostupných dát nevieme povedať, ktorý z prípadov nastal, a teda ani pri chýbajúcich dátach uprostred obrázka, v rámci kužeľa, nemôžeme s istotou povedať, že výpadok spôsobila scintilácia v ionosfére. Ako môžeme vidieť, tak počas dvoch dní došlo k nejakým výpadkom až 9-krát. To robí túto predikčnú úlohu ešte zložitejšou. Čiastočné riešenie by mohli poskytnúť surové dáta, z ktorých by bolo jasné, či došlo k výpadku elektrickej energie, pri ktorej by sa neuložili žiadne dáta alebo či došlo k softvérovej chybe v podobe zamrznutia procesu. Ani tie by ale neriešili všetky prípady, nakoľko mechanické zatienenie antény môže spôsobiť napríklad aj kŕdeľ vrabcov, ktorý si na ňu sadne. To by v dátach nebolo možné rozoznať.

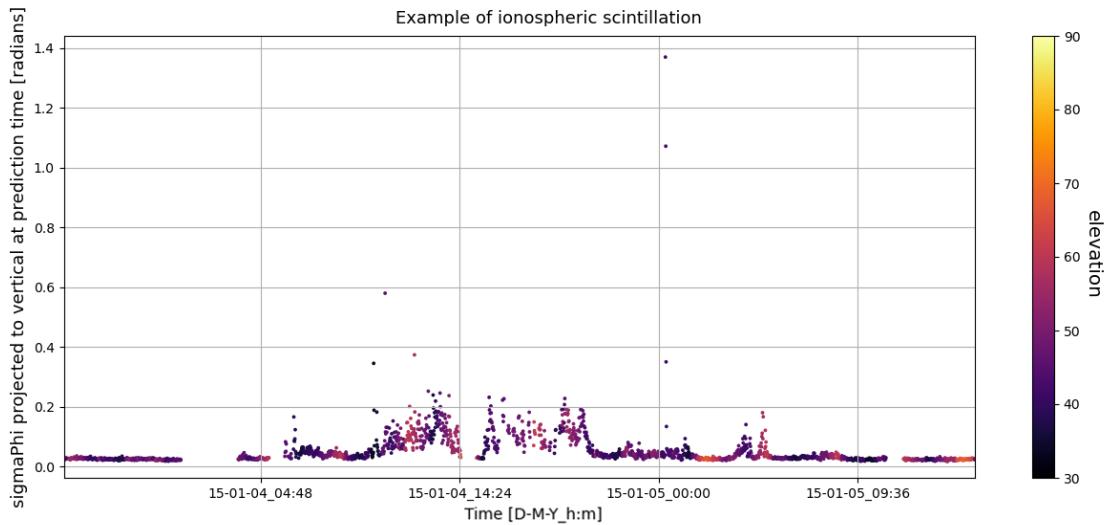
Na Obrázku 3–8 môžeme naopak vidieť miernu scintiláciu, pri ktorej nedošlo



**Obrázok 3 – 7** Vizualizácia individuálnej  $\sigma_\phi$  scintilácie.

k dlhotrvajúcemu výpadku. Priebeh tohto grafu zároveň poskytuje ďalší dôvod, prečo je k predikcií scintilácií lepšie pristupovať ako k regresnému problému a nie klasifikačnému, ako to robili autori McGranaghan et al. (2018). Hodnota  $\sigma_\phi$  osciluje okolo 0,1 a je zrejmé, že počas trvania ionosférickej fluktuácie je približne polovica meraní nad a polovica pod touto hranicou. Pri trénovaní binárneho klasifikačného modelu by to spôsobovalo protirečivé chybové signály, či sa jedná alebo nejedná o scintiláciu. V rámci modelu by tak vznikol nežiadúci šum. Preto by bolo vhodnejšie označiť ako pozitívnu triedu všetky merania, ktoré sa časovo nachádzajú v oblasti scintilácie, aj keď  $\sigma_\phi$  je pre niektoré menšia ako 0,1. Rozlíšiť pokojnú ionosféru od tej turbulentnej je relatívne jednoduché. Na ľavom aj pravom okraji Obrázka 3 – 8 si môžeme všimnúť, že počas obdobia kľudnej ionosféry nadobúda parameter  $\sigma_\phi$  takmer konštantné hodnoty do 0,05.

Rozsiahly dataset, ktorý sme vyššie v tejto kapitole predstavili celkovo pozostáva zo 175 stĺpcov. Všetky tieto parametre boli vybrané na základe pravdepodobnej existencie fyzikálnych vzťahov so scintiláciami vo vysokých zemepisných šírkach. Vyšší rozmer vstupných dát má však za následok nižší výkon algoritmov strojového



**Obrázok 3 – 8** Vizualizácia individuálnej  $\sigma_\phi$  scintilácie.

učenia. A to nielen z pohľadu výpočtových nárokov a teda dlhšieho času trénovania, ale aj z pohľadu úspešnosti predikcie, keďže sa zvyšuje informačný šum. Zlepšenie výkonu možno dosiahnuť odstránením málo informatívnych a vysoko korelujúcich atribútov. Pri počte stĺpcov 175 sa dá s istotou povedať, že viacero z nich bude medzi sebou mať silnú koreláciu.

### 3.2.1 Korelačná analýza

Na výpočet korelácie existuje viacero metód, ktoré majú k dátam rôzne prístupy a teda sa líšia aj výsledkami. My sme využili funkciu corr() z knižnice Pandas (Wes McKinney, 2010) v programovacom jazyku Python. Táto funkcia poskytuje 3 rôzne metódy výpočtu korelácií a to:

- Pearsonov/Výberový korelačný koeficient,
- Spearmanov korelačný koeficient,
- Kendallov koeficient tau.

Na naše dátá sme použili všetky tieto metódy a výsledné korelačné matice sme nahrali do príloh na priloženom CD, nakoľko sú príliš rozmerné na to, aby mohli byť čitateľne vytlačené. Preto výsledky uvádzame iba slovne. Za vysoko korelujúce atribúty sme považovali tie stĺpce, ktoré mali hodnotu korelácie v absolútnej hodnote  $\geq 0,8$ . Tento prah je zámerne zvolený taký vysoký, aby boli odstránené len stĺpce s takmer duplicitnou informáciou. Podľa Pearsonovej metódy túto podmienku spĺňalo 119 stĺpcov, podľa Spearmanovej 123 stĺpcov a podľa Kendallovej 95 stĺpcov. Vo veľkej miere sa jednalo o atribúty, ktoré pochádzajú z modelov NRLMSISE a IRI s rovnakým fyzikálnym významom, ale rôznymi výškami nad povrhom. V budúcnosti je preto postačujúce zahrnúť iba príznaky pre jednu, nanajvýš dve rôzne výšky, v ktorých sa scintilácie najčastejšie vyskytujú a to 200 a 300 km. Porovnaním jednotlivých výsledkov sme zistili, že vysoké korelácie vo všetkých troch použitých metódach vykazovalo 90 stĺpcov, aspoň v dvoch 28 stĺpcov a len v jednej sa vyskytovalo 11 stĺpcov. Zvyšných 50 stĺpcov neprekročilo nami zvolenú hodnotu korelácie so žiadnym ďalším príznakom a preto sme pri výpočte významnosti, ktorú popíšeme nižšie, pracovali už len s touto podmnožinou.

Ďalej sme sa v rámci korelačnej analýzy zameriavali na parametre, ktoré chceme predikovať. V našom prípade to je hodnota scintilačného indexu  $\sigma_\phi$ , pričom sa ju snažíme predpovedať pre štyri rôzne časy v budúcnosti: 1 minútu, 5 minút, 15 minút a 1 hodinu dopredu. Stĺpec  $\sigma_\phi$  s týmito posunmi sme preto pridali do nášho datasetu ako samostatné stĺpce pred výpočtom jednotlivých korelácií. Pearsonova metóda podľa očakávaní mala veľmi nízke hodnoty závislostí, keďže je schopná zachytávať iba lineárne vzťahy a ionosférické scintilácie sú komplexný a predovšetkým nelineárny proces. Najvyššia hodnota korelácie vyšla pre všetky štyri posuny so stĺpcom *AE-index* a to 0,25. Ďalšie stĺpce s hodnotami okolo 0,2 boli *ASY/H*, *Kp index*, *ap index*, a všetky stĺpce modelu OVATION. Najviac zaujímavý je ale stĺpec *spectral slope*. Ten na rozdiel od ostatných, ktoré vykazujú približne konštantné hodnoty pre všetky časové posuny, vykazoval pre jednotlivé posuny zostupnú koreláciu. Hodnota

korelácie pre  $\sigma_\phi$  o minútu dopredu bola 0,38 a pre hodinu dopredu už len 0,18.

Druhou skúmanou bola Spearanova metóda. Tá na rozdiel od Pearsonovej funguje aj pre monotónne vzťahy. Monotónny vzťah je taký, pri ktorom keď jedna veličina stúpa, tak stúpa aj druhá alebo keď jedna stúpa, tak druhá klesá. Nie je ale potrebné, aby porovnávané veličiny klesali/stúpali konštantnou rýchlosťou ako pri lineárnom vzťahu. Táto metóda je pre korelačnú analýzu nášho problému vhodnejšia, čo sa odzrkadlilo aj na výstupnej matici. Jednotlivé časové posuny korelovali s oveľa väčším počtom stĺpcov. Napríklad korelácia pre silu medziplanetárneho magnetického poľa bola na hodnote 0,2. Za pozornosť ale stojí fakt, že korelovala iba z-ová zložka a x-ová s y-ovou boli na hodnote 0. Pre zmenu pri parametroch slnečného vetra existuje slabá záporná korelácia s x-ovou zložkou, ale pri zvyšných dvoch osiach korelácia nie je. Zaujímavá je tiež korelácia všetkých časových posunov  $\sigma_\phi$  s takmer každým parametrom modelu IRI minimálne na hodnote 0,2; čo dáva zmysel, nakoľko IRI je semi-empirický model ionosféry. Z pohľadu konkrétnych prvkov je celkovo najsilnejšia korelácia s atomárnym kyslíkom vo výške 200 km. To súvisí s tým, že ionizácia kyslíka je hlavným zdrojom volných elektrónov v ionosfére. Najsilnejšie korelácie však boli pre rovnaké stĺpce ako pri Pearsonovej metóde, ale tentokrát na hodnotách medzi 0,4 a 0,5. Kedže Spearanova a Kendallova metóda sú si veľmi podobné, tak výsledky druhej menovanej nebudeme rozoberať. Neukázali sa v nej žiadne nové súvislosti, ktoré by neboli spomenuté pri predchádzajúcich dvoch metódach.

Radi by sme však uvideli korelačnú závislosť medzi stĺpcom  $\sigma_\phi$  a od neho odvodenými stĺpcami. Hodnoty pre jednotlivé metódy môžeme vidieť v Tabuľke 3 – 1. Podľa predpokladov korelácia je tým nižšia, čím dalej v čase sa posúvame. Pozoruhodná je však rýchlosť klesania týchto hodnôt. To svedčí o tom, že scintilácie sú veľmi dynamické atmosférické fluktuácie, ktoré sa v čase veľmi rýchlo menia. Z pohľadu korelačnej analýzy je ale samotná hodnota  $\sigma_\phi$  z minulosti jedným z najužitočnejších parametrov na predikciu jej budúcej hodnoty.

**Tabuľka 3 – 1** Korelačná analýza stĺpca  $\sigma_\phi$  a od neho odvodenými stĺpcami  $\sigma_\phi$  posunutými o 1, 5, 15 a 60 minút dopredu.

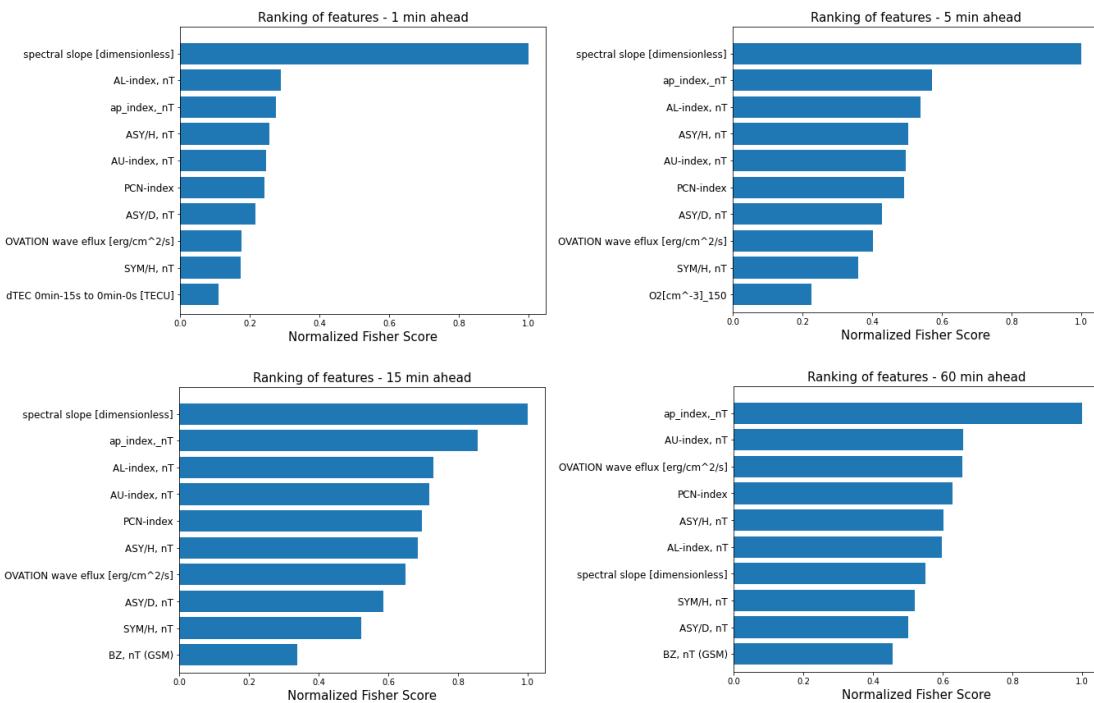
	<b>o 1 min</b>	<b>o 5 min</b>	<b>o 15 min</b>	<b>o 60 min</b>
<b>Pearson</b>	0,64	0,28	0,19	0,12
<b>Spearman</b>	0,75	0,69	0,64	0,50
<b>Kendall</b>	0,56	0,51	0,46	0,34

### 3.2.2 Významnosť príznakov

Na výber významných príznakov sme využili analýzu rozptylu (*Analysis of variance - ANOVA*). Je to široko používaná a výpočtovo efektívna štatistická technika, ktorá sa používa na kontrolu toho, či sa priemery dvoch alebo viacerých skupín navzájom výrazne líšia. Používa F-testy na štatistické testovanie priemerov. Tento prístup predpokladá, že vstupné príznaky sú nezávislé s normálnym rozdelením a rovnakým neznámym rozptylom. Ďalej predpokladá, že náhodné veličiny vo vnútri jednej skupiny majú rovnaké stredné hodnoty a medzi rôznymi skupinami môžu, ale nemusia, mať rôzne stredné hodnoty. Malé skóre naznačuje, že tieto dve skupiny majú podobný priemer, zatiaľ čo veľké hodnoty znamenajú, že sú odlišné.

Obrázok 3 – 9 zobrazuje výsledky tejto analýzy pre hodnotu  $\sigma_\phi$  1, 5, 15 a 60 minút dopredu. Stĺpec so súčasnými hodnotami  $\sigma_\phi$  v čase 0 minút sme z tejto analýzy vynechali, nakoľko jeho informatívnosť oproti ostatným príznakom bola značne vyššia. Uvádzame iba 10 najvýznamnejších príznakov. Pre prvé 3 časové posuny dosahuje najvyššie skóre príznak *spectral slope*, ktorý bol aj najviac korelujúcim s týmito stĺpcami. Z fyzikálneho hľadiska to naznačuje, že podmienky súčasnej fázy scintilácie sú informatívnejšie ako ktorýkoľvek iný individuálny stĺpec. To súvisí s tým, že životnosť ionosférických fluktuácií vo vysokej zemepisnej šírke je štatisticky dlhšia ako jedna hodina. Nasledujúcich 6 významných príznakov súvisí s geomagnetickou aktivitou. Aj pre ňu platí, že povaha zmien má vo väčšine prípadov periódu dlhšiu ako 60 minút. Obidva faktory napovedajú, že ionosféra v týchto priestorových mier-

kach vykazuje „pamäť“ aspoň v časovom rozmedzí hodiny a teda v tomto rozsahu môže byť predvídateľná. Taktiež existuje predpoklad, že priestorovo väčšie scintilácie majú dlhšie trvanie ako tie menšie. V rámci nasledujúcich štúdií by preto možno bolo vhodné získať dátu, kde sa priestorová zložka nenormalizuje do vertikálneho smeru vzhľadom na polohu prijímača. Po týchto desiatich najvýznamnejších príznakoch ďalej nasledovali stĺpce modelu OVATION, parametre slnečného vetra a koncentrácie molekulárneho kyslíka. Kompletné tabuľky tejto analýzy sú na priloženom CD v prílohách.

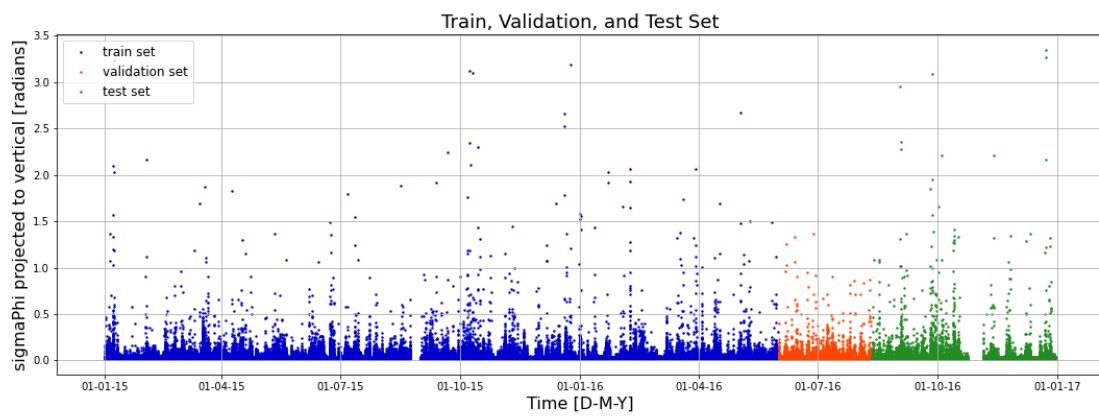


**Obrázok 3–9** Analýza významnosti príznakov pre predikciu jednotlivých stĺpcov  $\sigma_\phi$  o 1, 5, 15 a 60 minút dopredu.

### 3.3 Experimenty

V tejto časti našej práce sa budeme venovať trénovaniu modelov. Vyskúšali sme značné množstvo rôznych prístupov, modifikácií architektúr a zmien hyperparametrov, ktoré opíšeme a uvedieme porovnania. Nebudeme sa podrobne venovať kaž-

dému modelu, ale len tým, ktoré priniesli zaujímavé poznatky o charaktere problému a mohli by byť užitočné v nadväzujúcich štúdiách. Všetky trénovania prebiehali na jednom počítači pri konštantnom zatažení, takže ak bol učiaci čas jednej metódy nižší ako pri inej, tak je to objektívne porovnanie. Samozrejme pri využití slabšieho alebo výkonnejšieho stroja by bolo trénovanie pomalšie, respektíve rýchlejšie. Pri tvorbe modelov sme postupovali od jednoduchších k zložitejším. Keďže rôzne prístupy si vyžadovali rôzne predspracovanie dát, tak ho neuvádzame samostatne, ale na začiatku každej podkapitoly uvedieme jednotlivé úpravy a dôvody, prečo sme ich urobili. Jeden krok bol však spoločný a ním je rozdelenie dát na trénovaciu, testovaciu a validačnú množinu. Na trénovanie sme vyčlenili 70% datasetu, testovacia množina pozostávala z 20% datasetu a zvyšných 10% zostalo na validáciu. Rozdelenie nebolo náhodné, ale zachovávalo časovú následnosť, aby sa predišlo vplyvu testovacích dát na tréning. Na Obrázku 3 – 10 môžeme vidieť toto rozdelenie graficky. Ako sme uvideli vyššie, budeme sa snažiť vytvoriť regresné predikčné modely schopné predpovedať hodnotu scintilačného indexu  $\sigma_\phi$  o minútu, 5 minút, 15 minút a hodinu dopredu.



**Obrázok 3 – 10** Vizualizácia rozdelenia datasetu na trénovaciu množinu (modrá), validačnú množinu (oranžová) a testovaciu množinu (zelená).

Modely budeme porovnávať na základe ich výkonnosti na testovacej množine. Prvým kritériom bude priemerná absolútна chyba opísaná v kapitole 2.3, keďže sa

jedná o regresnú úlohu. Problémom však je, že stĺpec  $\sigma_\phi$  obsahuje veľké množstvo nízkych hodnôt, ktoré túto chybu tahajú nadol a nás zaujímajú práve zriedkavé vysoké hodnoty. Priemerná hodnota  $\sigma_\phi$  je len 0,031. Z tohto dôvodu bude druhým používaným kritériom porovnanie konfúznych matíc, ktoré vygenerujeme z predikovaných hodnôt použitím prahu 0,1. Všetky hodnoty  $\sigma_\phi < 0,1$  budú považované za negatívnu triedu, teda že scintilácia nenastane a hodnoty  $\sigma_\phi \geq 0,1$  budú považované za pozitívnu triedu a budú znamenať, že scintilácia nastane. Pre jednoznačnosť na Obrázku 3 – 11 uvádzame rozloženie hodnôt v konfúznej matici tak, ako ich používame vo zvyšku práce. Na označenie jednotlivých častí budeme používať anglické skratky, pretože v komunite strojového učenia je to bežnejšie a slovenské ekvivalenty by mohli byť mätúce.

		Predikovaná hodnota	
		negatívna	pozitívna
Skutočná hodnota	negatívna	TN	FP
	pozitívna	FN	TP

**Obrázok 3 – 11** Ukážka konfúznej matice a jej rozdelenia.

Ďalej zavedieme aj pojmy presnosť a návratnosť, aby bola konfúzna matica ľahšie kvantifikateľná a nebolo potrebné ju pri každom modeli uvádzať vo forme tabuľky:

$$\text{presnosť} = \frac{TP}{TP + FP} \quad \text{a} \quad \text{návratnosť} = \frac{TP}{TP + FN}. \quad (3.1)$$

### 3.3.1 Dopredné neurónové siete

Prvým prístupom, ktorý sme vyskúšali bolo použiť na predikciu jednoduchú doprednú neurónovú sieť. Výhodou je jednoduchosť a relatívne priamočiara príprava

dát, nevýhodou ale je, že nedokáže zachytíť časové následnosti v dátach. Príprava dát spočívala v min-max normalizácii dát a vo vytvorení vektora váh pre jednotlivé trénovacie prípady. Nakolko je dataset veľmi nevyvážený, tak by neurónová sieť mohla mať tendenciu approximovať iba nízke hodnoty. To sa dá vyriešiť tým, že triede, ktorá je menej početná, priradíme vyššiu váhu a neurónová sieť jej tým pádom bude v trénovacom procese venovať vyššiu pozornosť. Uvedieme výsledky tréningu s použitím tohto vektora, ale aj bez neho.

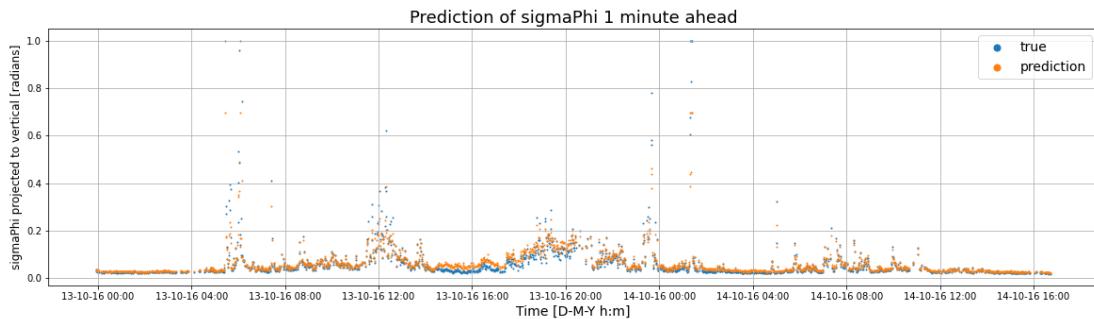
Naša základná sieť z ktorej sme vychádzali obsahovala 3 skryté vrstvy, pričom na každej bolo 256 neurónov. Pre každú z týchto vrstiev bol nastavený dropout 0,3; teda každý neurón mal 30% šancu, že sa nezúčastní trénovania ani predikcie. Skrytými aktivačnými funkciami boli funkcie ReLU. Na výstupnej vrstve bol jeden neurón s lineárhou aktivačnou funkciou. Ako hodnotiacu funkciu pri trénovaní sme použili priemernú kvadratickú chybu. Tá sa viac zameriava na extrémne hodnoty ako priemerná absolúttna chyba, a preto je na takýto typ problému vhodnejšia. Druhú menovanú sme ale v tréningu taktiež použili a to pri predčasnom zastavení, kde fungovala ako chybová funkcia pre validačnú množinu. Predčasné zastavenie bolo nastavené na 20 epoch, čiže ak sa 20 po sebe nasledujúcich epoch model nezlepší, tak sa učenie zastavilo. Pri učení sme využili optimalizátor Adam a pred každou epochou sa trénovacie príklady náhodne premiešali. Takéto premiešanie slúži na to, aby sa neurónová sieť snažila approximovať hľadanú funkciu čo najväčšejšie. Ak by pri obyčajnej doprednej neurónovej sieti bol parameter premiešania vypnutý, tak by sa mohlo stať, že by sa sieť naučila iba posledné príklady a tie čo videla ako prvé by zabudla.

Ako prvú sme riešili predikciu hodnoty  $\sigma_\phi$  o jednu minútu dopredu a pri trénovaní sme použili len prvých 5 stĺpcov podľa významnosti z kapitoly 3.2.2. Trénovanie jednej epochy trvalo približne minútu. Taktiež sme využili váhovanie trénovacích príkladov, kedy hodnoty  $\sigma_\phi$  nad 0,1 mali 10-krát vyšší dopad na úpravu váh ako hodnoty pod 0,1. Aj keď bolo trénovanie nastavené na 50 epoch, najlepší model bol

nájdený už v druhej epoche a odvtedy sa nezlepšoval. Na testovacej množine tento model dosiahol chybu  $MAE = 0,0133$ , návratnosť 91% a presnosť 20%. To znamená, že model správne predpovedal 91% scintilácií, ale falošná pozitivita bola tiež veľmi vysoká. Iba každá piata predpovedaná scintilácia bola reálna a zvyšné 4 boli planý poplach.

Nakoľko sa model veľmi rýchlo prestal učiť, tak sme znížili regularizáciu. Odstránili sme dropout zo všetkých skrytých vrstiev, takže celá siet sa naplno zúčastňovala tréningu aj predikcie. To prinieslo zlepšenie v presnosti, kedy bola reálna každá treťia predikovaná scintilácia. Návratnosť klesla na hodnotu 85%. Stále nízka presnosť nám napovedala, že pozitívne príklady sú príliš favorizované a tak sme znížili ich dopad na učenie len na trojnásobok oproti hodnotám  $\sigma_\phi$  pod 0,1. Týmto sme dosiahli chybu  $MAE = 0,0045$  a presnosť 75%. Rozhodli sme sa teda pokračovať v nastolenom trende a úplne sme vypli váhovanie trénovacích príkladov. Tým sa ukázalo, že naša pôvodná úvaha, že to prinesie lepšie výsledky, bola nesprávna, pretože sme dosiahli  $MAE = 0,0033$ , presnosť 92% a návratnosť 93%. Ďalšími zmenami hyperparametrov sme nedosiahli lepšie výsledky, takže sme sa rozhodli vrátiť k dátam. Pridali sme ďalšie stĺpce na vstup neurónovej siete a to konkrétnie prvých 10 najvýznamnejších príznakov z ANOVA analýzy. Tento krok rovnako nepriniesol výrazné zlepšenie a výkonnosť siete zostala na približne rovankých hodnotách.

Následne sme pristúpili k zmene architektúry siete. Pridali sme ďalšiu skrytú vrstvu a počty neurónov sme zvýšili od vstupnej po výstupnú vrstvu na hodnoty 10, 512, 512, 256, 128 a 1. Zvýšenie komplexnosti modelu podľa očakávaní predĺžilo čas trénovania na niečo vyše dvoch minút na epochu, ale bez výrazného zlepšenia v predikcii, hodnoty konfúznej matice zostali rovnaké. Za zmienku určite stojí aj zjednodušenie architektúry modelu, kedy sme počet skrytých vrstiev znížili na jednu s 256 neurónmi. Takáto neurónová sieť dosiahla výsledky  $MAE = 0,0025$ , presnosť až 99%, ale návratnosť sa znížila na 59%.



**Obrázok 3 – 12** Predikcia hodnoty  $\sigma_\phi$  1 minútu dopredu pomocou klasickej doprednej neurónovej siete.

Z vykonaných experimentov vyplýva, že pri použití klasickej doprednej neurónovej siete na predikciu  $\sigma_\phi$  o minútu dopredu postačuje naša základná architektúra opísaná na začiatku. Tiež platí, že sa dá dosiahnuť vyššia presnosť na úkor návratnosti a naopak, napríklad pomocou váhovania vstupov. V praxi je dôležitejšia vyššia návratnosť ako presnosť, lebo falošný poplach výpadku navigačných služieb je menej nebezpečný ako neočakávaná strata signálu. Na Obrázku 3 – 12 môžeme vidieť úspešnosť predikcie pre konkrétnu scintiláciu a v Tabuľke 3 – 2 vidíme konfúznu maticu najlepšieho modelu.

**Tabuľka 3 – 2** Konfúzna matica predikcie hodnoty  $\sigma_\phi$  o 1 minútu dopredu pomocou klasickej doprednej neurónovej siete.

TN = 124 533	FP = 98
FN = 82	TP = 1148

Pri predikcii hodnoty  $\sigma_\phi$  o 5 minút dopredu sme postupovali podobným spôsobom. Začali sme so základnou sieťou, ale tentoraz bez dropoutu a váhovania vstupov. Prvý dosiahnutý výsledok bol presnosť 44%, MAE = 0,0053 a návratnosť len 10%. Predikcia ďalej v čase je o čosi ľahšia úloha, ale s takouto slabou výkonnosťou je model nepoužiteľný. Takže sme skúsili opäť pridať váhovanie trénovacích príkladov a tentokrát to prinieslo zlepšenie. Pri rovnakej architektúre modelu a rovnakých

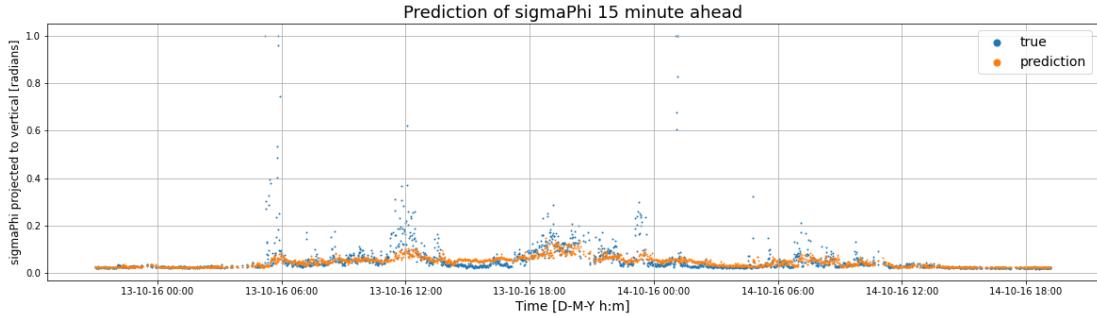
hyperparametroch návratnosť dosiahla 41% a presnosť 33%, pri hodnote MAE = 0,0061. Vzhľadom na výsledky bolo našim nasledujúcim krokom pridanie dodatočných príznakov na vstup a zvýšenie počtu skrytých neurónov na 512. Vďaka tomu sa model opäť o čosi zlepšil. Na metrikách sa to prejavilo zvýšením presnosti na 36%, návratnosť zostala rovnaká. Ďalšími úpravami, ktoré nejdeme podrobne rozoberať sa nedosiahli výrazné zlepšenia a výkonnosť skôr stagnovala. Konfúznu maticu z najúspešnejšieho modelu uvádzame v Tabuľke 3 – 3.

**Tabuľka 3 – 3** Konfúzna matica predikcie hodnoty  $\sigma_\phi$  o 5 minútu dopredu pomocou klasickej doprednej neurónovej siete.

TN = 117 487	FP = 842
FN = 676	TP = 471

Pokračovali sme predikciou o 15 minút dopredu. Základná neurónová sieť bez váhovania vstupov síce dosiahla MAE = 0,0058, ale návratnosť bola len 2%. Postupne sme teda zvyšovali váhy pre pozitívne príklady a pridávali príznaky. Najvyváženejší model dosiahol návratnosť 20% a presnosť 32%, pri MAE = 0,0079. Pre praktickú aplikáciu je návratnosť o čosi dôležitejšia, takže sme sa nastavili váhu pre pozitívne trénovacie príklady až na 15-násobok váhy tých negatívnych. Vďaka tomu sme dosiahli návratnosť 67% pri presnosti 7%. To znamená, že model správne predikoval 2/3 skutočných scintilácií. Avšak na každú pravdivo pozitívnu scintiláciu pripadá 13 falošne pozitívnych.

Ako môžeme vidieť na Obrázku 3 – 13, tak model dokáže zachytiť trend. To znamená, že pri pokojnej ionosfére vracia nízke, približne konštantné hodnoty a pri fluktuačiách predikuje nepravidelné hodnoty s väčším rozptylom. Má však problémy odhadnúť presné hodnoty a preto v metrikách dosahuje nízku výkonnosť. V nadväzujúcich štúdiách by z tohto dôvodu bolo vhodné preskúmať možnosť vytvorenia vlastnej metriky, ktorá by bola založená na nepravidelnosti, respektíve rozptyle v rámci malého časového okna v budúcnosti.

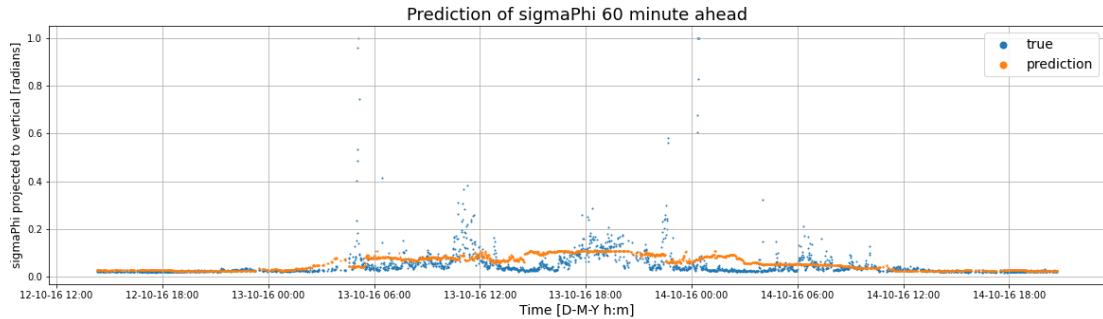


**Obrázok 3 – 13** Predikcia hodnoty  $\sigma_\phi$  15 minút dopredu pomocou klasickej doprednej neurónovej siete.

Posledným stĺpcom, ktorý sme sa snažili predikovať, je posunutie hodnoty  $\sigma_\phi$  o hodinu dopredu. Táto úloha je spomedzi predchádzajúcich najťažšia. Opäť, bez zvýraznenia vplyvu pozitívnych prípadov na učiaci proces model trafil len 30 hodôňov z približne 1000, ktoré sú väčšie ako 0,1. Začali sme preto s našou základnou architektúrou, piatimi najvýznamnejšími príznakmi a negatívne príklady mali 10-krát menší dopad na optimalizáciu váh neurónovej siete. S týmito nastaveniami sme dosiahli MAE = 0,026, návratnosť 56% a presnosť 4,5%. Následnými modifikáciami hyperparametrov a kombináciou rôznych vstupných príznakov sa nám podarilo naštrenať model s MAE = 0,011, návratnosťou 44% a presnosťou 10%, ktorý je o niečo lepší. Táto neurónová sieť, rovnako ako pri predikcii hodnoty  $\sigma_\phi$  o 15 minút, dokáže zachytiť trend. Na Obrázku 3–14 si treba všimnúť, že model správne odhadol blížiacu sa scintiláciu zvýšením predikovanej hodnoty a odhadol aj koniec scintilácie návratom na pokojné hodnoty ešte skôr ako skončila samotná scintilácia. Tieto zmeny teda predvídal s viac ako hodinovým predstihom, aj keď má problém predikovať presné hodnoty.

### 3.3.2 Autoregresné modely

Tieto komplikovanejšie typy sietí sme sa rozhodli najprv otestovať tak, že jediným vstupným príznakom bude súčasná hodnota  $\sigma_\phi$  a budeme sa snažiť predpovedať jej hodnotu rovnako pre 1, 5, 15 a 60 minút dopredu. Takýto prístup by mohol



**Obrázok 3 – 14** Predikcia hodnoty  $\sigma_\phi$  60 minút dopredu pomocou klasickej doprednej neurónovej siete.

fungovať najmä pre 1 a 5 minút dopredu, nakoľko korelácia týchto stĺpcov medzi sebou je vysoká. Rovnako by tento spôsob trénovania mohol poskytnúť odpoveď na otázku, aké široké by malo byť časové okno, aby v ňom LSTM vrstva dokázala zachytiť scintilačný trend.

Pred samotným trénovaním je potrebné urobiť prípravu dát, pretože 1-dimenzionálna konvolučná aj LSTM vrstva na svoj vstup neberú len jeden riadok dát, ale celé dátové okno. Na tento účel sme využili funkciu *TimeseriesGenerator* z knižnice Keras (Gulli and Pal, 2017). Tá vytvorí z datasetu jednorozmerné vektory po sebe nasledujúcich hodnôt, ktoré sú už vhodné na vstup do takejto neurónovej siete. Vytvorili sme jeden generátor pre trénovaciu, validačnú aj pre testovaciu množinu dát. Náš dataset má ale dva problémy, na ktoré treba myslieť. Prvým je značné množstvo chýbajúcich hodnôt, ktoré sú rovnomerne rozložené po celom datasete. Tie nebolo možné pred vytvorením časových okien odstrániť, lebo by sa stratila časová následnosť niektorých dát. Tento problém sme vyriešili odstránením všetkých okien, ktorým chýbala nejaká hodnota. Druhým problémom je nevyváženosť skúmaných dát. Preto sme si zo všetkých trénovacích okien vytvorili dve množiny. V prvej boli okná, ktoré obsahovali aspoň jednu hodnotu  $\sigma_\phi \geq 0,1$  a v druhej boli zvyšné okná. Veľkosťou je prvá množina približne 10-krát menšia ako druhá. Týmto krokom vieme nastavovať pomer pozitívnych príkladom voči negatívnym počas trénovania tak, aby sieť neap-

roximovala iba nízke hodnoty. Validačný aj testovací generátor časových radov sme nechali bez zmeny, aby odzrkadľovali reálny pomer dát. Odstránili sme z nich len okná s chýbajúcimi hodnotami, ktoré by sa aj tak nedali použiť.

V tomto prípade je našou základnou architektúrou neurónová sieť s konvolučnou vrstvou na začiatku. Táto vrstva vykonáva jednorozmernú konvolúciu a obsahuje 256 filtrov veľkosti 6. Za ňou nasleduje obojsmerná LSTM vrstva s 256 neurónmi. Po nej idú dve plne prepojené skryté vrstvy s 256 neurónmi a ReLU aktivačnou funkciou. Na konci je jeden výstupný neurón s lineárной aktiváciou, respektíve bez aktivácie.

Pri predikcii o jednu minútu dopredu sme vyskúšali okrem základnej architektúry aj modifikácie ako napríklad pridať dropout s hodnotou 0,3; znížiť počet skrytých vrstiev, znížiť počet neurónov, zvýšiť počet neurónov, použili sme veľkosti okien pre vstupné dát 5, 10, 15 aj 30 a vyskúšali sme aj meniť veľkosť konvolučných filtrov. Voči všetkým úpravám bola výkonnosť pomerne robustná. Najnižšia dosiahnutá hodnota MAE bola 0,0041 a najvyššia 0,0049. Čo sa týka presnosti, tak najvyššia dosiahnutá bola 67% a najlepšia návratnosť sa dostala na úroveň 59%.

Predikcia o 5 minút na tom bola veľmi podobne, čo sa týka necitlivosti na zmeny. Model na nich reagoval len minimálne. Výkonnosť z pohľadu metrík ale bola o poznanie nižšia oproti 1-minútovej predpovedi. MAE sa hýbala medzi hodnotami 0,0051 a 0,0057. Najlepšia presnosť a návratnosť boli v poradí 44% a 23%.

Zvyšné dva stĺpce uvedieme spoločne. Zmeny v hyperparametroch a architektúre znova takmer neovplyvnili metriky. Zaujímavé však je, že zníženie počtu vstupných okien bez scintilácie posunuli predikcie modelu daným pomerom smerom k vyšším hodnotám. To je pravdepodobne spôsobené tým, že sa neurónová sieť naučila čiastočne approximovať funkciu s vyšším priemerom, aký je reálne v dátach. Na predikciu o 15 a 60 minút jednoducho samotný stĺpec súčasných hodnôt  $\sigma_\phi$  nestačí. Takýto výsledok sice bol očakávaný, ale predpokladali sme, že bude možné dosiahnuť aspoň

o čosi lepšiu návratnosť. Tá dosiahla pri 15-minútovej predikcii hodnotu 7% a pri 60-minútovej len 2%.

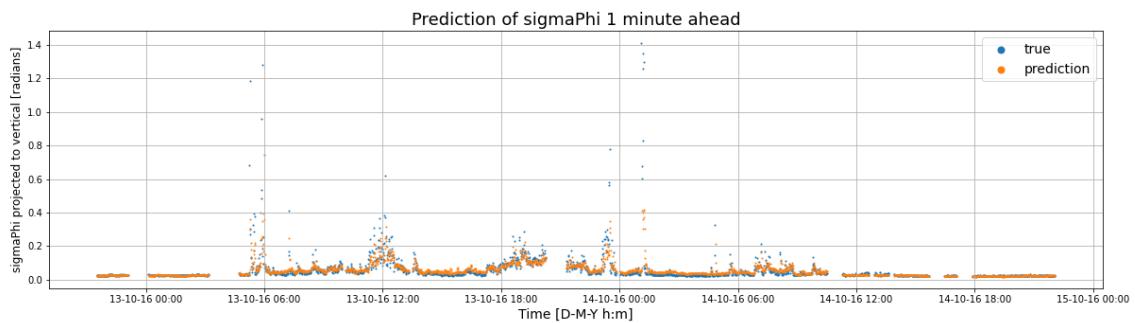
### 3.3.3 Konvolučné a rekurentné modely

Príprava dát je totožná ako pri autoregresných modeloch. To znamená, že sme si vytvorili množiny trénovacích, validačných aj testovacích okien, z ktorých sme odstránili všetky s chýbajúcimi hodnotami. Na začiatok sme veľkosť okna nastavili na 15 minút. Dáta určené na trénovanie sme následne rozdelili podľa toho, či obsahujú scintiláciu. Pri tomto kroku sme si pripravili aj vektor váh pre vstupné dátu ako pri klasických dopredných modeloch, aby sme mohli otestovať, ktorá forma augmentácie dát je vhodnejšia.

Základnou architektúrou, z ktorej sme vychádzali je sieť, ktorá má na začiatku konvolučnú vrstvu s 256 filtriemi veľkosti 5. Za ňou je umiestnená obojsmerná LSTM vrstva, ktorá má tak tiež 256 neurónov. Po nich už nasleduje plne prepojená časť zložená z dvoch skrytých vrstiev s 256 neurónmi a s ReLU aktivačnou funkciou. Na konci je jeden výstupný neurón bez aktivačnej funkcie. Dropout sme v tejto sieti nevyužili. Trénovanie prebiehalo pomocou optimalizátora Adam a hodnotiacou funkciou bola priemerná kvadratická chyba.

Ako prvú sme tradične trénovali predpoved o 1 minútu dopredu. Vzhľadom na výsledky z podkapitoly 3.3.1 sme očakávali minimálne podobný výsledok. Lenže konfúzna matica bola o poznanie horšia. Návratnosť sme dosiahli len na úrovni 50% a presnosť bola 67%. Zvýšenie komplexity modelu pridaním skrytých neurónov nemalo veľký vplyv na tieto výsledky, preto sme zosilnili váhy pre vstupné dátu obsahujúce scintilácie, vďaka čomu sa obidve kritéria zlepšili o približne 10%. To však stále nedosahovalo hodnoty dosiahnuté s obyčajnou sieťou. Preto sme sa rozhodli pre-skúmať vplyv počtu vstupných príznakov, nakoľko sme ich používali iba 5. Urobili sme analýzu citlivosti, v ktorej sme začali na dvoch vstupných príznakoch a zvyšovali sme ich počet až po 50 a sledovali sme, po aký počet sa bude model zlepšovať

a od koľkých začne výkonnosť stagnovať, prípadne klesať. Na dvoch sme začínali z toho dôvodu, že jeden sme používali pri autoregresných modeloch v predchádzajúcej podkapitole. Príznaky sme najprv zoradili podľa významnosti z podkapitoly 3.2.2 a pridávali sme ich v poradí od najinformatívnejších po tie najmenej informatívne. Žiadne iné parametre počas tohto trénovania menené neboli. Počet epoch pre každý model bol 50, s predčasným zastavením po 15-tich epochách, ak sa výkonnosť na validačnej množine nezlepšovala. Celá analýza trvala zhruba 5 hodín a vykonali sme ju pre každý posun stĺpca  $\sigma_\phi$ , ktorý sa snažíme predpovedať. Pre predpoved o 1 minútu dopredu vyšiel ako najlepší počet príznakov 11. S týmito stĺpcami sme po miernej úprave hyperparametrov dosiahli aj zlepšenie na testovacej množine. Predikciu tohto modelu môžeme vidieť na Obrázku 3 – 15 a konfúzna matica je v Tabuľke 3 – 4. Tá nakoniec nebola lepšia ako pri obyčajnej doprednej sieti, čo mohlo byť spôsobené väčším informačným šumom pochádzajúcim z vyšej rozmernosti vstupných dát. Tento predpoklad by ale bolo vhodné overiť ďalšou analýzou.



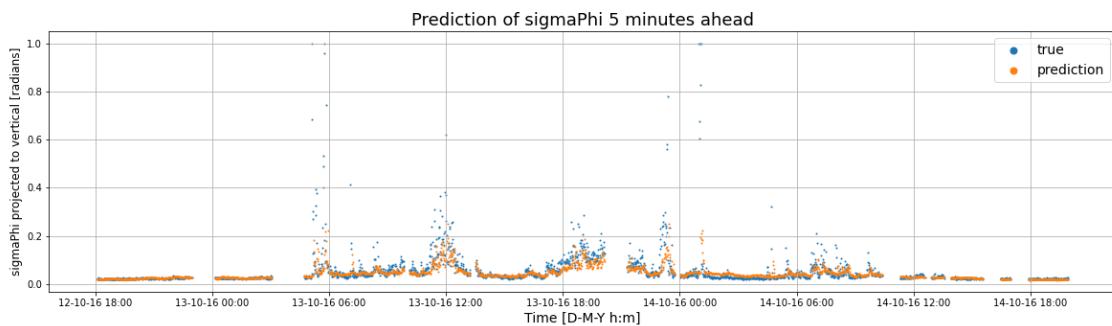
**Obrázok 3 – 15** Predikcia hodnoty  $\sigma_\phi$  1 minútu dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou.

**Tabuľka 3 – 4** Konfúzna matica predikcie hodnoty  $\sigma_\phi$  o 1 minútu dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou.

TN = 136 668	FP = 224
FN = 241	TP = 1138

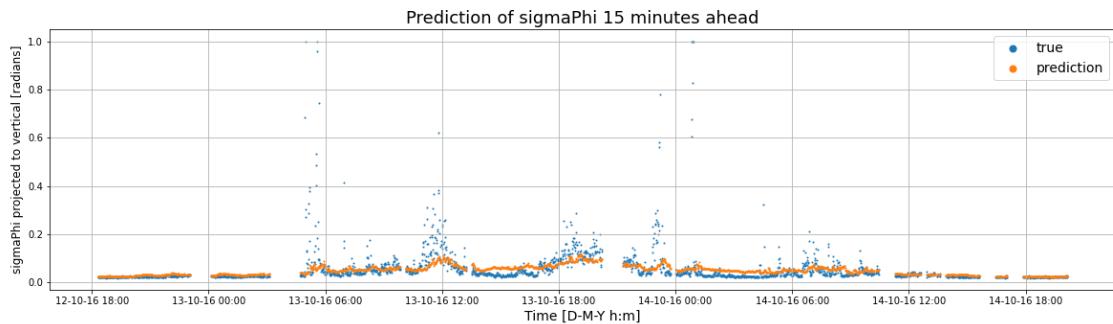
V experimentoch sme pokračovali na stĺpco  $\sigma_\phi$  posunutom o 5 minút dopredu.

Začali sme analýzou citlivosti na počet vstupných príznakov. Z nej vyšiel optimálny počet 18 príznakov. Opäť sme na začiatku nedosiahli lepší výsledok ako obyčajnej neurónovou sieťou a bolo potrebné hľadanie správnych nastavení. Najlepšie výsledky nám vyšli, keď sme zvýšili veľkosť vstupného okna na 20, pridali dvojnásobok skrytých neurónov a zvýšili pomer okien so scintiláciami v trénovacej množine. Výsledky najlepšieho modelu boli  $MAE = 0,0064$ , návratnosť 55% a presnosť 50%. Vizuálne však predikcie vyzerajú oveľa lepšie, pretože trend scintilácií je zachytený, ako vidíme na Obrázku 3 – 16, akurát nedokáže „dotiahnuť“ vysoké hodnoty.



**Obrázok 3 – 16** Predikcia hodnoty  $\sigma_\phi$  5 minút dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou.

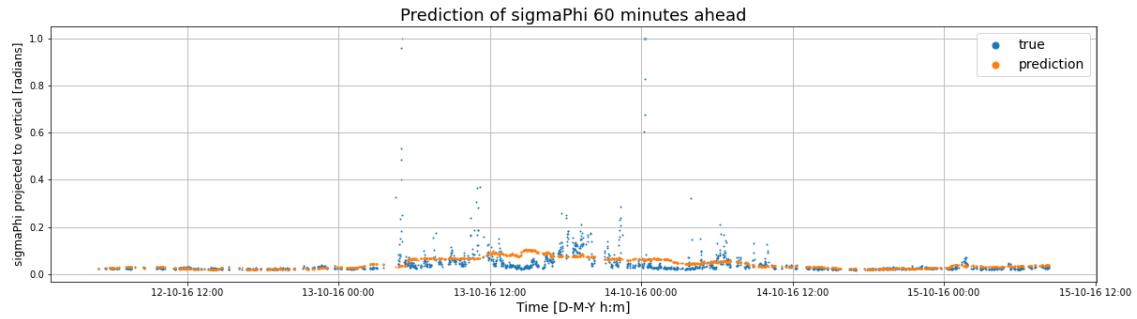
Pre predikciu hodnoty  $\sigma_\phi$  o 15 minút prekvapivo vyšiel ako najvhodnejší o dosť nižší počet vstupných príznakov ako v predchádzajúcim prípade a to konkrétnie 6. To môže byť dôsledok toho, že 15 minút je už dosť dlhá doba, pri ktorej sa strácajú výrazné korelácie s príznakmi, ktoré boli prítomné pri predchádzajúcich predikciách. To znamená väčší šum vo vstupných dátach, vďaka ktorému sa model skôr prestal zlepšovať. Inak povedané, priaznivý pomer informačnej hodnoty voči šumu sa znížil. Dosiahli sme však lepšie výsledky ako v podkapitole 3.3.1. Najlepší model mal základnú architektúru, veľkosť vstupného okna bola 15 a trénovacia množina obsahovala trojnásobne viac vstupných okien so scintiláciami, ako tých bez nich. Presnosť tejto neurónovej siete na testovacej množine je 53%, návratnosť dosiahla úroveň 31% a  $MAE$  je 0,0057. Vizualizáciu predikcie vidíme na Obrázku 3 – 17.



**Obrázok 3 – 17** Predikcia hodnoty  $\sigma_\phi$  15 minút dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou.

Poslednou predikovanou hodnotou je  $\sigma_\phi$  o hodinu dopredu. Táto úloha si vyžadovala najviac úsilia z pohľadu modifikácií a tie najdôležitejšie z nich opíšeme. V rámci analýzy citlivosti na vstupné príznaky sa výkonnosť základného modelu zlepšovala až po počet 12 stĺpcov a následne sa začala zhoršovať. Počas tréningu sme vyskúšali tento počet aj na iných architektúrach a celkovo sa javil ako najvhodnejší. Pri predikcii o jednu hodinu dopredu je na mieste otázka, aké veľké vstupné okno je potrebné na zachytenie dostatočného množstva informácie, aby mal model čo najvyššiu šancu správne odhadnúť hodnotu  $\sigma_\phi$ . Pri experimentoch sme začali na okne veľkosti 5 a postupne sme ho zväčšovali. Problém však spôsobovali chýbajúce hodnoty. Čím väčšie dátové okno, tým väčšia šanca že bude obsahovať chýbajúcu hodnotu a teda že bude v rámci prípravy dát vyradené. Už pri veľkosti vstupného okna 30 bola trénovacia množina 10-násobne menšia, ako pri okne veľkosti 5. Kedže sme nechceli do dát vnášať falošnú informáciu umelým doplňaním hodnôt, ani narúšať časovú postupnosť dát odstránením nevyhovujúcich riadkov pred tvorbou okien, tak veľkosť 30 bol najväčšia akú sme testovali. Tieto výsledky však nie sú úplne reprezentatívne, napäťko práve počas silných scintilácií dochádza k výpadkom v merniach hodnoty  $\sigma_\phi$  a to následne znemožňuje použitie väčších okien. Naviac, model nedostane potrebné informácie o silných scintiláciách a zameria sa viac na tie slabšie. Aj to môže byť jeden z dôvodov, prečo pri predikcii o minútu dopredu klasická neurónová sieť dosiahla lepšie výsledky a prečo pri 5 a 10-minútovej predpovedi majú

modely problém „dotiahnuť“ vysoké hodnoty meraní.



**Obrázok 3 – 18** Predikcia hodnoty  $\sigma_\phi$  60 minút dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou.

Najlepší výsledok (vid. Obrázok 3 – 18 a Tabuľku 3 – 5), ktorý sme dosiahli, bol MAE = 0,0068, presnosť 30% a návratnosť 10%. Vstupné okno bolo veľkosti 10. Táto neurónová sieť mala 256 filtrov v konvolučnej vrstve, ktoré mali veľkosť 5. V plne prepojenej časti mala dve skryté vrstvy, pričom každá mala 256 neurónov. Trénovaná bola bez dropoutu. Náhodný charakter samotných scintilácií a rýchle zmeny v meraných hodnotách pravdepodobne poskytujú sieti dostatočnú regularizáciu. Počas modelovania tohto predikčného problému bolo celkovo preučenie siete veľmi zriedkavé.

**Tabuľka 3 – 5** Konfúzna matica predikcie hodnoty  $\sigma_\phi$  o hodinu dopredu pomocou neurónovej siete s konvolučnou a LSTM vrstvou.

TN = 50 649	FP = 101
FN = 395	TP = 44

### 3.4 Vyhodnotenie

Z vyššie popísaných experimentov vyplýva, že strojové učenie je použiteľné na predikciu ionosférických scintilácií. Predikciu hodnoty  $\sigma_\phi$  o minútu dopredu zvládne

aj relatívne jednoduchá klasická dopredná neurónová sieť bez špeciálnych vrstiev. Na predikcie 5 a 15 minút v budúcnosti je vhodné použiť kombináciu konvolučných a rekurentných vrstiev. Predpoveď hodnoty  $\sigma_\phi$  o hodinu dopredu je problém, ktorý si vyžaduje dodatočnú analýzu a prípravu dát. Nepodarilo sa nám natrénovať model, ktorý by dokázal dostatočne presne approximovať merané hodnoty, a teda určiť silu budúcej scintilácie. Do určitej miery je však schopný predpovedať, kedy existuje zvýšená pravdepodobnosť vzniku scintilácií.

Na zlepšenie týchto modelov je potrebné venovať ďalšiu pozornosť dátam a tvorbe datasetu. Jednou z možností je pridať priestorovú zložku a bráť to ako časovo-priestorový problém a nie len časovú radu. V takom prípade bude nevyhnutné spracovať surové dáta iným spôsobom. Mohlo by to priniesť pridanú hodnotu aj v tom, že by teoreticky bolo možné natrénovať globálny predikčný model scintilácií.

Ďalšou výzvou, ktorú bude potrebné prekonat je vysporiadanie sa s chýbajúcimi hodnotami, ktorých je v dátach z GNSS prijímačov značné množstvo. To súvisí s potrebou nájsť efektívny spôsob na to, ako z údajov rozlísiť, či prípadný výpadok signálu spôsobila ionosférická scintilácia medzi prijímačom a satelitom alebo nejaký iný inštrumentálny problém.

V neposlednom rade, kvalita dát sa lísi v závislosti od typu použitého prijímača a taktiež sa môžu lísiť aj dáta z rovnakých prijímačov, ak sú nesprávne kalibrované. Pri citlivosti, akú dosahujú satelity navigačných systémov, môžu aj malé odchýlky v konečnom dôsledku znamenať veľké rozdiely v údajoch. Riešeniu tohto problému by mohla pomôcť unifikácia dát, teda vytvorenie štandardného formátu, ktorý by uľahčil získavanie a predspracovanie dát a zároveň zjednodušil trénovanie modelov.

## 4 Záver

Atmosféra Zeme je dynamickým prostredím, ktoré je zhora neustále ovplyvňované kozmickým počasím. Prebieha v nej množstvo procesov, pričom nie všetky sú plne preskúmané a pochopené, kvôli komplexnosti vzťahov medzi nimi. V tomto smere strojové učenie môže slúžiť ako efektívny dátovo-riadený nástroj modelovania tohto systému.

V našej práci sme sa venovali predpovedi ionosférických fázových scintilácií vo veryšokých zemepisných šírkach. Cieľom bolo vytvoriť teoretický prehľad vhodných metód hlbokého učenia, analyzovať a spracovať dátá potrebné pri riešení tohto problému a podať dôkaz realizovateľnosti tvorby predikčného modelu. Na tento účel sme využívali dátá z kanadskej siete pozemných GNSS prijímačov, z databáz meraní parametrov slnečného vetra, slnečnej aktivity a zemskej magnetosféry a z viacerých atmosférických modelov. Ukázalo sa, že metódy hlbokého učenia sú vhodné na riešenie tohto problému, ale je potrebný ďalší výskum na zlepšenie predstavených výsledkov. Ten bude vykonaný v nadväzujúcich štúdiách a diplomových prácach.

Táto práca priamo súvisí s projektom „Štúdia uskutočiteľnosti dátovo-riadenej autonómnej služby na predpovedanie ionosférických scintilácií (APSiS)“, ktorý vznikol ako spolupráca medzi Katedrou kybernetiky a umelej inteligencie Technickej univerzity v Košiciach a Ústavom experimentálnej fyziky Slovenskej akadémie vied. Tento projekt bol prijatý v rámci šiestej výzvy PECS (*Plan for European Coöperating States*) Európskej vesmírnej agentúry, z ktorej je financovaný. Aktuálnosť riešeného problému umocňuje aj fakt, že nedávno bola získaná dodatočná podpora z projektu PITHIA-NRF (*Plasmasphere Ionosphere Thermosphere Integrated Research Environment and Access services: a Network of Research Facilities*), najmä vo forme aktuálnych a relevantných dát. Projekt PITHIA-NRF je financovaný v rámci programu Horizont 2020 Európskej únie.

## Literatúra

- Aarons, J. (1982). Global morphology of ionospheric scintillations, *Proceedings of the IEEE* **70**(4): 360–378.
- Al-Bayari, O. and Sadoun, B. (2007). *Global Navigation Satellite Systems*, John Wiley & Sons, Ltd, chapter 56, pp. 877–895. <https://onlinelibrary.wiley.com/doi/10.1002/9781118256114.ch56>.
- Alom, M. Z., Taha, T., Yakopcic, C., Westberg, S., Sidike, P., Nasrin, M., Hasan, M., Essen, B., Awwal, A. and Asari, V. (2019). A state-of-the-art survey on deep learning theory and architectures, *Electronics* **8**: 292.
- Ba, J. and Caruana, R. (2014). Do deep nets really need to be deep?, *Advances in neural information processing systems* **27**.
- Basu, S., MacKenzie, E. and Basu, S. (1988). Ionospheric constraints on vhf/uhf communications links during solar maximum and minimum periods, *Radio Science* **23**(3): 363–378. <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/RS023i003p00363>.
- Beach, T. L. (2006). Perils of the gps phase scintillation index (sigma phi), *Radio Science* **41**(5). <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2005RS003356>.
- Benedicto, J., Dinwiddie, S., Gatti, G., Lucas, R. and Lugert, M. (2000). Galileo: Satellite system design, *European Space Agency*, Citeseer.
- Bolla, P. and Borre, K. (2018). Performance analysis of dual-frequency receiver using combinations of gps l1, l5, and l2 civil signals, *Journal of Geodesy* **93**(3): 437–447.
- Bora, S. (2017). Ionosphere and radio communication, *Resonance* **22**(2): 123–133.

- Bryson, A. E. (1961). A gradient method for optimizing multi-stage allocation processes, *Proc. Harvard Univ. Symposium on digital computers and their applications*, Vol. 72, p. 22.
- Buis, A. (2019). Earth's atmosphere: A multi-layered cake. <https://climate.nasa.gov/news/2919/earths-atmosphere-a-multi-layered-cake/>.
- Camporeale, E. (2019). The challenge of machine learning in space weather: Nowcasting and forecasting, *Space Weather* **17**(8): 1166–1207. <https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2018SW002061>.
- CHAIN (2022). Welcome to the canadian high arctic ionospheric network. <http://chain.physics.unb.ca/chain/>.
- Chartier, A., Forte, B., Deshpande, K., Bust, G. and Mitchell, C. (2016). Three-dimensional modeling of high-latitude scintillation observations: High-latitude scintillation modeling, *Radio Science* **51**.
- Clifford, W. M. (2022). Einstein's relativity and everyday life. <https://physicscentral.com/explore/writers/will.cfm>.
- Dasgupta, A. (2016). Evolution of the global navigation satellite system (gnss). <https://www.geospatialworld.net/article/global-navigation-satellite-system-gnss/>.
- Datta-Barua, S., Altshuler, E., Walter, T. and Pullen, S. (2021). Ionospheric scintillation effects on satellite navigation, *Geophysical Monograph Series* p. 493–510.
- Demyanov, V., Sergeeva, M., Fedorov, M., Ishina, T., Gatica-Acevedo, V. J. and Cabral-Cano, E. (2020). Comparison of tec calculations based on trimble, javad, leica, and septentrio gnss receiver data, *Remote Sensing* **12**(19). <https://www.mdpi.com/2072-4292/12/19/3268>.

- Enciso, P. and Zingaretti, L. (2019). A guide for using deep learning for complex trait genomic prediction, *Genes* **10**: 553.
- Forte, B. and Radicella, S. (2002). Problems in data treatment for ionospheric scintillation measurements, *Radio Science - RADIO SCI* **37**: 8–1.
- Garner, R. (2015). Nasa's goddard space flight center. <https://www.nasa.gov/goddard>.
- Glorot, X., Bordes, A. and Bengio, Y. (2011). Deep sparse rectifier neural networks, in G. Gordon, D. Dunson and M. Dudík (eds), *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, Vol. 15 of *Proceedings of Machine Learning Research*, PMLR, Fort Lauderdale, FL, USA, pp. 315–323. <https://proceedings.mlr.press/v15/glorot11a.html>.
- Goodfellow, I., Bengio, Y. and Courville, A. (2016). *Deep Learning*, MIT Press. <http://www.deeplearningbook.org>.
- Gulli, A. and Pal, S. (2017). *Deep learning with Keras*, Packt Publishing Ltd.
- He, K., Zhang, X., Ren, S. and Sun, J. (2015). Delving deep into rectifiers: Surpassing human-level performance on imagenet classification, *Proceedings of the IEEE international conference on computer vision*, pp. 1026–1034.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory, *Neural Comput.* **9**(8): 1735–1780.
- Jain, L. C. and Medsker, L. R. (1999). *Recurrent Neural Networks: Design and Applications*, 1st edn, CRC Press, Inc., USA.
- Jain, V. (2019). Everything you need to know about activation functions in deep learning models. <https://towardsdatascience.com/everything-you-need-to-know-about-activation-functions-in-deep-learning-models>

- Janiesch, C., Zschech, P. and Heinrich, K. (2021). Machine learning and deep learning, *Electronic Markets* **31**(3): 685–695.
- Kalman, R. E. (1960). A new approach to linear filtering and prediction problems, *Transactions of the ASME-Journal of Basic Engineering* **82**(Series D): 35–45.
- Kelley, H. J. (1960). Gradient theory of optimal flight paths, *Ars Journal* **30**(10): 947–954.
- Kingma, D. P. and Ba, J. (2014). Adam: A method for stochastic optimization, *arXiv preprint arXiv:1412.6980*.
- Kintner, P. M., Ledvina, B. M. and de Paula, E. R. (2007). Gps and ionospheric scintillations, *Space Weather* **5**(9). <https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2006SW000260>.
- Koulouri, A., Smith, N. D., Vani, B. C., Rimpiläinen, V., Astin, I. and Forte, B. (2020). Methodology to estimate ionospheric scintillation risk maps and their contribution to position dilution of precision on the ground, *Journal of Geodesy* **94**(2). <https://doi.org/10.1007%2Fs00190-020-01344-0>.
- Kwiatkowski, R. (2021). Gradient descent algorithm - a deep dive. <https://towardsdatascience.com/gradient-descent-algorithm-a-deep-dive-cf04e8115f21>.
- LeCun, Y., Bengio, Y. and Hinton, G. (2015). Deep learning, *nature* **521**(7553): 436–444.
- LeCun, Y. et al. (1989). Generalization and network design strategies, *Connectionism in perspective* **19**(143-155): 18.
- Linnainmaa, S. (1976). Taylor expansion of the accumulated rounding error, *BIT Numerical Mathematics* **16**(2): 146–160.

- Little, C. and Maxwell, A. (1952). Scintillation of radio stars during aurorae and magnetic storms, *Journal of Atmospheric and Terrestrial Physics* **2**(6): 356–360. <https://www.sciencedirect.com/science/article/pii/0021916952900767>.
- Mackovjak, Š., Varga, M., Hrivňák, S., Palkoci, O. and Didebulidze, G. (2021). Data-driven modeling of atomic oxygen airglow over a period of three solar cycles, *Journal of Geophysical Research: Space Physics* **126**(3): e2020JA028991.
- McCaffrey, A. M., Jayachandran, P. T., Langley, R. B. and Sleewaegen, J.-M. (2017). On the accuracy of the gps l2 observable for ionospheric monitoring, *GPS Solutions* **22**(1).
- McCulloch, W. S. and Pitts, W. (1943). A logical calculus of the ideas immanent in nervous activity, *The bulletin of mathematical biophysics* **5**(4): 115–133.
- McElroy, M. B. (2012). Ionosphere and magnetosphere. <https://www.britannica.com/science/ionosphere-and-magnetosphere>.
- McGonagle, J., Shaikouski, G., Williams, C., Hsu, A., Khim, J. and Miller, A. (n.d.). Backpropagation. <https://brilliant.org/wiki/backpropagation/>.
- McGranaghan, R. M., Mannucci, A. J., Wilson, B., Mattmann, C. A. and Chardwick, R. (2018). New capabilities for prediction of high-latitude ionospheric scintillation: A novel approach with machine learning, *Space Weather* **16**(11): 1817–1846. <https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2018SW002018>.
- Moshayedi, A. J., Roy, A. S., Kolahdooz, A. and Shuxin, Y. (2022). Deep learning application pros and cons over algorithm, *EAI Endorsed Transactions on AI and Robotics* **1**: 1–13.
- Nair, V. and Hinton, G. E. (2010). Rectified linear units improve restricted boltzmann machines, *ICML*, pp. 807–814. <https://icml.cc/Conferences/2010/papers/432.pdf>.

- Newell, P. T., Sotirelis, T., Liou, K., Meng, C.-I. and Rich, F. J. (2007). A nearly universal solar wind-magnetosphere coupling function inferred from 10 magnetospheric state variables, *Journal of Geophysical Research: Space Physics* **112**(A1). <https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2006JA012015>.
- Newell, P. T., Sotirelis, T. and Wing, S. (2010). Seasonal variations in diffuse, monoenergetic, and broadband aurora, *Journal of Geophysical Research: Space Physics* **115**(A3). <https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2009JA014805>.
- Odi, U. and Nguyen, T. (2018). Geological facies prediction using computed tomography in a machine learning and deep learning environment, *Technical report*, URTEC-2018-2901881.
- Parkinson, B. (1974). Navstar: Global positioning system an evolutionary research and development program, *NASA. Goddard Space Flight Center Proc. of the Sixth Ann. Precise Time and Time Interval (PTTI) Planning Meeting*.
- Pi, X., Boulat, B., Mannucci, A. and DA, S. (2002). Latitudinal characteristics of l-band ionospheric scintillation, *Proceedings of the ION GPS 2002*, pp. 24–27.
- Picone, J. M., Hedin, A. E., Drob, D. P. and Aikin, A. C. (2002). Nrlmsise-00 empirical model of the atmosphere: Statistical comparisons and scientific issues, *Journal of Geophysical Research: Space Physics* **107**(A12): SIA 15–1–SIA 15–16. <https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2002JA009430>.
- Rao, P., Seemala, G., Niranjan, K. and Prasad, D. (2006). Study of spatial and temporal characteristics of l-band scintillations over the indian low-latitude region and their possible effects on gps navigation, *Annales Geophysicae* **24**.
- Rosenblatt, F. (1957). *The perceptron, a perceiving and recognizing automaton Project Para*, Cornell Aeronautical Laboratory.

Rumelhart, D. E., Hinton, G. E. and Williams, R. J. (1986). Learning representations by back-propagating errors, *nature* **323**(6088): 533–536.

Septentrio (n.d.). Iono+ : Ionospheric scintillation monitoring. <https://www.septentrio.com/en/company/septentrio-gnss-technology/iono-ionospheric-scintillation-monitoring>.

Sinčák, P. (2021). *Neurónové siete - inžiniersky prístup verzia 3.0*, Technical University of Košice.

Smagulova, K. and James, A. P. (2020). Overview of long short-term memory neural networks, *Deep Learning Classifiers with Memristive Networks*, Springer, pp. 139–153.

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. and Salakhutdinov, R. (2014). Dropout: a simple way to prevent neural networks from overfitting, *The journal of machine learning research* **15**(1): 1929–1958.

Tian, Y., Pei, K., Jana, S. and Ray, B. (2018). Deeptest: Automated testing of deep-neural-network-driven autonomous cars, *Proceedings of the 40th international conference on software engineering*, pp. 303–314.

Trevisan, V. (2022). Comparing robustness of mae, mse and rmse. <https://towardsdatascience.com/comparing-robustness-of-mae-mse-and-rmse-6d69da870828>.

UCAR (2014). Center for science education. <https://scied.ucar.edu/learning-zone/atmosphere/ionosphere>.

Wes McKinney (2010). Data Structures for Statistical Computing in Python, in Stéfan van der Walt and Jarrod Millman (eds), *Proceedings of the 9th Python in Science Conference*, pp. 56 – 61.

- Yamashita, R., Nishio, M., Do, R. K. G. and Togashi, K. (2018). Convolutional neural networks: an overview and application in radiology, *Insights into imaging* **9**(4): 611–629.
- Yang, Z. and Liu, Z. (2016). Investigating the inconsistency of ionospheric roti indices derived from gps modernized l2c and legacy l2 p(y) signals at low-latitude regions, *GPS Solutions* **21**(2): 783–796.
- Zhang, T. (2004). Solving large scale linear prediction problems using stochastic gradient descent algorithms, *Proceedings of the twenty-first international conference on Machine learning*, p. 116.
- Zhou and Chellappa (1988). Computation of optical flow using a neural network, *IEEE 1988 International Conference on Neural Networks*, pp. 71–78 vol.2.

## **Zoznam príloh**

**Príloha A** Systémová príručka

**Príloha B** Používateľská príručka

**Príloha C** CD médium obsahujúce zdrojové kódy, diplomovú prácu a prílohy v elektronickej podobe