

Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky

**Zlepšenie modelu detektie TLE na
snímkach kamier AMOS**

Bakalárska práca

2023

Lívia Muranková

Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky

**Zlepšenie modelu detektie TLE na
snímkach kamier AMOS**

Bakalárská práca

Študijný program:	Hospodárska informatika
Študijný odbor:	Informatika
Školiace pracovisko:	Katedra kybernetiky a umelej inteligencie (KKUI)
Školiteľ:	doc. Ing. Peter Butka, PhD.
Konzultanti:	Ing. Viera Krešňáková, PhD. RNDr. Šimon Mackovjak, PhD. Ing. Lenka Kališková

Košice 2023

Lívia Muranková

Abstrakt v SJ

Prechodné svetelné javy (TLE) sú krátkodobé, elektricky indukované formy svetnej plazmy, ktoré sa vyskytujú vysoko nad hladinou oblakov. Na Slovensku ich monitoruje Slovenská videometeorická sieť, ktorú v súčasnosti tvorí päť poloautonomých, diaľkovo ovládaných systémov na pozorovanie meteorov na celej oblohe (AMOS). Cieľom bakalárskej práce je oboznámiť sa s technikami strojového učenia a nátrénoval model umelej inteligencie, ktorý dokáže správne identifikovať výskyt TLE javov na snímkach. V súčasnosti už existuje jeden model konvolučnej neurónovej siete YOLO na detekciu TLE javov, ale nie je dostatočný, a preto sa praktická časť tejto práce zameriava na odstránenie nedostatkov a zlepšenie súčasného modelu.

Klúčové slová

TLE, AMOS, neurónové siete, YOLO, augmentácia dát, detekcia objektov

Abstrakt v AJ

Transient luminous events (TLEs) are short-lived, electrically induced forms of luminous plasma occurring high above the cloud surface. In Slovakia, they are monitored by the Slovak Video Meteor Network, which currently consists of five semi-autonomous, remotely operated, All-sky Meteor Orbit System (AMOS). The aim of the bachelor thesis is to learn about machine learning techniques and to train an artificial intelligence model capable of correctly identifying the occurrence of TLE phenomena in images. One YOLO convolutional neural network model for detecting TLE phenomena already exists, but it is not sufficient, therefore the practical part of the thesis focuses on eliminating inaccuracies and improving the current model.

Klúčové slová v AJ

TLE, AMOS, neural networks, YOLO, data augmentation, object detection

69388

TECHNICKÁ UNIVERZITA V KOŠICIACH
FAKULTA ELEKTROTECHNIKY A INFORMATIKY
Katedra kybernetiky a umelej inteligencie

ZADANIE
BAKALÁRSKEJ PRÁCE

Študijný odbor: Informatika

Študijný program: Hospodárska informatika

Názov práce:

Zlepšenie modelu detektie TLE na snímkach kamier AMOS

Improvement of TLE detection model from AMOS images

Študent: **Lívia Muranková**

Školliteľ: doc. Ing. Peter Butka, PhD.

Školiace pracovisko: Katedra kybernetiky a umelej inteligencie

Konzultant práce: Ing. Viera Maslej Krešňáková, PhD., RNDr. Šimon Mackovjak, PhD., Ing. Lenka Kališková

Pracovisko konzultanta: Ústav experimentálnej fyziky SAV

Pokyny na vypracovanie bakalárskej práce:

1. Podať teoretický prehľad problematiky metód hlbokého učenia, s dôrazom na vhodné metódy pre automatickú detekciu TLE udalostí v obrazových dátach.
2. Analyzovať možnosti rozšírenia (augmentácie) dát v rámci množiny celooblohouvých snímok kamery AMOS pre zlepšenie detektie TLE udalostí.
3. Navrhnuť, realizovať a vyhodnotiť vplyv zvolených metód rozšírenia dát v rámci modelu hlbokého učenia pre detektie TLE udalostí z kamier AMOS.
4. Vypracovať dokumentáciu podľa pokynov katedry a vedúceho práce.

Jazyk, v ktorom sa práca vypracuje: slovenský

Termín pre odovzdanie práce: 26.05.2023

Dátum zadania bakalárskej práce: 31.10.2022



.....
prof. Ing. Liberios Vokorokos, PhD.
dekan fakulty



Čestné vyhlásenie

Vyhlasujem, že som bakalársku prácu vypracovala samostatne s použitím uvedenej odbornej literatúry.

Košice 25. 5. 2023

.....

Vlastnoručný podpis

Poděkovanie

Tento formou by som chcela poděkovat celému tímu pod vedením doc. Ing. Petra Butku, PhD. a konzultantom Ing. Viere Krešňákovej, PhD., RNDr. Šimonovi Mackovjakovi, PhD. a Ing. Lenke Kališkovej za organizáciu letnej školy, pravidelné konzultácie, cenné odborné rady, motiváciu, prejavenu dôveru a správne usmernenie pri spracovaní bakalárskej práce. Vďaka patrí aj mojej rodine a blízkym, ktorí mi boli počas celého obdobia veľkou oporou.

Obsah

Úvod	1
1 Úvod do umelej inteligencie a neurónových sietí	3
1.1 Umelá inteligencia	4
1.2 Strojové učenie	4
1.3 Neurónové siete	5
1.3.1 Štruktúra biologického neurónu	6
1.3.2 Topológia neurónovej siete	6
1.3.3 Učenie neurónovej siete	8
1.3.4 Konvolučné neurónové siete	8
1.4 Hlboké učenie	9
1.5 Detekcia objektov	10
1.6 You Only Look Once	11
1.6.1 Princíp algoritmu YOLO	12
2 Prechodné svetelné javy a ich pozorovanie	13
2.1 Prechodné svetelné javy	14
2.1.1 Škriatkovia	14
2.1.2 Modré výtrysky	16
2.1.3 Modré štartéry	16
2.1.4 Gigantické výtrysky	17
2.1.5 Elfovia	17
2.2 Celoblokový systém na snímanie meteorov	17
3 Zlepšenie modelu detekcie TLE na snímkach kamier AMOS	19
3.1 Analýza súčasných modelov detekcie TLE	19
3.2 Pochopenie ciela	22
3.3 Pochopenie dát	24
3.4 Príprava dát	25

3.4.1	Horizontálne prevrátenie	27
3.4.2	Vertikálne prevrátenie	28
3.4.3	Rotácia o náhodný počet stupňov	29
3.4.4	Segmentácia TLE objektov pomocou prahovania	30
3.4.5	Zamedzenie označovania nesprávnych objektov	32
3.5	Modelovanie	33
3.5.1	Výber modelu neurónovej siete	33
3.5.2	Rozdelenie dát na trénovaciu, validačnú a testovaciu množinu	33
3.5.3	Simulácia existujúceho modelu	35
3.5.4	Modelovanie nového modelu	38
3.6	Vyhodnotenie zlepšených modelov	39
3.7	Vyhodnotenie výskumu	42
4	Záver	45
Zoznam príloh		52

Zoznam obrázkov

1 – 1	Vzťah umelej inteligencie, strojového učenia, neurónových sietí a hlbokého učenia	3
1 – 2	Matematický model umelého neurónu	7
1 – 3	Princíp fungovania YOLO algoritmu. Obrázok je upravený z Redmon et al. (2016).	14
2 – 1	Prechodné svetelné javy upravené z Blelly (2020).	15
2 – 2	Prvá AMOS kamera umiestnená na univerzitnom observatóriu v Modre Volek (2017).	18
3 – 1	ASIM na module Columbus. Obrázok upravený z ESA (1970) . . .	20
3 – 2	Lietadlo EXL98 Gulfstream II a jedna z kamier snímania Siefring et al. (2010)	21
3 – 3	(A) Skupina stĺpových výtryskov nasnímaných v svetelne znečisťenej oblasti Tel Avivu 31. októbra 2006. (B) Skupina mrkvových výtryskov, snímaná z Mizpe-Ramon v noci 14. januára 2006 Yair et al. (2009).	22
3 – 4	Schematický diagram členenia dátových súborov z kamier AMOS .	25
3 – 5	Snímka vyhotovená 30. mája 2017 nasnímaná kamerou AMOS umiestnenou v areáli Arboréta Tesárske Mlyňany	26
3 – 6	Pôvodný obrázok a obrázok po použití horizontálneho preklopenia	28
3 – 7	Pôvodný obrázok a obrázok po použití vertikálneho preklopenia .	29
3 – 8	Pôvodné ohraničujúce pole zmenené vplyvom rotácie na nové pole	30
3 – 9	Pôvodný obrázok a obrázok rotovaný o náhodný počet stupňov .	31
3 – 10	Pôvodný obrázok a vysegmentovaný TLE jav umiestnený na iný obrázok bez prechodného svetelného javu	32
3 – 11	Najčastejšie nesprávne označené objekty a ich prekrytie	32
3 – 12	Porovnanie predpovedí modelov YOLOv5 a YOLOv8 simulujúcich existujúci model na testovacej množine	38

3 – 13	Porovnanie predpovedí modelov YOLOv5 a YOLOv8 simulujúcich existujúci model na testovacej množine	41
3 – 14	Distribúcia TLE javov v priebehu rokov	43
3 – 15	Distribúcia TLE javov v priebehu mesiacov a rokov	44
3 – 16	Distribúcia TLE javov v priebehu hodín a dní	44

Zoznam tabuliek

3–1	Rozdelenie vstupných údajov podľa rokov	24
3–2	Rozdelenie dát pre trénovanie simulácie existujúceho modelu	34
3–3	Rozdelenie dát pre trénovanie modelu na augmentovaných dátach . .	35
3–4	Zhrnutie trénovania modelu simulujúceho existujúci model na verzii neurónovej siete YOLOv5 a YOLOv8	36
3–5	Zhrnutie testovania modelu simulujúceho existujúci model na verzii neurónovej siete YOLOv5 a YOLOv8	37
3–6	Porovnanie metrík modelov YOLOv5 a YOLOv8 vygenerovaných mo- delmi na testovacej množine	40
3–7	Zhrnutie testovania modelov neurónovej siete YOLOv5 a YOLOv8 . .	41
3–8	Počet nájdených snímok s TLE javmi za jednotlivé roky	42

Zoznam symbolov a skratiek

AI Artificial Intelligence

AGO Astronomické a geofyzikálne observatórium v Modre

AMOS All-Sky Meteor Orbit System

ANN Artificial Neural Networks

ARBO Arborétum Tesárske Mlyňany

ASIM Atmosphere-Space Interaction Monitor

CG Cloud-to-Ground lightning

conf. Confidence Score

CPU Central Processing Unit

CNN Convolutional Neural Network

DL Deep Learning

E-layer Electrical-Layer

ELF Extremely Low Frequency

ELVES Emission of Light and Very Low Frequency perturbations due to Electromagnetic Pulse Sources

ESA European Space Agency

EXL98 Energetic of Upper Atmospheric Excitation by Lightning

FMFI UK Fakulta matematiky, fyziky a informatiky Univerzity Komenského

GPU Graphics Processing Unit

ILAN Imaging of the Lightning And Nocturnal flashes

IoU Intersection over Union

ISS International Space Station

KNM Hvezdáreň Kysucké Nové Mesto

mAP50 mean Average Precision calculated at IOU threshold 0.5

ML Machine Learning

P Precision

R Recall

ReLU Rectified Linear Unit

Sprite Stratospheric Perturbations Resulting from Intense Thunderstorm Electrification

TLE Transient Luminous Events

TN True Negative

TP True Positive

YAML YAML Ain't Markup Language

YOLO You Only Look Once

YOLOv5 You Only Look Once version 5

YOLOv8 You Only Look Once version 8

Úvod

Detekcia objektov bola predmetom viacerých rozsiahlych výskumov a k dispozícii je mnoho natréновaných modelov a architektúr. Napriek tomu niektoré oblasti predstavujú pri pokuse o trénovanie komplexných modelov hlbokého učenia značné výzvy, najmä ak sú dostupné súbory údajov obmedzené a nevyvážené. Jedným z týchto príkladov je detekcia objektov v reálnom čase pomocou astronomických snímok získaných zo Slovenského celooblohouvého systému na snímanie meteorov. Systém je primárne určený na pozorovanie meteorov, no zaznamenané dátá možno využiť aj na skúmanie iných astronomických javov, akými sú napríklad prechodné svetelné javy. Prechodné svetelné javy, ako sú škriatkovia, modré výtrysky, modré štartéry, gigantické výtrysky alebo elfovia sú elektrické výboje vznikajúce z obyčajných bleskov na vrchole aktívnej búrky. Sú veľmi krátke, trvajú menej ako jednu sekundu, a zo zeme ich vidno len zriedka. Tieto javy sú v posledných rokoch predmetom mnohých pozorovaní vykonaných na lokalizačných systémoch bleskov. Zo zemského povrchu sa javy dajú zvyčajne zachytiť len citlivým fotografickým zariadením, a keďže vyžarujú slabé svetlo, fotografie je možné robiť len v noci. Veľkosť takýchto javov na obrazových záznamoch je veľmi malá v pomere s celkovou veľkosťou snímky, čo ich detekciu stázuje. Ďalším problémom je fakt, že na pomerne obrovskéj vzorke dát sa tieto javy vyskytujú len ojedinele. Každá novoobjavená snímka s výskytom prechodného svetelného javu má veľkú cenu. Vývoj spoľahlivého a presného modelu pre túto aplikáciu by sa ukázal ako veľmi prospešný pri prehľadávaní množstva astronomických dát a skúmaní vzťahov medzi nimi.

V prvej kapitole práce je popísaný teoretický úvod do umelej inteligencie a neurónových sietí. Kapitola priblíží vzťah umelej inteligencie, strojového učenia, umelých neurónových sietí a metód hlbokého učenia. Nasledujúca pasáž sa zaoberá detekciou objektov a konvolučnou neurónovou sieťou *You Only Look Once*.

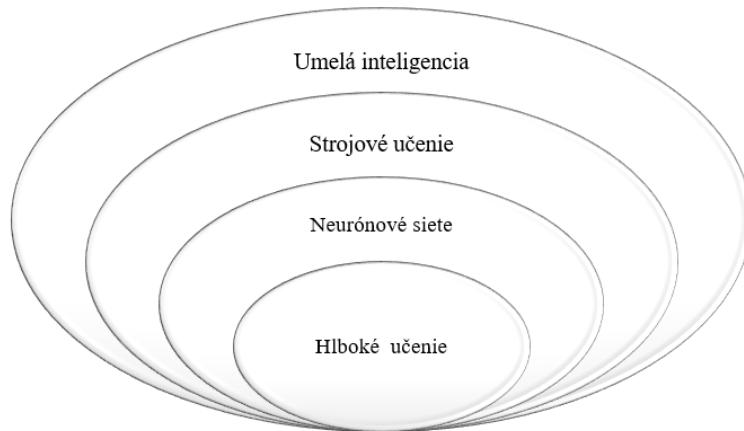
Druhá kapitola sa venuje doménovej časti tejto práce. Poskytuje náhľad do problematiky prechodných svetelných javov, ich kategórií a charakterizuje celooblohouvý

systém na snímanie meteorov.

Tretia kapitola popisuje praktickú časť práce. V úvode je rozobraná analýza obdobných modelov slúžiacich na skúmanie prechodných svetelných javov. Následne je priblížený cieľ práce, pochopenie dát, príprava dát a rôzne metódy augmentácie dát, modelovanie detekčného modelu pomocou konvolučnej neurónovej siete YOLOv5 a YOLOv8, výhodnotenie modelov a prínos získanej množiny dát vzhľadom na pozorované korelácie medzi dátami.

1 Úvod do umelej inteligencie a neurónových sietí

Systémy umelej inteligencie zohrávajú čoraz väčšiu úlohu v spoločnosti. „Môže stroj myslieť?“ Túto otázku, ktorá pritahuje čoraz väčšiu pozornosť vedcov a odborníkov z praxe, položil už v roku 1950 Alan Turing, a tak určil smer rozvoja umelej inteligencie. Systémy umelej inteligencie sa od ostatných bežných počítačových programov líšia svojou jedinečnosťou, pretože sú schopné samostatného učenia sa, zbierať skúsenosti a prichádzať s rozmanitými riešeniami na základe analýzy rôznych situácií nezávisle od vôle ich tvorca. Ľudia ich používajú najmä preto, aby udržiavali krok s aktuálnymi trendmi v spoločnosti, ale aj na uľahčenie svojej práce. Zvyčajne sa tieto systémy spájajú so strojovým učením, neurónovými sietami či hlbokým učením, a hoci všetky tieto pojmy zohrávajú určitú úlohu, zvyknú sa jednotne označovať terminom umelá inteligencia. Vo všeobecnosti možno ich vzťah popísť obrázkom 1 – 1, kde každý z týchto pojmov tvorí podmnožinu predchádzajúceho pojmu. Aby sa však predišlo nejasnostiam v súvislosti s nuansami medzi nimi, táto kapitola sa zameria na objasnenie ich významu.



Obrázok 1 – 1 Vzťah umelej inteligencie, strojového učenia, neurónových sietí a hlbokého učenia

1.1 Umelá inteligencia

Inteligenciu ľudí možno popísať ako schopnosť riešiť problémy pomocou znalostí, ktorými iné bytosti nedisponujú. Výskum v oblasti umelej inteligencie (angl. *Artificial Intelligence*, skr. AI) sa zameriava najmä na tieto zložky inteligencie - uvažovanie, riešenie problémov, vnímanie, učenie a používanie jazyka Copeland (2023). Umelú inteligenciu možno charakterizovať ako oblasť informatiky, ktorej cieľom je pochopit uvážlivé správanie a navrhnut systémy indikujúce vlastnosti inteligencie. Zaoberá sa študovaním a navrhovaním inteligentných agentov, ktorí sa na základe pozorovaní okolitého prostredia snažia vyriešiť problémy doteraz riešiteľné iba pomocou ľudskej mysele Bini (2018). Algoritmy sú schopné simulovať ľudskú myseľ tak, aby vykazovali schopnosť učiť sa uvažovať a konať ako človek Aggarwal et al. (2022).

Napriek neustálemu pokroku v rýchlosťi spracovania a pamäťovej kapacite počítačov zatiaľ neexistujú programy, ktoré by mohli konkurovať alebo sa vyrovnať ľudským schopnostiam. Vedci stále nedokázali definovať, čo znamená flexibilita človeka reagovať na rôzne podnety. Schopnosti inteligentných počítačových programov sú tak do veľkej miery obmedzené na myšlienkové pochody tvorcov programov Copeland (2023). Ak je človek pri riešení problému lepší ako počítač, alebo ak počítač na jeho riešenie používa veľa výpočtov, aby úlohu zvládol rovnako dobre ako človek, svedčí to o neschopnosti počítača logicky myslieť. Naznačuje to, že programátori nerozumejú intelektuálnym mechanizmom, ktoré sú potrebné na efektívne vykonanie úlohy McCarthy et al. (2007).

1.2 Strojové učenie

Strojové učenie (angl. *Machine Learning*, skr. ML) je oblasť umelej inteligencie, ktorá sa zaoberá vývojom algoritmov učiacich sa formou rozpoznávania vzorov na základe získaných skúseností. Proces učenia sa začína od vstupných dát, ktorým zodpovedajú konkrétnie výstupy. Systém z vložených dát odvodí pravidlo, podľa ktorého sa budú spracovať nasledujúce vstupy. S narastajúcim počtom vstupných dát a iterácií tré-

novania, sa za optimálnych podmienok zvyšuje aj presnosť vytvorených predpovedí algoritmov Bini (2018). V takom prípade ide o induktívne učenie. Učenie však môže byť aj deduktívne. Deduktívne učenie nastáva vtedy, ak na začiatku systému zadefinujeme všeobecné princípy, z ktorých sa neskôr odvodia nové, špecifickejšie pravidlá. Ak sú odvodeným pravidlám priradené váhy, ktoré značia pravdepodobnosť, s akou záver po aplikovaní pravidla nastane, hovoríme o štatistických metódach učenia Ij (2018).

Strojové učenie môže prebiehať pod dohľadom, v takom prípade hovoríme o kontrolovanom učení, alebo bez dozoru, kedy dochádza k nekontrolovanému učeniu. Kontrolované učenie sa vykonáva na vopred označených vstupných dátach. Vstupné dátá zároveň nesú informáciu o tom, ako by mal vyzerat správny výstup. Výsledkom kontrolovaného učenia je spätná väzba o úspešnosti učenia, ktorá vyjadruje pravdepodobnosť, s akou je naučený model schopný odhadnúť správny výsledok. Pri nekontrolovanom učení sa algoritmus strojového učenia trénuje bez akýchkoľvek znalostí na neoznačených vstupných dátach. Cieľom učenia bez dozoru je, aby algoritmus na trénovacích dátach sám našiel skryté vzory, vzťahy alebo korelácie, ktoré dátovú množinu definujú. Tieto algoritmy nemajú zadefinovaný žiadny konkrétny výstup, ktorý by mali predpovedať. Učenie iba zoskupí príklady do zhľukov podľa podobných vzorov, no správnosť riešenia sa nedá spätne overiť Machová (2002), Mahesh (2020).

1.3 Neurónové siete

Vďaka neustálemu napredovaniu v oblasti vedy a techniky, možno za ďalší významný moment označiť objavenie neurónových sietí. Umelé neurónové siete (angl. *Artificial Neural Networks*, skr. ANN) sú modely strojového učenia, ktoré dokážu spracovať vstupy údajov takmer rovnakým spôsobom ako ľudský mozog - môžu experimentovať, učiť sa a rozvíjať sa samy bez zásahu človeka Aggarwal et al. (2022). Pozostávajú z umelých neurónov uložených vo vrstvách, ktoré sa pomocou matematických

operácií snažia nájsť základné vzťahy v súbore údajov Krenker et al. (2011).

1.3.1 Štruktúra biologického neurónu

Biologický neurón ako základná stavebná a funkčná bunka neurónovej siete, je schopný prijímať, prenášať, spracovať a uchovávať určitú formu informácie. Tvorí ho axón, teda telo, ktorým sa šíri informácia od neurónu, a dendrity, ktoré zachytávajú vstupné informácie. Na medzineurónovom rozhraní sa nachádzajú synapsie, ktoré sú zodpovedné za samotný prenos informácií Mourek (2005).

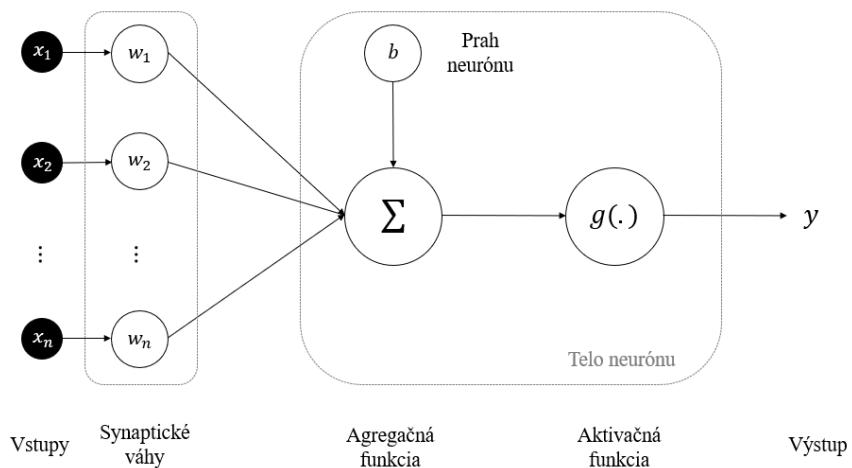
Umelé neurónové siete stavbou pripomínajú biologické nervové bunky - neuróny s dendritmi, ktoré vzájomným prepojením vytvárajú neurónovú sieť. Na vstupe je informáciu priradená váha, čo možno analogicky pripojiť k úlohe synapsí. Každý dendrit predstavuje uzol, teda vstup, ktorý prijíma istý typ informácie. Vo vnútri uzla sa informácia spracuje - vážené vstupy sa sčítajú a na získanie výsledkov sa použije aktivačná funkcia. Táto operácia zodpovedá v biologickom neuróne úlohe bunkového tela. Takto spracovaná informácia sa prostredníctvom siete šíri na vyššiu úroveň. Proces šírenia informácie možno pripojiť k odovzdávaniu elektrochemickej informácie z jedného neurónu do druhého alebo do iných častí nervového systému Gurney (1997).

1.3.2 Topológia neurónovej siete

Vo väčšine prípadov tvorí základnú štruktúru neurónovej siete viacero vrstiev neurónov, pričom každý typ vrstvy vykonáva inú úlohu. Vstupná vrstva je zodpovedná za prijímanie informácií z vonkajšieho prostredia. Jedna alebo viac skrytých medzihláľich vrstiev sa podieľa na generovaní vzorov súvisiacich s analyzovaným procesom. Výstupná vrstva sa zúčastňuje na tvorbe a prezentácii konečných výstupov siete.

Každá vrstva siete pozostáva z jedného alebo viacerých neurónov, ktoré prijímajú vstupné hodnoty, spracovávajú informácie pomocou súboru váh a vytvárajú výstupný signál. Základná stavba matematického modelu umelého neurónu je znázornená na obrázku 1 – 2. Vstupy do umelého neurónu sú vážené, čo znamená, že

každá vstupná hodnota sa vynásobí jedinečnou váhou. Váha udáva silu spojenia medzi dvoma neurónmi. V strede neurónu sa nachádza funkcia súčtu, ktorá sčíta všetky vážené vstupy. Následne odovzdá súčet vážených vstupov aktivačnej funkcií, ktorá určí, či sa má neurón aktivovať alebo nie. Prah je konštanta pripočítaná k výsledku súčtovej funkcie a používa sa na urýchlenie alebo spomalenie aktivácie daného uzla.



Obrázok 1 – 2 Matematický model umelého neurónu

Výstup jednej vrstvy slúži ako vstup do ďalšej vrstvy. Výnimkou je výstup poslednej vrstvy siete, ktorý je celkovým výstupom siete. Výstup neurónu určíme matematickým vzťahom:

$$y = f(x, w) = g\left(\sum_{i=0}^n x_i \cdot w_i + b\right) \quad (1.1)$$

Každá nasledujúca vrstva musí mať komplexnejšie pochopenie informácií, ako tá predchádzajúca, čo umožňuje sieti učiť sa zložité vzory a vzťahy v údajoch. Topológiu siete a počet medziľahlých vrstiev s príslušným počtom neurónov pomáhajú nastaviť počiatočné hodnoty hyperparametrov trénovania, váhové matice a prahové hodnoty každého neurónu Da Silva et al. (2017), Koech (2022).

1.3.3 Učenie neurónovej siete

Neurónové siete sa učia procesom nazývaným spätné šírenie (angl. *backpropagation*), pri ktorom sa sieti dodáva súbor vstupných údajov so známymi výstupmi. Synaptické váhy sú na začiatku nastavené na náhodné hodnoty a siet ich následne upravuje v každom neuróne tak, aby minimalizovala rozdiel medzi predpovedaným výstupom a skutočným výstupom. Chyba v predpovediach modelu sa šíri späť cez vrstvy siete, čo umožňuje modelu upraviť svoje váhy s cieľom zlepšiť svoje predpovede. Tento proces sa opakuje počas mnohých iterácií, pričom siet postupne zlepšuje svoju schopnosť predpovedať správny výstup Bashir and El-Hawary (2009), Da Silva et al. (2017).

Neurónové siete sa používajú v mnohých aplikáciách vrátane rozpoznávania obrazu, rozpoznávania reči, spracovania prirodzeného jazyka a mnohých ďalších. Jednou z výhod neurónových sietí je ich schopnosť učiť sa z veľkého množstva údajov, a tým aj zovšeobecňovať získané znalosti na nové situácie. Ich trénovanie však môže byť výpočtovo náročné, preto je na dosiahnutie dobrého výkonu potrebné dôkladné prispôsobenie architektúry siete a jej hyperparametrov Masum et al. (2021).

1.3.4 Konvolučné neurónové siete

Konvolučná neurónová siet (angl. *Convolutional Neural Network*, skr. CNN) je architektúra hlbokého učenia inšpirovaná prirodzeným mechanizmom vizuálneho vnímania živých organizmov.

Vstupom konvolučnej siete môže byť obrazový, zvukový alebo aj textový záznam. Neurónová siet je konvolučná, ak obsahuje aspoň jednu konvolučnú vrstvu (angl. *convolutional layers*), ktorá umožňuje extrahovať príznaky zo vstupov pomocou konvolúcie. Tvorí ju niekoľko konvolučných jadier, ktoré sa používajú na výpočet príznakových máp (angl. *feature maps*). Každý neurón z mapy príznakov je prepojený s okolitými susednými neurónmi z predchádzajúcej vrstvy. Tieto susediace neuróny tvoria recepčné pole neurónu v predchádzajúcej vrstve. Novú mapu príznakov možno získať tak, že vstup sa najprv prevedie do zhluku s naučeným jadrom a na

skonvolované výsledky sa aplikuje nelineárna aplikačná funkcia. Kompletné mapy príznakov sa získavajú použitím niekoľkých rôznych jadier Gu et al. (2018).

Aktivačná funkcia zavádza do konvolučných neurónových sietí nelinearitu. K najčastejšie používaným nelineárny aktivačným funkciám patrí Rektifikovaná lineárna jednotka (*angl. Rectified Linear Unit*, skr. ReLU), ktorá mení záporné hodnoty na 0, pričom kladné hodnoty ostanú nezmenené. K typickým aktivačným funkciám patrí aj *sigmoid* alebo *tanh*. Okrem konvolučných vrstiev obsahujú aj vzorkovacie vrstvy (*angl. pooling layers*), ktoré slúžia na regulovanie siete a zníženie rozmerov príznakových máp. Prostredníctvom vzorkovania sa mapa príznakov rozdelí na menšie, nавzájom disjunktné časti, z ktorých sa vždy ponechá len priemerná alebo maximálna hodnota. Zlúčením nových výstupov sa vytvorí zredukovaná príznaková mapa. Takto zredukované príznakové mapy vytvoria vstup do nasledujúcej konvolučnej vrstvy.

Tretím typom vrstiev sú plne prepojené vrstvy (*angl. fully-connected layers*), ktoré sa používajú na spojenie výstupných príznakových máp do jednej vrstvy. Zvyčajne ide o jednu výstupnú vrstvu používanú na klasifikačné úlohy. Na klasifikáciu možno použiť niekolko funkcií, napríklad funkciu *Softmax*, ktorá každej triedie priradí pravdepodobnosť, s akou vstup patrí do príslušnej triedy, pričom súčet všetkých pravdepodobností je rovný 1. Pri klasifikácii bude objektu priradená trieda s najvyššou pravdepodobnosťou Gu et al. (2018).

1.4 Hlboké učenie

Hlboké učenie (*angl. Deep Learning*, skr. DL) je proces strojového učenia, ktorý na učenie a vytváranie predpovedí využíva hlboké viacvrstvové neurónové siete umožňujúce proces učenia sa na viacerých úrovniach abstrakcie Arel et al. (2010). Metódy hlbokého učenia vyžadujú veľké množstvo nespracovaných vstupných údajov, ktoré sú postupne iterované, aby sa algoritmus naučil rozpoznávať dôležité znaky, na základe ktorých môže s dátami ďalej pracovať Panch et al. (2018).

Proces učenia prebieha v niekoľkých krokoch. Najprv sa vyberie vhodná archi-

tektúra siete pre danú úlohu a inicializujú sa jej váhy. Následne sa súbor dát rozdelí na trénovaciu, validačnú a testovaciu množinu. Potom nasleduje fáza trénovalia, v ktorej sa vstupy do siete postupne porovnávajú s očakávanými výstupmi. Na základe rozdielu medzi predpovedaným výstupom a skutočným výstupom sa určí chybová funkcia, a váhy siete sa aktualizujú pomocou algoritmu spätného šírenia chyby. Tento proces sa opakuje v mnohých iteráciách, aby sa minimalizovala chyba siete na trénovacej množine a dosiahli sa presnejšie predpovede. Po dokončení trénovalia sa siet testuje na testovacej množine, čím sa overí jej schopnosť generalizácie a schopnosť predikovať výstupy pre nové vstupy, ktoré neboli zahrnuté do trénovalia. Ak je výkon siete dostačujúci, môže sa použiť na riešenie súvisiacej úlohy Arel et al. (2010).

Jednou z výhod hlbokého učenia je jeho schopnosť automaticky sa učiť príznaky z nespracovaných údajov, čím sa eliminuje potreba ďalšieho vytvárania príznakov. Naopak, trénovanie modelov hlbokého učenia môže byť výpočtovo veľmi náročné, pretože si vyžaduje špecializovaný hardvér, ako sú grafické procesory (angl. *Graphics Processing Unit*, skr. GPU) prispievajúce k urýchleniu procesu trénovalia Patel (2021).

1.5 Detekcia objektov

Detekcia objektov je technika počítačového videnia, ktorá umožňuje detegovať a lokalizovať objekty na digitálnych snímkach alebo videách pomocou algoritmov strojového učenia.

Na detekciu objektov sa najčastejšie používajú hlboké neurónové siete, ktoré sú trénované na rozpoznávanie rôznych tried objektov z obrazových vstupov. Prvým krokom detekcie objektov je vytvorenie trénovacej množiny dát, ktorá obsahuje obrázky alebo videá s anotáciami označujúcimi umiestnenie objektov a ich triedy. Na trénovanie sa používa neurónová sieť, ktorá sa snaží rozpoznať tvar, veľkosť, farbu, materiál a ďalšie špecifické vlastnosti objektu, ktoré ho odlišujú od iných objektov.

Zároveň je dôležité, aby sa algoritmus siete naučil, ako objekty navzájom súvisia. Preto sa siet trénuje opakovane, až kým nedosiahne požadovanú úspešnosť. Získané poznatky sa môžu použiť na detekciu objektov na nových obrázkoch alebo videách. Pri hľadaní nových objektov sieť rozdelí vstupný obraz na menšie časti, v ktorých sa snaží vyhľadávať požadované objekty. Ak daná časť obsahuje hľadaný objekt, výstupom siete bude pravdepodobnosť, s akou je presvedčená, že objekt detegovala správne, a tiež určí súradnice, kde sa tento objekt nachádza Akbar et al. (2022).

Algoritmy detekcie objektov sa vo všeobecnosti rozdeľujú do dvoch kategórií na základe toho, kolkokrát ten istý vstupný obraz prejde sietou. Detekcia objektov v jednom zábere využíva jeden priechod vstupného obrazu na vytvorenie predpovede o prítomnosti a umiestnení objektov v obrazu. Spracúva celý obraz v jednom priechode, vdaka čomu je výpočtovo efektívnejšia, avšak vo všeobecnosti menej účinná a presná pri detekcii malých objektov. Dvojzáberová detekcia objektov využíva dva prechody vstupného obrazu na vytvorenie predpovedí o prítomnosti a umiestnení objektov. Prvý priechod sa používa na vytvorenie súboru návrhov alebo potenciálnych umiestnení objektov a druhý priechod sa používa na spresnenie týchto návrhov a vytvorenie konečných predpovedí. Tento prístup je presnejší ako detekcia objektov v jednom zábere, ale zároveň aj výpočtovo náročnejší Parab et al. (2022).

1.6 You Only Look Once

You Only Look Once (skr. YOLO) je jeden z najpopulárnejších algoritmov detekcie objektov, ktorý dokáže rozpoznať viacero objektov na obrázku a predpovedať ich zaradenie do triedy. Algoritmus predstavil počítačový vedec Joseph Redmon s jeho tímom na Univerzite vo Washingtone Redmon et al. (2016). Prvý model bol predstavený v roku 2015, avšak odvtedy už prešiel niekoľkými modifikáciami. Poslednou aktualizovanou verziou je YOLOv8, ktorú vyvinula spoločnosť Ultralytics Glenn (2023).

Detekcia objektov prostredníctvom YOLO algoritmu je založená na hlbokom

učení konvolučnej neurónovej siete so spracovaním obrazu v reálnom čase. Preto sa model dokáže učiť veľmi rýchlo. Vysoká miera učenia sa využíva princíp regresného modelu, z ktorého algoritmus vychádza. Jednou z jeho veľkých výhod oproti iným metódam detekcie objektov je percepcia obrazu ako celku. Pri trénovaní sa algoritmus nepozerá len na určitý segment obrazu s vysokou pravdepodobnosťou výskytu hľadaného objektu, ale pracuje s celou oblasťou, v ktorej sa snaží predpovedať ohraňujúce polia, na ktorých by sa hľadaný objekt mohol nachádzať. Objekty v obraze sú vyhľadávané dopredným prechodom konvolučnej neurónovej siete. Siet predpovedá ohraňujúce polia s pravdepodobnosťami výskytov tried hľadaných objektov v rámci jedného vyhodnotenia. Cielom výsledného modelu je potom podľa vopred definovaných hyperparametrov rozpoznať objekt, detegovať ho, určiť jeho súradnice a zaradiť ho do niektoréj z tried Nie et al. (2019), Redmon et al. (2016).

1.6.1 Princíp algoritmu YOLO

Na vstupe algoritmus načíta obrázok, ktorému nastaví pevnú veľkosť. Vstupný obrázok rozdelí na mriežku o veľkosti $S \times S$ dielikov a každému dieliku predpovedá pravdepodobnosť výskytu objektu v jeho vnútri. Ak objekt leží vo viac ako jednom dieliku mriežky, za detekciu objektu bude zodpovedať dielik, v ktorom sa nachádza stred objektu. Zároveň každý dielik predikuje B ohraňujúcich polí, skóre dôveryhodnosti pre tieto polia a podmienené pravdepodobnosti tried C . Skóre dôveryhodnosti udáva pravdepodobnosť, s akou je model presvedčený, že sa objekt nachádza v ohraňujúcom poli, a tiež to, ako presne je zistený objekt ohraňčený. Matematicky ho možno popísť ako súčin pravdepodobnosti výskytu objektu a spoločného prieniku (angl. *Intersection over Union*, skr. IoU) medzi predvídaným ohraňujúcim poľom a pravdivým ohraňujúcim poľom:

$$P(\text{Objekt}) * IoU_{\text{Predikovaný}}^{\text{Pravdivý}} \quad (1.2)$$

Ak sa v dieliku hľadaný objekt nenachádza, pravdepodobnosť výskytu objektu je rovná nule. V takom prípade je nulové aj skóre dôveryhodnosti.

Každé ohraničujúce pole je definované piatimi číselnými údajmi $x, y, w, h, skóre dôveryhodnosti$. Súradnice x a y definujú stred ohraničujúceho poľa. Šírka w a výška h predstavujú šírku a výšku ohraničujúceho poľa vzhľadom na celý obrázok.

Každý dielik mriežky predikuje aj podmienené pravdepodobnosti tried C , ktoré určujú pravdepodobnosť, s akou objekt v dieliku prináleží k danej triede:

$$P(Trieda_i|Objekt) \quad (1.3)$$

V čase testu sa vynásobia podmienené pravdepodobnosti tried a predpovede dôveryhodnosti jednotlivých ohraničujúcich políčok. Výsledkom bude skóre dôveryhodnosti pre každé pole ohraničujúce objekt istej triedy:

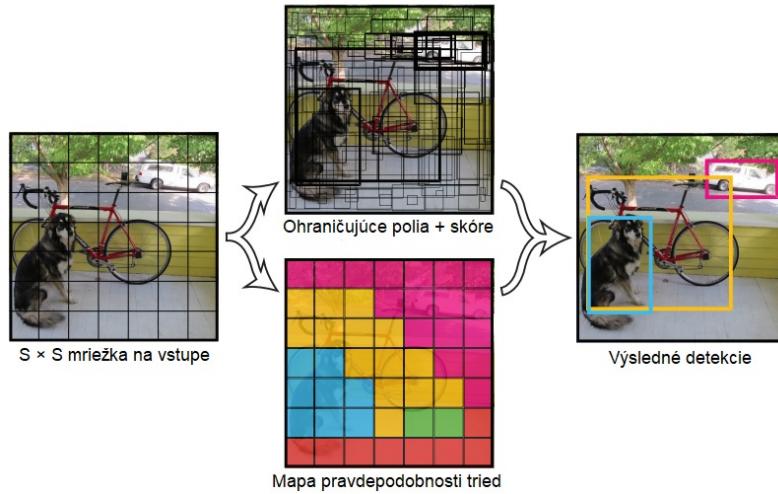
$$P(Trieda_i|Objekt)*P(Objekt)*IOU_{Predikovaný}^{Pravdivý} = P(Trieda_i)*IOU_{Predikovaný}^{Pravdivý} \quad (1.4)$$

Rozdelenie obrazu do tvaru mriežky je výpočtovo veľmi efektívne a umožňuje algoritmu detegovať viacero objektov všetkých tried v jednom obrazze. Na zlepšenie presnosti detekcie objektov a odstránenie nadbytočnosti ohraničujúcich boxov algoritmus využíva metódu potlačenia bez maximálnej hodnoty (z angl. *non-max suppression*), ktorá zabezpečuje vyradenie ohraničujúcich polí prekrývajúcimi sa s inými poliami s vyšším skóre dôveryhodnosti. Celý princíp fungovania YOLO algoritmu je zobrazený na obrázku 1–3. Na výstupe algoritmus YOLO pre každý dielik predpovedá B ohraničujúcich polí objektov spolu so získaným skóre dôveryhodnosti a príslušnosťou do jednotlivých tried C :

$$S \times S \times (B * 5 + C) \quad (1.5)$$

2 Prechodné svetelné javy a ich pozorovanie

Prechodné svetelné javy (angl. *Transient Luminous Events*, skr. TLE) sú krátko trvajúce svetelné javy, ktoré vznikajú za poruchy pôsobenia troposferickej elektricky indukovanej aktivity nad systémom silných búrok v nadmorských výškach stratosféry, mezosféry a termosféry, od približne 15 kilometrov do 110 kilometrov nad



Obrázok 1 – 3 Princíp fungovania YOLO algoritmu. Obrázok je upravený z Redmon et al. (2016).

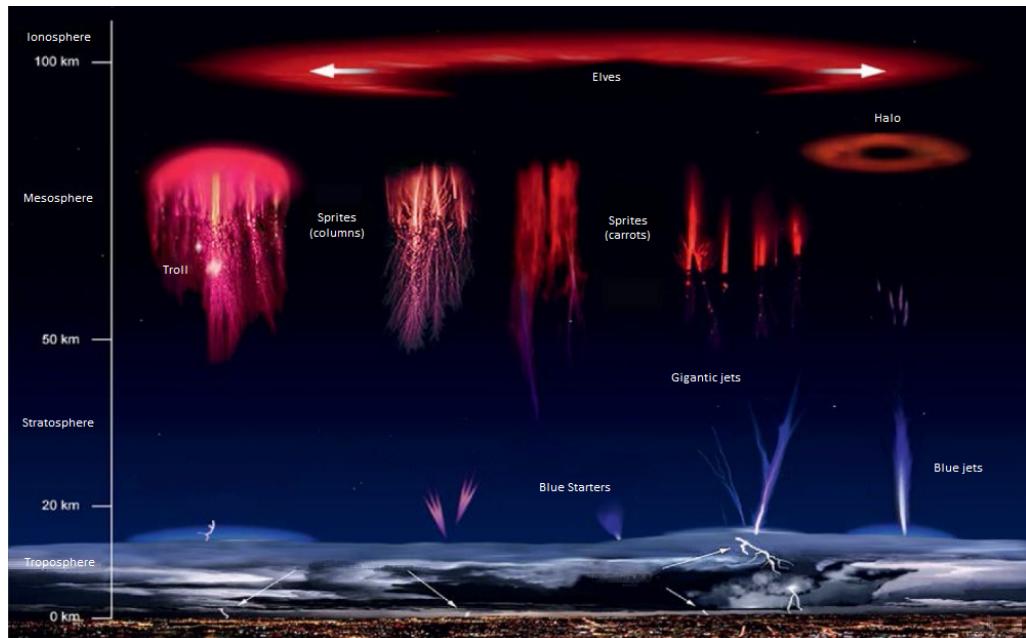
zemským povrchom. Typické trvanie svetelných javov sa líši od toho ktorého javu, no vo všeobecnosti sa pohybuje v rozmedzí okolo 1 milisekundy až 100 milisekúnd Pasko et al. (2012).

Pozemnými pozorovaniami boli identifikované rôzne typy svetelných emisií, ktoré v závislosti od rôznych vlastností môžu byť rozdelené do týchto tried - škriatkovia (angl. *sprites/red sprites*), modré výtrysky (angl. *blue jets*), modré štartéry (angl. *blue starters*), gigantické výtrysky (angl. *gigantic jets*) a elfovia (angl. *elves*). Rôzne typy prechodných javov v závislosti od ich výskytu sú zobrazené na obrázku 2 – 1. Veľkosti TLE sa môžu pohybovať od niekoľko desiatok metrov až po stovky kilometrov Surkov and Hayakawa (2012).

2.1 Prechodné svetelné javy

2.1.1 Škriatkovia

Škriatkovia (angl. *Stratospheric Perturbations Resulting from Intense Thunderstorm Electrification*, skr. *Sprites*) je názov pre stratosférické/mezosférické poruchy vyplývajúce z intenzívnej búrkovej činnosti. Prejavujú sa ako krátkodobé úponkovité záblesky červeného svetla dosahujúce nadmorskú výšku od 50 kilometrov po 90 kilo-



Obrázok 2 – 1 Prechodné svetelné javy upravené z Blelly (2020).

metrov. Poruchy vznikajú pozitívnymi výbojmi blesku, medzi vrcholom búrkového oblaku a zemou, pri jasnej červenej žiare, ktorá sa s klesajúcou nadmorskou výškou pod 50 kilometrov postupne mení na modrú farbu Surkov and Hayakawa (2012). Ich trvanie na oblohe je viditeľné od niekoľkých submilisekúnd po niekoľko desiatok milisekúnd. Zvyčajne sa vyskytujú v skupinách po dvoch, troch alebo viacerých zábleskoch. Niektoré vytvárajú tesné zhluky, iné sa zas môžu voľne rozprestierať do niekoľko desiatok kilometrov. Na základe ich tvaru a vzhľadu rozlišujeme tri typy škriatkov - medúzy (angl. *jellyfish*), stĺpy (angl. *columns*) a mrkvy (angl. *carrots*) Sanders (2004), Singh et al. (2017).

Pozorovanie škriatkov na oblohe je obzvlášť náročné, pretože sú často skryté za búrkovými systémami, ktoré ich vytvárajú. Na rozdiel od bleskov, ktoré sú extrémne horúce, škriatkov tvorí studená plazma. Vznik krátkodobých zábleskov možno pripojiť k reakcii vo vnútri žiarovky. Aby žiarovka mohla vyžarovať svetlo, potrebuje zdroj energie, ktorý ionizuje plyny zachytené vo vnútri. Aj škriatkovia potrebujú elektrický výboj na spustenie fluorescenčnej reakcie. Vo vnútri búrkového oblaku

dochádza k treniu medzi stúpajúcimi kryštálmi ľadu, ktoré sú kladne nabité, a padajúcimi časticami krúp s negatívnym nábojom. Tieto kladne nabité ľadové kryštáliky spôsobujú, že sa nad nimi vo vzduchu vytvára záporná ochranná vrstva. Ked dôjde ku kladnému výboju v podobe úderu blesku, mrak sa neutralizuje, ale záporná ochranná vrstva zostáva. Práve táto nestabilná, záporne nabité ochranná vrstva spôsobuje elektrický výboj, čím vznikajú záblesky v podobe škriatkov Gordillo-Vázquez and Pérez-Invernón (2021).

2.1.2 Modré výtrysky

Modré výtrysky (angl. *Blue jets*) sú svetelné kužeľovité prúdy modrej farby, ktorú spôsobujú modro-fialové emisie excitujúce z molekulárneho dusíka. Pripomínajú veryšoké stromy s kvázi vertikálnym kmeňom a vláknitými vetvami. Vznikajú v hornej časti búrkového oblaku z výboju, ktorý sa od aktívnej búrky šíri smerom nahor rýchlosťou rádovo 100 kilometrov za sekundu do konečnej výšky 40 až 50 kilometrov. Modré výtrysky sa v porovnaní so škriatkami vyskytujú v atmosfére oveľa nižšie, čo je dôvodom, prečo fluoreskujú modrou farbou. Ich priemerná životnosť je jedna desatina sekundy Mishin and Milikh (2008), Singh et al. (2017).

2.1.3 Modré štartéry

Modré štartéry (angl. *Blue starters*) sú menšou verziou modrých výtryskov. Líšia sa nižšou konečnou výškou, pretože dosahujú maximálne 18 až 25 kilometrov. Niekoľko sú označované ako neúspešné modré výtrysky. Pasko et al. (1996) vysvetluje základné vlastnosti modrých výtryskov a štartérov na základe pozitívnych prúdníc, pričom naznačuje, že sa tieto TLE javy zrejme vyskytujú v oblastiach búrok, ktoré produkujú negatívne záblesky medzi oblakmi a zemou (angl. *cloud-to-ground*, skr. CG) od oblaku k zemi. Štartéry charakterizuje jasná svietivosť a pri vzniku vystupujú z vrcholu oblaku smerom nahor Surkov and Hayakawa (2012).

2.1.4 Gigantické výtrysky

Gigantické výtrysky (angl. *Gigantic jets*) je pomerne zriedkavo sa vyskytujúci rozsiahly svetelný jav, ktorý sa v porovnaní s modrými výtryskami vyznačuje dosahovaním väčších výšok a intenzívnejším prejavom výbojov. Pri vytváraní elektrického spojenia medzi búrkovým mrakom a vodivej E-vrstvy (angl. *Electrical-Layer*, skr. E-layer) ionosféry sa prejavujú šírením smerom nahor. Môžu sa šíriť až po dno ionosféry, čo spôsobuje, že farba v hornej časti javu sa mení z modrej na červenú Surkov and Hayakawa (2012). V záverečnej fáze šírenia je pre nich typické dosahovanie podstatne vyšších rýchlosťí Mishin and Milikh (2008).

2.1.5 Elfovia

Označenie Elfovia (angl. *Elves*) vzniklo ako skratka z anglického pomenovania *Emission of Light and Very Low Frequency perturbations due to Electromagnetic Pulse Sources*, čo možno volne preložiť ako emisia svetla vyvolaná elektromagnetickým impulzom vytvoreným v spodnej časti blesku na odrazovej hranici vlnovodu s veľmi nízkou frekvenciou. Svetlo vzniká excitáciou molekúl dusíka v dôsledku zrážok elektrónov nabitéych elektromagnetickým impulzom spôsobeným výbojom z búrky. Vzhľadom pripomínajú sústredné svetelné prstence o priemere niekoľko stoviek kilometrov. Vyskytujú sa v spodnej časti ionosféry vo výške 100 kilometrov nad zemou. Na rozdiel od škriatkov, je ich výskyt predvídateľný ešte pred samotným vznikom. Pre ich krátke trvanie, niekoľko milisekúnd, sú voľným okom nespozorovateľné Wu (2019).

2.2 Celooblohový systém na snímanie meteorov

Celooblohový systém na snímanie meteorov (angl. *All-sky Meteor Orbit System*, skr. AMOS) je video-systém vytvorený v roku 2007 na Astronomickom a Geofyzikálnom observatóriu Fakulty matematiky, fyziky a informatiky Univerzity Komenského v Modre (FMFI UK). Systém bol primárne vyvinutý na určovanie dráh meteorov. Okrem pozorovania meteorov sa však môže využívať aj na rôzne meteorologické,

geofyzikálne, letecké alebo satelitné pozorovania Tóth et al. (2015). V súčasnosti sa AMOS kamery používajú aj pri výskume prechodných svetelných javov, ktorý je taktiež predmetom tejto bakalárskej práce.

Obsluha kamier je poloautomatická, vyžaduje prívod elektrickej energie a prístup k internetovému pripojeniu, vďaka ktorému je kamery možné ovládať aj diaľkovo. Celý AMOS systém pozostáva zo štyroch hlavných komponentov - objektívu typu rybie oko, zosilňovača obrazu, projekčného objektívu a digitálnej videokamery. Komponenty sú chránené vnútornými aj vonkajšími krytmi, a zabezpečené snímačmi teploty, dažďa a osvetlenia oblohy Tóth et al. (2019).

Na detekciu javov TLE v tomto výskume boli poskytnuté snímky zhotovené piatimi v súčasnosti existujúcimi slovenskými kamerami AMOS. Kamery sú umiestnené na nasledujúcich miestach - Astronomické a geofyzikálne observatórium v Modre (AGO) znázornené na obrázku 2–2, Arborétum Tesárske Mlyňany (ARBO), Hvezdáreň Kysucké Nové Mesto (KNM), Važec a SOLAR Hvezdáreň Senec. Ročný výkon jednotlivých slovenských kamier AMOS zodpovedá detekcii približne 10 000 meteорov, 50 krátko trvajúcich elektrických výbojov, a zhruba 100 satelitných zábleskov na stanicu. Okrem Slovenskej republiky sa kamery AMOS prevádzkujú aj v zahraničí, a to na Kanárskych ostrovoch, v Čile a na Havaji Tóth et al. (2019).



Obrázok 2–2 Prvá AMOS kamera umiestnená na univerzitnom observatóriu v Modre Volek (2017).

3 Zlepšenie modelu detektie TLE na snímkach kamier AMOS

Výskum prechodných svetelných javov je dôležitý pre niekoľko vedeckých účelov. Umožňuje pochopiť procesy vzniku bleskov, príspevku na globálne elektrické obvody, ako aj chemického vplyvu na zemskú klímu. Tieto javy možno pozorovať vypustením rôznych pozorovacích telies do vesmíru, z lietadiel a balónov alebo priamo z povrchu Zeme. Zatiaľ čo pozemné pozorovania zohrali kľúčovú úlohu pri pochopení fyzikálnych procesov TLE, experimenty s kozmickými sondami objasnili aj vedecky dôležité parametre, ako je presný jas, horizontálna morfológia a globálne rozšírenie Adachi et al. (2016). Cieľom tejto bakalárskej práce je analyzovať niektoré súčasné modely zaobrajúce sa skúmaním TLE javov, pochopiť ich prínos a vyvinúť model neurónovej siete, ktorý na základe údajov získaných z AMOS kamier dokáže odhaliť ich výskyt s dostatočnou presnosťou. Vďaka modelu taktiež prehľadáme veľké množstvo astronomických údajov, z ktorých získame jedinečnú vzorku TLE javov. Vyhodnotíme výsledky a analyzujeme vzťahy vyplývajúce zo získanej vzorky dát.

3.1 Analýza súčasných modelov detektie TLE

Aktivitu bleskov monitoruje niekoľko pozemných, vzdušných a vesmírnych systémov vo všetkých častiach sveta. V tejto podkapitole budú opísané vybrané projekty systémov detektie TLE.

Prvý z modelov je súčasťou misie ASIM (angl. *Atmosphere-Space Interaction Monitor*), ktorá bola úspešne vypustená 2. apríla 2018 raketou SpaceX Falcon9 na lodi SpaceX Dragon z Mysu Canaveral na Floride. ASIM je medzinárodný projekt, ktorý realizovala Európska vesmírna Agentúra (angl. *European Space Agency*, skr. ESA). Jej cieľom bolo pozorovanie bleskov v horných vrstvách atmosféry nad prudkými búrkami a meranie röntgenového vysokoenergetického žiarenia, ktoré z nich vychádza. ASIM je pripojený mimo Medzinárodnej vesmírnej stanice (angl. *International Space*

Station, skr. ISS) k modulu Columbus s nadirným výhľadom na Zem, čo je ideálne miesto na monitorovanie búrok do vzdialenosťi 100 kilometrov od povrchu Zeme. ASIM pripojený k modulu Columbus je zobrazený na obrázku 3–1. Na vizuálne pozorovanie TLE javov má systém vlastný optický prístroj MMIA (angl. *Modular Multispectral Imaging Array*), ktorý meria optické emisie pomocou dvoch vlnových dĺžok na meranie zmien toku fotónov. Snímanie sa uskutočňovalo len v noci, pretože obidve kamery prístroja sú citlivé na svetlo. Nepretržite pracujúci systém deteguje náhle zmeny toku fotónov a zhromažďuje údaje pred a po udalosti, uloží ich, a odošle do centra spracovania na Zem Neubert et al. (2019).



Obrázok 3–1 ASIM na module Columbus. Obrázok upravený z ESA (1970)

Energetická excitácia horných vrstiev atmosféry vplyvom bleskov (angl. *Energetic of Upper Atmospheric Excitation by Lightning*, skr. EXL98) bola misia aljaškej univerzity realizovaná v lete 1998. Jej úlohou bolo vykonávanie vzdušných pozorovaní prechodných svetelných javov pomocou prístrojov umiestnených na palube prúdového lietadla Gulfstream II, ktoré je zobrazené na obrázku 3–2. Cieľom pozorovania bolo získať poznatky o energetických charakteristikách prechodných svetelných javov prostredníctvom diaľkového snímania emisií a rôznych vlnových dĺžok. Na pomoc sa použili systémy predpovede počasia, ako aj informácie pre pozemné operácie na oznamovanie polohy a výskytu veľkých búrok. Systém na detekciu TLE pozostával z ôsmich zosúladených zobrazovacích systémov poskytujúcich simultánne pozorovanie TLE vo vlnovej dĺžke v rozsahu 340 až 4,3 mikrónov. Už počas prvej noci pozorovania bolo vhodne štruktúrované silné prúdenie vzduchu a nastala séria

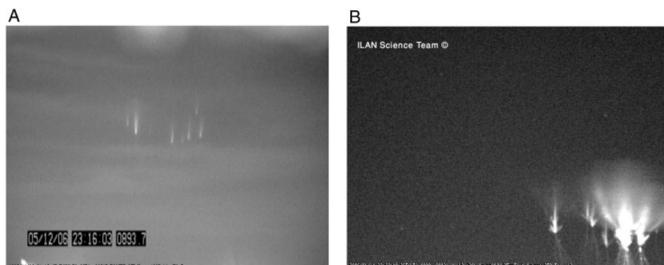
TLE javov typu škriatkovia. Zachytené gravitačné vlny naznačili súvis niektorých funkcií, ako napríklad ich výskyt na takmer rovnakom mieste alebo podobný sklon Siefring et al. (2010).



Obrázok 3 – 2 Lietadlo EXL98 Gulfstream II a jedna z kamier snímania Siefring et al. (2010)

Pozorovanie TLE z vesmíru je oproti pozorovaniam z povrchu zeme výhodnejšie v tom, že rozptyl a atmosférická absorpcia sú na zemi oveľa intenzívnejšie. Existuje však aj niekoľko systémov pozorovania TLE, ktoré sú umiestnené priamo na zemskom povrchu. Jedným takým pozorovaním je kampaň ILAN (angl. *Imaging of the Lightning And Nocturnal flashes*), ktorá bola zameraná na získanie a spracovanie čo najväčšieho počtu výskytov TLE javov v Stredomorí. Pozemné pozorovania detekcie TLE boli vykonávané každú zimu z dvoch miest - Areál Tel-Avivskej univerzity a Observatórium Wise v Mitzpe-Ramon v Negevskej púšti, ktoré sa nachádza 170 kilometrov od Tel-Avivu. Na tieto pozorovania boli použité dve kamery. Hlavná panchromatická CCD kamera Watec 100N s 12 milimetrovým objektívom a snímkovou frekvenciou 25 snímok za sekundu a vedľajšia panchromatická CCD kamera Watec 902H s 25 milimetrovým objektívom a snímkovou frekvenciou 30 snímok za sekundu. Tieto kamery vykonávali videozáZNAM v reálnom čase, ktorý prechádzal cez systém zabezpečujúci kompresiu údajov. V dvoch zimných sezónach nebola väčšina vybraných nocí jasná viditeľnosť, a preto len 10 nocí poskytlo úspešné snímky s TLE nad búrkami. Celkovo počas dvoch zím nastalo 66 pozorovaní TLE - 32 za

zimu 2005/2006 a 34 za zimu 2006/2007. Zachytené snímky sú zobrazené na obrázku 3–3 Yair et al. (2009).



Obrázok 3–3 (A) Skupina stĺpových výtryskov nasnímaných v svetlne znečistenej oblasti Tel Avivu 31. októbra 2006. (B) Skupina mrkvových výtryskov, snímaná z Mizpe-Ramon v noci 14. januára 2006 Yair et al. (2009).

3.2 Pochopenie cieľa

Okrem vyššie spomenutých modelov, v súčasnosti existuje aj jeden model konvolučnej neurónovej siete YOLOv5, ktorý slúži na automatickú detekciu TLE javov. Model bol natrénovaný na snímkach získaných zo slovenských AMOS kamier v minuloročnej bakalárskej práci Kamenská (2022). Samotný systém dokáže nájsť TLE javy s pomerne vysokou presnosťou, avšak jeho veľkou nevýhodou je, že zároveň náhľadzovať falošných javov. K chybne identifikovaným dátam patria napríklad kríky, nosné konštrukcie, kostolná veža alebo iné objekty, ktoré medzi správne predikované TLE javy vnášajú šum. Ročne model odhalí tisícky snímok, na ktorých by sa mali vyskytovať prechodné svetelné javy, hoci v skutočnosti ide len o približne 50 javov. Ďalším problémom je, že model neidentifikuje všetky prechodné svetelné javy. Niekoľko model nerozpozná hľadaný objekt - prechodný svetelný jav, čím o túto cennú snímku prídeme. Z dosiahnutých výsledkov vyplýva, že trénovanie modelu umelej inteligencie na detekciu TLE javov na snímkach z AMOS kamier je náročná úloha. Zdokonalenie modelu konvolučnej neurónovej siete YOLO používanej na automatickú detekciu javov TLE je problém, ktorým by sme sa chceli v tejto bakalárskej práci zaoberať.

Aby model hlbokého učenia dokázal správne detegovať objekty s vysokou pravdepodobnosťou, potrebuje dostatočné množstvo údajov, na ktorých sa naučí identifikovať vlastnosti hľadaných objektov. Na detekciu prechodných svetelných javov je k dispozícii približne 270 000 snímok z kamier AMOS, no pomocou existujúceho modelu YOLOv5 bolo identifikovaných len 377 snímok s aspoň jedným prechodným svetelným javom. Počet doteraz nájdených snímok s výskytom TLE javov nie je postačujúci na uspokojivé natrénovanie modelu.

Zlepšenie modelu by sme chceli docieliť umelým rozšírením dátovej množiny potrebnej na trénovanie nového modelu. Kvalita dátovej množiny zohráva kľúčovú úlohu vo fáze trénovania, a zároveň ovplyvňuje samotnú úspešnosť modelu. Čím viac rôznorodých údajov má siet k dispozícii, tým lepšie sa môže naučiť identifikovať prechodné svetelné javy na nových snímkach. Okrem rozšírenia trénovacej množiny, bude našim cieľom aj spresnenie anotácií a následne detekcií existujúcich javov, a taktiež možné objavenie nových snímok s TLE javmi. Ďalším zámerom je analyzovať výsledný súbor správne detegovaných obrázkov, preskúmať korelácie a graficky znázorniť výsledky.

V tejto kapitole vychádzame z existujúceho YOLOv5 modelu, ktorý sa snažíme simulovať vytvorením podobného modelu. Ten nám poslúži ako východiskový bod pre porovnanie s novým, presnejším modelom detekcie TLE objektov. Keďže v januári 2023 bola vydaná nová verzia konvolučnej neurónovej siete YOLO, budeme trénovať modely v dvoch jej verziách, a to vo verzii 5, a v novej verzii 8. Tieto dva modely porovnávame so základným modelom a tiež medzi sebou. Aby sme modely porovnali objektívne, zachováme rovnaké rozdelenie údajov aj hyperparametrov neurónovej siete. Na spracovanie dát a trénovanie modelu využijeme programovací jazyk Python a prostredie JupyterLab.

3.3 Pochopenie dát

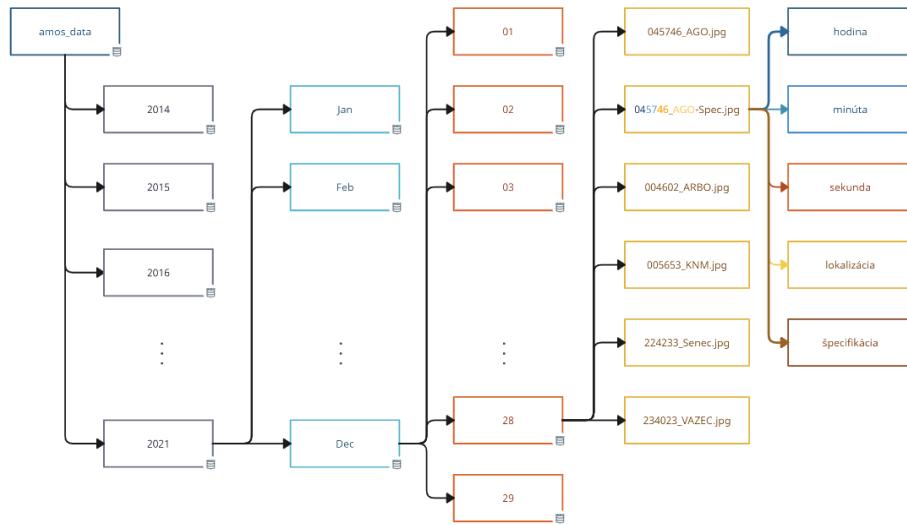
Na trénovanie modelu detekcie TLE objektov nám boli poskytnuté údaje na základe spolupráce s Oddelením astronómie a astrofyziky na Fakulte matematiky, fyziky a informatiky Univerzity Komenského v Bratislave. K dispozícii máme dataset snímok z piatich slovenských AMOS kamier v rozmedzí rokov 2014 až 2021. Z prvých dvoch rokov máme len 27 snímok s výskytom prechodných svetelných javov. Ďalšie roky obsahujú v priemere 44 500 snímok, pričom v každom roku je známych približne 60 jedinečných snímok s výskytom aspoň jedného TLE javu. Podrobnejšie rozdelenie dát je zobrazené v tabuľke 3 – 1.

	Obrázky s TLE	Všetky obrázky
2014	9	9
2015	18	18
2016	61	41 987
2017	77	48 189
2018	25	52 371
2019	48	53 964
2020	96	39 375
2021	43	31 251
SÚČET	377	267 164

Tabuľka 3 – 1 Rozdelenie vstupných údajov podľa rokov

Snímky sú zatriedené do priečinkov podľa rokov, kedy boli vytvorené. Každý rok obsahuje podadresáre dvanásť mesiacov a každý mesiac obsahuje podadresáre očíslované dňom, kedy bola snímka vytvorená. Názov snímky pozostáva z časovej pečiatky, skratky názvu umiestnenia kamery AMOS, a v niektorých prípadoch obsahuje aj ďalšie špecifikácie. Štruktúra priečinka je zobrazená na obrázku 3 – 4.

Východiskovou pozíciou pre prvé trénovanie modelu bude podmnožina správne identifikovaných prechodných svetelných javov z existujúceho modelu Kamenská



Obrázok 3 – 4 Schematický diagram členenia dátových súborov z kamier AMOS

(2022). Každý nájdený jav pozostáva z obrázka v JPG formáte a textového súboru, ktorý bol získaný na výstupe pri testovaní existujúcim YOLOv5 modelom. Textový súbor obsahuje označenie triedy a súradnice nájdeného TLE. Súčasný model rozpoznáva len jednu triedu, a to, či sa na obrázku nachádza prechodný svetelný jav. Ak sa na obrázku jav nachádza, neurónová sieť túto triedu označila v textovom súbore číslom 0. Ak sa na jednom obrázku nachádzal viac ako jeden TLE jav, pre každý výskyt bola vytvorená kópia obrázku a nový jednoriadkový textový súbor. Okrem označenia triedy, textový súbor obsahuje aj informácie o umiestnení a veľkosti ohraničujúceho pola, ktoré obklopuje nájdený objekt.

3.4 Príprava dát

Hlavným cieľom tejto práce je vyvinúť lepší model na detekciu TLE javov. Jedným zo spôsobov, ako možno zvýšiť úspešnosť detekčného modelu YOLO, je umožniť modelu učiť sa na väčšom spektre situácií. Avšak v porovnaní s predchádzajúcim modelom budeme vychádzať z rovnakej množiny AMOS dát. Okrem toho však pristúpime k umelému rozšíreniu údajov, na ktorých bude nový model natrénovaný. Proces umelého navýšenia trénovacej množiny úpravou kópií existujúcich údajov sa nazýva

augmentácia dát. Umožňuje zvýšiť rozmanitosť dát bez potreby doplnenia nových údajov. Augmentácia dát zahŕňa vykonanie menších zmien v súbore údajov alebo použitie hlbokého učenia na generovanie nových dátových zdrojov. Jej účelom je zlepšiť schopnosť modelu zovšeobecňovať poznatky, zvýšiť jeho presnosť a znížiť prípadné príliš veľké prispôsobenie na trénovacie údaje.

V súčasnosti existuje mnoho prístupov, ako možno údaje rozšíriť. Vzhľadom na problém, ktorý riešime, však nemôžeme použiť ľubovoľné metódy rozšírenia údajov. Údaje z kamier AMOS, ktoré máme k dispozícii, sú čiernobiele snímky, ktoré boli zhodené kolmou projekciou oblohy zo zeme. Výskyt javov TLE je možný len pozdĺž okraja oblohy, pričom daný jav je kolmý na zemský povrch a v porovnaní s veľkosťou snímky je veľmi malý. Popísané fakty možno pozorovať na vybranom obrázku 3 – 5 reprezentujúcim dátovú množinu. Z tohto dôvodu bolo potrebné zvoliť také metódy augmentácie dát, ktoré nenarušia tieto skutočnosti.



Obrázok 3 – 5 Snímka vyhotovená 30. mája 2017 nasnímaná kamerou AMOS umiestnenou v areáli Arboréta Tesárske Mlyňany

Pre umelé navýšenie dátovej množiny sme sa rozhodli aplikovať štyri spôsoby

rozšírenia:

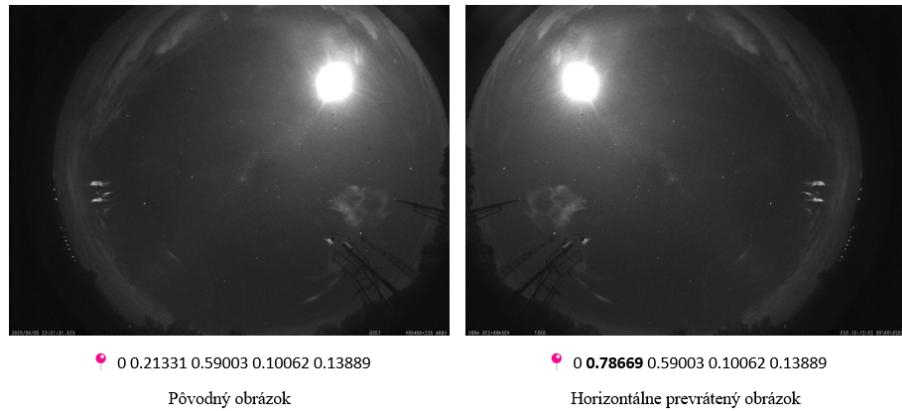
- horizontálne prevrátenie,
- vertikálne prevrátenie,
- rotáciu o náhodný počet stupňov z vopred stanoveného intervalu v smere alebo proti smeru hodinových ručičiek
- zlúčenie segmentu TLE javu z jednej snímky s inou snímkou bez výskytu TLE javu.

V prípade prevrátenia a otočenia obrazu o náhodný počet stupňov sa sklon TLE javu voči rovine nezmení. Aby sme tento poznatok zachovali aj pri umiestnení segmentovaného javu na novú snímku z dostupných údajov AMOS, umiestnili sme jav na rovnaké súradnice, z ktorých sme ho vyselektovali z pôvodnej snímky. S cieľom vyhnúť sa prekrývaniu javov TLE sme segmentované javy umiestnili len na snímky bez výskytu prechodných svetelných javov. Typy rozšírení údajov, ktoré sme využili, sú priblížené na nasledujúcich stranách. Všetky údaje boli rozšírené pomocou programovacieho jazyka Python s použitím knižnice OpenCV, ktorá obsahuje súbor funkcií zameraných na počítačové videnie.

Jedným z problémov existujúceho YOLOv5 modelu slúžiaceho na detekciu prechodných svetelných javov je aj označovanie veľkého množstva chybných objektov. Prevažne ide o nehybné útvary umiestnené na okraji snímok. Z tohto dôvodu sme sa rozhodli pristúpiť k rovnakému riešeniu, aké už bolo aplikované v bakalárskej práci Kamenská (2022). Vo fáze predspracovania údajov sme frekventované nesprávne označované miesta prekryli čiernymi obdlžníkmi.

3.4.1 Horizontálne prevrátenie

Horizontálne prevrátenie je technika rozšírenia údajov, ktorá rozdelí obrázok na maticu pixelov, ktorej riadky aj stĺpce prevráti vo vodorovnom smere. Výsledkom je obrázok preklopený pozdĺž osi y .



Obrázok 3 – 6 Pôvodný obrázok a obrázok po použití horizontálneho preklopenia

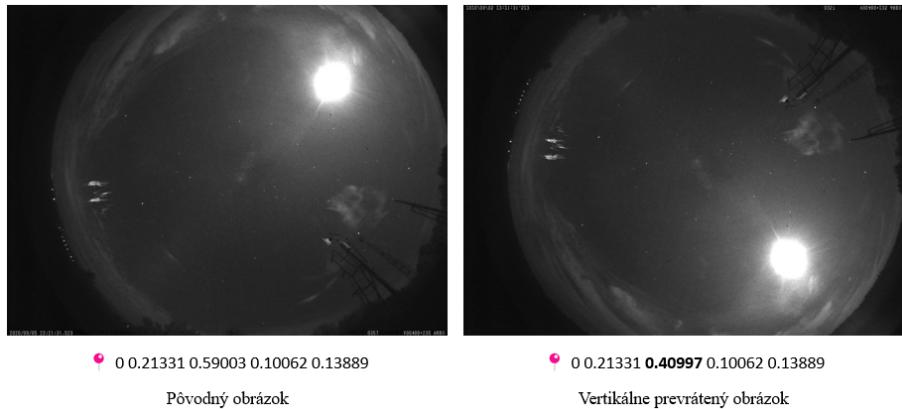
Na trénovanie modelu neurónovej siete je okrem vstupného obrázka potrebné definovať aj textový súbor obsahujúci triedu klasifikácie objektu a súradnice objektu, ktorého vlastnosti sa má naučiť rozpoznávať. Pre všetky východiskové obrázky sme už tieto anotačné textové súbory mali, avšak vzhľadom na vykonanú augmentáciu sme potrebovali prepočítať súradnice umiestnenia objektov na novú polohu.

Pri horizontálnom prevrátení obrazu sa pixely preklopia zrkadlovo cez pomyselnú horizontálnu os, čím sa ľavá strana obrazu symetricky premietne na pravú stranu a naopak. V dôsledku toho pixely objektu nezmenia súradnicu y , meniť sa bude len súradnica x . Zmenu polohy možno matematicky opísť vzťahom $1 - x$.

3.4.2 Vertikálne prevrátenie

Vertikálne prevrátenie je technika rozšírenia údajov, ktorá zohľadňuje riadky aj stĺpce matice reprezentujúcej obrázok a vertikálne ich preklopí. Výsledkom je obrázok prevrátený pozdĺž osi x . Stredom obrázka možno preložiť pomyselnú vodorovnú os, ktorá obrázok rozdeľuje na hornú a dolnú polovicu. Pri vertikálnom prevrátení sa potom pixely z hornej časti obrázka symetricky premietnu do spodnej časti obrázka a naopak. Taktiež sa mení iba jedna súradnica ohraničujúceho poľa. V tomto prípade ide o súradnicu y . Analogicky prevrátenie možno vyjadriť matematickým vzťahom $1 - y$. Vertikálne prevrátenie obrázka a prepočet súradníc je zobrazený na

obrázku 3 – 7.



Obrázok 3 – 7 Pôvodný obrázok a obrázok po použití vertikálneho preklopenia

3.4.3 Rotácia o náhodný počet stupňov

Rotácia je technika rozšírenia údajov, ktorá sa používa na otáčanie obrazu v smere alebo proti smeru hodinových ručičiek o určitý počet stupňov. Jej výsledkom je otočený obrázok so zmenenou polohou objektov na snímke.

V prvom kroku sme každú kópiu obrázka náhodne otočili o najviac 45 stupňov, a to buď v smere alebo proti smeru hodinových ručičiek. Po rotácii však nastala zmena veľkosti obrázkov, ktorú sme v druhom kroku zjednotili na veľkosť 1280 x 960 pixelov. Zachovanie jednotnej veľkosti je dôležité pre vstup do neurónovej siete YOLO, a tiež zohráva dôležitú úlohu pri prepočítavaní nových súradníc ohraňujúceho poľa detegovaného TLE javu.

Na to, aby sme rotovali ľubovoľný dvojrozmerný bod so súradnicami $[x, y]$ o uhol θ , musíme ho vynásobiť rotačnou maticou:

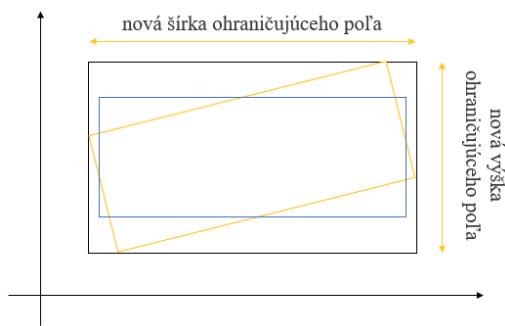
$$\begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix} \quad (3.1)$$

Po vynásobení maticou rotácie bude bod otočený proti smeru hodinových ručičiek o uhol θ . Pre získanie novej pozície bodu stačí maticu rotácie vynásobiť s ma-

ticou súradníc.

$$\begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix} * \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x' \\ y' \end{pmatrix} \quad (3.2)$$

Po otočení všetkých štyroch rohov ohraničujúceho poľa musíme nájsť dva najvzdialenejšie otočené body pozdĺž osi x , táto vzdialenosť bude zodpovedať novej šírke ohraničujúceho poľa, a osi y , čo bude zodpovedať novej výške ohraničujúceho poľa. Nové ohraničujúce pole je znázornené na obrázku 3–8.

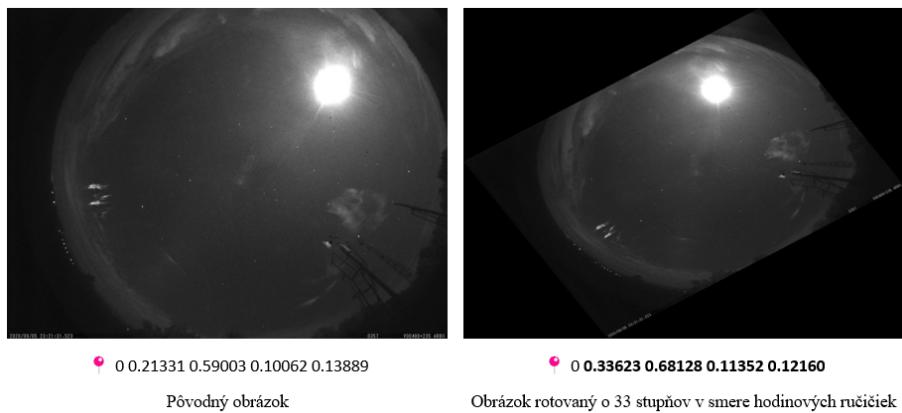


Obrázok 3–8 Pôvodné ohraničujúce pole zmenené vplyvom rotácie na nové pole

Kedže YOLO akceptuje iba ohraničujúce polia rovnobežné s priamkou $y = x$, výška a šírka ohraničujúceho poľa sa musí zodpovedajúcim spôsobom upraviť Rizwan (2023). Výpočet pomocou rotačnej matice sme v programovacom jazyku Python definovali do samostatnej metódy a vo výsledku sme získali nové súradnice ohraničujúceho poľa. Proces rotácie obrázkov je zobrazený na obrázku 3–9.

3.4.4 Segmentácia TLE objektov pomocou prahovania

Segmentácia obrazu predstavuje zoskupenie podobného súboru pixelov obrazu, aby bolo možné ľahko klasifikovať a kategorizovať objekty na obrázkoch. V tejto bakalárskej práci bola použitá segmentácia objektov na extrakciu prechodných svetelných javov, ktoré sa umiestnili na obrázky bez výskytu TLE javov. Množinu snímok bez výskytu tohto javu sme vybrali tak, aby v nej bola zastúpená každá kamera AMOS, a aby sa líšili od tých, o ktorých je známe, že sa na nich vyskytuje TLE. Segmentáciu

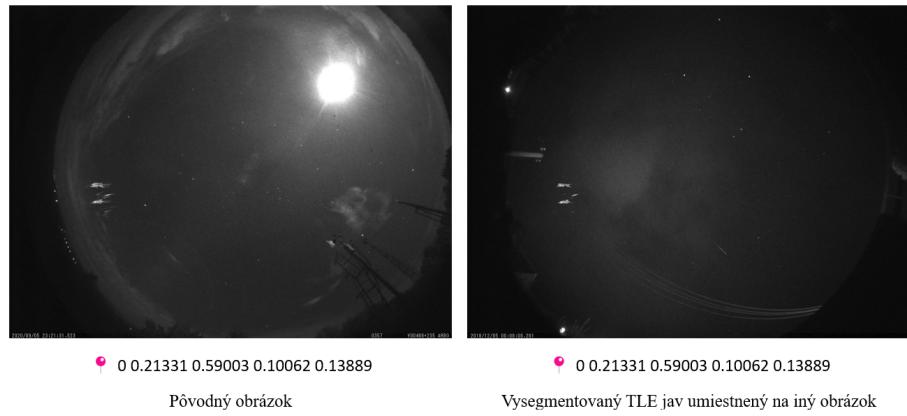


Obrázok 3 – 9 Pôvodný obrázok a obrázok rotovaný o náhodný počet stupňov

objektov sme vykonávali pomocou metódy prahovania. Prahovanie je typ segmentácie obrazu, pri ktorom meníme pixely obrazu, aby sa obraz dal ľahšie analyzovať. Pri prahovaní prevádzkame obraz z farebného alebo šedého na binárny obraz, čo predstavuje čiernobiely obraz.

Segmentáciu TLE javov sme začali vyrezaním TLE javov z pôvodných obrázkov. Obrázok s vyrezaným javom sme previedli na obrázok v šedej škále. Následne sme vypočítali hodnotu prahu, vykonali segmentáciu časti obrázka pri zistenej prahovej hodnote a vyextrahovaný jav sme umiestnili na náhodne zvolený obrázok z množiny obrázkov bez výskytu TLE javov. Vyextrahovaný jav sme umiestnili na rovnaké súradnice, na akých sa nachádzal na pôvodnom obrázku. Dodržanie polohy javu TLE je dôležité pre zachovanie jeho sklonu k rovine. Z toho vyplýva, že nové textové súbory s anotáciami sa zhodujú s tými pôvodnými, preto sme ich pre skupinu segmentovaných dát vytvorili okopírovaním pôvodných textových súborov. Novovzniknutý obrázok je zobrazený na obrázku 3 – 10.

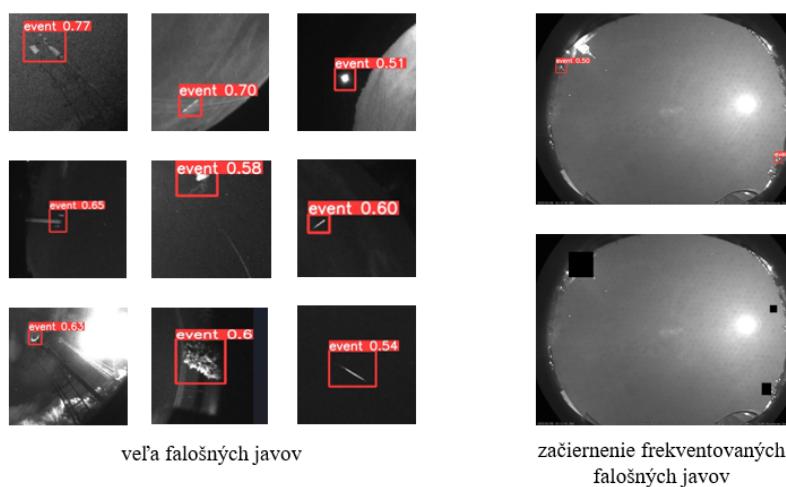
Nové rozšírené údaje sme manuálne skontrolovali a nevhodné obrázky vyradili. Prostredníctvom algoritmu sme na každý augmentovaný aj neaugmentovaný obrázok vykreslili anotácie. Opäť sme vykreslené anotácie skontrolovali, a v prípade potreby sme ich optimalizovali.



Obrázok 3–10 Pôvodný obrázok a vysegmentovaný TLE jav umiestnený na iný obrázok bez prechodného svetelného javu

3.4.5 Zamedzenie označovania nesprávnych objektov

Súčasný model na AMOS dátach označoval okrem TLE javov aj veľa objektov nesprávne. Aby sme tento dopad eliminovali, na základe existujúceho riešenia popísaného v práci Kamenská (2022) sme oblasti obrázkov s najčastejším výskytom nevhodných objektov prekryli čiernym obdĺžnikom. Čierne obdĺžníky sme na konkrétnie miesta obrázka vykreslovali podľa toho, na akej AMOS stanici bol obrázok vytvorený. Prekrytie nevhodných objektov je zobrazené na obrázku 3–11.



Obrázok 3–11 Najčastejšie nesprávne označené objekty a ich prekrytie

3.5 Modelovanie

Proces modelovania pozostáva z výberu modelu neurónovej siete, rozdelenia predspracovaných údajov na trénovaciu, validačnú a testovaciu množinu, simulácie existujúceho modelu a vytvorenia nového modelu. Každý krok je podrobnejšie opísaný v nasledujúcich sekciách.

3.5.1 Výber modelu neurónovej siete

Výber modelu, ktorý je vhodný na detekciu objektov závisí od jeho konkrétnej aplikácie. Naším cieľom je natrénovať model, ktorý bude rozpoznávať výskyt prechodných svetelných javov na oblohe. Na snímkach z kamier AMOS sú však TLE javy veľmi malé, čo môže skresľovať proces trénovalia. Existujúci model, ktorý deteguje prechodné svetelné javy, bol natrénovaný na neurónovej sieti YOLOv5. Túto verziu YOLO algoritmu predstavila spoločnosť Ultralytics v roku 2020. Na prelome rokov 2022/2023 však rovnaká spoločnosť vydala novú verziu YOLOv8. YOLOv8 vychádza z modelu YOLOv5, pričom obsahuje niekoľko úprav. Ôsma verzia obsahuje nové funkcie a vylepšenia na zvýšenie výkonu a flexibility. Jej výhodou je najmä rýchlosť a presnosť, no taktiež poskytuje jednotný rámc pre rôzne typy úloh, ako je trénovalie modelov, vykonávanie detekcie objektov, segmentácia inštancií a klasifikácia obrazu. Ultralytics uvádzá, že pokiaľ ide o výber najlepšieho modelu detekcie objektov, YOLOv8 aj YOLOv5 majú svoje silné aj slabé stránky. Verzia YOLOv5 je jednoduchšia na ovládanie, zatiaľ čo verzia YOLOv8 je rýchlejšia a presnejšia. Úspešnosť modelu však ovplyvňuje aj aplikácia modelu na vybraný typ úlohy Glenn (2022), Glenn (2023). My sme sa rozhodli natrénovať nový model na oboch verziach neurónovej siete a navzájom ich porovnať.

3.5.2 Rozdelenie dát na trénovaciu, validačnú a testovaciu množinu

Na prvé trénovalie sme mali k dispozícii 377 obrázkov, na ktorých sa spolu nachádzalo 396 prechodných svetelných javov. Taktiež sme z množiny obrázkov bez

výskytu TLE javov zvolili náhodných 58 obrázkov. Dáta sme následne rozdelili na trénovaciu, validačnú a testovaciu množinu. Tieto dátu budú slúžiť na trénovanie modelu a jeho následné testovanie. Trénovacia množina je najväčšia a obsahuje údaje, na ktorých bude model naučený rozpoznávať TLE objekty. Je to súbor údajov, z ktorého sa model učí skryté vlastnosti a vzory v údajoch. Validačná množina po- zostáva z údajov odlišných od trénovacej množiny, na ktorých sa overuje, ako dobre sa model naučil rozpoznávať prechodné svetelné javy. Táto množina pomáha nastaviť hyperparametre a poskytuje spätnú väzbu na posúdenie, či sa tréning modelu uberá správnym smerom. Model sa trénuje na trénovacej množine a súčasne sa po každej epoche vykonáva vyhodnotenie modelu na validačnej množine. Cielom vali- dačnej množiny je vykonať presnú kvalifikáciu na údajoch, ktoré model v trénovaní nevidel. Na testovacej množine sa po ukončení trénovania otestuje, s akou presnos- tou vie model predikovať správne výsledky. Údaje boli rozdelené do množín tak, aby všetky tri množiny boli navzájom disjunktné. Presné rozdelenie dát je znázor- nené v tabuľke 3 – 2. Počty skutočne pozitívnych obrázkov (angl. *True Positive*, skr. TP), v našom prípade obrázkov s výskytom prechodných svetelných javov, sú uve- dené v stĺpci TP. Stĺpec TN popisuje počty skutočne negatívnych obrázkov *True Negative*, skr. TN), t.j. obrázkov bez výskytu prechodného svetelného javu.

MNOŽINA/OBRÁZKY	TP	TN	SÚČET	%
Trénovacia	342	0	342	75,3
Validačná	40	0	40	8,8
Testovacia	14	58	72	15,9
SÚČET	396	58	454	100

Tabuľka 3 – 2 Rozdelenie dát pre trénovanie simulácie existujúceho modelu

Vo fáze prípravy dát sme pripravili rozdelenie dát pre trénovanie modelu učeného na obohatenej množine o augmentované dátá. Aby sme mohli porovnať základný a nový model, vychádzali sme z rovnakého rozdelenia údajov. Pôvodná trénovacia množina obsahovala 396 obrázkov s TLE. Napísali sme kód v programovacom jazyku

Python, ktorý iteroval nad každým obrázkom v trénovacej množine, a na základe názvu obrázka prekopíroval do trénovacej množiny najviac štyri nové rozšírené verzie tohto obrázka z augmentovanej množiny údajov. Týmto spôsobom sme zachovali disjunktnosť množín, t. j. nemôže nastať situácia, že by upravená kópia obrázka bola priradená k inej množine, než v ktorej sa nachádza pôvodný obrázok. Rovnaký postup sme aplikovali na validačnú množinu. Skupina 14 obrázkov s prechodným svetelným javom v testovacej sade ostala nezmenená. Proces trénovania tohto modelu prebiehal v mnohých iteráciách. Každým ďalším trénovaním sa prispôsobovali hyperparametre, a zároveň nachádzali nové prechodné svetelné javy. Novonájdené obrázky s TLE javmi sme v každej nasledujúcej iterácii pridali do trénovacej alebo validačnej množiny tak, aby pomer rozdelenia údajov ostal zachovaný. Rozdelenie originálnych a augmentovaných dát do množín, na ktorom bol natrénovaný najlepší model, je znázornené v tabuľke 3–3. Syntetické obrázky vznikli zlúčením segmentu TLE javu z jednej snímky s inou snímkou bez výskytu TLE javu.

MNOŽINA/ OBRÁZKY	TP	Horizontálne prevrátené	Vertikálne prevrátené	Syntetické	Rotované	TN	SÚČET	%
Trénovacia	399	399	399	374	399	0	1970	75,3
Validačná	47	47	47	45	47	0	233	8,9
Testovacia	14	0	0	0	0	400	414	15,8
SÚČET	460	460	460	419	460	400	2617	100

Tabuľka 3–3 Rozdelenie dát pre trénovanie modelu na augmentovaných dátach

3.5.3 Simulácia existujúceho modelu

Aby sme mohli porovnať nové modely s existujúcim modelom YOLOv5 natrénovaným na detekciu TLE javov, najprv nasimulujueme existujúci model. Model budeme simulovať pomocou neurónovej siete YOLO vo verzii 5 a vo verzii 8. Trénovanie oboch modelov bude prebiehať na vzdialenom školskom serveri a grafickej karte typu Quadro RTX 4000. Dôležité informácie ohľadom trénovania sú zobrazené v tabuľke 3–4. Detailné nastavenia hyperparametrov sú popísané v systémovej príručke.

	YOLOv5	YOLOv8
velkosť modelu	yolov5s	yolov8s
počet epoch	300	300 (ukončenie po 203. epoche)
počet vzoriek (angl. <i>batch size</i>)	10	10
velkosť obrazu	1280	1280
doba trénovania (h)	3:01	2:25

Tabuľka 3 – 4 Zhrnutie trénovania modelu simulujúceho existujúci model na verzii neurónovej siete YOLOv5 a YOLOv8

Na trénovanie modelov sme pre obe verzie použili modely typu *s*. Tieto modely sú ideálne na vykonávanie inferencie na menej výkonného počítači. Model YOLOv5s je malý model s približne 7,2 miliónov parametrov. Model YOLOv8 je tiež malý model, ktorý však obsahuje približne 11,2 milióna parametrov, čo je o 4 milióny viac v porovnaní s modelom YOLOv5.

Pre model YOLOv8 je pozoruhodné predčasné ukončenie tréningu po 203 epochách, keďže v posledných 50 epochách nebolo pozorované žiadne zlepšenie. To sa v prípade trénovania modelu YOLOv5 nestalo. Zistenie by mohlo súvisieť s vyšším počtom parametrov v ôsmej verzii. Trénovanie ukazuje, že hoci je ôsma verzia pamäťovo a výpočtovo náročnejšia, čas trénovania je o niečo kratší práve vďaka zvládnutiu tréningu v menšom počte epoch.

Natrénované modely sme následne vyhodnotili na testovacej množine. Testovacia množina pozostávala zo 14 obrázkov, ktoré obsahovali aspoň jeden TLE jav, a 58 obrázkov bez výskytu tohto javu. Pre účely testovania sme v oboch prípadoch nastavili hodnotu prahu priesčníka nad zjednotením (angl. *Intersection over Union*, skr. IoU) na 0,3. IoU je číslo, ktoré kvantifikuje stupeň prekrytie dvoch polí - skutočne ohraňujúceho pola a predpovedaného ohraňujúceho pola. Vypočítá sa ako podiel prieniku a zjednotenia týchto polí. Pri detekcii objektov sa IoU používa na hodnotenie výkonnosti algoritmu. Ukarovateľ môže nadobúdať hodnoty z intervalu od 0 do 1 vrátane, kde hodnota 0 znamená žiadne prekrývanie, zatiaľ čo hodnota

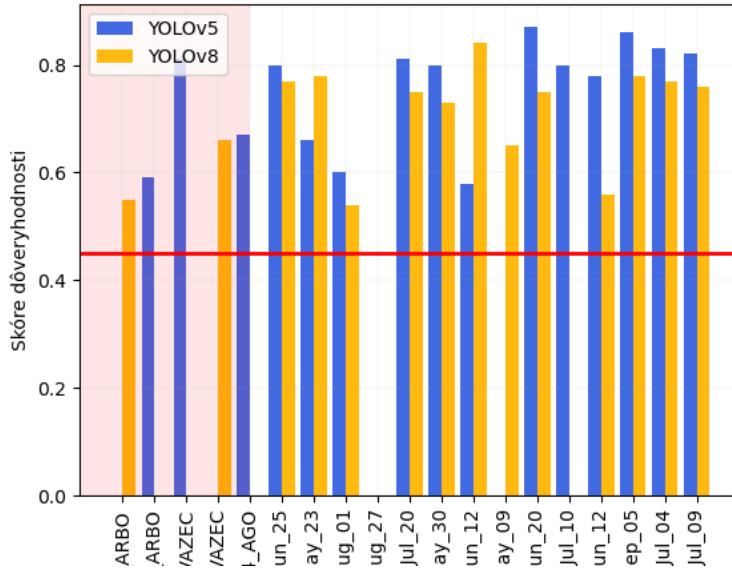
1 znamená znamená dokonalé prekrývanie. Predpovedaný ohraničujúci box sa považuje za správnu detekciu, ak je jeho skóre IoU vyššie ako špecifikovaná prahová hodnota. Skóre dôveryhodnosti (angl. *Confidence Score*, skr. conf.), t. j. minimálnu pravdepodobnosť, s akou algoritmus správne deteguje objekt, a ako presne ohraničí nájdený objekt sme nastavili na hodnotu 0,45. To znamená, že náš model musí byť presvedčený, že objekt, ktorý sa snaží klasifikovať, patrí do vopred definovej triedy aspoň na 45%. Výsledky testovania sú zobrazené v tabuľke 3 – 5.

Model YOLOv5 detegoval 12 zo 14 snímok TLE správne. Naviac detegoval aj 3 falošne pozitívne javy. Model YOLOv8 predikoval 12 zo 14 obrázkov s prechodnými svetelnými javmi správne. Naviac označil aj objekty na dvoch obrázkoch bez výskytu prechodných svetelných javov.

	YOLOv5	YOLOv8
počet TP	12/14	12/14
počet FP	3/58	2/58

Tabuľka 3 – 5 Zhrnutie testovania modelu simulujúceho existujúci model na verzii neurónovej siete YOLOv5 a YOLOv8

Testovací súbor obsahuje len 14 obrázkov s výskytom požadovaného objektu, čo nie je dostatočne reprezentatívne množstvo na vydelenie záverov. Táto vzorka údajov však odzrkadluje skutočnosť, že nemáme potrebné množstvo údajov na získanie dostatočne dobrých výsledkov modelu. Celkovo možno testovanie vyhodnotiť tak, že ani jeden z modelov nenašiel všetky snímky s TLE javmi. Taktiež oba modely odhalili aj falošne pozitívne obrázky. Zaujímavé je, že každý z modelov falošne zachytil rôzne obrázky. Nesprávne označené obrázky sú znázornené v grafe 3 – 12 v svetločervenej časti grafu. Časť s bielym pozadím odráža detekciu správne predpovedaných javov. Predikcia YOLOv5 modelom je znázornená modrou farbou a predikcia YOLOv8 modelom je znázornená žltou farbou. Z grafu vyplýva, že takmer vo všetkých prípadoch neurónová sieť YOLOv5 predpovedala výsledky s vyšším skóre dôveryhodnosti.



Obrázok 3 – 12 Porovnanie predpovedí modelov YOLOv5 a YOLOv8 simulujúcich existujúci model na testovacej množine

3.5.4 Modelovanie nového modelu

Trénovanie nového modelu prebiehalo takmer totožne ako trénovanie popísané v predošej sekcií. Taktiež sme trénovali dve verzie neurónovej siete YOLO, a to YOLOv5 a YOLOv8. Samotné trénovanie modelov sa opakovalo v iteráciách, kedy sme postupne navyšovali trénovaciu a validačnú množinu o augmentované dátá. Ako sme predpokladali, so zvyšujúcim sa počtom údajov v trénovacej množine sa zvyšoval aj počet správne detegovaných údajov na testovacej množine. Úspešnosť detekcie však rástla len veľmi pomaly v porovnaní s pribúdajúcimi údajmi v trénovacej množine.

Iteratívny prístup k modelovaniu znamená, že po vyhodnotení natrénovaných modelov, sme na základe výsledkov na testovacej množine vybrali najlepší model. Na dovedy najlepšom modeli sme spustili detekciu objektov na AMOS dátach z vybraného roku, z ktorých sme odstránili už známe obrázky s TLE javmi. Vyhodnotením detekcií sme postupne nachádzali nové obrázky s prechodnými svetelnými javmi. Na novonájdených obrázkoch sme dodatočne vykonali už spomenuté štyri spôsoby

augmentácie dát, a tento originálny obrázok s jeho augmentovanými kópiami sme rovnakým spôsobom pridali buď do trénovacej, alebo validačnej množiny. S postupným navyšovaním dát v trénovacej a validačnej množine rástla aj úspešnosť dovtedy najlepšieho modelu.

Najlepšie modely verzie YOLOv5 a YOLOv8 sme natrénovali na rozdelení dát popísanom v tabuľke 3 – 3. Oproti pôvodnému počtu všetkých obrázkov s TLE javmi, vrátane kópii, ak sa na jednom obrázku nachádzalo viac javov, sa množina navýšila o 64 obrázkov, ktoré sme pridali do trénovacej alebo validačnej množiny. Z celkového počtu 460 obrázkov s TLE javmi bolo 389 unikátnych.

Aby sme modely vedeli porovnať, hodnoty hyperparametrov ostali zachované. Keď sa na tomto rozdelení dát trénoval model YOLOv5, prebehlo všetkých 300 deklarovaných epoch. Ak sa trénoval model YOLOv8, tréning sa sám zastavil približne v dvoch tretinách epoch s oznamením, že v posledných 50 epochách nedošlo k žiadnemu zlepšeniu. Obe trénovania prebehli na grafickej karte typu Quadro RTX 4000, kde bolo alokovaných 8 GB pamäte. Model YOLOv5 sa trénoval vyše 12 hodín. Trénovanie modelu YOLOv8 sa ukončilo po 9 hodinách a 40 minútach.

3.6 Vyhodnotenie zlepšených modelov

Natrénované modely sme vyhodnotili na testovacej množine. Neurónová sieť hodnotí metriky - presnosť (angl. *precision*, skr. P), návratnosť (angl. *recall*, skr. R), stredná priemerná presnosť vypočítaná pri prahu IoU 0,5 (angl. *mean Average Precision calculated at IOU threshold 0.5*, skr. mAP50) a F1 skóre.

Presnosť P je metrika strojového učenia, ktorá meria presnosť predpovedí, t. j. percento správnych predpovedí. Matematicky ju možno vyjadriť ako percentuálny podiel skutočne pozitívnych obrázkov ku súčtu skutočne pozitívnych obrázkov a falošne pozitívnych obrázkov, čo znázorňuje vzťah 3.3.

$$\text{Presnosť} = \frac{TP}{TP + FP} \quad (3.3)$$

Návratnosť R je metrika, ktorá vyjadruje percentuálny podiel správne predpo-

vedaných prípadov voči všetkým anotovaným prípadom na vstupe. Vypočíta sa ako podiel skutočne pozitívnych obrázkov ku súčtu skutočne pozitívnych obrázkov a skutočne negatívnych obrázkov (angl. *True Negative*, skr. TN). Matematicky možno návratnosť znázorniť vzťahom 3.4.

$$\text{Návratnosť} = \frac{TP}{TP + FN} \quad (3.4)$$

Stredná priemerná presnosť vypočítaná pri prahu IoU 0,5 *mAP50* je metrika, ktorá sa vypočíta na základe priemernej presnosti vo všetkých triedach a/alebo celkových prahových hodnôt IoU. Neurónová siet YOLO vypočíta túto hodnotu v desiatich intervaloch pre rôzne IoU v rozmedzí od 0,5 po 0,95. Hodnoty spriemeruje. Táto metrika je kompromisom medzi presnosťou a návratnosťou.

F1 skóre je metrika hodnotenia strojového učenia, ktorá je definovaná ako harmonický priemer presnosti a návratnosti modelu. Jej cieľom je zlúčiť tieto dve metriky do jednej metriky. Matematický výpočet pre F1 skóre znázorňuje vzťah 3.5.

$$F1\text{skóre} = 2 * \frac{\text{Presnosť} * \text{Návratnosť}}{\text{Presnosť} + \text{Návratnosť}} \quad (3.5)$$

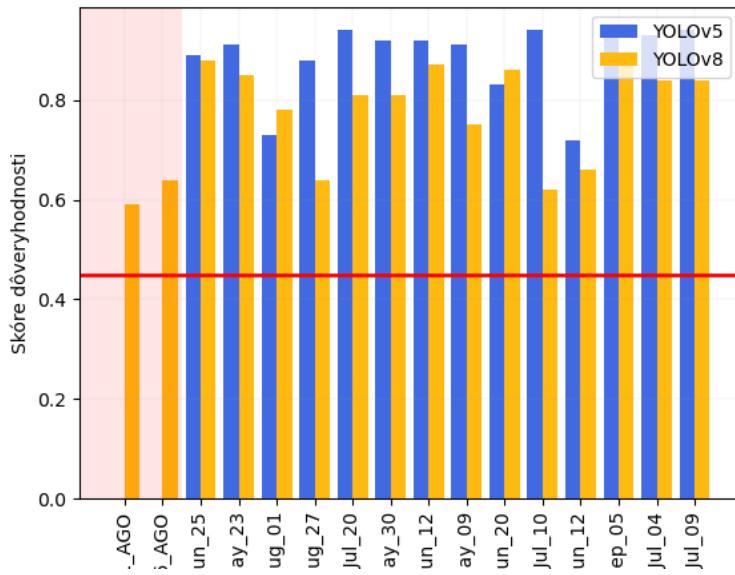
Hodnoty metrík získané modelmi sú uvedené v nasledujúcej tabuľke 3 – 6. Model neurónovej siete YOLOv5 má vyššie hodnoty presnosti a návratnosti, čo sa premetia aj do metriky F1 skóre. Táto skutočnosť sa potvrdila, keď sme porovnali výsledky predpovedí oboch modelov na testovacej množine, čo je znázornené v grafe 3 – 13.

	P	R	mAP50	F1 skóre
YOLOv5	0,848	0,857	0,79	0,852
YOLOv8	0,785	0,783	0,878	0,784

Tabuľka 3 – 6 Porovnanie metrík modelov YOLOv5 a YOLOv8 vygenerovaných modelmi na testovacej množine

Testovanie oboch YOLO verzii na pôvodnej testovacej množine bolo realizované tak, že hodnoty IoU a skóre dôveryhodnosti ostali rovnaké ako pre modely simulujúce existujúci model. Model YOLOv8 naopak dominuje v hodnotení metrikou mAP50.

Avšak zatiaľ čo metriky presnosť a návratnosť sú relatívne metriky, teda závisia od hodnoty skóre dôveryhodnosti, mAP je absolútна metrika, ktorá od hodnoty skóre dôveryhodnosti nezávisí.



Obrázok 3 – 13 Porovnanie predpovedí modelov YOLOv5 a YOLOv8 simulujúcich existujúci model na testovacej množine

Model YOLOv5 detegoval 14 zo 14 skutočne pozitívnych obrázkov správne a 0 falošne pozitívnych obrázkov. Model YOLOv8 taktiež detegoval 14 zo 14 obrázkov správne, no naviac označil 2 obrázky nesprávne. Výsledky testovania sú znázornené v tabuľke 3 – 7.

	YOLOv5	YOLOv8
počet TP	14/14	14/14
počet FP	0/58	2/58

Tabuľka 3 – 7 Zhrnutie testovania modelov neurónovej siete YOLOv5 a YOLOv8

Model YOLOv5 má takmer vo všetkých prípadoch vyššie skóre dôveryhodnosti a zároveň nedetegoval žiadny obrázok falošne. Výsledky potvrdzujú hodnoty vyššie spomenutých metrík. Model YOLOv8 tiež našiel všetky obrázky s TLE javmi

v testovacej sade, a zároveň vykazuje lepšie výsledky pre metriku stredná priemerná presnosť.

3.7 Vyhodnotenie výskumu

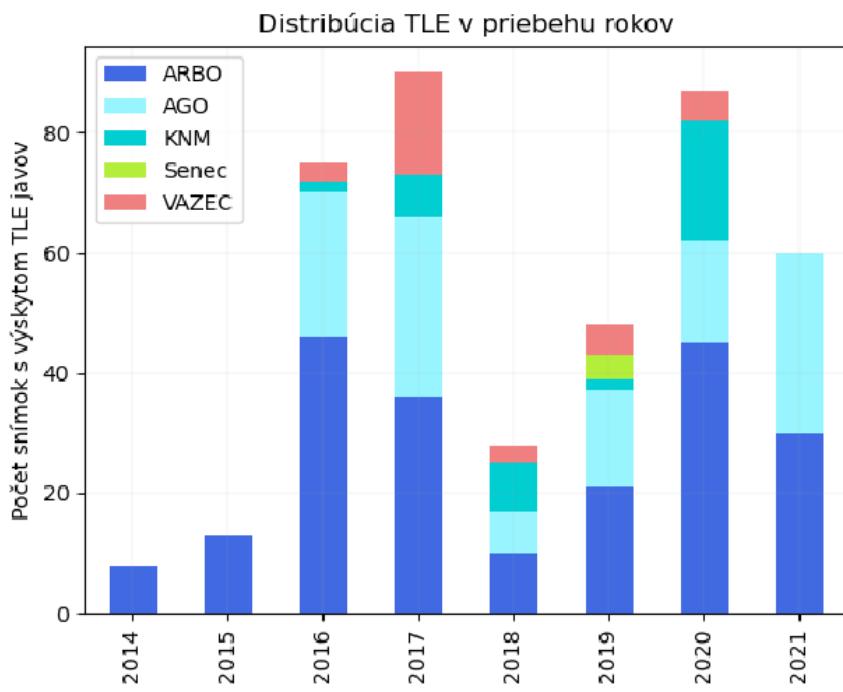
V našom výskume sme použili algoritmy umelej inteligencie, vďaka ktorým sme vytvorili unikátnu zbierku pozostávajúcu zo 409 snímok s prechodnými svetelnými javmi. Celkovo sme objavili 56 nových snímok s prechodnými svetelnými javmi, a zároveň z pôvodnej množiny obrázkov s TLE javmi odstránili 24 obrázkov, pretože anotované objekty neboli TLE javmi. Chyby v anotovaní mohli vzniknúť v dôsledku neznalosti starších spolužiakov, ktorí anotácie minulý rok vykonávali.

Počty snímok získané za jednotlivé roky sú uvedené v tabuľke 3 – 8. Detailnejší prehľad počtov objavených snímok s TLE javmi z piatich AMOS kamier za roky 2014 až 2021 je zobrazený v stohovanom stĺpcovom grafe 3 – 14. Z grafu vyplýva, že viac ako polovica snímok s výskytom týchto javov pochádza z AMOS kamery umiestnenej v Areáli Arboréta Tesárske Mlyňany, zhruba 30% bolo vytvorených kamerou umiestnenou na Astronomickom a geofyzikálnom observatóriu v Modre a necelých 20% dát bolo získaných z ostatných troch AMOS kamier.

2014	2015	2016	2017	2018	2019	2020	2021
8	13	75	90	28	48	87	60

Tabuľka 3 – 8 Počet nájdených snímok s TLE javmi za jednotlivé roky

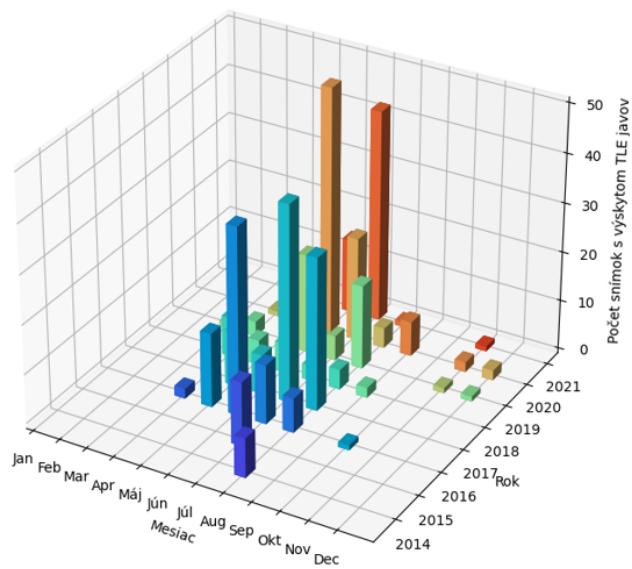
Na základe dát, ktoré sme získali, možno zhodnotiť, že v našich zemepisných šírkach sa prechodné svetelné javy vyskytujú prevažne v jarných a letných mesiacoch. Zistenie môže súvisieť s kumulatívnym mesačným úhrnom atmosferických zrážok, ktorý dosahuje najvyššie hodnoty práve v období od júna do septembra. Zaujímavé je, že počas sledovaného obdobia sme v zimných mesiacoch našli len 3 snímky vyhotovené v decembri. V mesiacoch január a február sme nezaznamenali žiadny jav. Podrobnejšie korelácie medzi mesiacmi a rokmi sú znázornené v grafe 3 – 15.



Obrázok 3 – 14 Distribúcia TLE javov v priebehu rokov

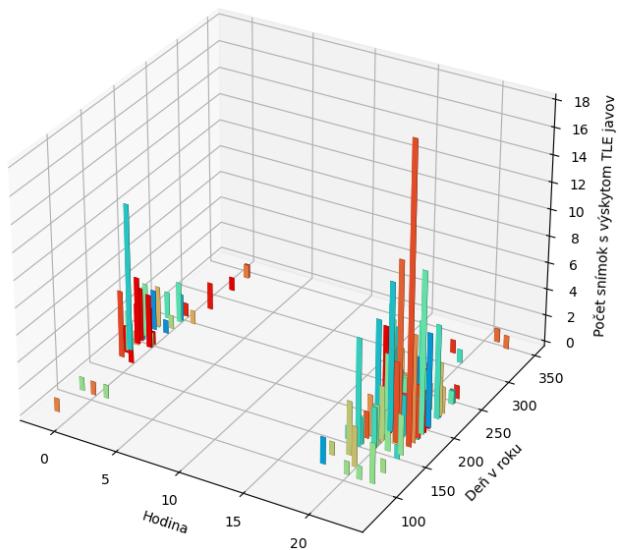
Z dát taktiež vyplýva, že svetelné javy sa vyskytovali v noci. Dôvodom je skutočnosť, že TLE sú elektrické výboje vyžarujúce slabé svetlo, ktoré možno zachytiť zo zemského povrchu len v tme, t. j. v nočných hodinách. Frekvenciu výskytu týchto javov v čase sme znázornili na obrázku 3 – 16. Farebná schéma je zvolená tak, aby bol graf ľahko čitateľný. Neindikuje žiadnu vlastnosť.

Distribúcia TLE javov v priebehu mesiacov a rokov



Obrázok 3 – 15 Distribúcia TLE javov v priebehu mesiacov a rokov

Distribúcia TLE javov v priebehu hodín a dní



Obrázok 3 – 16 Distribúcia TLE javov v priebehu hodín a dní

4 Záver

Cieľom práce bolo oboznámiť sa s problematikou konvolučných neurónových sietí a prechodných svetelných javov, a získané poznatky aplikovať na modelovanie dosta- točne kvalitného detekčného modelu YOLO na snímkach z kamier AMOS. Riešenie pozostávalo z analýzy niektorých súčasných modelov detegujúcich TLE javy, ume- lého navýšenia dátovej množiny, prípravy dátového súboru, trénovania konvolučnej neurónovej siete vo verzii YOLOv5 a YOLOv8, detegovania prechodných svetelných javov a vyhodnotenia modelu ako aj prínosu nájdených snímok.

Problémom, ktorému sme čelili pri vytváraní modelu, bol nedostatok údajov pre natrénovanie lepšieho modelu na detekciu TLE javov. Úlohu sme sa rozhodli vyriešiť umelým rozšírením dátovej množiny, pričom sme vytvorili kópie existujúcich obrázkov s TLE javmi a aplikovali na nich štyri metódy rozšírenia - horizontálne prevrátenie obrazu, vertikálne prevrátenie obrazu, otočenie obrazu a segmentáciu javu, ktorý sme umiestnili na rovnaké miesto na iný obrázok. Metódy rozšírenia údajov boli zvolené tak, aby sa zachovala poloha javov výlučne po obvode snímok, ako aj ich kolmá orientácia na zemský povrch.

Rozšírením trénovacej a validačnej množiny o augmentované dátá sa nám poda- rilo natrénovať také YOLO modely v dvoch verziách, ktoré na testovacej množine dokázali identifikovať všetky obrázky s výskytom TLE javov. Výhodou modelu YO- LOv5 bolo, že správne detegované obrázky mali vo väčšine prípadov vyššie skóre dôveryhodnosti, a zároveň neoznačil žiadnen obrázok falošne pozitívne. Model YO- LOv8 našiel taktiež všetky obrázky s TLE javmi a navyše označil aj dva obrázky ako falošne pozitívne. Jeho výhodou však bolo vyššie hodnotenie metriky stredná priemerná presnosť, čo považujeme za smerodajné.

Po spustení detekcie modelu YOLOv8 na celej dátovej množine pri nastaveniach prahu IoU na hodnotu 0,1 a hodnote skóre dôveryhodnosti 0,1 dokázal model identi- fikovať všetky snímky s TLE javmi správne. Neurónová sieť bola v priemere na 70 % presvedčená o správnosti detekcie objektov. Testovanie pri nízkej hodnote skóre dô-

veryhodnosti bolo nastavené skrze niektorých problematických výskytov TLE javov, ako napríklad za mrakom alebo pri zemskom horizonte, kedy sa hodnota skóre dôveryhodnosti rapídne znížila. Okrem toho však siet, napriek zatieneniu statických údajov, označila v priemere 6 000 obrázkov ročne falošne, čo je jej negatívom. Model by však aj napriek tejto skutočnosti uľahčil prácu výskumníkom, pretože by osemnásobne znížil priestor prehľadávania ročného súboru snímok.

V porovnaní s existujúcim modelom, náš model YOLOv8 dokázal odhaliť všetky TLE javy. V procese spracovania dát sme vyčistili množinu známych obrázkov s TLE javmi o nesprávne anotované dáta, a zároveň objavili cenných 56 nových snímok, ktoré predošlý model neodhalil. Skutočnosť, že stále rozpoznáva mnoho objektov falošne, je nevýhodou, no súvisí to s malým rozmerom TLE javov, čo stažuje proces ich rozpoznávania oproti iným objektom.

Model na detekciu prechodných svetelných javov by sa v budúcnosti dal vylepšiť pretrénovaním na vyššom množstve údajov alebo navýšením pamäťovej kapacity, pri ktorej by sme mohli navýsiť hodnoty dôležitých hyperparametrov, napríklad počet dávok alebo počet epoch, a tým dosiahnuť vyššiu presnosť a precíznosť modelu. Na väčšej vzorke údajov by bolo možné natrénovať model, ktorý by okrem binárnej detekcie TLE javov dokázal svetelné javy aj zatriediť do kategórií podľa ich typu.

Literatúra

- Adachi, T., Sato, M., Ushio, T., Yamazaki, A., Suzuki, M., Kikuchi, M., Takahashi, Y., Inan, U. S., Linscott, I., Hobara, Y. et al. (2016). Identifying the occurrence of lightning and transient luminous events by nadir spectrophotometric observation, *Journal of Atmospheric and Solar-Terrestrial Physics* **145**: 85–97.
- Aggarwal, K., Mijwil, M. M., Al-Mistarehi, A.-H., Alomari, S., Gök, M., Alaabdin, A. M. Z., Abdulrhman, S. H. et al. (2022). Has the future started? the current growth of artificial intelligence, machine learning, and deep learning, *Iraqi Journal for Computer Science and Mathematics* **3**(1): 115–123.
- Akbar, F. S. P., Ginting, S. Y. P., Wu, G. C., Achmad, S. and Sutoyo, R. (2022). Object detection on bottles using the yolo algorithm, *2022 4th International Conference on Cybernetics and Intelligent System (ICORIS)*, IEEE, pp. 1–5.
- Arel, I., Rose, D. C. and Karnowski, T. P. (2010). Deep machine learning-a new frontier in artificial intelligence research [research frontier], *IEEE computational intelligence magazine* **5**(4): 13–18.
- Bashir, Z. and El-Hawary, M. (2009). Applying wavelets to short-term load forecasting using pso-based neural networks, *IEEE transactions on power systems* **24**(1): 20–27.
- Bini, S. A. (2018). Artificial intelligence, machine learning, deep learning, and cognitive computing: what do these terms mean and how will they impact health care?, *The Journal of arthroplasty* **33**(8): 2358–2361.
- Blelly, P.-L. (2020). Uncovering the hidden side of storms.
URL: <https://www.irap.omp.eu/en/2020/11/uncovering-the-hidden-side-of-storms-frances-taranis-satellite-to-launch-in-november/>
- Copeland, B. J. (2023). Artificial intelligence.
URL: <https://www.britannica.com/technology/artificial-intelligence>

Da Silva, I. N., Hernane Spatti, D., Andrade Flauzino, R., Liboni, L. H. B., dos Reis Alves, S. F., da Silva, I. N., Hernane Spatti, D., Andrade Flauzino, R., Liboni, L. H. B. and dos Reis Alves, S. F. (2017). *Artificial neural network architectures and training processes*, Springer.

ESA (1970). Asim on columbus.

URL: https://www.esa.int/Science_Exploration/Human_and_Robotic_Exploration/Research/Atmosphere_Space_Interactions_Monitor

Glenn, J. (2022). Ultralytics yolov8.

URL: <https://github.com/ultralytics/ultralytics>

Glenn, J. (2023). Ultralytics yolov8 official documentation.

URL: <https://docs.ultralytics.com/>

Gordillo-Vázquez, F. J. and Pérez-Invernón, F. J. (2021). A review of the impact of transient luminous events on the atmospheric chemistry: Past, present, and future, *Atmospheric Research* **252**: 105432.

Gu, J., Wang, Z., Kuen, J., Ma, L., Shahroudy, A., Shuai, B., Liu, T., Wang, X., Wang, G., Cai, J. et al. (2018). Recent advances in convolutional neural networks, *Pattern recognition* **77**: 354–377.

Gurney, K. (1997). *An introduction to neural networks*, CRC press.

Ij, H. (2018). Statistics versus machine learning, *Nat Methods* **15**(4): 233.

Kamenská, P. (2022). Automatická detekcia tle na snímkach amos pomocou hlbokého učenia.

URL: https://space-lab-sk.github.io/pdfs/2022_Petra_Kamenska-BPTLE_detektia_AMOS.pdf

Koech, K. E. (2022). The basics of neural networks.

URL: <https://towardsdatascience.com/the-basics-of-neural-networks-neural-network-series-part-1-4419e343b2b>

Krenker, A., Bešter, J. and Kos, A. (2011). Introduction to the artificial neural networks, *Artificial Neural Networks: Methodological Advances and Biomedical Applications*. InTech pp. 1–18.

Machová, K. (2002). Machine learning: principles and algorithms, *Košice: Elfa* p. 117.

Mahesh, B. (2020). Machine learning algorithms-a review, *International Journal of Science and Research (IJSR).[Internet]* **9**: 381–386.

Masum, M., Shahriar, H., Haddad, H., Faruk, M. J. H., Valero, M., Khan, M. A., Rahman, M. A., Adnan, M. I., Cuzzocrea, A. and Wu, F. (2021). Bayesian hyperparameter optimization for deep neural network-based network intrusion detection, *2021 IEEE International Conference on Big Data (Big Data)*, IEEE, pp. 5413–5419.

McCarthy, J. et al. (2007). What is artificial intelligence.

Mishin, E. V. and Milikh, G. M. (2008). Blue jets: Upward lightning, *Space science reviews* **137**: 473–488.

Mourek, J. (2005). *Fyziologie: učebnice pro studenty zdravotnických oborů*, Grada.

Neubert, T., Østgaard, N., Reglero, V., Blanc, E., Chanrion, O., Oxborrow, C. A., Orr, A., Tacconi, M., Hartnack, O. and Bhandari, D. D. (2019). The asim mission on the international space station, *Space Science Reviews* **215**: 1–17.

Nie, Y., Sommella, P., O’Nils, M., Liguori, C. and Lundgren, J. (2019). Automatic detection of melanoma with yolo deep convolutional neural networks, *2019 E-Health and Bioengineering Conference (EHB)*, IEEE, pp. 1–4.

- Panch, T., Szolovits, P. and Atun, R. (2018). Artificial intelligence, machine learning and health systems, *Journal of global health* **8**(2).
- Parab, C. U., Mwitta, C., Hayes, M., Schmidt, J. M., Riley, D., Fue, K., Bhandarkar, S. and Rains, G. C. (2022). Comparison of single-shot and two-shot deep neural network models for whitefly detection in iot web application, *AgriEngineering* **4**(2): 507–522.
- Pasko, V. P., Inan, U. and Bell, T. (1996). Blue jets produced by quasi-electrostatic pre-discharge thundercloud fields, *Geophysical Research Letters* **23**(3): 301–304.
- Pasko, V. P., Yair, Y. and Kuo, C.-L. (2012). Lightning related transient luminous events at high altitude in the earth’s atmosphere: Phenomenology, mechanisms and effects, *Space science reviews* **168**: 475–516.
- Patel, H. (2021). What is feature engineering—importance, tools and techniques for machine learning, *by Towards Data Science*. url: <https://towardsdatascience.com/what-is-feature-engineering-importance-tools-and-techniques-formachine-learning-2080b0269f10> (visited on 08/31/2022) .
- Redmon, J., Divvala, S., Girshick, R. and Farhadi, A. (2016). You only look once: Unified, real-time object detection, *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 779–788.
- Rizwan, U. (2023). How to rotate yolo bounding boxes?
URL: https://usmanr149.github.io/urmlblog/yolo/2020/03/05/rotate_yolo_bbox.html
- Sanders, R. (2004). Satellite experiment snaps photos of sprites, jets and elves.
URL: https://newsarchive.berkeley.edu/news/media/releases/2004/07/16_sprite.shtml
- Siefring, C. L., Morrill, J. S., Sentman, D. D. and Heavner, M. J. (2010). Simultaneous near-infrared and visible observations of sprites and acoustic-gravity waves during the exl98 campaign, *Journal of Geophysical Research: Space Physics* **115**(A10).

Singh, M., Kumar, A. and Pathak, P. (2017). Review of various findings about sprites, *Journal of Environmental and Biosciences* **31**(2): 485–488.

Surkov, V. and Hayakawa, M. (2012). Underlying mechanisms of transient luminous events: a review, *Annales Geophysicae*, Vol. 30, Copernicus GmbH, pp. 1185–1212.

Tóth, J., Kornoš, L., Zigo, P., Gajdoš, Š., Kalmančok, D., Világi, J., Šimon, J., Vereš, P., Šilha, J., Buček, M. et al. (2015). All-sky meteor orbit system amos and preliminary analysis of three unusual meteor showers, *Planetary and space science* **118**: 102–106.

Tóth, J., Šilha, J., Matlovič, P., Kornoš, L., Zigo, P., Világi, J., Kalmančok, D., Šimon, J. and Vereš, P. (2019). Amos—the slovak worldwide all-sky meteor detection system, *Proc. 1st NEO and Debris Detection Conference*, Vol. 1.

Volek, P. (2017). Víkend pozorovania nočnej oblohy na univerzitnom observatóriu v modre.

URL: http://aastro.eu/Vypravy/ago_2017.html

Wu, Y.-J. (2019). Electricity in the atmosphere—elves.

Yair, Y., Price, C., Ganot, M., Greenberg, E., Yaniv, R., Ziv, B., Sherez, Y., Devir, A., Sátori, G. et al. (2009). Optical observations of transient luminous events associated with winter thunderstorms near the coast of israel, *Atmospheric Research* **91**(2-4): 529–537.

Zoznam príloh

Príloha A CD médium – záverečná práca v elektronickej podobe, príručky v elektronickej podobe a zdrojový kód

Príloha B Používateľská príručka

Príloha C Systémová príručka