

Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky

**Automatická detekcia erupčných vlákiel
na Slnku pomocou hlbokého učenia**

Diplomová práca

2023

Bc. Lívia Potočňáková

Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky

**Automatická detekcia erupčných vlákien
na Slnku pomocou hlbokého učenia**

Diplomová práca

Študijný program:	Hospodárska informatika
Študijný odbor:	Informatika
Školiace pracovisko:	Katedra kybernetiky a umelej inteligencie (KKUI)
Školiteľ:	doc. Ing. Peter Butka, PhD.
Konzultant:	RNDr. Šimon Mackovjak, PhD. Ing. Viera Maslej Krešňáková, PhD. Ing. Lenka Kališková

Košice 2023

Bc. Lívia Potočňáková

Abstrakt v SJ

Dôsledky slnečných erupcií majú výrazný vplyv na našu Zem. Ich skúmanie je dôležité pre ochranu našich technológií a bezpečnosť. Erupčné vlákna pozorované počas ich priebehu predstavujú možný kľúč k pochopeniu vzniku tých najintenzívnejších erupcií. Diplomová práca je zameraná na využitie metód hlbokého učenia v kombinácii so štandardnými technikami spracovania obrazu. Navrhnutý prístup spája využitie konvolučnej neurónovej siete a metód počítačového videnia. Vytvára tak riešenie pozostávajúce z automatickej segmentácie s následnou detekciou paralelných flare ribbons, typických pri najintenzívnejších slnečných erupciách. Detegované udalosti budú použité pre ďalší výskum a lepšie pochopenie slnečných erupcií.

Klúčové slová

konvolučné neurónové siete, počítačové videnie, slnečné erupcie, erupčné vlákna

Abstrakt v AJ

Consequences of solar flares have a significant impact on planet Earth. Studying them is important for the protection of our technology and safety. Flare ribbons, occurring during their course, can help in understanding the formation of the most intense solar flares. This thesis focuses on the use of deep learning methods in combination with standard image processing techniques. The proposed approach combines the use of a convolutional neural network and computer vision methods. It thus creates a solution consisting of automatic segmentation followed by the detection of parallel flare ribbons, typical of the most intense solar eruptions. Detected events will be used for further research and a better understanding of solar flares.

Klúčové slová v AJ

convolutional neural networks, computer vision, solar flares, flare ribbons

TECHNICKÁ UNIVERZITA V KOŠICIACH
FAKULTA ELEKTROTECHNIKY A INFORMATIKY
Katedra kybernetiky a umelej inteligencie

Z A D A N I E
D I P L O M O V E J P R Á C E

Študijný odbor: **Informatika**

Študijný program: **Hospodárska informatika**

Názov práce:

**Automatická detekcia erupčných vlákien na Slnku pomocou
hlbokého učenia**

Automatic detection of solar flare ribbons by deep learning

Študent: **Bc. Lívia Potočnáková**

Školtiel: **doc. Ing. Peter Butka, PhD.**

Školiace pracovisko: **Katedra kybernetiky a umelej inteligencie**

Konzultant práce: **RNDr. Šimon Mackovjak, PhD., Ing. Lenka Kališková, Ing.
Viera Maslej Krešňáková, PhD.**

Pracovisko konzultanta: **Ústav experimentálnej fyziky SAV**

Pokyny na vypracovanie diplomovej práce:

1. Podať teoretický prehľad problematiky metód hlbokého učenia, s dôrazom na vhodné metódy pre detekciu slnečných erupčných vlákien.
2. Získať a predspracovať dátá pre detekciu erupčných vlákien v obrázkoch Slnka vo zvolenej vlnovovej dĺžke.
3. Navrhnuť, realizovať a vyhodnotiť experimenty s detekciou erupčných vlákien pomocou hlbokého učenia na pripravenej množine dát.
4. Vypracovať dokumentáciu podľa pokynov katedry a vedúceho práce.

Jazyk, v ktorom sa práca vypracuje: slovenský

Termín pre odovzdanie práce: 21.04.2023

Dátum zadania diplomovej práce: 31.10.2022



.....
prof. Ing. Liberios Vokorokos, PhD.
dekan fakulty



Čestné vyhlásenie

Vyhlasujem, že som diplomovú prácu vypracoval(a) samostatne s použitím uvedenej odbornej literatúry.

Košice 27. 4. 2023

.....

Vlastnoručný podpis

Podakovanie

Týmto chcem podakovať vedúcemu práce Doc. Ing. Petrovi Butkovi, PhD. za usmernenie a pripomienky, ktoré výrazne dopomohli k vzniku tejto práce. Taktiež chcem podakovať môjmu konzultantovi RNDr. Šimonovi Mackovjakovi, PhD. za objasnenie domény vesmírneho počasia a korekciu správnosti údajov. Moja vdaka patrí aj konzultantke Ing. Viere Maslej Krešňákovej, PhD. za jej postrehy a cenné rady v oblasti hlbokého učenia. V neposlednom rade ďakujem aj konzultantke Ing. Lenke Kališkovej za kontrolu obsahu práce.

Obsah

Úvod	1
1 Slnečné erupcie	3
1.1 Vplyv slnečných erupcií na Zem	5
1.2 NASA SDO	7
2 Hlboké učenie a neurónové siete	10
2.1 Aktivačné funkcie	11
2.2 Optimalizácia	13
2.3 Chybové funkcie	13
2.4 Regularizácia	14
3 Metódy spracovania obrazu	16
3.1 Segmentácia obrazu	16
3.2 Konvolučné neurónové siete	17
3.2.1 Konvolučné neurónové siete pre segmentáciu obrazu	19
3.2.2 Architektúra U-Net	19
3.2.3 Vyhodnocovacie metriky segmentácie obrazu	21
3.3 Houghova transformácia	22
3.4 Morfologické operácie	23
3.4.1 Erózia	25
3.4.2 Dilatácia	25
3.4.3 Otvorenie a zatvorenie	26
3.4.4 Skeletonizácia	26
4 Analýza súčasného stavu	28
5 Segmentácia a detekcia slnečných erupcií	33
5.1 Použité technológie	33

5.2	Katalóg RibbonDB	36
5.3	Príprava dát	36
5.3.1	Stahovanie dát	38
5.3.2	Vytváranie masiek	41
5.4	Segmentácia slnečných erupcií	44
5.4.1	Trénovanie modelu SCSS-net	44
5.4.2	Vyhodnotenie segmentácie	46
5.5	Detekcia paralelného tvaru	49
5.5.1	Skeletonizácia masiek	50
5.5.2	Aplikácia pravdepodobnostnej Houghovej transformácie	51
5.5.3	Úprava výstupov Houghovej transformácie	53
5.5.4	Overenie paralelnosti čiar	56
5.5.5	Vyhodnotenie detekcie	58
6	Záver	61
	Zoznam príloh	66
	Príloha A	67

Zoznam obrázkov

1 – 1	Štruktúra slnečnej atmosféry prepojená magnetickými siločiarami. Vrstvy zhora nadol: horúca koróna, prechodová oblasť – prepája- júca chromosféru a korónu, chromosféra, fotosféra (Christe et al., 2017).	4
1 – 2	Slnečná erupcia triedy X3.1. Zdroj snímky, jej čas a zariadenie, ktoré ju získalo, sú uvedené priamo na obrázku.	7
1 – 3	SDO kozmická loď (Pesnell et al., 2012)	9
1 – 4	Ukážka snímok SDO rôznych kanálov (Hatfield, 2021)	9
2 – 1	Grafické znázornenie podučenia a preučenia modelu	15
3 – 1	Vrstvy konvolučnej neurónovej siete	18
3 – 2	Grafické znázornenie architektúry U-Net (Ronneberger et al., 2015)	20
3 – 3	Ukážka Houghovej transformácie. Zlava: vstup, Houghov priestor, výstup s detegovanými čiarami.	24
3 – 4	Ukážka úpravy obrazu operáciou erózie	25
3 – 5	Ukážka úpravy obrazu operáciou dilatácie	26
3 – 6	Porovnanie techník skeletonizácie – a) pôvodný skeleton, b) me- toda DSE, c) morfológické stenšovanie (Bai and Latecki, 2007). . .	27
5 – 1	Histogram vrcholu erupcie triedy M	37
5 – 2	Porovnanie snímok z roku 2010 a 2012	38
5 – 3	Ukážka vstupov, vytvorených masiek a ich prekrytie	42
5 – 4	Graf rozdelenia dát na množiny	43
5 – 5	Architektúra siete SCSS-Net (Mackovjak et al., 2021)	45
5 – 6	Ukážka výsledkov nepretrénovaného modelu určeného pre segmen- táciu aktívnych oblastí. Zlava: vstup modelu, manuálne vytvorená maska, segmentácia, porovnanie výsledkov.	46
5 – 7	Výsledky modelu. Zlava: vstup, manuálna segmentácia, segmentá- cia modelu, prekrytie a metriky.	49

5–8	Porovnanie klasickej skeletonizácie a 3D skeletonizácie	50
5–9	Ukážky pruningu skeletonu	52
5–10	Ukážky upravených výstupov PHT	55
5–11	Prípady, kedy sa čiary nepovažujú za paralelné	56
5–12	Ukážky detegovaných paralelných flare ribbons	60
6–1	Diagram postupu navrhnutého riešenia – od neupravených vstupov až po detekciu paralelných línií.	67

Zoznam tabuliek

1 – 1 Porovnanie pozorovaných regiónov atmosféry Slnka jednotlivými ka- nálmi AIA	10
5 – 1 Model-256: výsledky bez nastaveného prahu a s prahom 40%	48
5 – 2 Model-512: výsledky bez nastaveného prahu a s prahom 60%	48

Slovník termínov

AdaGrad Adaptive Gradient Algorithm

Adam Adaptive Moment Estimation

AIA Atmospheric Imaging Assembly

API Application Interface

BCE Binary Cross-entropy

CME Coronal mass ejections

CNN Convolutional Neural Network

DSE Discrete Skeleton Evolution

ESA European Space Agency

EUV Extreme Ultraviolet

EVE Extreme Ultraviolet Variability Experiment

FCN Fully-Convolutional Net

FN False Negative

FP False Positive

GPS Global Positioning System

HEC Heliophysics Event Catalog

HMI Helioseismic and Magnetic Imager

IoU Intersection Over Union

K Kelvin

MeV Mega electron-volt

MHz Mega Hertz

NASA National Aeronautics and Space Administration

PHT Probability Hough Transform

ReLU Rectified Linear Unit

RMSProp Root Mean Square Propagation

SCSS-Net Solar Coronal Structures Segmentation Network

SOHO Solar and Heliospheric Observatory

SDO Solar Dynamics Observatory

SXR Soft X-ray Radiation

TB Terabyte

TN True Negative

TP True Positive

UV Ultraviolet

XUV Extreme ultraviolet

YOLO You Only Look Once

Å Ångstrom

Úvod

Slnečné erupcie (angl. *solar flares*) sú najintenzívnejšie udalosti v blízkom vesmíre. Ich dôsledky môžu mať výrazný vplyv na Zem, dokážu narušiť satelitné a komunikačné systémy, alebo dokonca spôsobiť výpadky elektrických sietí a rôzne iné javy.

Erupčné vlákna (angl. *flare ribbons*¹) sú jasné útvary pozorované v spodnej časti slnečnej atmosféry počas priebehu slnečných erupcií. Ich paralelný tvar je spájaný s najintenzívnejšími slnečnými erupciami, ktoré majú najväčší vplyv na Zem. Cielom tejto diplomovej práce je vytvoriť prístup pomocou hlbokého učenia pre hľadanie a rozpoznanie paralelného tvaru flare ribbons zo satelitných snímok Slnka, a tým prispieť k ich ďalšiemu výskumu.

Tradične boli flare ribbons skúmané manuálnymi technikami, ako napríklad vizuálnym pozorovaním expertom. Takýto prístup je však veľmi časovo náročný a subjektívny, pričom sa nedá aplikovať na veľké množstvo dát, ktoré je momentálne dostupné.

Konvolučné neurónové siete dosahujú štandardne veľmi dobré výsledky pri úlohách spracovania obrazu, ako je napríklad detekcia objektov alebo segmentácia. V tejto práci navrhujeme kombináciu využitia hlbokého učenia v podobe konvolučných neurónových sietí pre účely segmentácie slnečných erupcií a tradičných metód spracovania obrazu pre následné hľadanie najintenzívnejších slnečných erupcií.

Vďaka nášmu prístupu dokážeme rýchlo a efektívne spracovať veľké množstvo dát a vytvoriť tak katalóg slnečných erupcií paralelného tvaru, určených pre ďalšie vedecké skúmanie. Výsledky tejto práce by mohli prispieť k lepšiemu porozumeniu a predpovedaniu slnečných erupcií a ich vplyvu na Zem.

Prvá kapitola diplomovej práce približuje problematiku skúmaných javov – slnečných erupcií, flare ribbons a ich vplyv na planétu Zem. Taktiež popisuje pôvod dát použitých v tejto práci. Druhá kapitola je venovaná oblasti hlbokého učenia. Vy-

¹Dalej v texte budeme využívať tento anglický názov, pretože neexistuje presný slovenský ekvivalent, ktorý by pomenoval tieto špecifické erupčné vlákna.

svetluje pojmy ako hlboké učenie, neurónové siete, strojové učenie, alebo počítačové videnie. V samostatných podkapitolách postupne popisuje jednotlivé prvky, ktoré sú súčasťou neurónových sietí. Tretia kapitola rozoberá rôzne metódy spracovania obrazu, ktoré boli využité v praktickej časti práce. Medzi tieto metódy patrí segmentácia obrazu prahovaním, Houghova transformácia a rôzne druhy morfologických operácií. Okrem týchto techník bližšie špecifikuje konkrétny druh neurónových sietí – konvolučné neurónové siete, ich využitie pre segmentáciu, jednu z architektúr takýchto sietí a metriky použité pre vyhodnocovanie segmentácie. Analýza súčasného stavu je popísaná vo štvrtej kapitole. Táto kapitola čitateľovi na základe existujúcich riešení podobných úloh približuje, čím je návrh nášho riešenia podložený a čím sa od ostatných odlišuje.

Praktická časť práce je popísaná v piatej kapitole. Postupne sú v nej predstavené jednotlivé súčasti, ktoré praktická časť obnáša. Kapitola podáva prehľad použitých technológií, prevedie čitateľa procesom pochopenia a prípravy dát, vrátane manuálnych segmentácií. Vysvetluje akým spôsobom prebieha navrhnutá automatická segmentácia a aké sú jej výhody. Objasňuje, aké kroky bolo potrebné vykonat na získaných segmentáciách pre detekciu paralelných tvarov v snímkach, a akým spôsobom boli výsledky overované. Na záver vyhodnocuje výsledky detektie a teda aj celého vykonaného procesu.

1 Slnečné erupcie

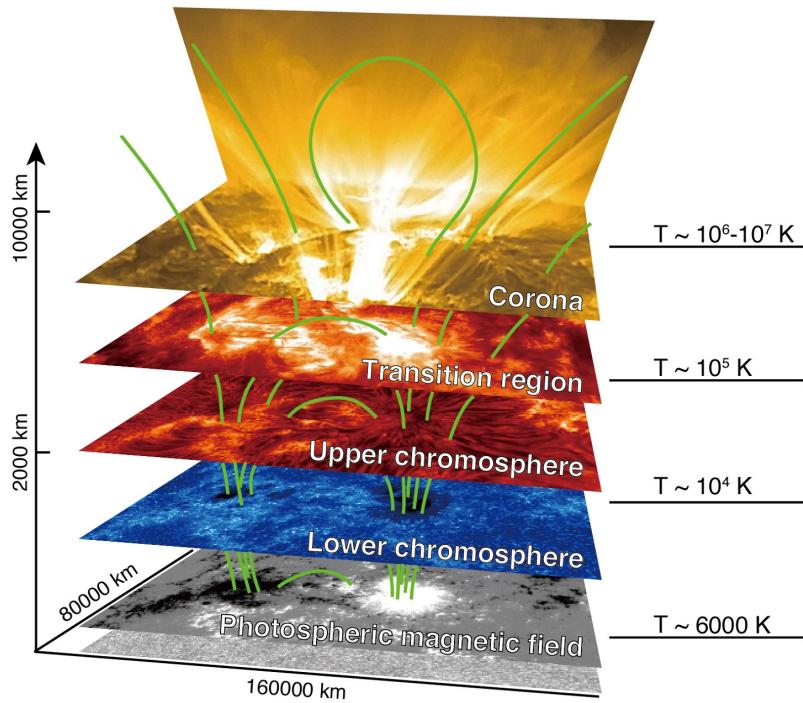
Slnečná erupcia je najenergetickejšou explóziou v solárnom systéme. Je to intenzívna a prudká udalosť, a to vo chvíli, keď sa náhle uvoľní nahromadená magnetická energia v atmosfére Slnka. Jadro slnečnej erupcie predstavuje oblasť na Slnku, z ktorej vychádza hlavná energia a častice v erupcii. Táto oblasť môže byť oblastou zvýšeného magnetického poľa, alebo oblastou silnej slnečnej aktivity.

Priebeh slnečnej erupcie môže byť rôznej dĺžky a pozostáva z troch štádií:

- predbežné (angl. *precursor* alebo *pre-flare*),
- impulzívne (angl. *impulsive*),
- rozkladové (angl. *decay* alebo *gradual*).

Počas prvého, takzvaného predbežného štátia, sa vyvolá uvoľnenie magnetickej energie, čo súvisí s 11-ročným cyklom slnečnej aktivity poháňanej magnetickým poľom Slnka. Predbežné štádium pozostáva z aktivity predchádzajúcej erupcii, kedy ešte radiácia impulzívneho štátia nie je detegovateľná, objavujú sa len malé žiarenia v UV až SXR vlnových dĺžkach niekoľko desiatok minút pred začatím erupcie. V druhom, impulzívnom štádiu, sa protóny a elektróny zrýchlia na rýchlosť presahujúcu 1 MeV. V tejto fáze nastáva najväčšie uvoľnenie energie. Trvá niekoľko desiatok sekúnd až niekoľko desiatok minút. Posledným štádiom je rozkladové. V tomto štádiu nastáva postupné vyžarovanie v röntgenovej (angl. *X-ray*) časti spektra. Každá z fáz môže skončiť po pár sekundách, alebo trvať až hodinu (Fletcher et al., 2011).

Slnečné erupcie nastávajú v aktívnych oblastiach. Sú to miesta, v ktorých je narušené magnetické pole Slnka. Obrázok 1 – 1 zobrazuje, ako sa aktívna oblasť prejavuje v rôznych vrstvách atmosféry Slnka. V týchto oblastiach sa často vyskytujú rôzne typy slnečnej aktivity. Okrem toho sa na nich objavujú aj slnečné škvurny, pomocou ktorých môžeme vizuálne spoznať aktívne oblasti. Sú to dočasne narušené oblasti, ktoré sú chladnejšie než ich okolie, a preto sa vizuálne javia ako tmavé miesta. Tento jav je viditeľný na najnižšej vrstve slnečnej atmosféry – fotosfére, najjasnejšej vrstve



Obrázok 1 – 1 Štruktúra slnečnej atmosféry prepojená magnetickými siločiarami. Vrstvy zhora nadol: horúca koróna, prechodová oblasť – prepájajúca chromosféru a korónu, chromosféra, fotosféra (Christe et al., 2017).

slnečnej atmosféry. Je to tenká vrstva plynu a je viditeľná pri pozorovaní slnečného disku, vidíme ju aj na Obrázku 1 – 1 v najspodnejšej vrstve. Slnečné škvreny v skutočnosti tmavé nie sú, javia sa tak len kvôli kontrastu s veľmi jasným okolím. Vznikajú ako výsledok vnútorného magnetického poľa, ktoré prenikne cez viditeľný povrch do slnečnej koróny. Ich magnetické pole je výrazne silnejšie než v iných oblastiach. Môže sa zjaviť len jedna škvrna, avšak zvyčajne sa vyskytujú v pároch alebo skupinách s opačnou polaritou. Pohybujú sa jednotne po celej ploche Slnka, keď sa otáča. Veľké množstvo slnečných škvŕn môže indikovať pravdepodobnosť výskytu slnečnej erupcie. Naopak, žiadne alebo len veľmi málo slnečných škvŕn zväčša znamená, že v danej oblasti nenastane žiadna, alebo len malá slnečná aktivita. Malé percento erupcií môže však nastaviť aj v oblastiach neobsahujúcich žiadne slnečné škvreny.

Flare ribbons sa vyskytujú počas slnečných erupcií. Flare ribbon sa prejavuje

ako svetlý, úzky pás okolo miesta, kde sú ukotvené siločiary magnetického poľa, zodpovedné za slnečnú erupciu. Tieto pásy sa tak často tvoria v blízkosti slnečných škvŕn. Flare ribbons sú dôležité pre štúdium slnečných erupcií, pretože ich vzhľad a tvar môžu poskytnúť informácie o vlastnostiach a dynamike magnetického poľa Slnka. Taktiež môžu byť použité na určenie miesta vzniku slnečnej erupcie a predpovedanie budúcich erupcií (Janvier, M. et al., 2016). Môžu mať dĺžku až desaťsíce kilometrov na dĺžku, pričom ale v ich najužších miestach majú šírku menej ako sto kilometrov.

Erupcie prenikajú až do najvzdialenejšej vrstvy Slnka, nazývanej slnečná koróna. Táto oblasť je zložená z riedkeho plynu, ktorý má teplotu niekoľko miliónov stupňov K. Erupcie dosahujú štandardne teplotu 10 – 20 miliónov stupňov K, ale ich teplota sa môže vyšplhať až na 100 miliónov stupňov K (Holman, 2001).

1.1 Vplyv slnečných erupcií na Zem

Slnečné erupcie majú značný vplyv na planétu Zem. Môžu mať rôzne formy, vrátane výronov koronálnej hmoty (angl. *Coronal mass ejections*, skr. CME). Keď nastávajú, uvoľňujú veľké množstvo nabitých častíc, radiácie a magnetických polí do vesmíru. Ak tieto časticie a polia smerujú k Zemi, môžu interagovať s magnetickým poľom našej planéty, čo spôsobuje rôzne efekty vesmírneho počasia (Fletcher et al., 2011).

Žiarenie, ktoré slnečné erupcie spôsobujú, sa na Zem dostane v priebehu ôsmych minút. Silné slnečné erupcie môžu dočasne narušiť hornú atmosféru Zeme, ktorá sa stáva viac ionizovanou a expanduje (Fox, 2013).

Na základe ich intenzity v röntgenovej časti spektra, sú slnečné erupcie radené do tried A, B, C, M alebo X. Do triedy A patria najslabšie erupcie, ktoré nemajú dostatočnú intenzitu na to, aby výrazne ovplyvnili Zem. Triedou X sa označujú najsilnejšie erupcie. Ukážka jednej z nich sa nachádza na Obrázku 1–2. Nastávajú približne 10-krát do roka. Erupcie triedy M sú 10-násobne menšie než erupcie triedy X. Najčastejšie sa na Slnku vyskytujú erupcie triedy A a B. V rámci každej triedy

sa erupcie hodnotia aj škálou 1 – 9, ktorá presnejšie definuje ich intenzitu. Výnimku tvorí trieda X, ktorá môže dosahovať aj vyššie hodnoty. Najväčšie erupcie triedy X sú najväčšími explóziami v solárnom systéme. Počas nich sa slučky, desaťnásobne väčšie ako Zem, zdvihnú zo Slnka, keď sa magnetické polia Slnka prekrížia cez seba a opäťovne spoja. Pri najväčších udalostiach môže tento proces opäťovného pripojenia vyprodukovať rovnaké množstvo energie ako miliarda vodíkových bômb (Fox, 2011).

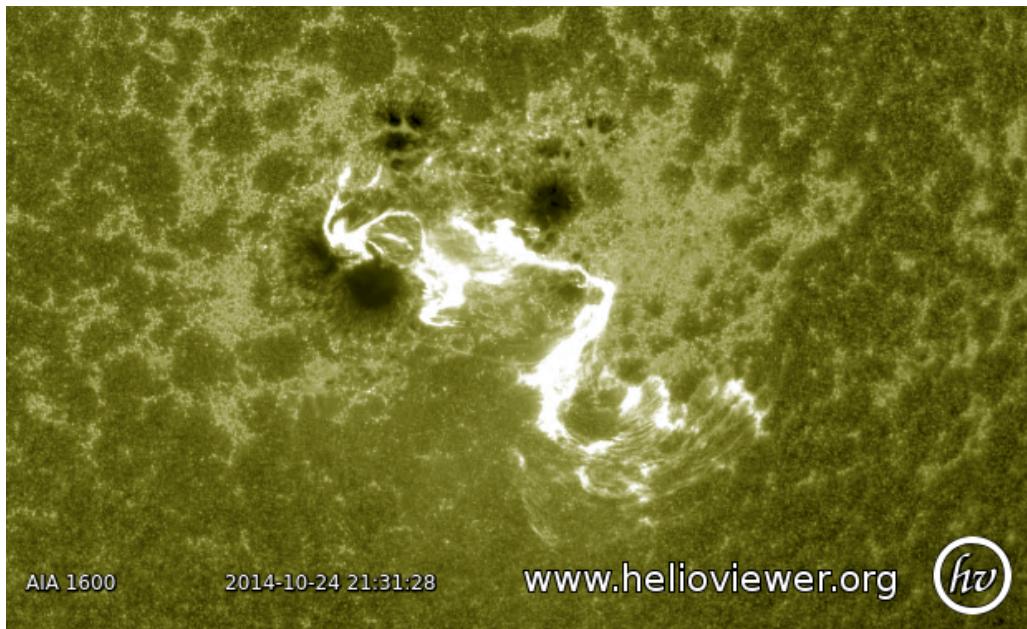
Silné erupcie tried M a X môžu vyvolať CME, teda veľké uvoľnenie plazmy a magnetického pola zo Slnka. Táto udalosť môže narušiť zemskú magnetosféru a vyvolať geomagnetické búrky.

Jedným z najčastejších dôsledkov solárnych erupcií je vznik polárnej žiary. Tieto farebné zobrazenia svetla vznikajú, keď sa nabité častice zo Slnka zrazia s atómami v zemskej atmosfére, pričom sa uvolní energia vo forme svetla. Môžu však mať aj väčšie následky – môžu narušiť satelitnú komunikáciu, navigáciu GPS a energetické siete, čo vedie k výpadkom prúdu a iným technologickým poruchám.

Búrky slnečného žiarenia môžu emitovať rýchlo sa pohybujúce nabité častice nesúce veľa energie, ktoré môžu ohrozíť astronautov a kozmické lode na obežnej dráhe Zeme. Astronauти počas takýchto búrok musia vyhľadať úkryt, všetky mimovozové aktivity sú pozastavené a systémy citlivé na radiáciu musia byť vypnuté.

Na strane Zeme otočenej k Slnku môžu erupcie tried M a X taktiež spôsobiť malé alebo rozsiahle rádiové výpadky. Týka sa to hlavne rádiových komunikácií vysokých frekvencií (3 – 30 MHz), no niekedy môžu byť ovplyvnené aj komunikácie veľmi vysokých frekvencií (30 – 300 MHz), alebo ešte vyšších.

Celkovo sa dá povedať, že slnečné erupcie môžu mať na Zem širokú škálu účinkov, od neškodných až po potenciálne nebezpečné a nákladné. Pochopenie týchto javov je dôležité pre ochranu našich technológií a zaistenie bezpečnosti tých, ktorí pracujú a cestujú vo vesmíre.



Obrázok 1 – 2 Slnečná erupcia triedy X3.1. Zdroj snímky, jej čas a zariadenie, ktoré ju získalo, sú uvedené priamo na obrázku.

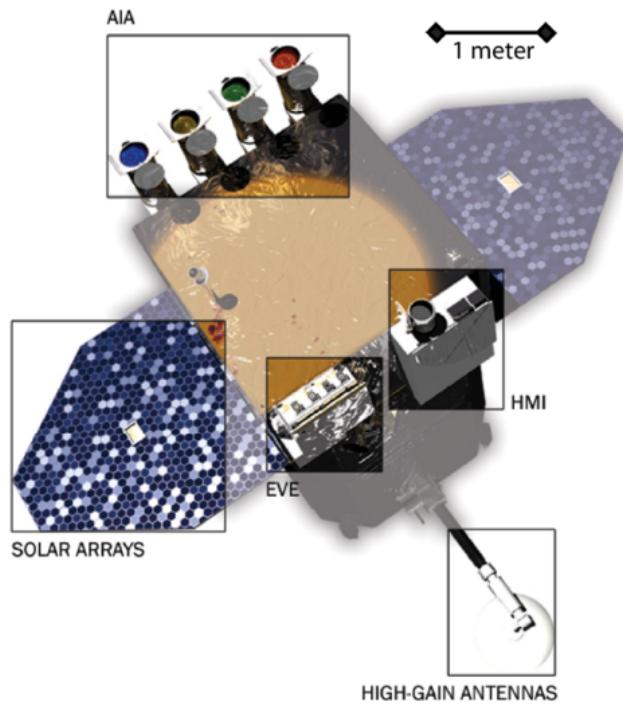
1.2 NASA SDO

NASA's Solar Dynamics Observatory (skr. SDO), začala svoje vesmírne pozorovania 11. februára 2010. Je to polo-autonómna kozmická loď nepretržite smerovaná k Slnku, ktorú vidíme na Obrázku 1 – 3. Na Obrázku sú vyznačené vysoko výkonné antény, solárne batérie a jednotlivé vedecké experimenty. Na opačnej strane lode sa nachádza hlavný motor a pomocná raketa. Každý deň zozbiera až 1,4 TB dát. Skúma, ako na Slnku vzniká slnečná aktivita, ako táto aktivita riadi kozmické počasie (angl. *space weather*), a aké sú dynamické podmienky vo vesmíre ovplyvňujúce celý solárny systém, vrátane Zeme. Bola vytvorená za účelom poskytnutia dát pre porozumenie a predikciu slnečnej aktivity. SDO prináša detailné snímky Slnka v ultra vysokom rozlíšení – 4096×4096 pixelov v trinástich vlnových dĺžkach (Addison, 2022). Okrem toho tiež vytvára celodiskové mapy a spektrá. Tieto dáta sú verejne dostupné a pre ich spracovanie, či už v plnom alebo zníženom rozlíšení, bolo vytvorených viacerých prístupov (Pesnell et al., 2012).

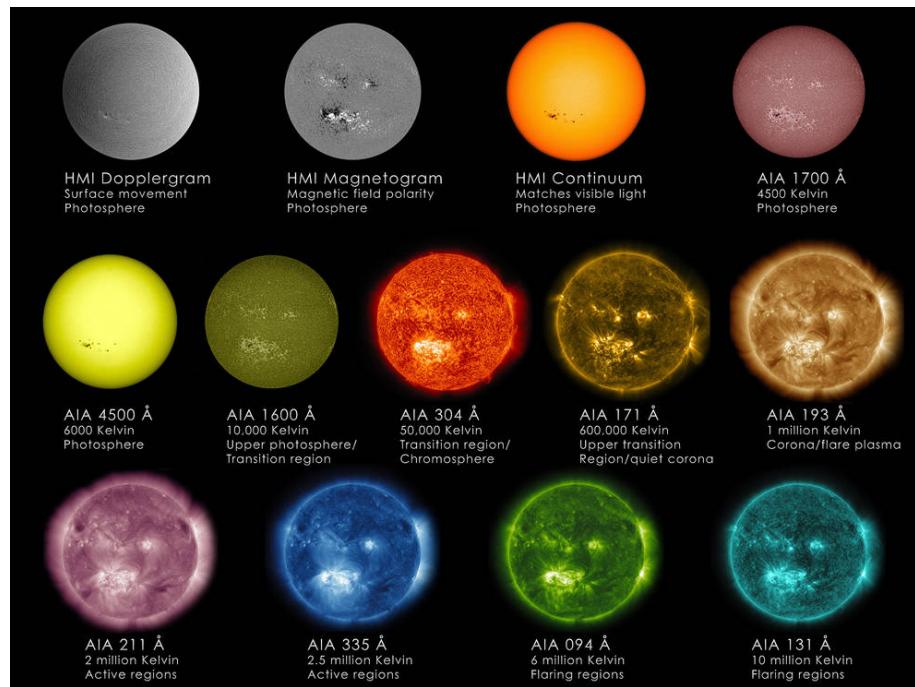
SDO má na palube tri vedecké experimenty:

- **Atmospheric Imaging Assembly (AIA)** – vyhotovuje snímky Slnka v rôznych vlnových dĺžkach,
- **EUV Variability Experiment (EVE)** – meria spektrum extrémne ultrafialového žiarenia (angl. *Extreme ultraviolet*, skr. XUV),
- **Helioseismic and Magnetic Imager (HMI)** – sleduje magnetické a rýchlosťné polia na povrchu Slnka.

AIA vytvára celodiskové EUV snímky každých desať sekúnd. Sú to snímky rôznych kanálov, ktorých ukážka je na Obrázku 1–4. Obrázok 1–3 zobrazuje štyri teleskopy, ktoré snímajú povrch a atmosféru Slnka a vytvárajú snímky pomocou filtrov v desiatich vlnových dĺžkach – sedem XUV, dve UV a jeden pás viditeľného svetla na odhalenie kľúčových aspektov slnečnej aktivity. Každé pásmo vlnovej dĺžky zvýrazňuje inú časť slnečnej atmosféry, a boli zvolené tak, aby pokrývali rozpätie od 6000 K do 3×10^6 K. Snímky kanálu 1600 Å zvýrazňujú hornú fotosféru a prechodomovú oblasť, nachádzajúcu sa medzi chromosférou a korónou. Tabuľka 1–1 zobrazuje prehľad jednotlivých kanálov a oblastí atmosféry Slnka, ktorá je pre nich viditeľná. Vďaka kanálu 1600 Å sú na snímkach lepšie viditeľné erupčné vlákna v porovnaní s inými kanálmi (Hatfield, 2021).



Obrázok 1 – 3 SDO kozmická loď (Pesnell et al., 2012)



Obrázok 1 – 4 Ukážka snímok SDO rôznych kanálov (Hatfield, 2021)

Kanál	Región atmosféry
4500 Å	Fotosféra
1700 Å	Teplotné minimum, fotosféra
304 Å	Chromosféra, prechodová oblast
1600 Å	Prechodová oblast, horná fotosféra
171 Å	Pokojná koróna, horná prechodová oblasť
193 Å	Koróna a horúca plazma
211 Å	Aktívna oblasť koróny
335 Å	Aktívna oblasť koróny
94 Å	Horúca koróna
131 Å	Prechodová oblasť, horúca koróna

Tabuľka 1 – 1 Porovnanie pozorovaných regiónov atmosféry Slnka jednotlivými kanálmi AIA

2 Hlboké učenie a neurónové siete

V dnešnej dobe sú počítače a umelá inteligencia súčasťou nášho každodenného života. S ich pomocou môžeme vykonávať rôzne úlohy, ktoré by sme inak museli robiť manuálne. Príkladom môže byť rozpoznávanie obrazu a hlasu, alebo tvorba odporúčaní pre budúce nákupy. Jednou z najdôležitejších oblastí v odvetví umelej inteligencie je hlboké učenie a neurónové siete.

Hlboké učenie je podmnožina strojového učenia, ktorá počítačom umožnila učiť sa z veľkého množstva dát, čím výrazne ovplyvnila vývoj umelej inteligencie. Je to proces učenia, kedy sa stroj učí reprezentovať vstupné dátá v hierarchickom usporiadanií vrstiev. Táto hierarchia zvyšuje úspešnosť rozpoznávania a zlepšuje výkon modelu.

Jednou z hlavných výhod hlbokého učenia je jeho schopnosť automaticky extrahovať potrebné informácie z nespracovaných dát, čo je možné dosiahnuť vďaka použitiu neurónových sietí. Neurónové siete sú typ algoritmu strojového učenia, inspirovaného fungovaním ľudského mozgu. Sú zložené zo vzájomne prepojených uzlov,

nazývaných aj neuróny, ktoré tvoria vrstvy siete. V tejto práci sa budeme konkrétnie venovať konvolučným neurónovým sieťam, ktoré sú najvhodnejším typom pre spracovanie obrazov a klasifikačné úlohy. Okrem jednotlivých vrstiev obsahuje každá neurónová sieť aj ďalšie dôležité aspekty, popísané v nasledujúcich podkapitolách. Neurónové siete môžu byť použité na rôzne úlohy, ako napríklad klasifikáciu, segmentáciu alebo tvorbu textu.

Strojové učenie je oblasť umelej inteligencie, ktorá sa zameriava na vývoj algoritmov a modelov, ktoré umožňujú počítaču učiť sa z dát a vyvíjať sa samostatne. Využíva techniky matematickej štatistiky pre analýzu dát a vytváranie predpovedí alebo rozhodovacích modelov.

Počítačové videnie je ďalšou oblasťou umelej inteligencie, ktorá sa zameriava na spracovanie obrazov pomocou počítača. Cieľom počítačového videnia je umožniť počítačom rozumieť a interpretovať obrazy a videá rovnako, ako to robia ľudia. Metódy počítačového videnia sú založené na matematických a štatistických princípoch, ktoré umožňujú spracovať obrazové dátá, a extrahovať z nich informácie. V praxi sa počítačové videnie používa na rôzne úlohy, ako napríklad rozpoznávanie tvári, áut, ulíc, obchodných značiek, detekciu objektov v reálnom čase, alebo sledovanie pohybu osôb.

2.1 Aktivačné funkcie

Medzi jeden zo základných prvkov neurónových sietí radíme aktivačné funkcie. Vy-počítavajú váženú sumu vstupov a zaujatosti (angl. *bias*), ktorú používajú na rozhodnutie, či bude daný neurón aktivovaný. Aktivačné funkcie môžeme rozdeliť na funkcie používané v skrytých alebo vo výstupných vrstvách siete, a zároveň sa delia aj podľa toho, či sú lineárne alebo nelineárne (Nwankpa et al., 2018).

Jednou z načastejšie používaných aktivačných funkcií v skrytých vrstvách je funkcia *Rectified Linear Unit* (skr. ReLU). Je oblúbená vďaka svojej jednoduchosti a efektívnosti v zlepšovaní výkonu hlbokých neurónových sietí. Reprezentuje takmer

lineárnu funkciu, vďaka čomu uchováva vlastnosti lineárnych modelov. Je definovaná matematickým vzorcom:

$$f(x) = \max(0, x), \quad (2.1)$$

kde x predstavuje vstup neurónu a $f(x)$ je výstup. ReLU nikdy nevráti negatívnu hodnotu a neurón je aktivovaný, len ak je vstup pozitívna hodnota. Vďaka tejto vlastnosti pomáha odstrániť problém miznúceho gradientu, ktorý môže v neurónových sietach nastat. Miznúci gradient nastáva, keď je gradient aktivačnej funkcie primalý a trénovanie sa stáva zložitým. Ďalšou výhodou ReLU funkcie je jej výpočtová efektivita. Kedže sa neskladá zo žiadnych komplexných matematických operácií, môže byť jednoducho implementovaná (Maas et al., 2013).

Medzi ďalšie aktivačné funkcie patria Sigmoid a Softmax, ktoré bývajú používané vo výstupnej vrstve modelu. Funkcia Sigmoid je nelineárna a navracia binárne hodnoty. Sigmoid môžeme vyjadriť vzorcom (2.2). Ak pravdepodobnosť hľadanej triedy vo vstupe dosiahne hranicu prednastaveného prahu, výstupom bude hodnota 1, v opačnom prípade to bude 0.

$$S(x) = \frac{1}{1 + e^{-x}} \quad (2.2)$$

Funkcia Sofmax je typicky používaná pre viac-triednu klasifikáciu, kde je výstupom rozdelenie pravdepodobnosti medzi niekoľko tried. Vstupné hodnoty namapuje na hodnoty z rozsahu $<0, 1>$, pričom ich súčet sa bude rovnať 1. Výslednou triedou bude tá, ktorá má priradenú najvyššiu hodnotu. Softmax je definovaná vzorcom (2.3), kde vstupom funkcie je vektor reálnych hodnôt z .

$$S(z) = \frac{e^{z_i}}{\sum_j e^{z_j}} \quad (2.3)$$

2.2 Optimalizácia

Optimalizačné funkcie sú jedným z dôležitých komponentov neurónových sietí. Používajú sa pre minimalizáciu empirického rizika. Jednou z často používaných optimalizačných funkcií je adaptívny algoritmus optimalizácie miery učenia (angl. *Adaptive Moment Estimation*, skr. Adam).

Adam je stochastický optimalizačný algoritmus používaný pri trénovaní neurónových sietí. Táto optimalizačná funkcia kombinuje výhody dvoch iných optimalizačných algoritmov – AdaGrad (angl. *Adaptive Gradient Algorithm*) a RMSprop (angl. *Root Mean Square Propagation*). Vďaka tomu môže dosiahnuť lepší výkon, čo sa týka rýchlosťi a presnosti konvergencie.

Optimalizácia Adam je založená na metóde postupného gradientu, ktorá upravuje parametre neurónovej siete tak, aby minimalizovala chyby. Vypočítava adaptívnu rýchlosť učenia pre každý parameter zvážením gradientu, aj predchádzajúcich gradientov. Taktiež používa exponenciálny kľazavý priemer štvorcových hodnôt gradientov na adaptívne prispôsobenie rýchlosťi učenia (Kingma and Ba, 2014).

Adam sa preukázal ako efektívna aktivačná funkcia v neurónových sieťach s rôznymi architektúrami a využitiami, vrátane spracovania obrazu, reči alebo prirodzeného jazyka. Samozrejme, existujú aj prípady, kedy nie je najvhodnejším riešením a nemusí nevyhnutne dosahovať dobré výsledky.

2.3 Chybové funkcie

Chybová funkcia počas trénovania hovorí, nakoľko správna alebo nesprávna je aktuálna predikcia siete a rozhoduje, ako budú optimalizované parametre. Našim cieľom je minimalizovať chybovú funkciu – menšia chyba znamená lepší model.

V závislosti od úlohy modelu je potrebné vybrať vhodnú chybovú funkciu. Nakoľko sa venujeme úlohe segmentácie, ktorá je vysvetlená v kapitole 3.1, popíšeme krížovú entropiu (angl. *cross-entropy*), ktorá je používaná pri takomto type modelov.

Krížová entropia je rozdiel dvoch rozdelení pravdepodobnosti. V kontexte seg-

mentácie obrazu predstavuje jedno rozdelenie pravdepodobnosti správnu segmentáciu obrazu, pričom druhé predstavuje predikovanú segmentáciu. Cieľom je minimalizovať rozdiel medzi nimi. Kedže ide o binárne snímky, budeme sa konkrétnie zaoberať binárhou krížovou entropiou (angl. *binary cross-entropy*, skr. BCE). Pre výpočet BCE je použitý vzorec (2.4), v ktorom premenná y predstavuje označenie triedy a \hat{y} je predikovaná trieda.

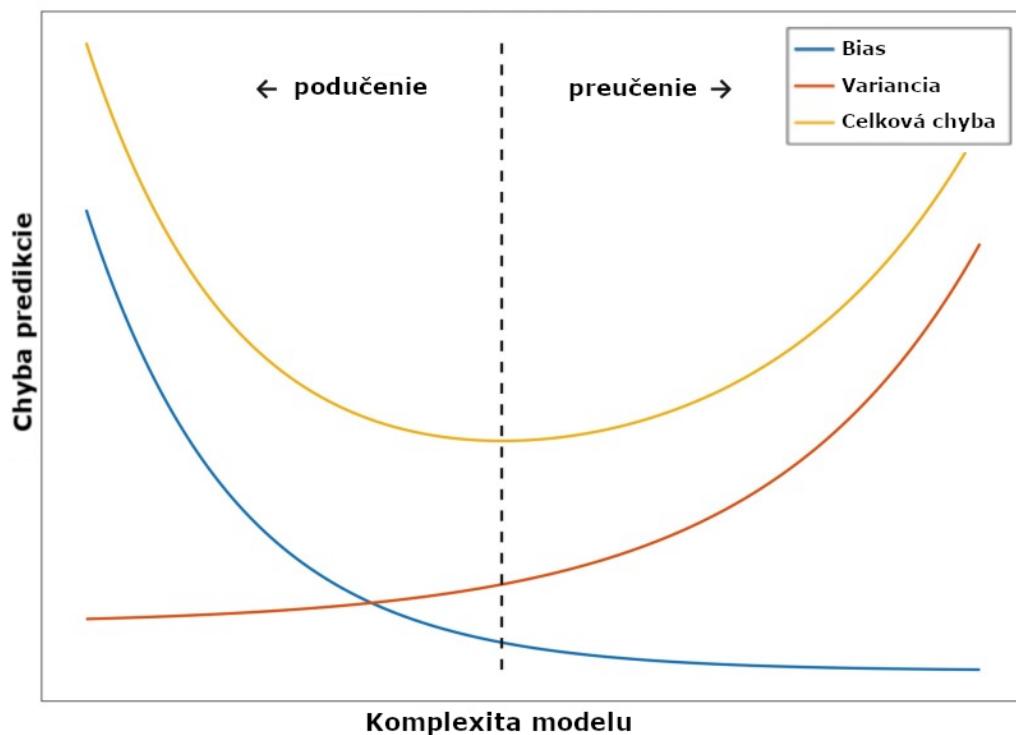
$$BCE = -(y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})) \quad (2.4)$$

2.4 Regularizácia

Pod pojmom regularizácia v neurónových sietach si môžeme predstaviť techniky strojového učenia, zabraňujúce preučeniu alebo podučeniu modelov. Tieto dva nežiaduce stavy sú zakreslené na Obrázku 2 – 1, kde prerušovaná čiara, prechádzajúca stredom grafu, znázorňuje ideálny stav.

Stav preučenia nastáva, keď model dosahuje veľmi dobré výsledky na trénovacej množine, avšak na testovacej množine je už neúspešný. Dôvodom tejto situácie je to, že sa model naučil príliš presné vlastnosti vstupov, a čo i len malú odchýlku, ako napríklad posunutie hladnej oblasti, už nevie správne predikovať. Podučenie zase znamená opačný stav, ktorý nastáva, keď model nedosahuje dostatočnú konvergenciu – nedokáže extrahovať potrebné príznaky z testovacej množiny. Techník regularizácie modelov je viacero a medzi najčastejšie používané môžeme zaradiť L1 a L2 normy, dropout alebo včasné zastavenie učenia.

Technika dropout vynecháva náhodné neuróny v skrytých, alebo aj vstupných vrstvách modelu, pod čím rozumieme ich dočasné vymazanie zo siete, spolu s ich vstupnými a výstupnými prepojeniami. Používa sa zvyčajne v plne prepojených vrstvách, keďže majú veľký počet parametrov a môžu spôsobiť preučenie. Vďaka dropoutu nebude mať žiadnen uzol priradené vysoké hodnoty parametrov, v dôsledku čoho budú hodnoty parametrov rozptylené a výstup aktuálnej vrstvy nebude závisieť



Obrázok 2 – 1 Grafické znázornenie podučenia a preučenia modelu

od jedného uzla (Srivastava et al., 2014). Medzi ďalšie výhody tejto techniky patrí výpočtová jednoduchosť a nezávislosť od typu neurónovej siete.

3 Metódy spracovania obrazu

Spracovanie obrazu je rýchlo rastúca oblasť, zaoberajúca sa manipuláciou digitálnych obrazov pomocou rôznych algoritmov a matematických operácií. Jej úlohou je pomôcť extrahovať alebo zvýrazniť zmysluplné informácie z obrazu. Nachádza využitie v rôznych doménach, ako napríklad v medicíne, robotike, pri spracovaní záberov zo sledovacích kamier a mnohých ďalších.

Táto kapitola sa zaoberá rôznymi technikami spracovania obrazu, a to segmentáciou, konvolučnými neurónovými sietami, Houghovou transformáciou a morfologickými operáciami. Tieto techniky boli použité v praktickej časti práce a každá z nich prináša svoje vlastné výhody a využíva sa pri rozdielnych úlohách spracovania obrazu.

3.1 Segmentácia obrazu

Segmentácia obrazu je jedným z hlavných problémov počítačového videnia. Zahŕňa rozdelenie obrazu na mnohé segmenty a objekty. Nachádza využitie v rôznych oblastiach, napríklad riadenie autonómnych vozidiel, analýza lekárskych snímok, alebo augmentovaná realita.

Existujú rôzne algoritmy zamerané na segmentáciu obrazu, medzi ktoré patria metódy prahovania, metódy založené na histogramoch, zhľukovanie algoritmom k-means, detekcia hrán, metódy založené na riedkosti a mnohé ďalšie. Metóda prahovania je jednou z najčastejšie používaných. Je používaná pre rozdelenie pozadia od popredia. Zvolením vhodnej hodnoty prahu môžeme jednoducho konvertovať obraz na binárny, ktorý by mal obsahovať všetky potrebné informácie o pozícii a tvare objektov. Hodnoty pixelov obrazu, ktoré sú nižšie než zvolený prah, budú upravené na hodnotu 0 – čierna, pričom ostatné nadobudnú hodnotu 1 – biela. Pre zvolenie správnej úrovne prahu sa často používa analýza histogramu.

V posledných rokoch boli pre účely segmentácie predstavené aj modely hlbokého učenia, ktoré dosahujú ešte lepšie výsledky než spomínané metódy. Pri využití hl-

bokého učenia delíme segmentáciu obrazu na dva typy: sémantickú segmentáciu a segmentáciu inštancií, pričom existuje taktiež ich kombinácia – panoptická segmentácia. Sémantická segmentácia prideľuje každému pixelu digitálneho obrazu označenie triedy. Je považovaná za klasifikačnú úlohu na úrovni pixelov. Jednotlivé objekty rovnakej triedy nie sú oddelené a nie je možné ich zrátať. Segmentácia inštancií je na rozdiel od sémantickej komplexnejšia a rozlišuje aj medzi viacerými objektmi rovnakej triedy (Minaee et al., 2022).

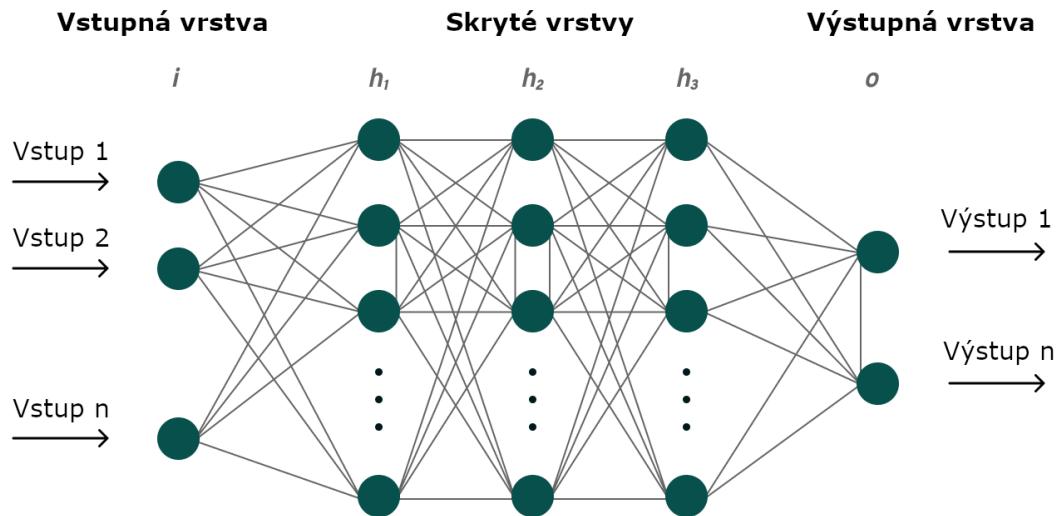
3.2 Konvolučné neurónové siete

Konvolučné neurónové siete (angl. *Convolutional neural network*, skr. CNN) sú jedným z najpoužívanejších typov hlbokých neurónových sietí. Sú modelované podľa prirodzených biologických nervových systémov a využívajú matematickú lineárnu operáciu konvolúcie, podľa ktorej sú aj pomenované.

Ich architektúra sa skladá z rôznych typov vrstiev. Každá CNN obsahuje tri hlavné typy vrstiev – vstupnú, skryté vrstvy, ktorých môže byť viacero, a výstupnú vrstvu. Takúto štruktúru zobrazuje Obrázok 3–1, kde vidíme, že sa každá vrstva môže skladať z rôzneho počtu vzájomne prepojených neurónov, v závislosti od architektúry siete.

Typicky je prvou skrytou vrstvou CNN konvolučná vrstva, ktorá aplikuje na vstupný obrázok filtro pre extrakciu dôležitých príznakov, ako napríklad hrany, čiary, alebo tvary. Konvolúcia je matematická operácia používaná pri spracovaní signálov, alebo obrazov v hlbokom učení. Používa filter (angl. *kernel*), teda dvojdimenzionálne pole určitých hodnôt. Tento filter sa počas procesu konvolúcie postupne posúva po vstupnom obraze o hodnotu kroku (angl. *strides*). Spočítava hodnoty pixelov pokrytej časti obrazu, ktoré následne násobí svojimi váhami a výslednú hodnotu zapíše na miesto pokryté počiatočným bodom filtra. Postupne prejde celým vstupom a vytvorí tak nový zmenšený obraz.

Ďalšími typmi vrstiev sú vzorkovacie (angl. *pooling*) a plne prepojené. Výstup



Obrázok 3 – 1 Vrstvy konvolučnej neurónovej siete

konvolučnej vrstvy sa ďalej posúva do vzorkovacej vrstvy, ktorá zmenšuje a zredukuje rozmery príznakovéj mapy. Ponecháva najdôležitejšie informácie získané z konvolučnej vrstvy. Dopomáha tomu, aby sieť nebola príliš citlivá na umiestnenie nájdených príznakov. Vstup rozdeľuje na neprekryvajúce sa časti. Vzorkovacie vrstvy bývajú väčšinou typu *max*, pri ktorom sa ponechajú najvyššie hodnoty v rámci jednotlivých častí, alebo *average*, pri ktorom sa hodnoty spriemerujú.

Postup konvolúcie a vzorkovania môže byť niekolokrát zopakovaný. Následne sa výstup upraví na jednorozmerný a použije sa ako vstup plne prepojenej vrstvy. Účelom plne prepojenej vrstvy je spočítavanie váh predchádzajúcich vrstiev siete. Táto vrstva indikuje, aké príznaky je potrebné hľadať vo vstupných obrázkoch pre ich správnu klasifikáciu. Okrem spomenutých vrstiev model musí obsahovať aj výstupnú vrstvu, ktorá obsahuje zvolenú aktivačnú funkciu, v závislosti od typu siete a počtu hľadaných tried (Albawi et al., 2017).

3.2.1 Konvolučné neurónové siete pre segmentáciu obrazu

Konvolučné neurónové siete nachádzajú využitie pre rôzne účely, medzi ktoré patrí aj segmentácia obrazu. V posledných rokoch sa v tejto oblasti používajú stále viac. Najčastejšie sa pomocou nich vytvára sémantická segmentácia a ich výstupom je binárna maska, indikujúca, ktoré pixely boli segmentované pre každý hľadaný objekt.

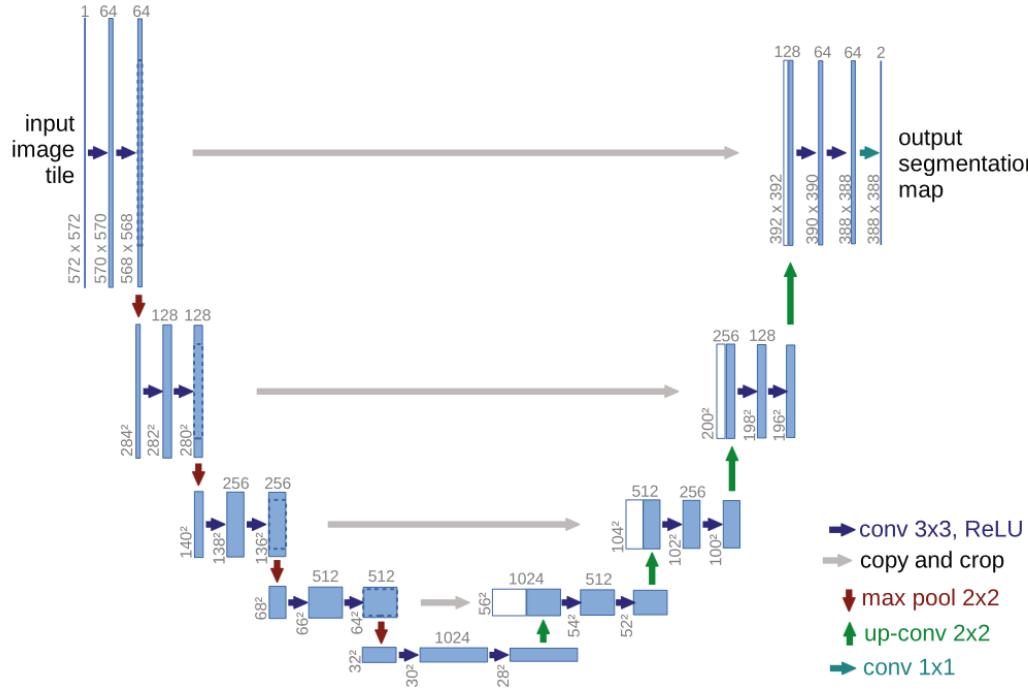
Pre tento typ úloh bolo navrhnutých viacero architektúr. Tieto sú zvyčajne založené na princípe enkóder-dekóder, kde enkóder získava vlastnosti z obrazu, a dekóder používa tieto vlastnosti pre vytvorenie segmentačnej mapy. Tento princíp je bližšie popísaný v podkapitole 3.2.2, ktorá sa zaobrá jednou z populárnych typov segmentačných architektúr – U-Net, použitej aj v praktickej časti tejto práce. Okrem architektúry U-Net patria medzi často používané architektúry aj FCN (angl. *Fully-Convolutional Net*), alebo SegNet.

3.2.2 Architektúra U-Net

U-Net je populárny typ architektúry konvolučných neurónových sietí, ktorý bol pôvodne navrhnutý na segmentáciu biomedicínskych snímok. Bol predstavený v roku 2015 autormi Ronneberger et al. (2015). Odvtedy bol využitý pri rôznych úlohách spracovania obrazu, ako napríklad segmentačné a klasifikačné úlohy, alebo detekcia objektov. Názov „U-Net“ vznikol na základe architektúry takýchto sietí, ktorá pozostáva zo zmršťovacej a zväčšujúcej cesty a pripomína tvar písmena „U“.

U-Net má symetrickú enkóder-dekóder štruktúru. Časť enkóder získava vysokoúrovňové vlastnosti zo vstupov aplikovaním konvolučných a vzorkovacích operácií, zatiaľ čo dekóder vykonáva operácie dekonvolúcie. Vďaka dekonvolúcii dokáže obnoviť informácie o mieste a rozmiestnení objektov, inak povedané priestorové informácie, vstupného obrazu. Hlavnou inováciou tejto architektúry je vynechanie spojení (angl. *skip connections*), ktoré prepájajú korešpondujúce enkóder a dekóder vrstvy, pre zachovanie priestorových informácií a lepšie šírenie vlastností.

Architektúra siete U-Net je vykreslená na Obrázku 3–2. Zmršťujúca cesta je po-



Obrázok 3 – 2 Grafické znázornenie architektúry U-Net (Ronneberger et al., 2015)

dobná typickej architektúre CNN, a pozostáva z opakovaného využitia 3×3 operácií konvolúcie, pričom za každou z nich nasleduje funkcia ReLU a 2×2 vzorkovacia vrstva. Tieto kroky postupne znižujú priestorové rozlíšenie máp vlastností a zároveň zvyšujú ich hĺbku. Na druhej strane sa nachádza zväčšujúca cesta, ktorej každý krok obsahuje zväčšenie mapy príznakov a dekonvolúciu o velkosti 2×2 . Taktiež obsahuje operácie zreteženia, ktoré postupne obnovujú priestorové rozlíšenie máp vlastností a zmenšujú ich hĺbku. Vynechanie spojení umožňuje dekóderu využívať vysoko-úrovňové vlastnosti korešpondujúcich vrstiev enkódera, čo pomáha zachovať jemnejšie detaľy vstupných snímok. Dokopy má architektúra 23 konvolučných vrstiev (vrátane dekonvolučných). Je dôležité, aby vstupné snímky mali štvorcové rozmery.

3.2.3 Vyhodnocovacie metriky segmentácie obrazu

Pre správne pochopenie výsledkov modelu a ich prehľad sa používajú vyhodnocovacie metriky. Existuje ich viacero, avšak nie všetky sú vhodné pre vyhodnotenie segmentačného modelu. Medzi metriky používané pre vyhodnotenie výsledkov segmentácie patria metriky *Intersection Over Union* (skr. IoU) a koeficient Dice, ktoré boli použité napríklad na vyhodnotenie segmentačného modelu SCSS-Net (Mackovjak et al., 2021).

IoU, alebo Jaccardov index, je oveľa presnejším vyjadrením úspešnosti segmentácie, než keby sme kontrolovali správnosť jednotlivých označených pixelov. To platí obzvlášť v prípade riedkych vstupných dát (van Beers et al., 2019). Je to podiel prieniku a spojenia vysegmentovanej oblasti a hľadanej oblasti. Dosahuje hodnoty $< 0, 1 >$, pričom hodnota 1 vyjadruje bezchybnú segmentáciu. Túto metriku môžeme vyjadriť vzorcom:

$$\text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \quad (3.1)$$

Dice koeficient, známy aj ako koeficient podobnosti, alebo F1 skóre, porovnáva zhodu pixelov predikovanej segmentácie a hľadanej oblasti. Je to podiel dvojnásobku prieniku oblastí a súčtu pixelov oboch snímok. Dice je veľmi podobný metrike IoU a sú pozitívne korelované. Rovnako, ako IoU, nadobúda hodnoty z rozsahu $< 0, 1 >$. Je vyjadrený nasledovným vzorcom:

$$\text{Dice} = \frac{2 * \text{TP}}{2 * \text{TP} + \text{FP} + \text{FN}} \quad (3.2)$$

V oboch vzorcoch sú použité hodnoty:

- TP (angl. *True Positive*) – správne označené pixely,
- FP (angl. *False Positive*) – označené pixely, ktoré by súčasťou segmentácie nemali byť,

- FN (angl. *False Negative*) – neoznačené pixely, ktoré by súčasťou segmentácie mali byť.

3.3 Houghova transformácia

Houghova transformácia je technika počítačového videnia používaná pre detekciu jednoduchých geometrických tvarov v obrázkoch, a to napríklad čiar, kruhov, alebo elips. Bola navrhnutá Paulom Houghom v roku 1962 za účelom detektie stôp na fotografiách bublinkovej komory (Illingworth and Kittler, 1988). Odvtedy bola použitá pre mnoho iných účelov.

Je založená na konvertovaní obrázku z priestorovej domény do Houghovho parametrického priestoru hľadaného tvaru, v ktorom je jednoduchšie identifikovať tieto geometrické tvary. Jednoduchý príklad takejto transformácie vidíme na Obrázku 3–3. Priestorová doména je $x - y$ -ový súradnicový priestor, v ktorom je každý pixel obrázku reprezentovaný jeho súradnicami x a y . Parametrický priestor je vyššie dimenzionálnym priestorom, reprezentujúcim parametre hľadaného tvaru. Napríklad pri hľadaní čiar by obsahoval dve dimenzie – sklon a priesečník s osou y (Duda and Hart, 1972).

Houghova transformácia pozostáva z troch hlavných krokov:

1. Detekcia hrán

Prvým krokom je detekcia hrán, zvyčajne vykonaná detekčným algoritmom, ako napríklad detekcia hrán *Canny*.

2. Hlasovanie

Na obrázku s detegovanými hranami sa následne vykonáva proces hlasovania, kedy každý pixel obrázku hlasuje za všetky možné tvary, ktoré by ním mohli prechádzať. Každý hlas je zaznamenaný v parametrickom priestore.

3. Detekcia vrcholov

Posledným krokom je nájdenie vrcholov v parametrickom priestore – geometrických tvarov, za ktoré hlasovalo najväčšie množstvo pixelov. Predstavujú najpravdepodobnejšie tvary na obrázku.

Za nevýhody Houghovej transformácie môžeme považovať jej výpočtovú náročnosť a fakt, že nemusí správne fungovať na hľadanie komplexnejších tvarov alebo na obrázkoch obsahujúcich šum.

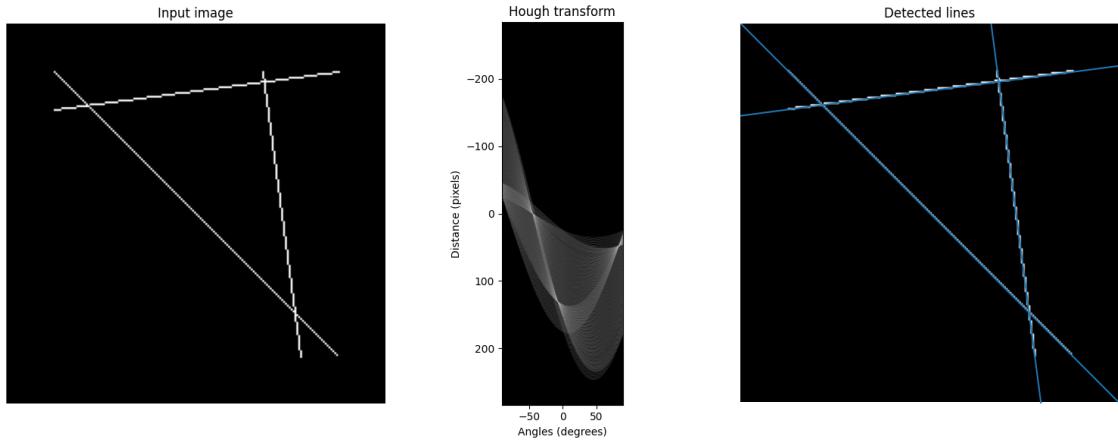
Pravdepodobnostná Houghova transformácia (skr. PHT) je jednou z variant Houghovej transformácie. Hlavným cieľom PHT je nájsť hypotézy o parametrizovanej polohe a orientácii geometrických objektov v obrazových dátach.

PHT, ktorá bola prvýkrát predstavená v roku 1981, je vylepšením Houghovej transformácie. Používa pravdepodobnostné modely na určenie parametrických hodnôt geometrických objektov. V porovnaní s tradičnou Houghovou transformáciou, ktorá vyžaduje veľké množstvo výpočtov a vysokú pamäťovú náročnosť, je PHT efektívnejšia a presnejšia. PHT vypočíta pravdepodobnosti pre každý bod v parametrickom priestore, a následne hľadá hlasovacie body, ktoré tvoria hlasovacie hladiny. Tieto body predstavujú geometrický objekt v obraze a na základe korelácie medzi hlasovacími hladinami sa určí jeho poloha a orientácia.

Houghova transformácia a PHT sú v súčasnosti veľmi často používané v mnohých oblastiach, ako sú medicína, priemysel, robotika, počítačové videnie a spracovanie obrazov. Medzi konkrétné príklady patrí detekcia cestných značiek, rovných liniek na stavebných plánoch a detekcia živých buniek v mikroskopických snímkach.

3.4 Morfologické operácie

Morfologické operácie sú jedny zo základých techník používaných v počítačovom videní. Slúžia na spracovanie obrazu a analýzu. Sú to nelineárne operácie a používajú sa na extrakciu a úpravu rôznych vlastností obrázkov, ako napríklad okraje, hrany, alebo tvary. Fungujú na princípe aplikácie matematických operácií na hodnoty pi-



Obrázok 3–3 Ukážka Houghovej transformácie. Zlava: vstup, Houghov priestor, výstup s detegovanými čiarami.

xelov obrazu. Zvyčajne bývajú používané pre odstránenie nedokonalostí z obrazu a najčastejšie sa používajú na binárnych snímkach.

Morfologická operácia sa na obraz aplikuje prostredníctvom štruktúrneho elementu. Štruktúrny element je malá binárna matica, ktorej tvar môže byť rôzny, v závislosti od toho, čo úpravami chceme dosiahnuť. Je postupne posúvaný po celom obraze a jeho hodnoty sú porovnávané s pixelmi obrazu. Pri tomto procese môžu nastať tri rôzne stavov:

- *Fit* – nastane iba v prípade presnej zhody štruktúrneho elementu s časťou obrazu, ktorú prekrýva.
- *Hit* – nastane, keď sa aspoň jedna jednotka štruktúrneho elementu zhoduje s jednotkami prekrytého obrazu.
- *Miss* – situácia, kedy sa žiadna jednotka štruktúrneho elementu nezhoduje s obrazom.

V závislosti od hľadaného stavu, sa kontroluje zhoda niektorých alebo všetkých hodnôt štruktúrneho elementu s časťou obrazu, ktorú v danej chvíli prekrýva. Ak je daný stav splnený, tak sa na miesto pokryté jeho počiatočným bodom zapíše hodnota 1. Základné morfologické operácie sú dilatácia a erózia.



Obrázok 3 – 4 Ukážka úpravy obrazu operáciou erózie

3.4.1 Erózia

Počas operácie erózie sa kontroluje presná zhoda štruktúrneho elementu s obrazom - hľadá sa stav Fit. Ak sa štruktúrny element a časť obrazu, ktorú v danej chvíli pokrýva, presne zhodujú (musia mať na rovnakých miestach hodnoty pixelov 1 a 0), zapíše sa na počiatočné miesto štruktúrneho elementu hodnota 1. Eróziou sa stenšujú okraje objektov a zväčšujú medzery. Rozmer a tvar štruktúrneho elementu ovplyvňuje, ako veľmi budú objekty zmenšené. Výsledok tejto operácie je viditeľný na Obrázku 3 – 4. Môžeme pomocou nej napríklad aj oddeliť spojené objekty alebo odstrániť malé výčnelky na okrajoch objektov.

3.4.2 Dilatácia

Pri dilatácii sa vyhľadáva stav Hit, teda pri akejkolvek zhode so štruktúrnym elementom sa zapíše do obrazu jednotka. Vďaka tomu dokáže operácia dilatácie zväčšiť objekty vykreslené na obraze. Jej efekt je opačný než pri erózii – pridáva pixely na okrajoch objektov, vyplňa diery, pridáva chýbajúce pixely obrazu, a v zásade zväčšuje objekty v ňom. Podobne ako pri erózii, čím väčší je štruktúrny element, tým viac sa objekty zväčšia. Ukážka úpravy obrazu prostredníctvom tejto operácie je znázornená na Obrázku 3 – 5.



Obrázok 3 – 5 Ukážka úpravy obrazu operáciou dilatácie

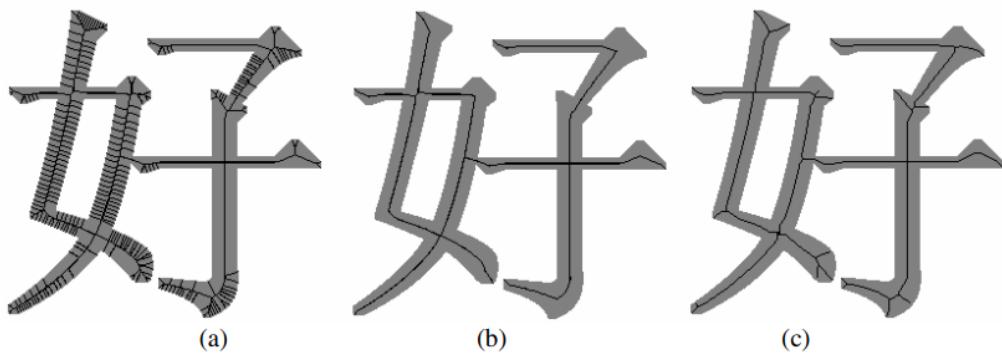
3.4.3 Otvorenie a zatvorenie

Kombináciou erózie a dilatácie vznikajú operácie otvorenia a zatvorenia. Otvorenie je erózia nasledovaná dilatáciou. Táto možnosť je efektívna pri odstraňovaní bieleho šumu z obrazov. Je nazvaná takto, pretože dokáže „otvoriť“ prepojenia pixelov, pričom objekty, ktoré prešli eróziou a zostali v obraze, sa navrátia do ich pôvodných rozmerov. Zatvorenie sa skladá z opačného poradia operácií – je to dilatácia nasledovaná eróziou. Táto operácia je vhodná pre odstránenie nedokonalostí z objektov, ako sú medzery alebo diery. Obe tieto operácie sú idempotentné – ich opakovanie s rovnakým štruktúrnym elementom vedie stále k rovnakým výstupom.

3.4.4 Skeletonizácia

Skeletonizácia, známa aj ako stenšovanie (angl. *thinning*), poskytuje efektívnu reprezentáciu objektu na obraze zmenšením jeho rozmerov na stredovú os alebo „kostru“. Je to proces extrakcie zjednodušenej reprezentácie objektu binárneho obrazu. Ponecháva geometrické vlastnosti pôvodného obrazu. Skeletonizácia môže byť aplikovaná na jedno, dvoj, alebo troj-rozmerné obrazy (Saha et al., 2016). Existuje viacero typov techník skeletonizácie, medzi najčastejšie používané patria:

- transformácia na stredovú os,
- vzdialenosná transformácia,
- morfologické stenšovanie.



Obrázok 3–6 Porovnanie techník skeletonizácie – a) pôvodný skeleton, b) metóda DSE, c) morfologické stenšovanie (Bai and Latecki, 2007).

Metóda skeletonizácie nachádza rôzne využitia, medzi ktoré patrí napríklad hľadanie tvarov, rozoznávanie vzorov, spracovanie lekárskych snímok alebo sledovanie objektov.

Digitálne obrazy komplikujú proces skeletonizácie. Skeletonizácia má vysokú senzitivitu na malé detaily na okrajoch objektov, deformácie, nepresné tvary a iné javy, ktoré v digitálnych obrazoch často nastávajú. Akokolvek malá odchýlka vytvára nové vetvy výslednej kostry, čím ju deformuje a stažuje prácu s obrazom. Okrem toho môže problémy spôsobovať napríklad aj šum v obrazu. Pre odstránenie týchto nedostatkov bolo navrhnutých viacero prístupov pre úpravu procesu skeletonizácie, všeobecne označovaných ako *pruning*. Jednou z nich je metóda nazvaná *Discrete Skeleton Evolution* (DSE), ktorá rieši prvý spomínaný problém, a bola predstavená v práci Bai and Latecki (2007).

Navrhuje metódu orezávania sietí pre spracovanie obrazu, ktorá sa zameriava na zlepšenie efektívnosti a presnosti segmentácie obrázkov. Iteratívne odstraňuje vytvorené vetvy, ktoré majú najmenšiu relevanciu pre hlavný tvar objektu. Týmto postupom nenaruší topológiu originálneho tvaru. Jej výsledok, ktorý je zároveň porovnaný s neupraveným výstupom skeletonizácie a výstupom morfológického stenšovania, vidíme na Obrázku 3–6.

4 Analýza súčasného stavu

Pre účely detekcie, segmentácie, klasifikácie, alebo predikcie rôznej solárnej aktivity bolo predstavených viacero rozličných prístupov. Na tieto účely slúžia vo všetkých uskutočnených štúdiách snímky NASA SDO, ktoré sú verejne prístupné online a neustále aktualizované.

Pre jednoduchší prehľad a spracovanie snímok obsahujúcich erupčné vlákna a aktívne oblasti, bol vytvorený katalóg ich vlastností RibbonDB (Kazachenko et al., 2017). Obsahuje informácie o 3137 erupčných vláknach. Pre výber konkrétnych dát, ktoré boli zahrnuté, bol využitý už existujúci *Heliophysics Event Catalog* (skr. HEC), čo je softvérový nástroj pre *Heliophysics Integrated Observatory*. Hlavným cieľom HEC je popísat héliosférické udalosti vzniknuté na Slnku. Dáta sú zozbierané za obdobie šiestich rokov – apríl 2010 až apríl 2016. RibbonDB pokrýva dáta z prvej polovice 24. solárneho cyklu. V katalógu nie sú zahrnuté snímky s vláknami, ktoré nemajú priradené číslo aktívnej oblasti. Pre minimalizáciu projekčných efektov taktiež neobsahuje tie, ktoré sa nenachádzajú v oblasti do 45° od centrálneho poludníka. Tento katalóg prináša dôležitý zdroj informácií o snímkach, ktoré budú použité v tejto práci. Medzi najpodstatnejšie získané údaje patria:

- čas začiatku nájdenej erupcie,
- čas vrcholu erupcie,
- čas konca erupcie,
- slnečná šírka polohy erupcie,
- slnečná dĺžka polohy erupcie,
- plocha, ktorú erupčné vlákno zaberá,
- intenzita erupcie.

Na základe časových údajov je možné jednoducho dané dátá stiahnuť v požadovanom filtri z webstránky [Helioviewer.com](https://helioviewer.com), ktorá poskytuje aj API prístupné v programovacom jazyku Python s využitím knižnice SunPy². Následne vieme vďaka údajom o polohe presne zobraziť hľadanú oblasť. Intenzita spočíva v zaradení erupcie do jednej z tried: C, M, X, ktoré majú zároveň priradené indexy 1 — 5. Najväčší počet snímok, a to až 91,5%, patria do triedy C. Trieda M je zastúpená vo výške 8% a len 0,5% patrí do triedy X. Erupcie menšie ako triedy C sa v katalógu nenachádzajú, na kolko nepredstavujú žiadne riziká a ich bližšie skúmanie nie je predmetom tejto práce.

Údaj o vrchole erupcií bol zistovaný na základe toho, kedy sa na snímke vyskytlo najväčšie množstvo najviac saturovaných pixelov. Dĺžku trvania erupcie vieme zistiť vďaka časom priradeným k jednotlivým záznamom. Pri vytváraní katalógu boli použité dátá AIA, zachytávajúce slnečnú korónu, a taktiež HMI dátá, zaznamenávajúce slnečnú fotosféru a magnetické štruktúry, ktoré sa v nej nachádzajú. Pracovali s filtrom AIA 1600 Å a HMI magnetogramom. Vďaka spracovávaným údajom zistili, že tok röntgenového žiarenia pre vrcholnú fázu erupcie má s magnetickým tokom aktívnych oblastí len veľmi malú koreláciu, avšak s rekonexným tokom erupčných vlákien má zase silnú koreláciu. Katalóg bol zhotovený manuálnou detekciou snímok, nie je to teda automatický prístup. Zhromaždené dátá umožňujú a zjednodušujú ďalší výskum, keďže vďaka nim môžeme jednoducho vytvoriť vstupnú množinu pre účely trénovalia modelu.

Úloha automatickej detektie a segmentácie, jednak spomínaných erupčných vlákien, alebo aj iných slnečných udalostí, bola už riešená viacerými prístupmi. Jedným z nich sú konvolučné neurónové siete. Výsledky ich modelov, natrénovaných na snímkach z rozličných filtrov AIA, prípadne HMI, dokazujú, že použitie CNN môže byť vhodným prístupom a správnym smerom pre ďalšie štúdie v tejto doméne. Takýto typ neurónových sietí má celkovo značný potenciál, keďže pri spracovaní obrazu vykazuje štandardne veľmi dobré výsledky. Napriek tomu neexistuje doposiaľ veľké

²<https://sunpy.org/>

množstvo CNN modelov v doméne vesmírneho počasia.

V práci Mackovjak et al. (2021) bol predstavený model neurónovej siete, vystupujúci pod názvom *Solar Coronal Structures Segmentation Network* (skr. SCSS-Net). Využíval architektúru U-Net, bližšie popísanú v podkapitole 3.2.2. Bol určený na segmentáciu solárnych koronálnych štruktúr EUV spekra, pričom bol testovaný na segmentáciu koronálnych dier aj aktívnych oblastí na Slnku. V modeli boli použité SDO snímky kanálov AIA 171 Å a AIA 193 Å. Vstupné snímky boli anotované manuálne študentmi a tiež aktuálne používanými algoritmami **SPoCA**, **CHIMERA** a **Region Growth**. Pre segmentáciu koronálnych dier bolo v tejto práci využitých 900 takýchto snímok, ktorých počet bol následne rozšírený augmentačnými metódami. Model bol natrénovaný na troch rôznych množinách – na vytvorenej množine, na množine, ktorú poskytoval iný algoritmus, a taktiež na ich kombinácii. Výsledky boli vyjadrené metrikami IoU a Dice, ktoré dosiahli rozdielne výsledky pre všetky štyri skúmané typy zdrojov anotácií koronálnych dier. Hodnoty IoU sa pohybovali v rozmedzí 0,64 – 0,78, pričom Dice nadobúdalo hodnoty 0,78 – 0,88. Tieto výsledky boli následne porovnávané s bežne používanými algoritmami, pričom dosiahli obdobné hodnoty. Zároveň publikácia uvádzá, že najväčšou prekážkou v zlepšení výsledkov modelu je kvalita vstupnej množiny dát. Na základe dosiahnutých výsledkov môžeme teda konštatovať, že využitie CNN sa na segmentáciu daných oblastí osvedčilo.

Ďalším z príkladov aplikácie CNN na snímkach SDO je model určený pre klasifikáciu erupčných vlákien (Love et al., 2020). Vstupné snímky pochádzali z AIA, konkrétnie to boli snímky filtra 1600 Å, ktorý bude použitý aj v našich vstupných dátach. Navrhnutý model klasifikoval vstupné snímky do štyroch tried: *Quiet Sun*, *two-ribbons*, *Limb flares*, *Compact/Circular ribbons*, ktoré boli zvolené na základe dostatočných viditeľných rozdielov medzi nimi, čo umožňuje lepšie natrénovanie modelu. Tieto triedy sú zamerané na morfológiu erupčných vlákien, konkrétnie vyjadrujú ich tvar, pričom trieda *Quiet Sun* je priradená, ak sa žiadna erupcia na snímke nenašla. Rovnako, ako v katalógu RibbonDB, bral tento model v úvahu len erupčné vlákna triedy C a vyššie. Model bol trénovaný a validovaný na 540 snímkach a tes-

tovaný na 430 snímkach. Dosiahol celkovú presnosť vo výške 94%. Na rozdiel od SCSS-Net, identifikované oblasti nesegmentoval. Rozdielne poznatky priniesla štúdia Panos and Kleint (2020), zaoberajúca sa predikciou erupčných vlákien. Navrhuje model hlbokej neurónovej siete, schopný predikovať slnečnú erupciu 35 minút pred jej začiatkom s úspešnosťou 86%, presnosťou a návratnosťou vo výške 80%, pričom sa tieto hodnoty zlepšujú so skracujúcim sa časom. V porovnaní s predchádzajúcimi štúdiami autori pracovali s inými dátami, a to s množinou skladajúcou sa zo snímok HMI. Zároveň skúmanie slnečných erupcií rozšírili o štúdium spektrálnej oblasti na základe dát z NASA IRIS³. Ich cieľom však nebolo priniesť čo najúspešnejšiu predikciu, ale preskúmať užitočnosť solárnych spektrálnych dát pri rozlišovaní medzi vláknami, ktoré vyprodukujú erupciu, a aktívnymi oblastami, v ktorých erupcia ne-nastane. V práci dokazujú, že spektrálne dáta sú užitočným doplňujúcim zdrojom dát pre predikciu erupcií.

Vhodnosť využitia hlbokých neurónových sietí potvrdzuje aj článok autorov Maslej-Krešňáková et al. (2021) zaoberajúci sa neurónovou sieťou, založenou na architektúre siete *You Only Look Once* (skr. YOLO). YOLO je algoritmus založený na princípe konvolučnej neurónovej siete, ktorá je určená na detekciu objektov vo vstupných snímkach. Vo výstupe vytvára ohraničujúce boxy na obrázkoch a zároveň ich klasifikuje s pravdepodobnosťami zaradenia do jednotlivých tried. Vyznačuje sa svojou jednoduchosťou, rýchlosťou spracovania dát a presnými výsledkami. Vykrešluje ohraničujúce boxy a predikuje triedy pre celú snímku v rámci jedného behu programu. Vytvorený model bol navrhnutý na automatickú detekciu atmosférických javov a zároveň prináša informácie o ich presnom čase a frekvencii. Ohraničujúce boxy boli tak tiež použité na následnú segmentáciu hľadaných oblastí. Výsledkom bol model dosahujúci hodnotu 94% pre všetky sledované metriky – F1 miera, presnosť a návratnosť. Architektúra siete YOLO bola v minulosti využitá pre rôzne účely. Na základe spomenutých výsledkov môžeme odvodiť, že je možné použiť model postavený na tejto architektúre na detekciu rôznych javov – vrátane javov podobných

³https://www.nasa.gov/mission_pages/iris/

tým, ktorými sa budeme zaoberať v našej štúdii.

Okrem CNN boli pre účely detektie erupčných vlákien využité aj iné metódy. Jednou z takýchto metód bola automatická detekcia prostredníctvom klasických metód získavania dát na analýzu obrazu (Hurlburt, N., 2015). Využitý bol takzvaný **Eruption Patrol**, softvérový modul navrhnutý pre tieto účely. Jeho výsledky sú konzistentné s manuálnymi anotáciami. Nevýhodou je, že modul môže prehliadnuť pomalé dlhotrvajúce erupcie. Okrem detektie meria aj frekvencie erupcií. Táto navrhnutá metóda však rovnako ako ani žiadna iná v minulosti navrhnutá metóda, neprináša automatickú segmentáciu erupčných vlákien.

5 Segmentácia a detekcia slnečných erupcií

Cieľom našej práce je vytvoriť postup pre hľadanie najintenzívnejších slnečných erupcií pomocou techník hlbokého učenia a štandardných metód spracovania obrazu. Takéto slnečné erupcie zvyčajne v prekurzívnom štádiu spôsobujú vznik flare ribbons, ktoré majú špecifický tvar. Tvar, ktorý často nadobúdajú, je nazývaný ako „paralelný“, pretože je volným okom viditeľné, že ho tvoria rovnobežky. Matematicky to však presné rovnobežky byť nemusia, môžu sa nachádzať v rôznej vzdialosti od seba, môžu mať rozdielne sklony a byť rôznej dĺžky. Pre potreby hľadania zadaného tvaru však potrebujeme najprv získať segmentované slnečné erupcie. Z tohto dôvodu sa naša práca skladá z dvoch hlavných častí – vytváranie segmentácií a hľadanie paralelného tvaru.

Aby sme vo flare ribbons dokázali rozpoznať paralelný tvar, potrebujeme:

1. zanalyzovať dostupný zoznam slnečných erupcií,
2. stiahnuť snímky vytvorené prostredníctvom SDO vo filtri, v ktorom sú flare ribbons najlepšie viditeľné,
3. vhodným spôsobom predpripriaviť dátu,
4. navrhnúť a otestovať automatické riešenie pre segmentáciu erupcií,
5. navrhnúť algoritmus na vyhodnotenie paralelného tvaru na segmentačných maskách,
6. overiť výstupy navrhnutého prístupu.

5.1 Použité technológie

Pre získanie potrebných snímok sme využili open-source vizualizačný nástroj Helioviewer. Je to projekt financovaný NASA (angl. *National Aeronautics and Space Administration*) a ESA (angl. *European Space Agency*), vďaka ktorému je možné

snímky Slnka, ktoré boli zachytené deviatimi slnečnými observatóriami, vyhľadávať a zobrazovať. Snímky a videá sa dajú exportovať priamo z nástroja, alebo sa dá využiť niektorá z integrácií pre automatické sťahovanie. Túto možnosť sme využili v našej práci a dátá sme získali prostredníctvom integrácie pre programovací jazyk Python. Python je open-source, interpretovaný, interaktívny programovací jazyk. Vďaka tomu, že je jednoduchý a platformovo nezávislý, je vhodným jazykom pre strojové učenie. Python sme využili okrem sťahovania dát aj pri ostatných častiach praktickej časti práce.

Využili sme viaceré open-source knižnice:

- **Tensorflow⁴** je knižnica strojového učenia, vyvinutá a udržiavaná spoločnosťou Google. Používa sa na vytváranie, trénovanie a nasadzovanie modelov pre rôzne úlohy, ako sú klasifikácia, detekcia objektov, predikcia a ďalšie.
- **Keras⁵** je knižnica strojového učenia, ktorá je súčasťou Tensorflow. Keras poskytuje jednoduché a intuitívne rozhranie pre tvorbu, trénovanie a nasadzovanie modelov strojového učenia.
- **OpenCV⁶** je využívaná pre spracovanie obrazu a počítačové videnie. Poskytuje nástroje a funkcie na spracovanie a analýzu obrazových dát, vrátane funkcií na detekciu a rozpoznávanie objektov, segmentáciu obrazu, sledovanie pohybu a mnoho ďalších.
- **Pillow⁷** je určená pre prácu s obrázkami. Je rozšírením pôvodnej knižnice *Python Imaging Library*. Pillow poskytuje množstvo funkcií na prácu s obrázkami, vrátane načítavania a ukladania obrázkov v rôznych formátoch, úpravy obrázkov alebo kreslenie na obrázky.

⁴<https://www.tensorflow.org/>

⁵<https://keras.io/>

⁶<https://opencv.org/>

⁷<https://python-pillow.org/>

- **NumPy**⁸ je knižnica pre programovanie v jazyku Python, ktorá sa špecializuje na vektorové a matematické operácie s vysokou efektivitou a presnosťou.
- **Scikit-image**⁹ bola vytvorená pre spracovanie obrazu. Táto knižnica poskytuje množstvo funkcií pre rôzne úlohy spracovania obrazu, ako sú napríklad operácie s filtrovaním obrazu, segmentácia, extrakcia príznakov a morfológické transformácie. Je postavená na knižnici NumPy a využíva mnoho NumPy funkcií pre prácu s obrazmi.
- **Sunpy** je knižnica zameraná na analýzu dát z oblasti slnečnej fyziky a astrofísike. V tejto knižnici je k dispozícii široká škála funkcií a nástrojov, ktoré umožňujú spracovanie a vizualizáciu dát týkajúcich sa slnečnej aktivity. Medzi ne patria napríklad údaje o slnečnej koróne, fotosfére, slnečných erupciách, slnečných búrkach a iných súvisiacich javoch.
- **Astropy**¹⁰ poskytuje nástroje pre astronómiu a astrofyziku. Astropy obsahuje mnoho funkcií a nástrojov, vrátane funkcií na prácu s časom, koordinátami a jednotkami, na správu astronomických dát a na vizualizáciu astronómie.
- **DSEpruning**¹¹ je knižnica pre hlboké učenie, ktorá bola vyvinutá na základe výskumu na tému automatického orezávania kostier snímok pomocou dynamického symbolického vykonávania (angl. *Dynamic Symbolic Execution*, skr. DSE). Je zjednodušenou implementáciou prístupu navrhnutého v práci (Bai and Latecki, 2007).

⁸<https://numpy.org/>

⁹<https://scikit-image.org/>

¹⁰<https://www.astropy.org/>

¹¹<https://github.com/originlake/DSE-skeleton-pruning>

5.2 Katalóg RibbonDB

Pre navrhnutie vhodného postupu predprípravy dát sme potrebovali porozumieť dátam zaznamenané v katalógu slnečných erupcií RibbonDB, vytvorenom v práci (Kazachenko et al., 2017). Všetky snímky použité v rámci našej práce boli stiahnuté na základe údajov v tomto katalógu.

RibbonDB nám poskytla zoznam jednotlivých erupcií intenzity triedy C a vyššie. Pre nás sú najdôležitejšie nasledovné informácie – čas celého priebehu slnečných erupcií, ich poloha a trieda. Katalóg poskytuje aj ďalšie informácie, ako napríklad číslo aktívnej oblasti, plochu aktívnej oblasti, plochu premenlivosti erupcie a ďalšie, ktoré ale nie sú dôležité pre naše účely.

Priebeh erupcií je v katalógu zaznamenaný troma stĺpcami, obsahujúcich dátum a čas v tvare *rok-mesiac-deň hodina:minúta*:

- TSTART [UT] – čas začiatku erupcie,
- TPEAK [UT] – čas vrcholu erupcie, teda čas, kedy bola erupcia najintenzívnejšia,
- TFINAL [UT] – čas skončenia erupcie.

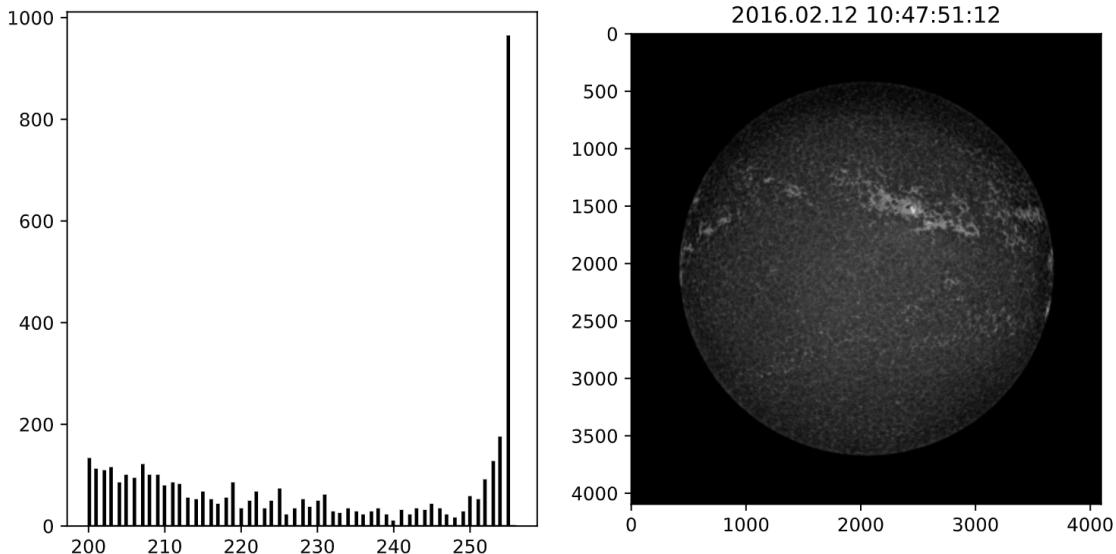
Poloha erupcií je udávaná prostredníctvom dvoch hodnôt, pričom obe sú zadané v stupňoch:

- LAT [\deg] – heliografická šírka (angl. *heliographic latitude*),
- LON [\deg] – heliografická dĺžka (angl. *heliographic longitude*).

Trieda erupcie je uvedená v stĺpci KEY. Stĺpec obsahuje spojené hodnoty – dátum a čas začiatku erupcie, číslo aktívnej oblasti, a konkrétnu triedu.

5.3 Príprava dát

Fázu prípravy dát môžeme rozdeliť na dve podčasti – proces stahovania dát, zahŕňajúci potrebné úpravy týchto dát, a vytváranie masiek pre trénovanie a testovanie

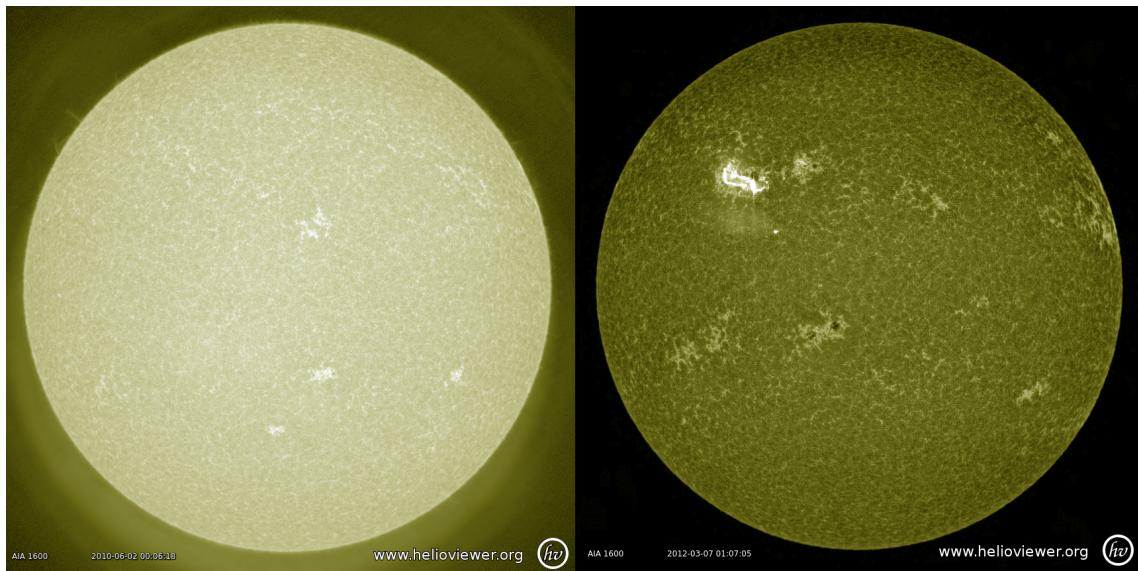


Obrázok 5 – 1 Histogram vrcholu erupcie triedy M

segmentačného modelu v ďalších fázach procesu.

Prvým krokom bola analýza priebehu slnečných erupcií zo zoznamu. Účelom bolo zistiť, či je pre našu prácu potrebný celý priebeh týchto udalostí, alebo len ich vrchol. Z katalógu sme zvolili náhodné erupcie pre každú z tried C, M a X, a vykreslili histogramy celého ich priebehu. Na Obrázku 5 – 1 sa nachádza ukážka vykresleného histogramu erupcie triedy M v čase jej vrcholu. Histogram je vygenerovaný pre celý disk. Hodnoty na osi x , predstavujúce hodnoty pixelov, sú zobrazené len z rozpätia $< 200, 255 >$. Toto rozpäťie bolo zvolené pre lepšiu viditeľnosť najvyšších hodnôt, keďže slnečné erupcie sú na snímkach najsvetlejšie, a ostatné oblasti pre nás výskum nie sú zaujímavé. Po analýze takýchto histogramov sme sa rozhodli využiť snímky celého priebehu, keďže proces zmeny intenzity jednotlivých erupcií je veľmi dynamický, rôznorodý a mení sa na škále minút.

Pri prezeraní snímkov slnečných erupcií z rôznych rokov sme zistili, že snímkov z roku 2010, kedy sa tieto dátá prostredníctvom NASA SDO prvýkrát začali zaznamenávať, je len veľmi málo. Vytvárali sa s veľkými časovými rozostupmi. V rámci niektorých mesiacov sa v tomto roku nedajú dohľadať žiadne snímkov. Taktiež sú



Obrázok 5 – 2 Porovnanie snímok z roku 2010 a 2012

inak saturované, než za nasledujúce roky, čo je viditeľné na Obrázku 5–2, ktorý zobrazuje dve snímky, prvú z roku 2010 a druhú z roku 2012. Na snímkach z roku 2010 erupcie nie sú voľným okom dostatočne viditeľné, pričom na snímkach za ďalšie roky sú tieto oblasti najvýraznejším miestom. Kedže by nám proces stahovania a segmentácie mohli takto výrazne rozdielne snímky len stažiť, rozhodli sme sa dátu z roku 2010 nepoužívať. Aj bez použitia tohto roku máme k dispozícii informácie o iných erupciách, ktorých počet je dostatočný.

5.3.1 Sťahovanie dát

Pre stiahnutie potrebných dát na základe informácií v katalógu RibbonDB bolo použité Helioviewer API, ktoré je prístupné vytvorením objektu `HelioviewerClient` knižnice SunPy. Toto API umožňuje priame stahovanie dát z aplikácie Helioviewer.

V prvom rade bolo potrebné načítať súbor obsahujúci informácie o erupciách – `ribbondb_v1.0.csv`. Pre každý riadok bol vytvorený časový rozsah pomocou funkcie `date_range()` z knižnice Pandas. Tento časový rozsah začína časom uvedeným v stĺpci `TSTART [UT]`, končí časom zo stĺpca `TFINAL [UT]`, a mal nastavenú minútovú frekvenciu.

Pre nájdenie presných časových údajov, potrebných pre stahovanie snímok, bola použitá funkcia `get_closest_image()`. Ako jej parameter sme použili jednotlivé časové údaje z vytvoreného časového rozsahu. Funkcia automaticky našla správny časový údaj najbližšej existujúcej snímky.

Samotné snímky sme stahovali vo formáte JPEG2000 (skr. jp2) prostredníctvom funkcie `download_jp2()`. JPEG2000 je formát obrazového súboru, ktorý sa používa na ukladanie a prenos obrazových dát. Bol vyvinutý ako nástupca pôvodného formátu JPEG, s cieľom poskytnúť lepsiú kvalitu obrazu a väčšiu kompresiu pri zachovaní väčšej flexibility. Tieto snímky boli stiahnuté vo vysokom rozlíšení, 4096×4096 pixelov a obsahovali celý slnečný disk.

Rozhodli sme sa nepoužívať snímky celého disku, nakoľko takto nebol dostatočne viditeľný tvar slnečných erupcií, s ktorým budeme neskôr pracovať. Namiesto toho sme potrebovali získať menší výsek snímok. Pre ich vhodné orezanie sme použili údaje stĺpcov `LAT [deg]` a `LONG [deg]`. Zároveň sme nemohli hľadanú oblast orezať príliš. Počas práce s dostupnými údajmi sme zistili, že vo viacerých prípadoch sa samotná erupcia nenachádza v presnej polohe uvedených koordinátov. Preto sme potrebovali nájsť rozostupy od jej koordinátov v takej vzdialosti, aby sme zo snímok nevystríhli hľadanú oblasť. Niekoľkými manuálnymi pokusmi sme nakoniec našli vhodný rozostup, pri ktorom bola oblasť dobre viditeľná. Vo výrezoch sme potrebovali dodržať štvorcové rozmery snímok pre vstup do CNN.

Stiahnuté dáta, obsahujúce celý disk, boli následne použité ako vstup funkcie `map.Map()` z knižnice SunPy, ktorá vytvára objekt typu `Map`. Tento objekt reprezentuje 2D obraz Slnka, ktorý obsahuje informácie o polohách pixelov na oblohe, kalibrácii, jednotkách a ďalších dôležitých vlastnostiach.

Vzniknuté `Map` objekty slúžili ako vstup funkcie `normalize_exposure()`, ktorá vykonáva normalizáciu intenzity obrazu s cieľom zvýrazniť detaily na snímke, ktoré by inak mohli byť skryté v tmavších alebo svetlejších oblastiach. Funkcia najprv vypočíta priemernú hodnotu intenzity obrazu, potom rozsah intenzity upraví na zadaný interval, a nakoniec aplikuje gama korekciu, aby zabezpečila správnu farebnú

reprodukciu. Vďaka tomu zvýši kontrast a detaily na obrazoch sú následne lepšie viditeľné.

Pre prepočet veľkosti a pozície výrezu snímok bola použitá trieda `SkyCoord` z knižnice SunPy. `SkyCoord` vytvára objekty na základe pozícii v špecifikovaných jednotkách, v našom prípade stupňoch, a koordinačného rámca. Použitý koordinačný rámc bol `Heliographic Stonyhurst`, ktorý je jedným z dvoch existujúcich koordinačných systémov, používaných pre identifikáciu pozície na Slnku. Vďaka vytvoreným objektom sme získali pozície pravého horného a ľavého dolného rohu hľadanej oblasti. Tieto dva údaje sme následne použili ako argumenty funkcie `submap()`, pochádzajúcej z balíka aiapy knižnice SunPy, ktorá na základe zadaných koordinátov namapovala snímky na daný rozmer.

Napriek nastaveniu rozmerov vytvárajúcich štvorec, boli snímky nepresných tvarov, hlavne pri porovnaní medzi rôznymi rokmi. Preto sme ešte zo snímok potrebovali dodatočne orezať zopár okrajových pixelov, aby tvorili presné štvorce. Vďaka väčšiemu zvolenému výrezu snímok, sme ich orezaním nezasiahli do dôležitých oblastí. Pri tomto procese sme zároveň obrázky konvertovali na šedotónové a zmenšili ich na rozmery o veľkosti 512×512 pixelov. Tieto rozmery boli zvolené pre čo najlepšie zachovanie viditeľnosti tvaru flare ribbons.

Popísaným spôsobom sa nám podarilo stiahnuť a upraviť až 52 465 snímok. Kedže neboli všetky použité pre účely modelovania, snímky sme v množine náhodne premiešali, za použitia zvolenej hodnoty `SEED`. Vďaka tomu vstupná množina obsahovala snímky slnečných erupcií rôznych rokov a tried.

Posledným krokom fázy prípravy dát bolo normalizovanie obrázkov na hodnoty pixelov z rozsahu $< 0,1 >$ a ich uloženie do poľa. Pre možnosť spätného dohladania informácií o erupciách sme vytvorili samostatné NumPy pole obsahujúce názvy jednotlivých snímok. Tieto názvy obsahovali dátum, čas a AIA filter snímok.

5.3.2 Vytváranie masiek

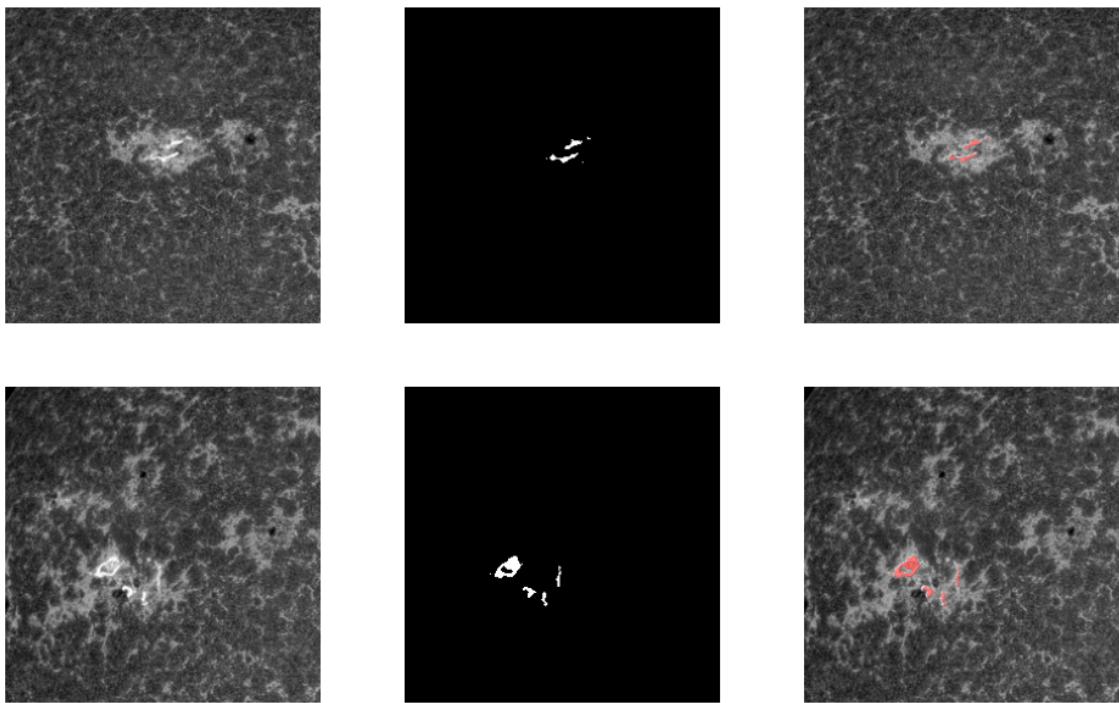
Pre natrénovanie segmentačnej neurónovej siete sme okrem upravených snímok zobrazujúcich flare ribbons potrebovali aj vstupné segmentácie. Takéto segmentácie budeme v tejto práci označovať ako „masky“.

Pri vytváraní masiek sme pre minimalizáciu šumu vstupy rozmažali funkciou `blur()` z knižnice OpenCV s použitím veľkosti filtra o veľkosti $(2, 2)$. Následne sme pomocou podmienok vytvorili binárne segmentačné masky. Pre tento účel bola použitá metóda prahovania, pričom sme nastavili tri rôzne úrovne prahov, v závislosti od veľkosti segmentovanej oblasti. Táto metóda je pre naše snímky vhodná, keďže vieme úrovňou jasu odlišiť erupcie od pozadia. Rozdielne prahy boli potrebné, pretože ak sme nastavili nižšiu úroveň prahu, línie väčších erupcií sa spájali, dôsledkom čoho ich tvar nebol dostatočne viditeľný. Ak sme zvolili len jednu vyššiu úroveň prahu, udalosti s menšími erupciami neboli dostatočne viditeľné a takisto sa stratil ich tvar.

Na prahované snímky sme následne použili morfologickú operáciu zatvorenia z knižnice OpenCV, `morphologyEx()`, ktorej zámer bol odstrániť šum a vyhladiť segmentované flare ribbons, do takej miery, aby sa nestratila informácia o ich tvare. Testovali sme použitie rôznych veľkostí a tvarov štruktúrnych elementov. Najpresnejšie masky boli vytvorené pomocou štruktúrneho elementu krížového tvaru o rozmeroch 3×3 . Niektoré snímky aj nadalej obsahovali drobné nedokonalosti, ktoré sme však nemohli odstrániť bez narušenia tvaru flare ribbons.

Pretože sme stiahli dátá obsahujúce celý priebeh slnečných erupcií, vznikli nám v množine viaceré snímky obsahujúce masku, ktorá mala vysegmentovanú len veľmi malú alebo dokonca žiadnu oblasť. Takéto dátá nie sú relevantné, takže sme ich z množiny odfiltrovali spočítaním jednotiek v ich maske s nastavenou minimálnou povolenou hodnotou. Ukážku výsledných masiek spolu so snímkami, na základe ktorých vznikli, vidíme na Obrázku 5–3.

Obrázky a manuálne vytvorené masky sme uložili ako dve samostatné NumPy



Obrázok 5 – 3 Ukážka vstupov, vytvorených masiek a ich prekrytie

polia. Následne boli tieto polia a pole obsahujúce názvy snímok uložené ako tri súbory typu npy. Npy je formát súboru používaný knižnicou NumPy na ukladanie polí NumPy v binárnom formáte. Vďaka ich uloženiu je jednoduchšia a rýchlejšia ďalšia práca s týmito dátami.

Výsledné snímky, spolu s ich maskami, sme rozdelili do troch vzájomne nezávislých množín. Rovnakým spôsobom bola rozdelená aj množina názvov snímok. Rozdelenie množiny dát na trénovaciu, testovaciu a validačnú je dôležitý proces v strojovom učení a analýze dát, pretože umožňuje overiť a optimalizovať výkonnosť modelov.

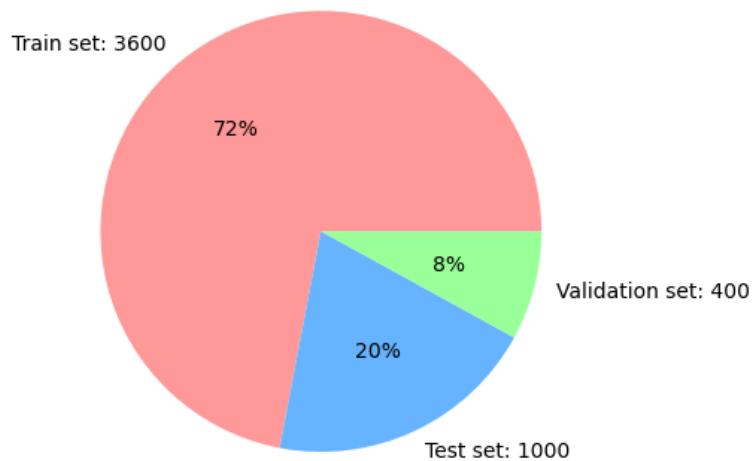
Trénovacia množina slúži na trénovanie modelu. V procese trénovania sa model učí na základe trénovacích dát a optimalizuje svoje váhy a parametre, aby čo najpresnejšie predikoval výstup. Testovacia množina slúži na overenie, ako dobre sa model generalizuje na nové, neznáme dátu. Model by mal dosiahnuť podobnú presnosť na testovacej množine ako na trénovacej množine, aby sme si mohli byť istí, že

sa nesnaží zapamätať si trénovacie dátá, ale skutočne sa naučil predikovať správne aj na nových dátach. Validačná množina sa používa na optimalizáciu modelu. Kedže sa testovacia množina používa na overenie výkonnosti modelu, nemôžeme použiť testovacie dátá na úpravu modelu, pretože by sa tak do nich zapojila informácia, ktorá by mohla skresliť výsledky. Na základe výsledkov na validačnej množine sa model optimalizuje a prispôsobuje tak, aby sa dosiahla čo najvyššia výkonnosť.

Tento proces rozdelenia množiny na trénovaciu, testovaciu a validačnú množinu pomáha minimalizovať preučenie modelu, a zároveň maximalizovať jeho schopnosť generalizovať sa na nové dátá.

Testovacia množina tvorila 20% všetkých vstupných dát, a zvyšných 80% bolo rozdelených na trénovaciu a validačnú množinu v pomere 9:1. Rozdelenie dát je vykreslené aj graficky na Obrázku 5–4. Počet snímok v jednotlivých množinách bol:

- trénovacia množina – obsahujúca 3600 snímok,
- testovacia množina – obsahujúca 1000 snímok,
- validačná množina – obsahujúca 400 snímok.



Obrázok 5 – 4 Graf rozdelenia dát na množiny

5.4 Segmentácia slnečných erupcií

V tejto časti podrobnejšie rozoberieme model SCSS-Net, ktorý sme už spomenuli v kapitole 4, a jeho natrénovanie a využitie v našej práci pre segmentáciu slnečných erupcií.

SCSS-Net je model konvolučnej neurónovej siete predstavený v práci Mackovjak et al. (2021). Bol navrhnutý na účely segmentácie a je inšpirovaný architektúrou U-Net. Vstupy siete sú obrázky s jedným farebným kanálom. Autori v práci využili snímky o rozmeroch 256×256 .

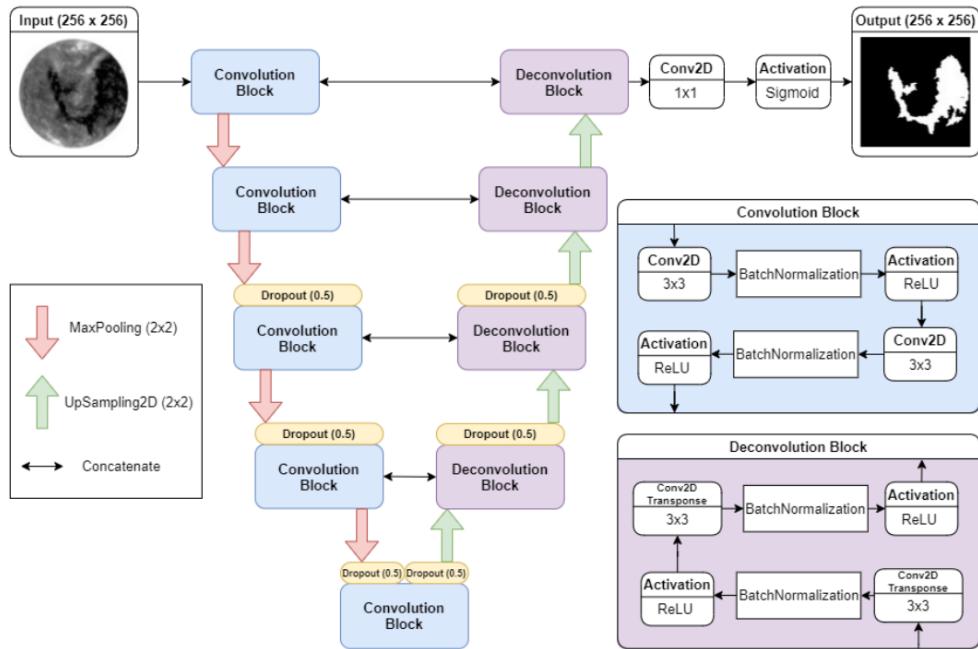
Architektúra modelu je vykreslená na obrázku 5–5. Obdobne, ako je to pri U-Net architektúrach, sa skladá z dvoch častí – enkóder a dekóder. Prvá časť, enkóder, je zložená z piatich konvolučných blokov, obsahujúcich konvolúciu o veľkosti 3×3 . Používajú batch normalizáciu a aktivačnú funkciu ReLU. Prvé štyri konvolučné bloky sú taktiež nasledované operáciou **max-pooling**. Druhá časť, dekóder, je zložená zo štyroch dekonvolučných blokov, ktoré využívajú transponované konvolúcie. Bloky enkódera a dekódera sú prepojené funkciou **concatenate**. Výstupná vrstva používa aktivačnú funkciu Sigmoid. Architektúra taktiež obsahuje regularizáciu formou funkcie dropout.

Našim zámerom je overiť univerzálnosť modelu SCSS-Net, jeho využitím pre segmentáciu iných oblastí, než sú aktívne oblasti a koronálne diery, na ktoré bol pretrénovaný.

5.4.1 Trénovanie modelu SCSS-net

Ako prvotný krok pri modelovaní sme skúsili využiť *transfer learning*. Stiahli sme už natrénovaný model pre hľadanie aktívnych oblastí, `model_ar_spoca.h5`, a otestovali výsledky segmentácie pomocou neho na našej vstupnej množine. Kedže bol tento model trénovaný na vstupoch o veľkosti 256×256 , museli sme našu vstupnú množinu upraviť na tieto rozmery.

Model nedosahoval dobré výsledky, nakoľko bol natrénovaný na hľadanie iných

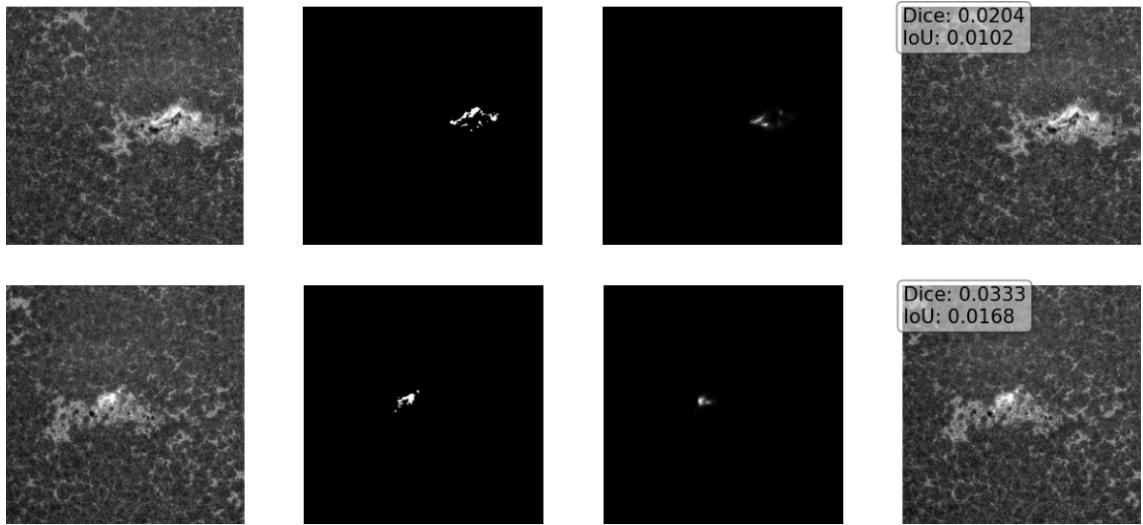


Obrázok 5 – 5 Architektúra siete SCSS-Net (Mackovjak et al., 2021)

oblastí. Výsledky modelu môžeme vidieť na dvoch rôznych erupciách na Obrázku 5 – 6. Masky, s ktorými bol výsledok segmentácie porovnávaný, boli vytvorené len jednoduchým nastavením prahu. Neboli žiadnym spôsobom ďalej upravované, preto nie sú úplne najlepšou reprezentáciou erupcií. Napriek tomu je evidentné, že výsledky segmentácie modelom sú veľmi nepresné a siet bolo preto potrebné pretrénovať.

Model bol trénovaný na päťdesiatich epochách použitím trénovacej množiny s validáciou na validačnej množine. Parametre modelu boli nastavené rovnako, ako aj v práci, v ktorej bol navrhnutý – 32 filtrov, 4 vrstvy, zapnutá batch normalizácia a dropout s hodnotou 0,5. Spustený bol s optimalizáciou Adam. Chybová funkcia bola nastavená na BCE. Sledovaná veličina bola chyba validácie s ukladaním len najlepšieho modelu, teda takého, ktorý dosiahol najnižšiu hodnotu validačnej chyby.

V rámci realizovaných experimentov sme vytvorili dva rôzne modely. Prvý z nich bol trénovaný na vstupných dátach o rozmeroch 256×256 , pre jednoduchosť ho budeme označovať ako „Model-256“. Druhý model bol trénovaný na výrazne väčších vstupoch, a to 512×512 , obdobne nazveme aj tento, „Model-512“. Model-256 bol



Obrázok 5 – 6 Ukážka výsledkov nepretrénovaného modelu určeného pre segmentáciu aktívnych oblastí. Zlava: vstup modelu, manuálne vytvorená maska, segmentácia, porovnanie výsledkov.

trénovaný na sto epochách. Model-512 bol kvôli značne vyššej výpočtovej náročnosti natrénovaný na päťdesiatich epochách.

5.4.2 Vyhodnotenie segmentácie

V tejto časti sa zameriame na vyhodnotenie výsledkov modelov konvolučnej neurónovej siete, použitých na segmentáciu flare ribbons.

Po natrénovaní modelov sme vizuálne overili ich výstupy, ktoré boli porovnané s manuálnymi segmentáciami. Výsledky ukázali, že výstupy modelov a vytvorené masky boli takmer totožné. Toto zistenie naznačuje, že modely boli schopné sa úspešne naučiť rozpoznávať a segmentovať flare ribbons na základe manuálne vytvorených segmentácií.

Nezistili sme však výrazné zlepšenie napríklad v potláčaní šumu, alebo vyhľadzovanie výstupov. Na základe kvalitatívneho vyhodnotenia teda môžeme zhodnotiť, že by nám stačilo využitie štandardných procesov počítačového videnia, ktoré boli použité na manuálne vytváranie segmentačných masiek. Veľkou nevýhodou masiek vytvorených pomocou štandardných metód je však to, že je potrebné nemalé množstvo

experimentov pri nastavovaní prahov, veľkostí filtrov, alebo použitých morfologickej operáciách. Pri akejkoľvek miernej zmene jasu alebo kontrastu tieto nastavenia nemusia korešpondovať so skutočnosťou, kde sa flare ribbon nachádza, preto je potrebná neustála kontrola manuálne vytvorených masiek.

Použitie modelu na segmentáciu obrazov prináša niekoľko výhod oproti manuálnej segmentácii. Najvýznamnejšou výhodou je rýchlosť a úspora nákladov. Model môže byť použitý na veľkom množstve dát v krátkom čase a jeho výstup môže byť použitý na segmentáciu nových obrázkov bez potreby manuálnej práce. Ďalšou výhodou je, že model je objektívny a produkuje opakovateľné výsledky, čo minimalizuje subjektívne rozdiely v segmentácii. Model taktiež umožňuje detektovať drobné detaily, ktoré by mohli byť prehliadané v manuálnych segmentáciách. Neurónová sieť dokáže extrahovať vysoko komplexné informácie, ktoré sa dokážu vysporiadať so zmenami snímok bez potreby fine tuningu alebo manuálnych zmien parametrov. Vzhľadom na tieto výhody sa ukazuje, že použitie modelu CNN pre segmentáciu flare ribbons je vhodnejšou voľbou v porovnaní s manuálnou segmentáciou. Model považujeme za spôsoblivejšie a časovo dostupnejšie riešenie.

Okrem vizuálnej kontroly sme obdobne, ako v práci (Mackovjak et al., 2021), model využinocovali pomocou dvoch metrík, ktorými boli IoU a Dice. Nakolko masky, na ktorých sa modely učili, a s ktorými sú ich výsledné segmentácie porovnávané, boli vytvorené manuálne, môže výsledok metrík mierne zavádzat. Manuálne vygenerované masky nemusia byť úplne presné, a teda v skutočnosti môže automatická segmentácia dokonca presnejšie reprezentovať tvar erupcií, než ich manuálna segmentácia. Sledovanými metrikami však túto skutočnosť overiť nevieme a manuálna kontrola by bola časovo veľmi náročná a subjektívna.

Tabuľky 5 – 1 a 5 – 2 zobrazujú výsledky sledovaných metrík modelov na testovacej množine o veľkosti 1000 obrázkov. Neupravené výsledky sú porovnané s výsledkami pri nastavenom prahu. Po skúmaní vplyvu prahu hodnôt sme zistili, že jeho nastavenie nad 40% pre Model-256 a 60% pre Model-512 výrazne zlepšuje výkon modelov. IoU Modelu-256 pri takomto nastavení prahu dosahuje hodnotu až 97,66%

Vstupný rozmer	Veľkosť množiny	IoU	Dice
256×256	1000	95,78 %	91,89 %
Prah 40%			
256×256	1000	97,66%	95,42 %

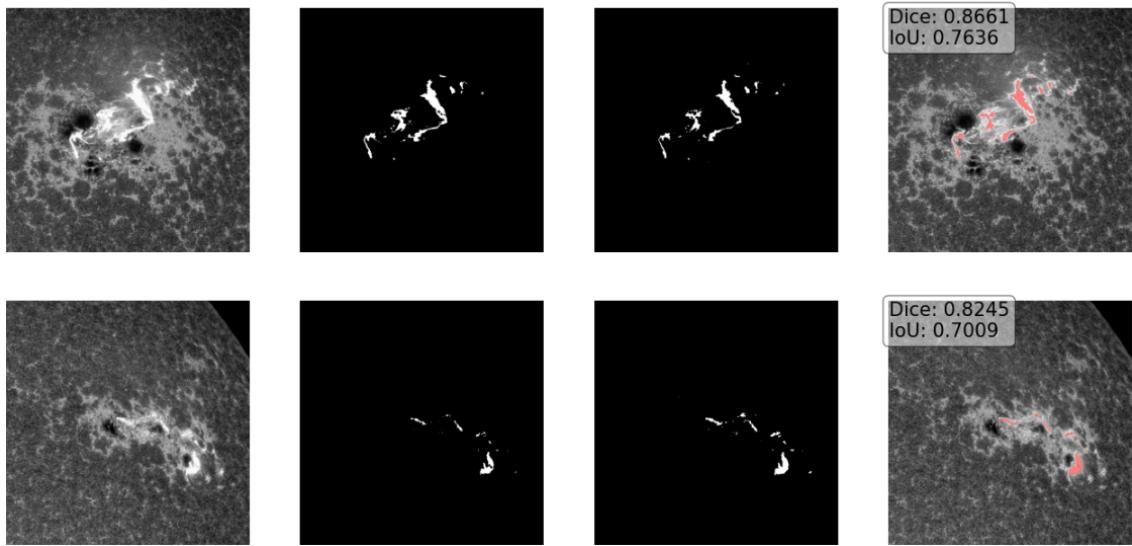
Tabuľka 5 – 1 Model-256: výsledky bez nastaveného prahu a s prahom 40%.

Vstupný rozmer	Veľkosť množiny	IoU	Dice
512×512	1000	78,01%	87,64%
Prah 60%			
512×512	1000	86,38%	92,69%

Tabuľka 5 – 2 Model-512: výsledky bez nastaveného prahu a s prahom 60%.

a Dice koeficient dosahuje hodnotu 95,42%. Tieto výsledky naznačujú, že model dokáže veľmi presne klasifikovať pixely patriace do záujmového objektu. Zároveň potvrdzujú výstup vizuálnej kontroly, a vieme z nich vyvodíť, že segmentácie modelu sú vo veľmi vysokej miere zhodné s manuálnymi. Model-512 nadobudol nižšie hodnoty sledovaných metrik. Je to viditeľné hlavne vo výsledkoch metriky IoU, kde je rozdiel vyše 10%. Porovnanie prahovaných výstupov Modelu-512 s manuálnymi segmentáciami vidíme na Obrázku 5 – 7. Výsledky metrik by mohli nasvedčovať, že model nevytvoril dostatočne presné segmentácie, ako je však evidentné z porovnania, ide o nepatrné rozdiely.

Kedže je veľmi dôležitou časťou našej práce zachovanie čo najlepšej viditeľnosti tvaru flare ribbons, musíme zohľadniť túto skutočnosť pri výbere segmentačného modelu. Na segmentovaných snímkach o veľkosti 256×256 nie sú dostatočne viditeľné. Pri takýchto rozmeroch je na nich taktiež obtiažne aplikovať ďalšie úpravy, pomocou ktorých by sme ich tvar vedeli rozlišovať. Z tohto dôvodu sme sa rozhodli používať Model-512, a teda snímky s väčším rozlíšením. Výstupy segmentácie modelu budeme používať na hľadanie najintenzívnejších slnečných erupcií, počas ktorých majú flare ribbons typicky paralelný tvar.



Obrázok 5 – 7 Výsledky modelu. Zlava: vstup, manuálna segmentácia, segmentácia modelu, prekrytie a metriky.

5.5 Detekcia paralelného tvaru

Po získaní segmentovaných snímok modelom SCSS-Net, bolo ďalším krokom hľadanie konkrétneho tvaru erupčných jadier. Túto úlohu sme sa rozhodli riešiť navrhnutím vlastného algoritmu pracujúceho s výstupmi modelu, ktorý determinuje, či segmentačné masky zobrazujú paralelný tvar slnečnej erupcie alebo nie.

Navrhnutý postup sa skladal z nasledovných krokov, ktoré popíšeme v jednotlivých podkapitolách:

1. skeletonizácia masiek,
2. úprava výstupov skeletonizácie,
3. pravdepodobnostná Houghova transformácia aplikovaná na skeletony,
4. úprava výstupov Houghovej transformácie,
5. rozhodnutie o paralelnom tvare na základe navrhnutých výpočtov.



Obrázok 5–8 Porovnanie klasickej skeletonizácie a 3D skeletonizácie

5.5.1 Skeletonizácia masiek

Prvým krokom v navrhnutom algoritme je úprava segmentácií pomocou operácie skeletonizácie. Skeletonizácia je jedným z možných spôsobov úpravy vstupov pre Houghovu transformáciu. Výstupy segmentácie neboli úplne vyhľadené – obsahovali drobné výčnelky, narúšajúce ich tvar, a šum. Úplne odstránenie takýchto nedostatkov nebolo možné bez toho, aby sa stratila informácia o tvare. Z tohto dôvodu aj skeleton opisoval tieto nerovnosti. Nás zaujímal len dominantný tvar erupcií, bez akýchkoľvek malých odchýlok, ktoré môžu stažiť nasledujúci postup.

Ako prvotný prístup k skeletonizácii sme zvolili funkciu `skeletonize()` z knižnice Scikit-image. Tá vyprodukovala skeleton obsahujúci veľké množstvo malých vetiev. Porovnali sme preto jeho výstup s výstupom ďalšej skeletonizačnej funkcie z rovnakej knižnice, `skeletonize_3d()`. Porovnanie vygenerovaných kostier na jednej zo snímok sa nachádza na Obrázku 5–8. Skeleton vygenerovaný funkciou `skeletonize_3d()`, nachádzajúci sa na pravej strane, má oveľa menej malých vetiev, narúšajúcich jeho tvar. Vo všetkých testovaných snímkach táto funkcia vyprodukovala čistejší skeleton, preto sme sa rozhodli pre jej použitie. Na výstupoch je však viditeľné, že výsledok oboch funkcií stále obsahoval množstvo malých vetiev a celkovo sa skladal z nerovných čiar.

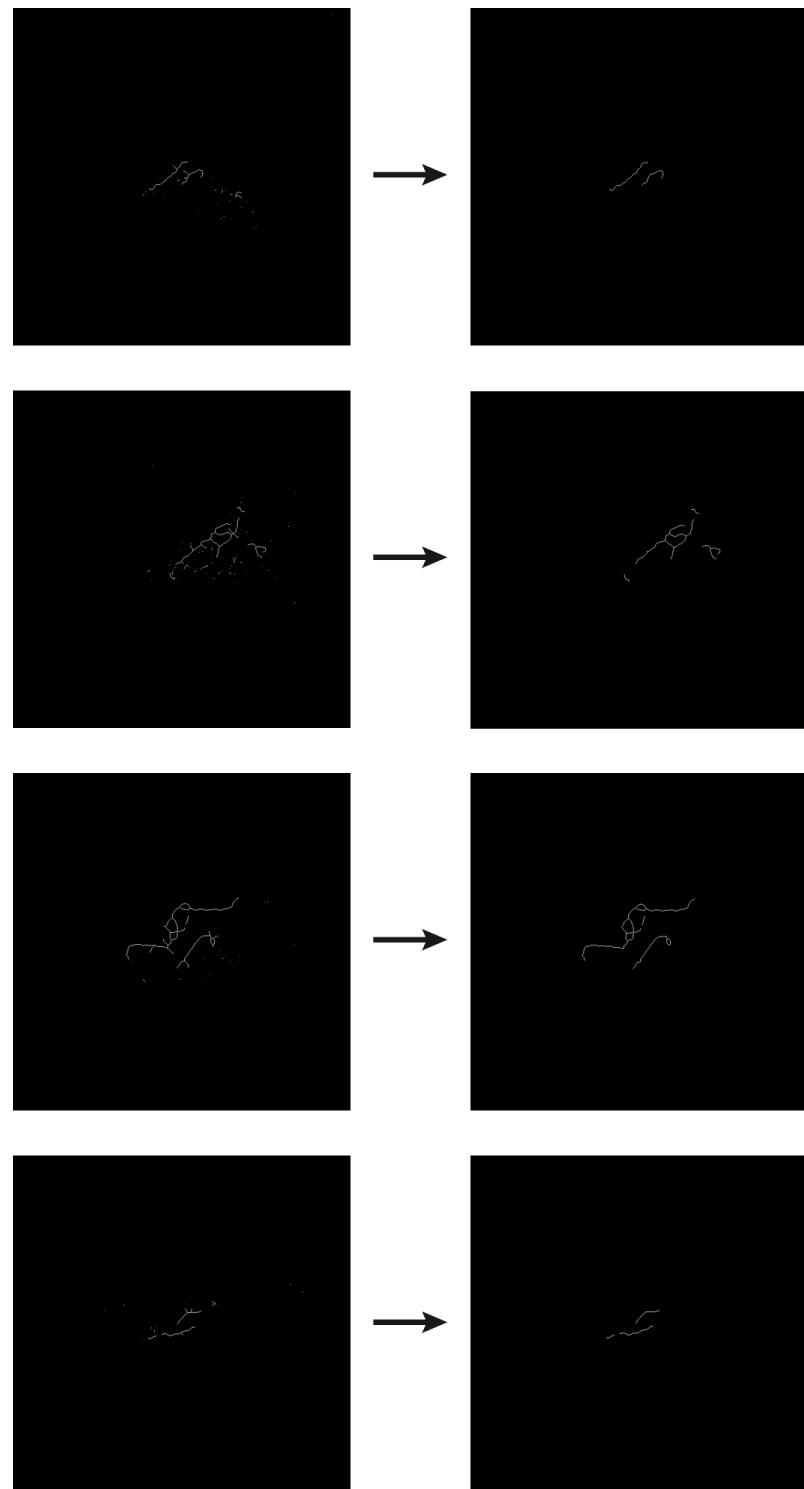
Pre odstránenie veľkej časti malých nepotrebných vetiev sme použili knižnicu **DSE-skeleton-pruning**, ktorá implementuje zjednodušenú verziu metódy navrhnutej v práci (Bai and Latecki, 2007) v jazyku Python. Postup využitia tejto metódy zahŕňal dve funkcie. Prvá z nich, `distance_transform_edt()`, slúžila pre vypočítanie vzdialenosí vetiev. Výstup funkcie bol následne použitý ako jeden z parametrov funkcie `skel_pruning_DSE()`, ktorá skeleton očistila o malé nepotrebné vetvy. Použitím spomínaných funkcií vznikol čistejší skeleton, lepšie vystihujúci hľadaný základný tvar danej erupcie. Ukážky upravených kostier, ktoré majú paralelný tvar vidíme na Obrázku 5 – 9. Na snímkach je viditeľné, že obsahujú menej vetiev a šumu.

5.5.2 Aplikácia pravdepodobnostnej Houghovej transformácie

Po získaní skeletonu slnečných erupcií bola možná aplikácia pravdepodobnostnej Houghovej transformácie. Táto transformácia musí byť prispôsobená na geometrický tvar, ktorý chceme nájsť, v našom prípade to predstavuje hľadanie čiar.

Pre aplikáciu PHT sme použili funkciu `HoughLinesP()` z knižnice OpenCV. Funkcia má sedem parametrov. Prvým parametrom je obraz, na ktorý sa aplikuje. Ďalšími parametrami sú ρ a θ , ktoré určujú presnosť kroku vzdialnosti ρ pre hľadanie priamok v pixeloch a presnosť uhla θ pre hľadanie priamok v radiánoch. Zvyšné parametre umožňujú nastavenie prahu vyjadrujúceho, z kolkých bodov sa minimálne musí čiara skladať, minimálnu dĺžku hľadaných čiar a maximálnu medzeru medzi bodmi, aby ešte boli považované za súčasť jednej čiary. Výstupom funkcie je pole obsahujúce koordináty x a y začiatočných a koncových bodov čiar.

Vzhľadom na výstup skeletonizácie, ktorý obsahoval veľa nedokonalostí, sme po vykonaní PHT získali množstvo krátkych čiar, ktoré obkreslovali skeleton. Takéto čiary však nebolo možné vyhodnotiť, či tvoria paralelný tvar alebo nie, keďže by sme dospeli k veľa falošne pozitívnym výsledkom. Pri veľkom množstve krátkych čiar by bolo jednoduché nájsť dve paralelné v akomkoľvek vstupnom tvere, čo nie je žiadaný stav. Výstup transformácie bolo teda ešte potrebné dodatočne upraviť pre získanie čiar, ktoré by dokázali presnejšie reprezentovať hlavný tvar erupcií.



Obrázok 5 – 9 Ukážky prunningu skeletonu

5.5.3 Úprava výstupov Houghovej transformácie

Úlohu úpravy výstupov PHT sme sa rozhodli riešiť spájaním jednotlivých čiar, ktoré tátó transformácia našla. Ich spájaním sme chceli docieliť menšie množstvo čiar, ktoré by neboli presnou kópiou skeletonu, ale opisovali by vyhladené hlavné línie jadier erupcií.

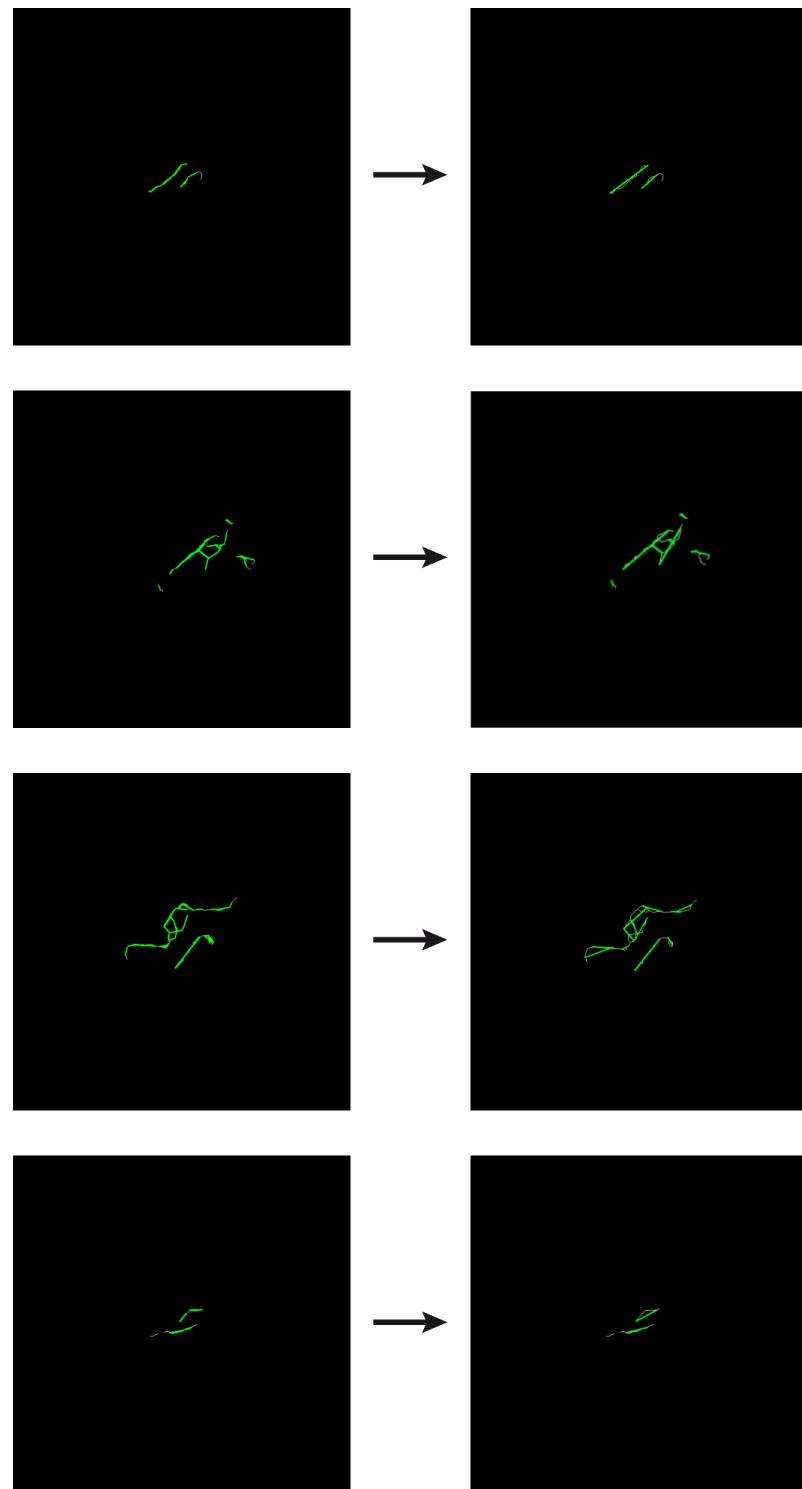
Na základe koordinátov jednotlivých čiar sme sa rozhodli vytvoriť nové, ktoré by spájali čiary, nachádzajúce sa blízko seba a s podobným sklonom. Podstata tohto prístupu spočívala vo vytvorení rekurzívnej funkcie, ktorú sme pomenovali `cleanLines()`. Funkcia postupne prechádzala všetky čiary vstupného dvojrozmerného poľa, obsahujúceho koordináty každej z čiar, nájdenej vďaka PHT, v danej snímke. Ak funkcia našla dve čiary, spĺňajúce stanovené kritériá ich podobnosti, nahradila ich novou. Nová čiara mala koordináty najdlhšej možnej čiary, vytvorenej prepojením ich najvzdialenejších bodov. To znamená, že ak našla takéto dve vertikálne orientované čiary, zvolila bod s najmenšou hodnotou koordinátu y a najväčšou hodnotou koordinátu y . Obdobne, pri horizontálne orientovaných čiarach, vybrala ako nové body tie, ktoré mali najmenšiu a najväčšiu hodnotu koordinátu x .

Kritériá podobnosti čiar zahŕňali rozdiel ich sklonov s maximálnou povolenou odchýlkou, rovnaké znamienka hodnôt sklonu a maximálnu povolenú vzdialenosť čiar. Maximálny možný rozdiel sklonov sme nastavili na hodnotu jedna. Vzdialenosť čiar bola vyrátaná funkciou `minDistance()`. Táto funkcia ráta vzdialenosť prvej čiary od zvoleného bodu druhej čiary, prípadne ich kolmú vzdialenosť, v závislosti od ich vzájomnej polohy. Zadaná čiara sa nepovažuje za priamku, ale za úsečku vytýčenú jej dvoma bodmi. Funkcia teda udáva najbližšiu priamu vzdialenosť.

Ked' dvojica čiar splní vymenované podmienky, je považovaná za súčasť jednej línie erupcie, a teda je spojená do novej čiary. Následne sa funkcia rekurzívne vyvoláva znova, tentokrát so zoznamom čiar, ktorý mal vymazané pôvodné dve čiary a pridanú novú, ktorá ich reprezentovala. Tento postup sa opakoval, kým funkcia ne-našla žiadne dve čiary, ktoré by mohli byť nahradené. Po aplikovaní opísanej funkcie,

bol výstup Houghovej transformácie vhodnejším pre naše účely. Čiary, kopírujúce zjednodušený tvar slnečnej erupcie, na ňom boli viditeľnejsie a bolo možné s nimi ďalej pracovať.

Obrázok 5 – 10 obsahuje ukážku úprav aplikovaných na štyroch rôznych snímkach obsahujúcich paralelný tvar erupcie. Pre lepšiu viditeľnosť zmien sú tieto snímky o rozmeroch 1024×1024 . Na ľavej strane obrázka sa nachádza neupravený výstup PHT. Pravá strana zobrazuje upravené výsledky. Obe časti obsahujú skeleton, na ktorom sú zelenou farbou znázornené nájdené čiary. Je viditeľné, že je po aplikovanej úprave nájdených čiar menej, sú dlhšie a nekopírujú presný tvar skeletonu, čo bolo aj našim zámerom. Na zložitejšom tvare erupcie, aká je vykreslená na treťom príklade, je vo výstupe stále veľké množstvo čiar. Ak by sme však nastavili podmienky ich spájania tak, aby ich zostało menej, v menších erupciách by sa ľahko stratil hľadaný tvar.

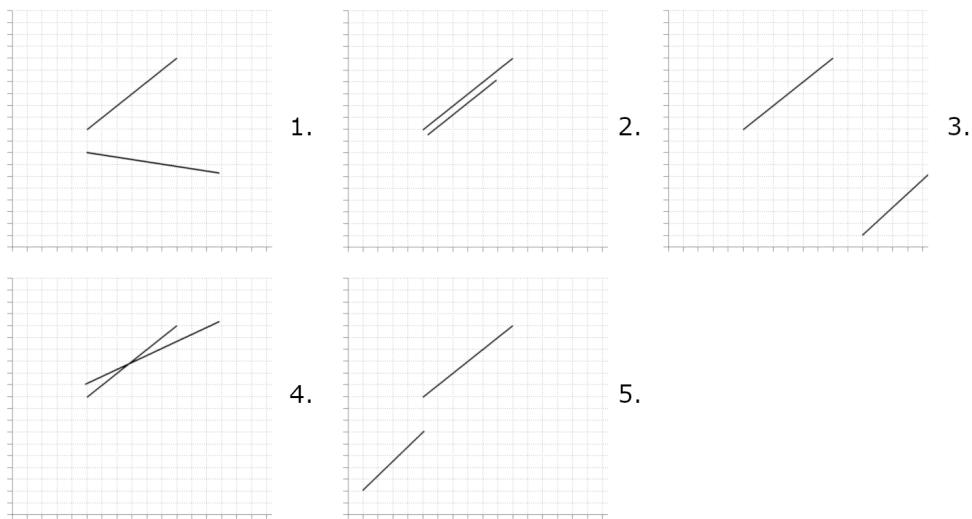


Obrázok 5 – 10 Ukážky upravených výstupov PHT

5.5.4 Overenie paralelnosti čiar

V tejto časti práce sme sa zameriavali na overenie paralelného tvaru pomocou nami navrhnutých výpočtov aplikovaných na upravené výstupy PHT. Predtým, než sme sa mohli pustiť do overovania paralelnosti čiar, bolo nevyhnutné porozumieť tomu, v akých prípadoch sa čiary nepovažujú za paralelné. Identifikovali sme päť hlavných situácií, kedy sa dá jednoznačne povedať, že čiary nie sú paralelné:

1. výrazne rozdielny sklon čiar,
2. príliš malá vzdialenosť čiar,
3. príliš veľká vzdialenosť čiar,
4. čiary sa križujú,
5. čiary sa nenachádzajú nad sebou, respektíve vedľa seba.



Obrázok 5 – 11 Prípady, kedy sa čiary nepovažujú za paralelné

Tieto prípady sú graficky znázornené na Obrázku 5 – 11, kde číselné označenia korešpondujú so zoznamom vyššie. Jedným z dôležitých aspektov je overenie sklonu čiar – z matematického hľadiska by rovnobežky mali mať rovnaký sklon, avšak obdobne ako pri vo funkciu `cleanLines()`, sme vzhľadom na nepresné tvary, nastavili maximálnu odchýlku rozdielu sklonov, ktorý môžu porovnávané čiary mať. Tento sklon však nesmie byť príliš rozdielny, čo vyjadruje situácia v 1. bode zoznamu.

Body 2 a 3 vyjadrujú príliš malú a príliš veľkú vzdialenosť čiar. Ak sa čiary nachádzajú vo veľmi malom odstupe, nejedná sa o rovnobežky, aké hľadáme. Sú buď výsledkom intenzívnej časti erupcie, kde bolo skeletonizáciou vytvorených viacero vedľa seba idúcich vetiev, alebo je to len jedna časť erupcie, ktorá sa kvôli šumu javí nepresne, dôvodom čoho v nej vzniklo viacero vetiev. Ak sa naopak nachádzajú v príliš veľkej vzdialosti, sú to len dve časti erupcie, v ktorých vznikol paralelný tvar, ktorý však neboli spôsobený vznikom flare ribbons.

V bode 4 vidíme prípad križovania čiar. V prípade, že sa čiary križujú, tak to samozrejme rovnobežky nie sú. Vzhľadom na povolený rozdiel sklonov, sme museli ošetriť aj takéto prípady.

Posledným stavom, ktorému sme sa potrebovali vyhnúť, je zakreslený v 5. bode. Táto situácia nastala, keď sa čiary nenachádzali jedna nad druhou, v prípade horizontálnych čiar, alebo vedľa seba, v prípade vertikálnych čiar. Vždy sme mali dva body tvoriace prvú čiaru vyjadrené ako (x_1, y_1) a (x_2, y_2) , a dva body tvoriace druhú čiaru ako (x_3, y_3) a (x_4, y_4) . Ak sme našli dve vertikálne položené čiary, tak prvá čiara musela mať aspoň jednu z hodnôt y_1 a y_2 z rozpätia $\langle y_3, y_4 \rangle$, prípadne aspoň jednu z hodnôt y_3 a y_4 druhej čiary musela byť z rozpätia $\langle y_1, y_2 \rangle$. Ak by to boli horizontálne položené čiary, platila by rovnaká podmienka ale pre koordináty osi x .

Čo sa týka samotného algoritmu, v zásade predstavoval zloženie rôznych podmienok, ktorými musela dvojica čiar prejsť, aby bola považovaná za paralelné. Vstupom do hlavnej funkcie je výstup funkcie `cleanLines` – vnorené pole koordinátov nájdených čiar. V kóde prechádzame toto pole, pričom porovnávame každú možnú dvojicu

čiar, čo zahŕňa zistenie uhla, sklonu, dĺžky čiar, najväčšej a najmenšej možnej vzdialenosťi čiar.

Overením rovnakého znamienka sklonu čiar a maximálneho povoleného rozdielu medzi nimi sme sa vyhli čiaram, spĺňajúcim 1. bod zo zoznamu neželaných pozícií. Výskytu 2. bodu sme čiastočne zabránili už pri očistení výstupov PHT funkciou `minDistance()`, kde sme všetky čiary, ktoré sa nachádzali veľmi blízko seba a spĺňali aj ostatné podmienky spojili. Ich vzdialenosť sme rovnakou funkciou overili aj v rámci tohto algoritmu. Príliš veľkej vzdialenosťi čiar sme sa vyhli obdobne, použitím funkcie `minDistance()`. 4. bod bol ošetrený funkciou `intersects()`, ktorá kontrolovala, či sa čiary v nejakom bode pretínajú. Piaty bod overený dvomi podmienkami, kontrolujúcimi, či má jedna z čiar, aspoň jednu hodnotu koordinátu x alebo y z rovnakého rozsahu, ako koordináty druhej čiary.

Okrem popísaných prvkov je dôležitá aj dĺžka čiar. Vzhľadom na rôzne tvary skeletonov aj samotných erupčných vlákien, dvojica čiar nemusí byť rovnakej dĺžky, avšak čiary nemôžu byť príliš krátke. Pri príliš krátkych nájdených čiarach to boli spravidla dve náhodne nájdené paralelné čiary, ktoré netvorili základný tvar erupcie. Minimálnou povolenou dĺžkou čiar sme ošetrili aj takéto prípady.

5.5.5 Vyhodnotenie detekcie

Vyhodnotenie výsledkov detekcie paralelných tvarov flare ribbons nie je možné vyjadriť kvantitatívnymi metrikami, keďže nemáme žiadny zoznam snímok, obsahujúcich hľadaný tvar. Výsledky preto môžeme overiť len kvalitatívne vizuálnou kontroloou získaných výsledkov.

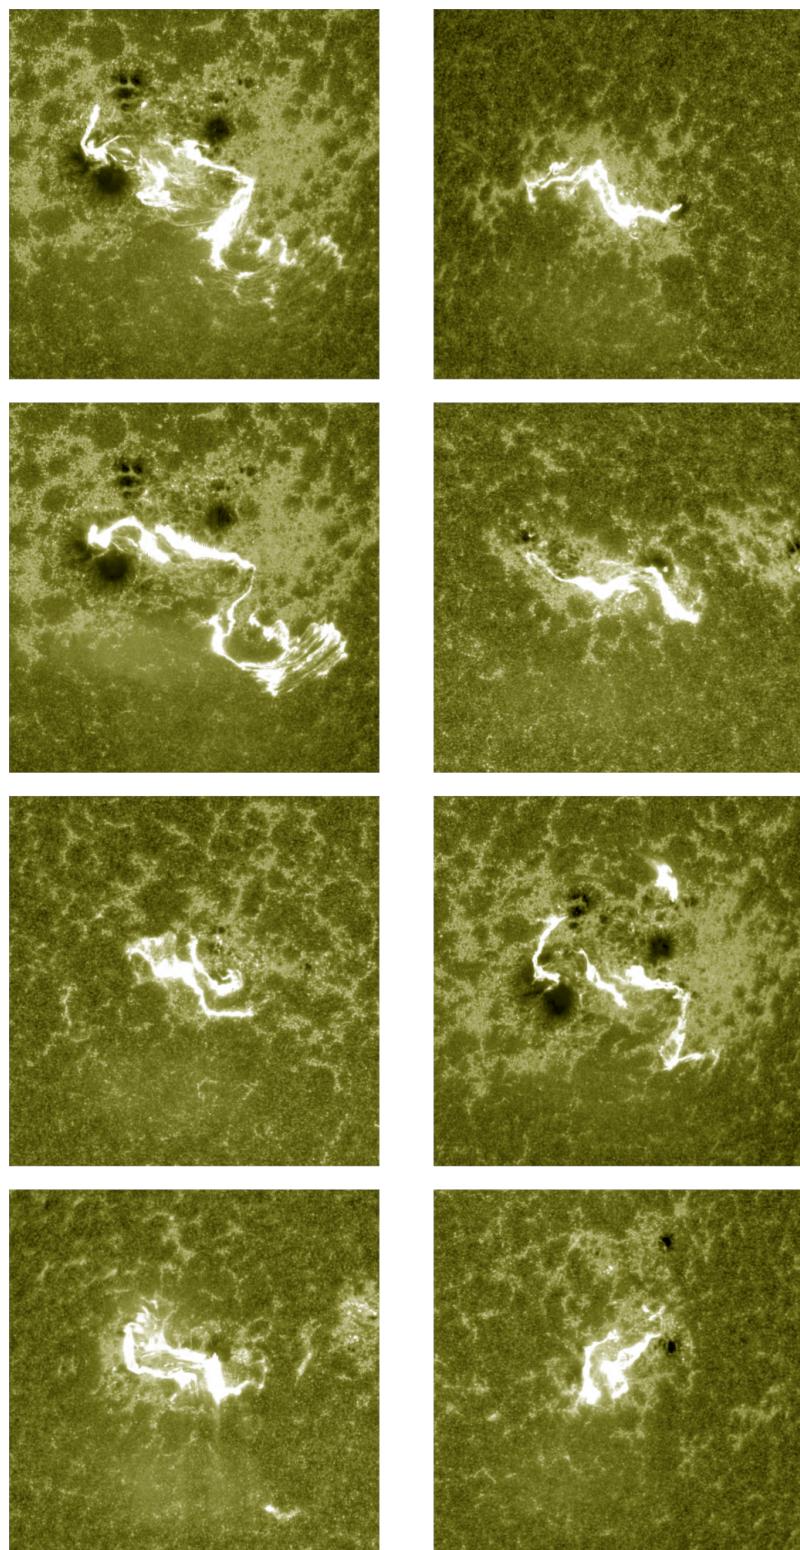
Výsledky detekcie hľadaného tvaru flare ribbons boli odoslané doménovým expertom, ktorí vyhodnotia tieto udalosti aj na základe ďalších fyzikálnych poznatkov, a následne sa na nich vykonajú analýzy určené pre ďalší vedecký výskum.

Napriek tomu, že výsledky metrík IoU a Dice, popísané v časti 5.4.2, dosahovali lepšie hodnoty pri nastavenom prahu 60%, pri detekcii paralelných čiar už najlepšie výstupy nezískali. Z množiny 1000 obrázkov detegoval algoritmus len 1 snímku ob-

sahujúcu paralelné flare ribbons pri nastavenom prahu. Keď sme použili neupravené výstupy bolo nájdených 9 takýchto snímok. Následne sme ešte vykonali experiment s použitím manuálne vytvorených segmentácií ako vstup. Výsledná množina obsahovala len 3 snímky – viaceré paralelné línie neboli nájdené. Posledným experimentom bolo použitie výsledkov Modelu-256, a teda menších snímok. V tomto prípade algoritmus nevedel správne nájsť paralelné čiary, pričom ani skeletony snímok nevyzerali ako vhodná reprezentácia ich tvaru. Na základe výsledkov týchto pokusov môžeme konštatovať, že Model-512 s bez prahovaných výstupov dokáže najlepšie segmentovať záujmové oblasti. Vďaka týmto zisteniam môžeme konštatovať, že model je vhodnejším riešením, než manuálne segmentácie.

Nakoľko výstup detekcie na testovacej množine objavil len malý počet flare ribbons splňajúcich nastavené podmienky, rozhodli sme sa pre segmentáciu a následnú detekciu použiť aj ďalšiu množinu dát. Táto množina bola vytvorená zo snímok, ktoré neboli použité v trénovacej, testovacej, ani validačnej množine, a ktorých počet bol 32 465. Boli to snímky, ktoré boli získané už na začiatku procesu, avšak kvôli výpočtovým kapacitám ich nebolo možné použiť vo fáze trénovania modelu.

Nová testovacia množina bola upravená rovnakým spôsobom ako prvotná testovacia množina. S tým rozdielom, že sme z nej už nevytvárali manuálne masky, ale použili len automatickú segmentáciu modelom. Vďaka spusteniu algoritmu na tejto množine, sa nám podarilo identifikovať ďalších 122 paralelných flare ribbons. Dokopy sme teda získali 131 snímok flare ribbons, vyhodnotených ako paralelné. Ukážku nájdených paralelných prípadov vidíme na Obrázku 5 – 12. Na jednotlivých snímkach vidíme, že sa nám podarilo detektovať flare ribbons rôznych tvarov. Finálny zoznam eventov, ktorý obsahuje dátumy, časy a triedy eventov je zahrnutý v **prílohe B**.



Obrázok 5 – 12 Ukážky detegovaných paralelných flare ribbons

6 Záver

V našej diplomovej práci sme sa venovali segmentácií flare ribbons na snímkach Slnka s cieľom detegovať paralelné tvary v týchto udalostiach. Tento výskum je dôležitý pre lepšie pochopenie slnečnej aktivity.

Využili sme techniky hlbokého učenia, v podobe modelu konvolučnej neurónovej siete, a metódy počítačového videnia. Natrénovaním segmentačného modelu, využívajúceho architektúru SCSS-Net, sa nám podarilo overiť jeho univerzálnosť. Celý postup riešenia je vykreslený v diagrame dostupnom v **prílohe A**. Diagram zobrazuje jednotlivé kroky, ktoré viedli k získaniu detekciei snímok – od stiahnutých celodiskových obrázkov, cez predprípravu dát, automatickú segmentáciu, skeletonizáciu, aplikáciu PHT a úprav jej výstupov, až k determinácii paralelného tvaru, čo je zároveň aj výstupom navrhnutého procesu.

Vypracovaný algoritmus a zoznam paralelných flare ribbons, klasifikovaných ako najintenzívnejšie, bude slúžiť na ďalší vedecký výskum vykonávaný Astronomickým ústavom Akadémie vied Českej republiky.

Vzhľadom na rôznorodý tvar a veľkosť vzniknutých flare ribbons, nie je ich spracovanie pomocou tradičných metód spracovania obrazu jednoduché. Tieto metódy sa preukázali ako pomerne citlivé na zmeny v obraze, a preto nemusia vždy správne identifikovať hľadaný tvar flare ribbons v rámci celého priebehu slnečnej erupcie.

Z tohto dôvodu by bolo efektívnejším riešením vytvorenie modelu konvolučnej neurónovej siete, ktorá by vedela automaticky flare ribbons klasifikovať, v závislosti od ich tvaru. Nami vytvorená množina paralelných erupcií, ktorú je potrebné ešte dodatočne overiť expertom a rozšíriť pomocou augmentačných techník, by mohla slúžiť ako vstupná množina pre takýto model.

Literatúra

Addison, K. (2022). About the sdo mission. <https://sdo.gsfc.nasa.gov/mission/>.

Albawi, S., Mohammed, T. A. and Al-Zawi, S. (2017). Understanding of a convolutional neural network, *2017 International Conference on Engineering and Technology (ICET)*, pp. 1–6.

Bai, X. and Latecki, L. J. (2007). Discrete skeleton evolution, *Energy Minimization Methods in Computer Vision and Pattern Recognition*.

Christe, S., Krucker, S., Glesener, L., Shih, A., Saint-Hilaire, P., Caspi, A., Allred, J. and Battaglia (2017). Exploring impulsive solar magnetic energy release and particle acceleration with focused hard X-ray imaging spectroscopy, *arXiv e-prints* p. arXiv:1701.00792.

Duda, R. O. and Hart, P. E. (1972). Use of the hough transformation to detect lines and curves in pictures, *Commun. ACM* **15**(1): 11–15.

URL: <https://doi.org/10.1145/361237.361242>

Fletcher, L., Dennis, B. R., Hudson, H. S., Krucker, S., Phillips, K., Veronig, A., Battaglia, M., Bone, L. and Caspi, A. (2011). An observational overview of solar flares, *Space Science Reviews* **159**(1-4): 19–106.

URL: <https://doi.org/10.1007%2Fs11214-010-9701-8>

Fox, K. C. (2011). Solar flares: What does it take to be x-class? https://www.nasa.gov/mission_pages/sunearth/news/X-class-flares.html.

Fox, K. C. (2013). Impacts of strong solar flares. https://www.nasa.gov/mission_pages/sunearth/news/flare-impacts.html.

Hatfield, M. (2021). How sdo sees the sun. https://www.nasa.gov/mission_pages/sdo/how-sdo-sees-the-sun.

Holman, G. D. (2001). What is a solar flare? <https://hesperia.gsfc.nasa.gov/sftheory/frame1.htm>.

Hurlburt, N. (2015). Automated detection of solar eruptions, *J. Space Weather Space Clim.* **5**: A39.

URL: <https://doi.org/10.1051/swsc/2015042>

Illingworth, J. and Kittler, J. (1988). A survey of the hough transform, *Computer Vision, Graphics, and Image Processing* **44**(1): 87–116.

URL: <https://www.sciencedirect.com/science/article/pii/S0734189X88800331>

Janvier, M., Savcheva, A., Pariat, E., Tassev, S., Millholland, S., Bommier, V., McCauley, P., McKillop, S. and Dougan, F. (2016). Evolution of flare ribbons, electric currents, and quasi-separatrix layers during an x-class flare, *A&A* **591**: A141.

URL: <https://doi.org/10.1051/0004-6361/201628406>

Kazachenko, M. D., Lynch, B. J., Welsch, B. T. and Sun, X. (2017). A Database of Flare Ribbon Properties from the Solar Dynamics Observatory. I. Reconnection Flux, *The Astrophysical Journal* **845**(1): 49.

Kingma, D. P. and Ba, J. (2014). Adam: A method for stochastic optimization.

URL: <https://arxiv.org/abs/1412.6980>

Love, T., Neukirch, T. and Parnell, C. E. (2020). Analyzing aia flare observations using convolutional neural networks, *Frontiers in Astronomy and Space Sciences* **7**.

URL: <https://www.frontiersin.org/article/10.3389/fspas.2020.00034>

Maas, A. L., Hannun, A. Y., Ng, A. Y. et al. (2013). Rectifier nonlinearities improve neural network acoustic models, *Proc. icml*, Vol. 30, Atlanta, Georgia, USA, p. 3.

Mackovjak, , Harman, M., Maslej-Krešňáková, V. and Butka, P. (2021). SCSS-net: solar corona structures segmentation by deep learning, *Monthly Notices of the*

Royal Astronomical Society **508**(3): 3111–3124.

URL: <https://doi.org/10.1093/mnras/stab2536>

Maslej-Krešňáková, V., Kundrát, A., Mackovjak, v., Butka, P., Jaščur, S., Kolmašová, I. and Santolík, O. (2021). Automatic Detection of Atmospherics and Tweek Atmospherics in Radio Spectrograms Based on a Deep Learning Approach, *Earth and Space Science* **8**(11): e02007.

URL: <https://doi.org/10.1029/2021EA002007>

Minaee, S., Boykov, Y., Porikli, F., Plaza, A., Kehtarnavaz, N. and Terzopoulos, D. (2022). Image segmentation using deep learning: A survey, *IEEE Transactions on Pattern Analysis and Machine Intelligence* **44**(7): 3523–3542.

Nwankpa, C., Ijomah, W., Gachagan, A. and Marshall, S. (2018). Activation functions: Comparison of trends in practice and research for deep learning.

URL: <https://arxiv.org/abs/1811.03378>

Panos, B. and Kleint, L. (2020). Real-time Flare Prediction Based on Distinctions between Flaring and Non-flaring Active Region Spectra, *The Astrophysical Journal* **891**(1): 17.

Pesnell, W. D., Thompson, B. J. and Chamberlin, P. C. (2012). *The Solar Dynamics Observatory (SDO)*, Springer US, New York, NY, pp. 3–15.

URL: https://doi.org/10.1007/978-1-4614-3673-7_2

Ronneberger, O., Fischer, P. and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation, in N. Navab, J. Hornegger, W. M. Wells and A. F. Frangi (eds), *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, Springer International Publishing, Cham, pp. 234–241.

Saha, P. K., Borgefors, G. and Sanniti di Baja, G. (2016). A survey on skeletonization algorithms and their applications, *Pattern Recognition Letters* **76**: 3–12. Special

Issue on Skeletonization and its Application.

URL: <https://www.sciencedirect.com/science/article/pii/S0167865515001233>

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. and Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting, *Journal of Machine Learning Research* **15**(56): 1929–1958.

URL: <http://jmlr.org/papers/v15/srivastava14a.html>

van Beers, F., Lindström, A., Okafor, E. and Wiering, M. A. (2019). Deep neural networks with intersection over union loss for binary image segmentation., *ICPRAM*, pp. 438–445.

Zoznam príloh

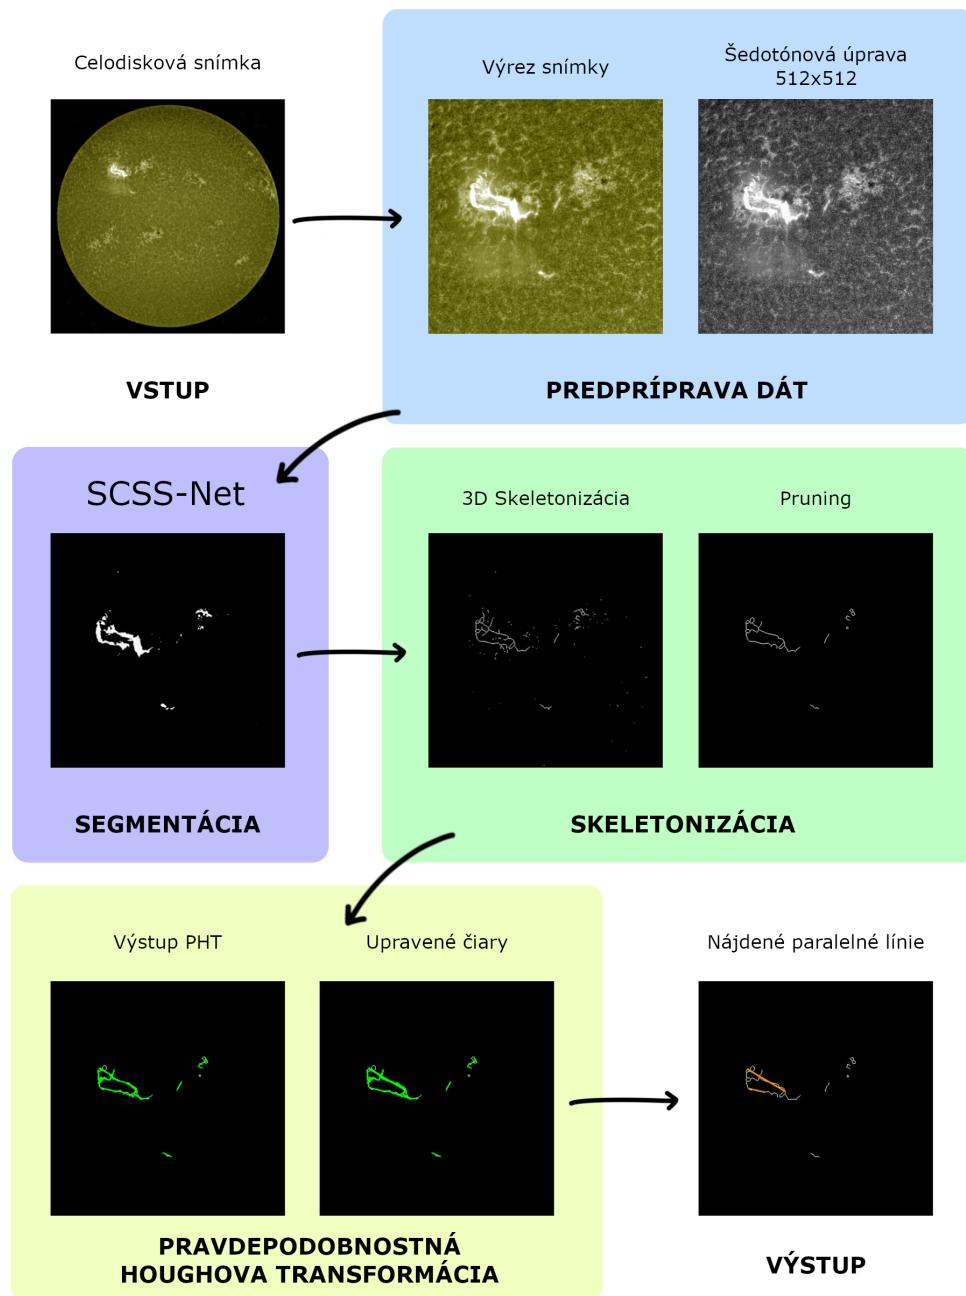
Príloha A Postup navrhnutého riešenia

Príloha B CD médium – záverečná práca v elektronickej podobe, príručky v elektronickej podobe, zdrojový kód, natrénovaný model a zoznam detegovaných slnečných erupcií.

Príloha C Používateľská príručka

Príloha D Systémová príručka

Príloha A – postup navrhnutého riešenia



Obrázok 6 – 1 Diagram postupu navrhnutého riešenia – od neupravených vstupov až po detekciu paralelných línií.